



Escuela Técnica Superior de
Ingeniería Informática

Trabajo fin de Grado

Grado en Ingeniería Informática – Ingeniería del Software

Diseño y desarrollo de un chatbot inteligente para la consulta de información académica y administrativa en la Universidad de Sevilla

Linceus Assistant

Realizado por

Santia Bregu

Dirigido por

José Antonio Parejo Maestre

Departamento

Lenguajes y Sistemas Informáticos

Sevilla, 18 de mayo de 2026

*“La IA es una herramienta para aumentar nuestras capacidades, no
para reemplazarnos.”*

– Yann LeCun

Agradecimientos

En primer lugar, quiero dedicar este proyecto a mi familia. Por sostenerme desde lejos durante estos cuatro años, por creer en mí incluso cuando yo dudaba, y por hacer que la distancia nunca fuese un obstáculo. Permitidme decíroslo en nuestro idioma, para que estas palabras lleguen tal y como las siento: *mami, babi, motra dhe Bianka, shumë faleminderit për gjithçka*.

A mi tutor, José Antonio Parejo Maestre, por confiar en esta idea desde el primer día y por acompañarme durante todo el proceso con una paciencia y una cercanía que reconozco y agradezco profundamente.

A mi equipo de People1, Joaquín, Fran y Miguel, gracias de corazón. Lo que para mucha gente es solo una sigla técnica, en mi caso fue un punto de inflexión profesional y personal. Sin lo aprendido a vuestro lado, ni siquiera sabría qué es RAG, y desde luego no habría tenido el atrevimiento de construir este proyecto.

A mis amigos de la ETSII, por haber convertido cada jornada de biblioteca, cada examen difícil y cada entrega imposible en algo compartido. Sin ese grupo, los días largos no habrían tenido el mismo sentido, y este TFG sencillamente no estaría escrito.

A mis compañeras de piso, y sobre todo amigas, Pilar, María Jesús y Laura, por estar a mi lado en los días más intensos de todo este trabajo, por la rutina compartida, por las cenas tardías y por todas las veces que escuchasteis cómo iba el TFG sin entender nada y, aun así, animándome. Pero sobre todo, gracias por estos últimos años de apoyo que han ido mucho más allá del TFG.

A Anass y Fares, que estáis conmigo desde el principio de esta etapa. Gracias por haber estado siempre, en lo importante y en lo cotidiano. Habéis sido un apoyo silencioso e imprescindible.

Y a Álvaro, por aparecer en esta recta final y recordarme, una y otra vez, de qué era capaz. Gracias por la confianza ciega y por hacerme sentir orgullosa de lo que estaba construyendo.

Gracias a todos.

Resumen

El avance de las herramientas digitales ha generado una expectativa clara en los usuarios: que la información relevante esté disponible de forma rápida y sea fácil de consultar. Esta expectativa, sin embargo, contrasta con la realidad de las instituciones de educación superior. Una universidad maneja un volumen enorme de información heterogénea (planes de estudio, normativas, calendarios, directorios de profesorado, sistemas de gestión académica) distribuida en múltiples fuentes y orientada a perfiles muy distintos: estudiantes, docentes, personal administrativo y órganos de gobierno. Unificar todo ese contenido en un único sistema es, por su propia naturaleza, una tarea de gran complejidad, y es razonable asumir que esta fragmentación seguirá siendo la norma en el futuro. La información existe y es accesible; el problema es que recuperarla exige conocer qué herramienta contiene cada dato y navegar entre ellas. La brecha entre lo que el usuario espera de un sistema de información moderno y lo que la institución puede ofrecer no es un fallo puntual, sino una limitación estructural conocida.

Este Trabajo Fin de Grado presenta **Linceus Assistant**, un asistente conversacional que cierra esa distancia consolidando el acceso a asignaturas, horarios y profesorado en un único punto de entrada. Desarrollado inicialmente para el alumnado de la ETSII de la Universidad de Sevilla, el sistema está concebido para extenderse al resto de centros de la universidad y, por su diseño, a cualquier institución de educación superior. Frente a los chatbots universitarios desplegados en el ecosistema español, la propuesta se diferencia en dos aspectos. Primero, está enfocada al **estudiante ya matriculado**, no solo al ciclo de captación y matrícula que cubren los asistentes institucionales existentes. Segundo, adopta una arquitectura de **recuperación aumentada por generación** (RAG) sobre los documentos oficiales, lo que le permite responder a preguntas no anticipadas en un guion cerrado, frente al modelo de menús predefinidos habitual en las soluciones comerciales.

El sistema se ha construido sobre Rasa 3.6, integrado con la API de Gemini para clasificación de intenciones, generación de SQL y renderizado de respuestas. La base de datos reside en Supabase con la extensión `pgvector`, lo que permite una **arquitectura híbrida NLU + RAG**: cada *custom action* combina una vía estructurada (*Text-to-SQL* sobre la base relacional) con una vía semántica (recuperación vectorial sobre los planes docentes) y escoge la rama adecuada según el contenido de la pregunta. El despliegue se realiza con Docker Compose en cuatro contenedores. El producto cubre los tres dominios funcionales del prototipo (**asignaturas, horarios y profesorado**), incorpora cambio dinámico de titulación y dispone de un panel de administración para garantizar la mantenibilidad del sistema.

La validación se ha organizado en cinco capas independientes y todas superan su umbral académico de referencia: **94,3 %** en la suite E2E (159 casos), **91,9 %** en RAG sobre 74 preguntas extraídas de planes docentes reales, **100 %** en política Rasa, **98,3 %** en el piloto con 59 sesiones de alumnos reales y una suite específica para el **panel de administración** que cubre los flujos críticos de gestión de datos. Las métricas no funcionales acompañan: latencia mediana de 3,4 segundos por turno y un coste anual de operación de aproximadamente **132 €** para el escenario actual (700 alumnos sobre el plan operativo del proyecto), que escala progresivamente hasta unos 540–780 €/año para 5 000 alumnos, manteniéndose en todo caso muy por debajo del coste de cualquier suscripción comercial equivalente.

La arquitectura es **extensible y escalable** por construcción: ampliar el sistema a nuevas titulaciones u otros centros de la Universidad de Sevilla, o incorporar dominios adicionales, descansa principalmente en la carga de datos a través del panel de administración, sin tocar el núcleo conversacional. El proyecto demuestra que la tecnología disponible permite cerrar esa distancia entre expectativa y realidad de forma sencilla, validada cuantitativamente y económicamente sostenible empleando herramientas accesibles a un trabajo de fin de grado.

Abstract

The progress of digital tools has set a clear expectation among users: that relevant information should be quickly available and easy to consult. This expectation, however, stands in contrast to the reality of higher education institutions. A university handles a large volume of heterogeneous information (study plans, regulations, calendars, faculty directories, academic management systems) distributed across multiple sources and aimed at very different audiences: students, faculty, administrative staff, and governing bodies. Bringing all that content together into a single system is, by its very nature, a highly complex task, and it is reasonable to assume that this fragmentation will remain the norm going forward. The information exists and is accessible; the problem is that retrieving it requires knowing which tool holds each piece of data and navigating between them. The gap between what a user expects from a modern information system and what the institution can offer is not an isolated shortcoming, but a well-known structural limitation.

This Bachelor's Thesis introduces **Linceus Assistant**, a conversational assistant that closes this gap by consolidating access to courses, timetables, and faculty into a single entry point. Initially developed for students of the ETSII at the University of Seville, the system is designed to extend to other schools within the university and, by its architecture, to any higher education institution. Compared to university chatbots deployed across the Spanish ecosystem, the proposal differs in two key aspects. First, it targets the **enrolled student**, not only the admissions and registration cycle covered by existing institutional assistants. Second, it adopts a **retrieval-augmented generation (RAG)** architecture over the official documents, which allows it to answer questions not anticipated by a closed script, in contrast to the menu-driven model typical of commercial solutions.

The system has been built on Rasa 3.6, integrated with the Gemini API for intent classification, SQL generation, and response rendering. The database resides in Supabase with the `pgvector` extension, which enables a **hybrid NLU + RAG architecture**: each custom action combines a structured path (*Text-to-SQL* over the relational tables) with a semantic path (vector retrieval over the teaching plans) and selects the appropriate branch depending on the content of the question. Deployment is carried out with Docker Compose across four containers. The product covers the three functional domains of the prototype (**courses, timetables, and faculty**), supports dynamic switching between degrees, and provides an administration panel to ensure long-term maintainability.

Validation has been organised into five independent layers, and all of them exceed their academic reference threshold: **94.3 %** on the E2E suite (159 cases), **91.9 %** on RAG over 74 questions extracted from real syllabi, **100 %** on Rasa policy accuracy, **98.3 %** on the pilot with 59 sessions of real students, and a dedicated test suite for the **administration panel** covering the critical data-management flows. Non-functional metrics keep pace: a median latency of 3.4 seconds per turn and an annual operating cost of approximately **132 €** for the current deployment (700 students), scaling progressively to around 540–780 €/year for 5 000 students, in all cases far below the cost of any equivalent commercial subscription.

The architecture is **extensible and scalable** by construction: extending the system to new degrees, to other schools at the University of Seville, or incorporating additional domains relies mostly on loading data through the administration panel, without touching the conversational core. The project shows that available technology makes it feasible to close the gap between expectation and reality in a simple, quantitatively validated, and economically sustainable way, using tools accessible to a final-year project.

Índice general

Agradecimientos	2
Resumen	3
Abstract	4
I Introducción y Conceptos	
1 Introducción	10
1.1 Contexto	10
1.2 Motivación	10
1.3 Objetivos	11
1.3.1 Objetivo general	11
1.3.2 Objetivos técnicos	11
1.3.3 Objetivos académicos y personales	12
1.4 Soluciones existentes	12
1.4.1 Asistentes en universidades españolas	12
1.4.2 Plataformas internacionales	13
1.4.3 Trabajos académicos comparables	14
1.4.4 Comparativa y diferenciación	14
1.5 Contribución de este trabajo	16
1.6 Estructura de la memoria	16
2 Preparación del proyecto	18
2.1 Estudio de las tecnologías y toma de decisiones	18
2.1.1 Decisión de frameworks conversacionales	18
2.1.2 Decisión de base de datos	20
2.1.3 Decisión de API de LLM	24
2.2 Infraestructura del sistema	26
2.2.1 Arquitectura del sistema	27
2.2.2 Componentes tecnológicos del sistema	27
2.3 Casos de uso principales	27
2.3.1 Gestión del contexto académico	28
2.3.2 Consulta sobre información de asignaturas	28
2.3.3 Consulta sobre horarios	29
2.3.4 Consulta sobre datos de contacto del profesorado	30
2.3.5 Diagrama de casos de uso	30
3 Conceptos iniciales	32
3.1 Sistema conversacional	32
3.2 Componentes del sistema conversacional con Rasa	32
3.2.1 Comprensión del lenguaje natural (NLU)	32
3.2.2 Gestión del diálogo	33
3.2.3 Mecanismos de respuesta: actions	33

3.2.4	Formularios	33
3.2.5	Fallback	33
3.3	Archivos de configuración de Rasa	33
3.4	Flujo de procesamiento de un mensaje	34
3.5	Generación aumentada por recuperación (RAG)	34
3.6	Backend y persistencia de datos	35
3.6.1	Supabase y PostgreSQL	35
3.6.2	pgvector	35
3.6.3	Embeddings	35

II Metodología y Planificación

4	Metodología	37
4.1	Metodología de desarrollo: Scrum adaptado	37
4.1.1	Scrum: fundamentos	37
4.1.2	Adaptación al proyecto individual	37
4.1.3	Sprints, número y duración	38
4.2	Gestión del código fuente	38
4.2.1	Política de ramas	38
4.2.2	Convenciones de commits	38
4.3	Estándares de codificación	39
4.4	Política de delegación al modelo de lenguaje	39
4.4.1	Criterio: heurísticas baratas primero, LLM cuando aporta	39
4.4.2	Aplicación en el sistema	40
4.4.3	Limitaciones conocidas	40
4.5	Gestión del trabajo	41
4.6	Versionado del sistema	41
5	Planificación	42
5.1	Estructura de Descomposición del Trabajo (EDT)	42
5.2	Diccionario EDT	42
5.2.1	Fase 1:Inicio	42
5.2.2	Fase 2:Desarrollo	44
5.2.3	Fase 3:Cierre	45
5.3	Resumen cuantitativo de la EDT	48
5.4	Backlog del producto	48
5.5	Planificación temporal	49
5.5.1	Estimación inicial por fase	49
5.5.2	Planificación de sprints	49
5.5.3	Cronograma e hitos	49
5.6	Planificación de costes	51
5.6.1	Costes de personal	51
5.6.2	Costes de material e infraestructura	51
5.6.3	Resumen de costes y contingencias	53
5.7	Análisis de desviaciones	54
5.7.1	Desviación temporal	54
5.7.2	Desviación en costes	54
5.7.3	Lecciones aprendidas	54

III Análisis, Diseño e Implementación

6 Análisis de requisitos	57
6.1 Identificación de actores	57
6.2 Requisitos funcionales	58
6.2.1 Dominio de asignaturas	58
6.2.2 Dominio de horarios	59
6.2.3 Dominio de profesorado	59
6.2.4 Comportamientos transversales	60
6.2.5 Funcionalidades del panel de administración	60
6.3 Criterios de aceptación	62
6.4 Requisitos de información	62
6.4.1 Entidades de dominio	63
6.4.2 Entidades del módulo RAG	63
6.4.3 Entidades de operación	64
6.4.4 Modelo conceptual	64
6.5 Requisitos no funcionales	65
6.6 Restricciones, suposiciones y dependencias externas	65
6.7 Prototipos de interfaz	65
6.8 Matrices de trazabilidad	71
6.8.1 Objetivos técnicos ↔ Requisitos funcionales	71
6.8.2 Requisitos funcionales ↔ Casos de prueba	71
6.9 Evolución del alcance respecto a la propuesta inicial	71
7 Arquitectura del sistema y decisiones de diseño	74
7.1 Arquitectura general	74
7.1.1 Capa de presentación	74
7.1.2 Capa de procesamiento conversacional	75
7.1.3 Capa de datos	75
7.2 Diagrama de componentes	75
7.3 Diagrama de despliegue	77
7.3.1 Nodos de ejecución	77
7.3.2 Protocolos de comunicación	78
7.4 Decisiones de diseño	78
7.4.1 Text-to-SQL con LLM en lugar de reglas estáticas	78
7.4.2 Gemini como servicio principal con Ollama como alternativa intercambiable	79
7.4.3 Embeddings de 2000 dimensiones con HNSW	79
7.4.4 Chunking con solapamiento para preservar contexto	80
7.4.5 Búsqueda vectorial con fallback a búsqueda por palabras clave	80
7.4.6 Fuzzy matching para resolución de nombres	80
7.4.7 Slots conversacionales para memoria de contexto	81
7.4.8 Pipeline NLU con preentrenado spaCy y featurización híbrida	81
7.4.9 Hash SHA-256 para evitar reprocesamiento de documentos	82
7.5 Patrones arquitectónicos aplicados	83
7.5.1 Arquitectura por capas (<i>Layered Architecture</i>)	83
7.5.2 Patrón <i>Action Server</i> (microservicio de lógica)	83
7.5.3 Patrón <i>Strategy</i> para clientes LLM	83
7.5.4 Patrón <i>Pipeline</i> para procesamiento RAG	83
7.5.5 Patrón <i>Repository</i> para acceso a datos	83
8 Marco tecnológico	85
8.1 Tecnologías de procesamiento conversacional	85

8.1.1	Rasa Framework	85
8.1.2	Procesamiento de Lenguaje Natural	86
8.2	Tecnologías de Inteligencia Artificial	86
8.2.1	Google Gemini como modelo de lenguaje principal	86
8.2.2	Ollama como alternativa local opcional	87
8.2.3	Embeddings y búsqueda semántica (RAG)	87
8.3	Tecnologías de base de datos	87
8.3.1	PostgreSQL y Supabase	87
8.3.2	pgvector	87
8.4	Tecnologías de frontend	88
8.4.1	Widget de chat	88
8.4.2	Panel de administración	88
8.4.3	Servidor web	88
8.5	Herramientas de desarrollo	88
8.5.1	Control de versiones	88
8.5.2	Gestión de dependencias	88
8.5.3	Variables de entorno	89
8.6	Consideraciones de seguridad	89
8.6.1	Protección de datos	89
8.6.2	Validación de entrada	89
8.6.3	Aislamiento del proveedor de LLM	89
8.7	Stack tecnológico completo	89
9	Estructura del proyecto	91
9.1	Visión general del repositorio	91
9.2	Directorio raíz	92
9.3	Directorio actions/	93
9.3.1	Organización por épicas	93
9.3.2	Subdirectorio shared/	93
9.4	Directorio admin/	94
9.5	Directorio rag/	94
9.6	Directorio data/	95
9.7	Directorio frontend/	95
9.8	Directorio docker/	95
9.9	Directorios tests/ y docs/	95
9.10	Separación de responsabilidades	96
10	Estructura de la base de datos	97
10.1	Diseño conceptual	97
10.1.1	Principios de diseño	97
10.2	Modelo entidad-relación	97
10.3	Entidades principales	97
10.3.1	Universidades	97
10.3.2	Centros	98
10.3.3	Departamentos	98
10.3.4	Titulaciones	98
10.3.5	Asignaturas	98
10.3.6	Profesores	98
10.3.7	Horarios	101
10.4	Tablas de vectorización (RAG)	101
10.4.1	Planes docentes	101
10.4.2	Chunks de planes docentes	102

10.5	Relaciones entre entidades	102
10.6	Índices y optimización	103
10.7	Integridad referencial	103
10.8	Estrategia de datos de prueba	104
11	Implementación	105
11.1	Anatomía común de una <i>custom action</i>	105
11.2	Épica de asignaturas	106
11.2.1	Consulta específica de asignatura	106
11.2.2	Listado y conteo de asignaturas	109
11.2.3	Horario por asignatura	110
11.3	Épica de profesores	110
11.4	Épica de horarios	113
11.5	Épica de contexto académico	115
11.6	Épica de fallback inteligente	115
11.7	Épica de <i>multi-intent</i> (desactivada)	115
11.8	Módulos compartidos	117
11.8.1	Cliente de Gemini	117
11.8.2	Conexión a base de datos	118
11.8.3	Matching difuso de nombres	118
11.8.4	Resolución de afirmación con inyección de entidades sintéticas	119
11.9	Pipeline RAG: chunking, embeddings y búsqueda	119
11.9.1	Chunking por secciones con deduplicación de cabeceras	119
11.9.2	Embeddings con <i>batching</i> y <i>rate limit handling</i>	120
11.9.3	Búsqueda en dos fases con <i>reranking</i> por sección	120
11.10	Panel de administración	121
11.10.1	Estructura de la API	121
11.10.2	Operaciones del panel	122
11.10.3	Pipeline de vectorización	126

IV Validación y Cierre

12	Pruebas y Validación	128
12.1	Estrategia general	128
12.1.1	Marco metodológico	128
12.1.2	Política de exclusión por trabajo futuro	129
12.1.3	Ejecución y registro	129
12.2	Ejecución funcional extremo a extremo	130
12.2.1	Alcance	130
12.2.2	Lectura frente a la literatura	130
12.3	Recuperación aumentada por generación	130
12.3.1	Capa baseline	131
12.3.2	Capa de profundidad	131
12.4	Clasificación NLU y política de diálogo	131
12.5	Reproducción de tráfico real tras el despliegue	132
12.5.1	Metodología de revisión	132
12.5.2	Resultados	132
12.6	Análisis de los casos fallidos	133
12.7	Métricas no funcionales: latencia y coste	134
12.7.1	Latencia	135
12.7.2	Coste por turno	135
12.8	Visión integrada y discusión	136

12.8.1	Cumplimiento del criterio de cierre	136
12.8.2	Amenazas a la validez	137
12.8.3	Limitaciones y trabajo futuro	137
12.9	Pruebas automatizadas del panel de administración	138
12.9.1	Resultados	138
13	Manuales	140
13.1	Manual de usuario	140
13.1.1	Acceso a la aplicación	140
13.1.2	Modelo conversacional	142
13.1.3	Funcionalidades disponibles	142
13.1.4	Recomendaciones de uso	142
13.2	Manual de administrador	146
13.2.1	Acceso e interfaz general	146
13.2.2	Pestaña Centros	147
13.2.3	Pestaña Asignaturas	147
13.2.4	Pestaña Profesores	148
13.2.5	Pestaña Horarios	149
13.2.6	Pestaña Conversaciones y feedback	149
13.2.7	Pestaña Estadísticas	150
13.2.8	Procedimiento recomendado de carga inicial	150
13.3	Manual de despliegue	152
13.3.1	Requisitos previos	152
13.3.2	Instalación	152
13.3.3	Arquitectura del despliegue	153
13.3.4	Verificación del despliegue	153
13.3.5	Operaciones habituales	153
13.4	Manual de desarrollo	154
13.4.1	Estructura del repositorio	154
13.4.2	Entorno de desarrollo	154
13.4.3	Ciclo de incorporación de cambios	155
13.4.4	Cómo añadir una nueva intención	156
13.4.5	Buenas prácticas y convenciones	156
14	Conclusiones y desarrollos futuros	158
14.1	Linceus en números	158
14.2	Cumplimiento de objetivos	158
14.2.1	Objetivo general	158
14.2.2	Objetivos técnicos	160
14.2.3	Objetivos académicos y personales	160
14.3	Lecciones aprendidas	160
14.4	Análisis de desviación	161
14.5	Desarrollos futuros	161
14.5.1	Optimización del sistema actual	162
14.5.2	Ampliación funcional	163
14.5.3	Validación reforzada	164
14.6	Contribución al estado del arte	164
14.7	Consideraciones éticas	165
14.8	Reflexión final	166
15	Uso de Inteligencia Artificial	167
15.1	Herramientas utilizadas	167

15.2	Uso de IA en el desarrollo del código	167
15.3	Uso de IA en la redacción de la memoria	168
15.4	Limitaciones y responsabilidad del autor	168
16	Vídeo demostración	169
16.1	Vídeo demostración	169
16.1.1	Estructura del vídeo	169
16.1.2	Notas sobre la producción	170
	Apéndices	171
.1	Actas de reuniones con el tutor	171
.2	Informe de tiempo invertido	174
.3	Registro de decisiones técnicas	175
.4	Catálogo de casos de trabajo futuro	179
	Bibliografía	181

Índice de figuras

2.1	Diagrama de casos de uso UML del sistema Linceus Assistant. Los actores se sitúan fuera del límite del sistema (línea discontinua).	31
5.1	Estructura de Descomposición del Trabajo (EDT): fases y paquetes de trabajo. . .	43
6.1	Modelo conceptual de los requisitos de información: dominio académico, módulo RAG y entidades de operación.	64
6.2	Widget conversacional integrado en la página institucional.	68
6.3	Panel de administración: vista de centros.	68
6.4	Panel de administración: detalle de horarios por curso y grupo.	69
6.5	Panel de administración: gestión del profesorado por departamento.	70
6.6	Panel de administración: auditoría de conversaciones del piloto.	70
7.1	Diagrama de componentes del sistema Linceus. El componente <i>multi-intent</i> aparece con trazo discontinuo porque su código permanece en el repositorio como referencia pero está desactivado en el modelo de diálogo del prototipo (ver Sección 11.7).	76
7.2	Diagrama de despliegue del sistema Linceus en DigitalOcean (Ubuntu 24.04 LTS) con el pipeline de despliegue automatizado vía GitHub Actions.	84
11.1	Pipeline de <i>ActionConsultaEspecifica</i> . La caja <i>Resolver asignatura</i> encapsula la cascada de cinco estrategias detallada en el Listado 11.1.	107
11.2	Pipeline de listado y conteo (<i>text-to-SQL</i>).	109
11.3	Pipeline de <i>ActionConsultaProfesor</i> . Tres puntos de decisión derivan al RAG: rol (<i>coordinador/suplente</i>), grupo concreto, o resultado SQL vacío como último recurso.	111
11.4	Pipeline de <i>ActionConsultaHorario</i>	114
11.5	Pipeline de <i>ActionSmartFallback</i>	116
11.6	Pantalla de inicio del panel de administración. Cada tarjeta representa un centro con el número de titulaciones que gestiona.	122
11.7	Vista de profesores del Departamento de Lenguajes y Sistemas Informáticos. La columna <i>Enriquecer desde us.es</i> lanza el scraper de directorio para actualizar los datos del PDI.	123
11.8	Vista de conversaciones agrupadas por sesión. La fila en verde indica una sesión marcada como revisada. El botón <i>Exportar esta página</i> vuelca las sesiones seleccionadas en CSV.	123
11.9	Panel de estadísticas generales. Los contadores se calculan en tiempo real contra Supabase. En el momento de la captura el sistema contaba con 244 asignaturas, 268 profesores, 157 planes docentes vectorizados y 1352 <i>chunks</i> RAG.	124
11.10	Página de acceso público del portal Sevius4 (https://sevius4.us.es/?PyP=LISTA). Los tres desplegables encadenados Centro → Titulación → Asignatura son la fuente que los <i>scrapers</i> del panel recorren para sincronizar los nombres del catálogo académico y descargar los planes docentes en PDF.	124

13.1	Página principal del prototipo con el <i>widget</i> de chat cerrado.	141
13.2	<i>Widget</i> desplegado con mensaje de bienvenida y selector de titulación.	141
13.3	Ejemplo de consulta sobre una asignatura concreta (ficha individual).	143
13.4	Ejemplo de consulta de horario con curso y grupo.	144
13.5	Ejemplo de consulta sobre profesorado.	145
13.6	Panel de administración: pantalla de inicio con la jerarquía de centros.	146
13.7	Pestaña <i>Asignaturas</i> con la barra de acciones disponibles para la titulación. . . .	147
13.8	Pestaña <i>Profesores</i> del panel de administración. La columna <i>Enriquecer desde us.es</i> dispara el scraper del directorio PDI para el departamento correspondiente. . . .	148
13.9	Pestaña <i>Horarios</i> con el botón <i>Generar horarios</i> activo para los centros con extractor disponible.	149
13.10	Pestaña <i>Conversaciones</i> con las sesiones agrupadas. La fila resaltada en verde indica una sesión ya revisada por el administrador.	150
13.11	Pestaña <i>Estadísticas</i> : contadores globales del catálogo cargado.	151
16.1	Miniatura del vídeo demostración alojado en YouTube. La imagen es un enlace activo en la versión PDF.	169

Índice de tablas

1.1	Comparativa de soluciones existentes frente a Linceus Assistant.	14
2.1	Comparación de frameworks conversacionales	20
2.2	Comparación de bases de datos	23
2.3	Comparación de APIs de LLM	26
2.4	Componentes tecnológicos del sistema en producción.	27
3.1	Archivos de configuración principales del sistema Rasa	34
4.1	Patrones de delegación al LLM aplicados en Linceus Assistant.	40
5.1	Diccionario EDT:1.1: Gestión del proyecto.	43
5.2	Diccionario EDT:1.2: Investigación tecnológica.	43
5.3	Diccionario EDT:1.3: Diseño de la arquitectura.	44
5.4	Diccionario EDT:2.1: Épica Asignaturas.	44
5.5	Diccionario EDT:2.2: Épica Profesores.	45
5.6	Diccionario EDT:2.3: Épica Horarios.	45
5.7	Diccionario EDT:2.4: Pipeline RAG.	46
5.8	Diccionario EDT:2.5: Panel admin y frontend.	46
5.9	Diccionario EDT:3.1: Validación y testing.	47
5.10	Diccionario EDT:3.2: Piloto con usuarios.	47
5.11	Diccionario EDT:3.3: Despliegue en producción.	47
5.12	Diccionario EDT:3.4: Memoria del proyecto.	48
5.13	Resumen cuantitativo de la EDT por fase y paquete de trabajo.	48
5.14	Priorización del backlog dentro de la fase de Desarrollo.	49
5.15	Estimación inicial de esfuerzo por fase.	49
5.16	Horas registradas por sprint (fuente: Clockify).	50
5.17	Hitos principales del proyecto.	50
5.18	Coste mensual real del despliegue actual.	53
5.19	Estimación de coste anual de operación según número de usuarios activos.	53
5.20	Resumen de costes del proyecto.	54
5.21	Desviación temporal por fase.	54
6.1	Requisitos funcionales del dominio de asignaturas.	59
6.2	Requisitos funcionales del dominio de horarios.	59
6.3	Requisitos funcionales del dominio de profesorado.	60
6.4	Requisitos funcionales transversales.	60
6.5	Requisitos funcionales del panel de administración.	61
6.6	Criterios de aceptación: selección representativa por dominio.	62
6.7	Requisitos de información del sistema.	63
6.8	Entidades de información del dominio académico.	63
6.9	Requisitos no funcionales, umbrales y valores alcanzados.	66
6.10	Restricciones, suposiciones y dependencias externas del prototipo.	67
6.11	Trazabilidad objetivos técnicos – requisitos funcionales.	71

6.12	Trazabilidad requisitos funcionales – cobertura de pruebas por categoría de la suite.	72
6.13	Evolución del alcance respecto a la propuesta inicial.	73
7.1	Protocolos y puertos de comunicación entre nodos del sistema.	78
8.1	Stack tecnológico completo del proyecto LinceUS Assistant.	90
10.1	Estructura de la tabla UNIVERSIDADES	98
10.2	Estructura de la tabla CENTROS	98
10.3	Estructura de la tabla DEPARTAMENTOS	99
10.4	Estructura de la tabla TITULACIONES	99
10.5	Estructura de la tabla ASIGNATURAS	100
10.6	Estructura de la tabla PROFESORES	100
10.7	Estructura de la tabla HORARIOS	101
10.8	Estructura de la tabla PLANES_DOCENTES	101
10.9	Estructura de la tabla PLANES_DOCENTES_CHUNKS	102
11.1	Tabla RERANK_WEIGHTS: bonificación aditiva por sección según el tipo de consulta detectado.	121
11.2	Operaciones del panel de administración por pestaña. Todos los <i>endpoints</i> van prefijados por <code>/api/admin</code>	125
12.1	Resultados por categoría de la suite E2E (revisión manual, 26/04/2026).	130
12.2	Cobertura de la capa de profundidad RAG por curso.	131
12.3	Resultados de la capa NLU y Policy.	132
12.4	Resultados de la reproducción de tráfico real.	132
12.5	Síntesis de los casos fallidos por patrón de causa raíz.	134
12.6	Latencia extremo a extremo (segundos).	135
12.7	Extrapolación del coste hipotético del LLM a 700 alumnos según intensidad de uso.	136
12.8	Visión integrada de las seis capas de validación.	136
12.9	Resultados de la suite <code>test_admin.py</code> (pytest, 26/04/2026).	139
13.1	Tipos de consulta soportados por el prototipo.	142
13.2	Acciones de la pestaña <i>Centros</i>	147
13.3	Acciones de la pestaña <i>Asignaturas</i>	148
13.4	Acciones de la pestaña <i>Profesores</i>	148
13.5	Acciones de la pestaña <i>Horarios</i>	149
13.6	Acciones de la pestaña <i>Conversaciones</i>	150
13.7	Secuencia recomendada para la carga inicial del catálogo de un centro.	151
13.8	Requisitos mínimos del entorno de despliegue.	152
13.9	Contenedores del despliegue y responsabilidad de cada uno.	153
13.10	Estructura del repositorio Linceus Assistant.	154
13.11	Etapas del ciclo de incorporación de cambios.	155
14.1	Indicadores cuantitativos de Linceus Assistant al cierre del prototipo (26/04/2026).	159
14.2	Cruce entre objetivos técnicos y evidencia obtenida.	160
16.1	Sucesión de escenas del vídeo demostración.	170
.2	Distribución del tiempo por categoría de actividad (Clockify, 02/05/2026).	175
.3	Horas registradas por sprint (Clockify, 02/05/2026).	175
.10	Catálogo de casos de trabajo futuro (<i>snapshot</i> 26/04/2026).	179

Índice de código

11.1 Cascada de resolucion de <code>resolver_asignatura()</code>	107
11.2 Atajos a RAG en <code>ActionConsultaProfesor</code>	112
13.1 Levantar la pila completa con Docker Compose.	152
13.2 Consultar registros de un contenedor.	153
13.3 Operaciones de mantenimiento habituales.	154
13.4 Preparacion del entorno de desarrollo local.	154
13.5 Arranque de los componentes en modo desarrollo.	155
13.6 Declaracion de una intencion con ejemplos NLU en <code>data/nlu.yml</code>	156
13.7 Estructura minima de una accion personalizada en Rasa.	156
13.8 Fragmento de <code>validar_sql</code> : lista de palabras prohibidas y verificacion de tabla.	157

Parte I

Introducción y Conceptos

Introducción

Este proyecto tiene como finalidad el diseño y desarrollo de un chatbot inteligente orientado a facilitar el acceso a información académica y administrativa en la Universidad de Sevilla, mediante técnicas de procesamiento del lenguaje natural [1] y recuperación aumentada por generación (RAG) [2].

1.1– Contexto

En la actualidad, el alumnado de la Universidad de Sevilla se enfrenta a una notable dispersión informativa. La información académica se encuentra repartida entre múltiples plataformas y páginas web, cada una gestionada de forma independiente por distintas facultades, servicios y departamentos. El portal institucional principal [3], la web de la propia ETSII [4], los portales internos Sevius [5] y Sevius4 [6], la Secretaría Virtual [7] y los procedimientos de matrícula y pago de tasas [8, 9] son solo algunos ejemplos. Esta fragmentación dificulta el acceso eficiente a datos esenciales como horarios, contacto con profesorado o información de las asignaturas.

Además, muchos contenidos relevantes no se presentan de forma unificada ni están estructurados para su consulta directa, sino que requieren navegar por documentos PDF (como proyectos docentes), correos informativos, páginas institucionales específicas u otros portales como Sevius o Sevius4. Esta situación resulta especialmente compleja para estudiantes de nuevo ingreso o internacionales, que no siempre conocen el funcionamiento interno del entorno universitario, lo que dificulta aún más la comprensión de la información disponible.

La ausencia de un punto de acceso único, interactivo y orientado al usuario final pone de manifiesto la necesidad de una herramienta conversacional que permita acceder a la información de manera contextual, simplificada y guiada. En este sentido, un chatbot capaz de interpretar consultas abiertas en lenguaje natural y conectarse con diferentes fuentes de información representa una solución innovadora, alineada con los principios de accesibilidad, automatización y modernización de los servicios universitarios.

1.2– Motivación

La motivación principal de este proyecto surge de la necesidad de centralizar el acceso a información académica dispersa y mejorar la experiencia del estudiante en su interacción con los sistemas universitarios. Conviene subrayar que esta dificultad no se limita al alumnado de nuevo ingreso o de programas de intercambio: la mayoría de estudiantes, incluso tras varios años en la titulación, no domina todos los procedimientos institucionales ni recuerda en qué portal reside cada dato. Quien necesita consultar un horario, el correo de un profesor o un detalle del plan docente termina con frecuencia recurriendo a buscadores externos o preguntando a compañeros, no porque la información no exista, sino porque está repartida entre fuentes que el usuario no consulta a diario.

Esta problemática no solo genera frustración y pérdida de tiempo, sino que también puede afectar negativamente al rendimiento académico y a la integración del estudiante en la comunidad universitaria. La dispersión de la información en múltiples fuentes web, documentos PDF y portales específicos dificulta la autonomía informativa del alumnado, que debe dedicar un esfuerzo significativo a buscar respuestas que deberían estar disponibles de forma inmediata.

Por tanto, el desarrollo de un asistente conversacional capaz de responder de forma rápida, precisa y en lenguaje natural constituye una mejora sustancial en la calidad del servicio universitario, promoviendo la autonomía del estudiante y reduciendo la carga administrativa de los servicios de atención.

1.3– Objetivos

1.3.1. Objetivo general

El objetivo principal de este proyecto es diseñar y desarrollar un chatbot inteligente que proporcione a los estudiantes de la Universidad de Sevilla una vía centralizada, accesible y eficiente para consultar información académica y administrativa relevante. La solución pretende integrar capacidades de comprensión del lenguaje natural mediante modelos de Inteligencia Artificial Generativa, junto con búsquedas en bases de datos estructuradas y vectorizadas, permitiendo resolver dudas frecuentes relacionadas con horarios, profesorado, documentación y normativas académicas. El asistente está dirigido al conjunto del alumnado y resulta de especial utilidad para quienes están menos familiarizados con los procedimientos institucionales, perfil que abarca a los estudiantes de nuevo ingreso o internacionales pero también a una parte significativa del alumnado ya matriculado. La funcionalidad de localización de espacios universitarios, contemplada en el anteproyecto, no forma parte del prototipo entregado; su aplazamiento se justifica en la Sección 6.9 y se retoma como línea de evolución en el Capítulo 14.

1.3.2. Objetivos técnicos

Los objetivos técnicos específicos del proyecto incluyen:

- Implementar un sistema conversacional basado en Rasa [10] que permita gestionar flujos de diálogo complejos y contextuales.
- Integrar la API de Gemini como capa generativa complementaria al clasificador NLU de Rasa, encargada de las decisiones más finas dentro de cada intención (subclasificación entre datos estructurales y plan docente, generación de *Text-to-SQL* a partir de la consulta del usuario y *smart fallback* cuando la confianza del clasificador es baja) y de la redacción final de las respuestas en lenguaje natural.
- Diseñar y desarrollar una base de datos híbrida en Supabase que combine información estructurada (asignaturas, horarios y profesorado) con embeddings vectoriales [11] para búsquedas semánticas sobre los planes docentes.
- Desarrollar acciones personalizadas en Python que permitan consultar datos estructurados y realizar búsquedas por similitud en documentación académica.
- Implementar un *widget* web ligero (HTML, CSS y JavaScript) que ofrezca una interfaz intuitiva y accesible para la interacción con el chatbot.
- Desarrollar un panel de administración independiente que permita gestionar los datos del sistema (asignaturas, horarios, profesorado, planes docentes) sin intervención técnica, garantizando la mantenibilidad del proyecto a largo plazo.

- Diseñar el sistema con una arquitectura escalable y extensible, de forma que la incorporación de nuevas titulaciones, centros o dominios funcionales pueda realizarse a través de la carga de datos, sin tocar el núcleo conversacional.
- Garantizar el cumplimiento de la normativa de protección de datos mediante el uso exclusivo de información de carácter público y el anonimato de las sesiones de usuario.

1.3.3. Objetivos académicos y personales

Desde el punto de vista académico y personal, este proyecto permite:

- Aplicar conocimientos adquiridos durante el Grado en Ingeniería del Software en un proyecto real de desarrollo de software.
- Adquirir experiencia práctica en el diseño de sistemas conversacionales y en la integración de modelos de inteligencia artificial generativa.
- Profundizar en el uso de técnicas de Retrieval Augmented Generation (RAG) y bases de datos vectoriales.
- Desarrollar competencias en metodologías ágiles aplicadas a proyectos individuales.
- Contribuir a la mejora de los servicios universitarios mediante una solución tecnológica innovadora y accesible.
- Devolver algo a la comunidad estudiantil de la que se forma parte, dejando una base sobre la que futuras generaciones de estudiantes puedan apoyarse y, si así lo deciden, ampliar el sistema a otros centros y titulaciones de la universidad.
- Demostrar la capacidad de diseñar, implementar y documentar un sistema completo de forma autónoma.

1.4– Soluciones existentes

Antes de justificar la propuesta de Linceus Assistant conviene revisar qué sistemas similares se han desplegado ya en el ámbito universitario, tanto dentro del Sistema Universitario Español como en el contexto internacional. La revisión que sigue se centra en asistentes conversacionales orientados a estudiantes que cubren consultas académicas, administrativas y de orientación, descartando otras categorías colindantes como los *chatbots* de atención a profesorado, los sistemas tutoriales adaptativos o los asistentes de evaluación docente, que persiguen objetivos distintos. La selección no pretende ser exhaustiva pero sí representativa: se han incluido los sistemas con mayor presencia institucional, los que comparten la naturaleza académica con el caso de uso del proyecto, y los que aportan elementos diferenciales técnicos o funcionales relevantes para la comparación.

1.4.1. Asistentes en universidades españolas

El despliegue de asistentes conversacionales en universidades españolas se ha intensificado en los últimos años, en buena parte gracias a la actividad comercial de proveedores especializados en el sector. La empresa alicantina 1MillionBot [12] concentra una parte significativa del mercado nacional, con presencia documentada en más de treinta universidades de España y Latinoamérica.

CATi (Universidad de Sevilla) [13, 14] es el asistente más cercano al ámbito de este proyecto. Está integrado en el Centro de Atención a Estudiantes de la propia Universidad de Sevilla y resuelve consultas sobre acceso, admisión, matrícula, becas, plazos y titulaciones, con una cobertura declarada de aproximadamente 160 preguntas frecuentes y disponibilidad permanente. En su

periodo de prueba inicial (enero de 2022) atendió alrededor de siete mil consultas procedentes de cuarenta países distintos, con una tasa de acierto declarada del 98 % sobre lenguaje conversacional abierto. Ahora bien, una interacción real con CATi en abril de 2026 muestra una limitación operativa relevante: cuando el alumno introduce una consulta concreta como “soy de ingeniería del software”, el sistema responde con un **menú cerrado de opciones** (preguntas predefinidas sobre automatrícula, plazos y procedimientos). Es decir, la primera capa de NLU clasifica el dominio, pero el flujo posterior se resuelve por selección guiada y no por recuperación abierta de información, lo que limita la capacidad de respuesta a preguntas no anticipadas en el guion.

Lola (Universidad de Murcia) [15, 16] fue uno de los primeros chatbots universitarios desplegados en España (julio de 2018). Construido sobre la plataforma DialogFlow de Google e integrado por 1MillionBot, está orientado a estudiantes de nuevo ingreso del Distrito Único de la Región de Murcia y cubre dudas sobre pruebas de acceso, admisión y matrícula. Los datos publicados por la propia universidad reportan 4.609 alumnos atendidos, 13.184 conversaciones y una tasa de respuestas acertadas del 91,67 % en sus primeros meses de funcionamiento.

Alhe (Universidad de Granada) [17, 18] es un proyecto más reciente, enmarcado en el Servicio Automatizado de Atención e Información de la UGR, también construido sobre la plataforma de 1MillionBot. Cubre oferta educativa, acceso, admisión, trámites académicos y servicios al estudiantado (becas, movilidad, comedores, salas de estudio, deportes, actividades culturales). Durante su primer año de operación atendió más de 38.708 consultas con una tasa de acierto superior al 91 %.

LUCA (Universidad de Cádiz) [19] es el asistente conversacional inteligente desplegado por el Área de Sistemas de Información de la UCA. Funciona durante 24 horas, 365 días al año, y se ofrece como punto de entrada inmediato a la información dirigida a futuros estudiantes universitarios.

Isidra y AIex (Universidad de Alcalá) representan dos generaciones distintas. **Isidra** [20] es el asistente institucional de la UAH, basado igualmente en aprendizaje automático, que durante sus cinco primeros días de actividad mantuvo más de 6.341 conversaciones con 4.812 personas distintas y una precisión declarada superior al 90 %. **AIex** [21], presentado en abril de 2026, es un asistente desarrollado por estudiantes de la propia UAH como proyecto académico para atender consultas durante la feria AULA 2026; ilustra que la línea de chatbot universitario también ha penetrado el ámbito formativo, no solo el institucional.

1.4.2. Plataformas internacionales

Más allá del Sistema Universitario Español, el ecosistema internacional ofrece dos referencias relevantes por su distinto enfoque.

UniBuddy [22, 23] opera en más de 600 instituciones a nivel global y combina una plataforma de mensajería persona a persona con un asistente conversacional de IA llamado Unibuddy Assistant. Su orientación principal no es la consulta académica del estudiante matriculado, sino la captación y conversión de candidatos durante el proceso de admisión: el sistema sirve para resolver preguntas factuales sobre la institución, sintetizar conversaciones mediante GPT y emparejar al candidato con embajadores de la universidad. Los análisis de conversaciones se generan con tecnología de OpenAI.

Hubert [24] adopta un enfoque distinto y se especializa en la recogida de *feedback* estudiantil sobre asignaturas y profesorado. En lugar de un formulario clásico, el alumno mantiene una conversación con el bot, que formula entre cuatro y cinco preguntas abiertas y agrupa las respuestas para que el docente las revise. Aunque su dominio queda fuera del caso de uso del prototipo Linceus, ilustra la utilidad de los modelos conversacionales para tareas de evaluación cualitativa que tradicionalmente sufren bajas tasas de respuesta.

1.4.3. Trabajos académicos comparables

La literatura científica sobre chatbots universitarios proporciona también un marco comparativo cuantitativo. Cuatro publicaciones se han tomado como referencia en el Capítulo 12 por reportar métricas comparables con las obtenidas por Linceus. **AdmitBot** [25] es un sistema de orientación para procesos de admisión universitaria que reporta una precisión de *intent* del 82 %. **EDUBOT/LiSA** [26], desarrollado en el Politécnico, proporciona soporte de *e-learning* con una tasa de respuestas correctas en torno al 78 %. El sistema descrito por **Ranoliya et al.** [27] cubre preguntas frecuentes universitarias con una exactitud del 85 % sobre cien consultas. Por último, el trabajo de **Dibya y Sahoo** [28] implementa un chatbot universitario basado en IA y NLP con una precisión declarada del 84 %.

1.4.4. Comparativa y diferenciación

La Tabla 1.1 resume las principales soluciones identificadas frente a los criterios diferenciales del proyecto Linceus Assistant.

Cuadro 1.1: Comparativa de soluciones existentes frente a Linceus Assistant.

Sistema	Dominio	Tecnología	Acceso	Diferenciación
CATi (US) [13]	Acceso, admisión, matrícula, becas	1MillionBot (NLP propietario)	Web institucional	Menús guiados; cobertura de FAQ (~160 preguntas)
Lola (UMU) [15]	Acceso y matrícula nuevo ingreso	DialogFlow + 1MillionBot	Web y app DURM	Pionero (2018); 91,67 % acierto
Alhe (UGR) [17]	Oferta educativa y servicios	1MillionBot	Web y Telegram	91 % acierto en primer año
LUCA (UCA) [19]	Información a futuro estudiante	1MillionBot	Web institucional	Disponibilidad 24/7
Isidra (UAH) [20]	Información institucional	1MillionBot	Web institucional	>90 % precisión declarada
UniBuddy [22]	Captación y admisión	GPT (OpenAI)	SaaS multi-canal	Mensajería P2P + IA
Hubert [24]	<i>Feedback</i> de cursos	NLP propietario	Web y enlaces	Encuesta conversacional
AdmitBot [25]	Admisión universitaria (académico)	NLU clásico	Prototipo	82 % <i>intent accuracy</i>
Linceus	Asignaturas, horarios y profesorado ETSII	Rasa 3.6 + Gemini + RAG (<i>pg-vector</i>)	Web (<i>widget</i>)	RAG sobre planes docentes; código abierto; validación cuantitativa

A la vista de la comparativa pueden destacarse cuatro ejes diferenciales del proyecto Linceus Assistant frente al panorama existente.

El primero, y probablemente el más relevante, es el **tipo de información cubierta**. Los asistentes institucionales españoles (CATi, Lola, Alhe, LUCA, Isidra) se concentran fundamentalmente en el ciclo de captación, acceso y matrícula, es decir, en información de tipo administrativo orientada a estudiantes potenciales o que aún no han comenzado sus estudios. Una vez el alumno se matricula, esos asistentes dejan de cubrir el grueso de las preguntas que pasan a ser pertinentes: qué se imparte en cada asignatura, en qué aula y horario tiene clase un determinado grupo, quién coordina una asignatura concreta o cómo se evalúa.

Linceus Assistant cubre exactamente ese hueco. El sistema atiende al estudiante en su día a día académico mediante tres dominios funcionales (asignaturas con su plan docente completo, horarios por curso y grupo, e información de contacto del profesorado) sin renunciar a ser útil

también al estudiante de nuevo ingreso, que en sus primeras semanas necesita justamente este tipo de información para orientarse: localizar el aula del primer día, identificar al coordinador de una asignatura o entender el sistema de evaluación. La herramienta no excluye, por tanto, al perfil que cubren CATi y similares, sino que extiende la cobertura más allá del momento de la matrícula.

Esta diferencia no es solo de alcance, sino de naturaleza del dato. Las consultas administrativas que cubren los asistentes existentes se resuelven con un conjunto cerrado de respuestas tipificadas; las consultas académicas que cubre Linceus se basan en documentación viva (planes docentes que cambian curso a curso, horarios que se publican cada cuatrimestre, asignaciones de profesorado revisables). Para que la información se mantenga al día sin intervención técnica, el sistema incorpora un **panel de administración conectado directamente a la base de datos**, desde el que el personal autorizado puede actualizar asignaturas, horarios, profesorado y planes docentes a través de la propia interfaz web. Cualquier cambio queda inmediatamente disponible para el chatbot, sin necesidad de regenerar el modelo ni de recurrir al proveedor. Las soluciones comerciales basadas en plataformas SaaS no suelen ofrecer este grado de control directo sobre el corpus.

El segundo es el **modelo conversacional**. La interacción real con CATi expuesta al inicio de esta sección permite documentar de forma directa que el asistente combina una primera capa NLU con un flujo guiado por menús en los turnos posteriores. El resto de asistentes españoles citados (Lola, Alhe, LUCA, Isidra) se construyen sobre tecnologías equivalentes (1MillionBot y DialogFlow), basadas también en clasificación de intención sin componente generativo abierto, y la documentación pública de cada uno de ellos describe su funcionamiento como un emparejamiento entre la pregunta del usuario y un conjunto cerrado de respuestas tipificadas. El patrón dominante en el ecosistema español es, por tanto, NLU clásico con menús cerrados o respuestas predefinidas, sin recuperación abierta sobre documentación.

Linceus Assistant adopta un planteamiento distinto: emplea un módulo de recuperación aumentada por generación (RAG) [2] sobre los documentos oficiales, lo que le permite responder a preguntas no anticipadas en el guion siempre que la información figure en el corpus indexado. La validación recogida en el Capítulo 12 muestra que el sistema responde correctamente al 91,9 % de un conjunto de 74 preguntas reales extraídas de los planes docentes oficiales, lo que excede el rango habitual de *exact-match* reportado para sistemas RAG de dominio cerrado en la literatura [2, 29].

El tercero es el **modelo de licencia y despliegue**. Las soluciones comerciales identificadas (1MillionBot, UniBuddy, Hubert) son productos cerrados ofrecidos como servicio (SaaS). Linceus Assistant es un sistema desarrollado en el ámbito académico, abierto en su código y desplegable en la infraestructura de la propia universidad mediante Docker Compose. Esta diferencia tiene consecuencias en términos de control sobre los datos, ausencia de coste de licencia y posibilidad de adaptación funcional sin dependencia de proveedor.

El cuarto es la **validación cuantitativa**. Las cifras publicadas por las soluciones comerciales españolas suelen consistir en una tasa de acierto agregada (entre el 91 % y el 98 %), sin desagregar por tipo de consulta ni acompañar de la metodología empleada para el cómputo. Linceus Assistant aporta un esquema de validación en cinco capas independientes (E2E, RAG *baseline*, RAG de profundidad, NLU y *policy*, tráfico real post-despliegue) cuya metodología y resultados se documentan exhaustivamente en el Capítulo 12, con trazabilidad completa frente a umbrales académicos publicados.

En conjunto, el panorama revisado muestra que existe espacio para una propuesta como la presente: orientada al estudiante en su día a día académico (tanto el ya matriculado como el de nuevo ingreso una vez comienza el curso), abierta en su tecnología, basada en RAG sobre documentación oficial real, con un panel de administración que permite mantener el corpus al día sin intervención técnica y validada con un esquema cuantitativo reproducible.

1.5– Contribución de este trabajo

Frente al estado del arte de asistentes universitarios revisado en la sección anterior y sintetizado en revisiones sistemáticas recientes [30], Linceus Assistant aporta tres contribuciones diferenciales que, en conjunto, justifican su valor más allá del de un prototipo de uso interno.

1. **Arquitectura híbrida NLU + RAG con dos vías de resolución por dominio.** El sistema combina, dentro de una misma *custom action*, una vía estructurada (*Text-to-SQL* [31] sobre Supabase) y una vía semántica (RAG sobre planes docentes con *pgvector* e índice HNSW [32]). Las dos vías no son alternativas en cascada sino estrategias seleccionadas por el contenido de la pregunta: la épica de profesores, por ejemplo, decide entre SQL y RAG en tres puntos del flujo en función de qué columnas necesita (Sección 11.3). Esta hibridación va más allá del patrón habitual “RAG sobre LLM” descrito en la literatura reciente y atiende a una limitación práctica del dominio universitario: la información estructural (créditos, horarios) vive en bases de datos relacionales y la información cualitativa (criterios de evaluación, profesorado por grupo) vive en planes docentes que solo existen como PDF.
2. **Ajuste iterativo y trazable de los umbrales del sistema.** Los tres umbrales que determinan la calidad de las respuestas (umbral de *fallback* del clasificador NLU, umbrales firme y de sugerencia del *fuzzy matching* sobre el directorio de profesorado, y umbral de similitud coseno del RAG) se ajustaron de forma iterativa durante el desarrollo a partir de la observación del comportamiento del bot sobre consultas reales del piloto, no se fijaron por convención. La Sección 11.8 documenta las tres observaciones cualitativas que guiaron la selección final del par 0,60 / 0,30 para el *fuzzy matching*: traslado de los casos ambiguos al flujo de confirmación con *ActionResolverAfirmacion*, rechazo de los nombres cortos sin especificidad léxica, y combinación con un filtro `SELECT . . . ILIKE` previo que reduce el universo de candidatos. Cada uno de los valores adoptados figura en `docs/sprints/` entre las decisiones del *sprint* correspondiente, lo que permite defender los porcentajes del Capítulo 12 como decisiones reproducibles y no como ajustes *ad hoc*.
3. **Panel de administración sin código que cierra el ciclo de vida del corpus.** El panel Flask descrito en la Sección 11.10 permite a una persona no técnica sincronizar centros, titulaciones y asignaturas desde Sevius, enriquecer el directorio de profesorado desde el PDI de `us.es` y vectorizar planes docentes (con su pipeline de *chunking*, *embeddings* y *rate limiting*) sin tocar línea de código ni reentrenar el modelo. Esta capa cubre una brecha repetidamente señalada en la literatura sobre chatbots educativos [30]: la mayoría de prototipos académicos llegan al despliegue pero no a la operación sostenida, porque la actualización de la base de conocimiento exige al desarrollador. El panel de Linceus traslada esa operación al perfil de mantenimiento (Sección 6.1) y la documenta con un manual reproducible (Capítulo 13).

Las tres contribuciones se materializan en código operativo, están cubiertas por suites de prueba con métricas reportadas en el Capítulo 12, y se acompañan de un registro de **113 decisiones técnicas** documentadas sprint a sprint en `docs/sprints/` (S2 a S7), de las cuales 66 (las de los sprints S6 y S7) se citan a lo largo de la memoria con el código *D-nnn*; las 47 restantes pertenecen a sprints anteriores y figuran con prefijo de sprint (*S2-nn*, *S3-nn*, *S4-nn*, *S5-nn*). El catálogo íntegro se recoge en el Apéndice .3 y cumple el requisito de trazabilidad RNF-12.

1.6– Estructura de la memoria

La memoria se organiza en cuatro partes que siguen el ciclo de vida del proyecto, desde el planteamiento hasta la validación y el cierre.

Parte I: Introducción y Conceptos. Contextualiza el proyecto, justifica su necesidad frente a las soluciones existentes, fija los objetivos, presenta el estudio comparativo de tecnologías que

sustenta las decisiones de diseño y define los conceptos técnicos fundamentales sobre sistemas conversacionales, NLU y arquitectura RAG.

Parte II: Metodología y Planificación. Describe la metodología de desarrollo empleada (SCRUM adaptado a un proyecto individual), las herramientas de gestión utilizadas y la planificación temporal del trabajo, con la estructura de descomposición en fases, paquetes y sprints.

Parte III: Diseño e Implementación. Recoge la especificación de requisitos, la arquitectura del sistema, el marco tecnológico definitivo, la estructura del proyecto y de la base de datos, y el detalle de implementación de cada épica funcional con sus pipelines de ejecución.

Parte IV: Validación y Cierre. Presenta la estrategia de pruebas en cinco capas y los resultados obtenidos, incluye el manual de usuario y administrador, las conclusiones y líneas de trabajo futuro, y cierra con los anexos sobre uso de IA durante el desarrollo y el vídeo demostración.

Preparación del proyecto

En esta fase previa se llevó a cabo un análisis exhaustivo de las tecnologías disponibles para construir el sistema conversacional, evaluando alternativas en función de criterios como coste, facilidad de integración, capacidad de despliegue local y compatibilidad con técnicas de RAG. Asimismo, se definió la arquitectura técnica del sistema y se identificaron los casos de uso principales que guiarían el desarrollo del proyecto.

2.1– Estudio de las tecnologías y toma de decisiones

2.1.1. Decisión de frameworks conversacionales

Frameworks analizados

Se han considerado distintos frameworks de chatbot **open source** que cumplen con los requisitos de despliegue local, integración en Python y soporte para RAG. Los principales son:

- **Rasa** [10], centrado en Python y con gran control de flujo.
- **Botpress (OSS)** [33], que destaca por su editor visual de flujos.
- **DeepPavlov** [34], más orientado a NLP avanzado con módulos reutilizables.
- **OpenDialog**, centrado en diseño visual y contextos conversacionales.
- **Tock** y **Botonic**, opciones alternativas con características interesantes, aunque con menor adopción o diferente enfoque tecnológico.

Comparación detallada

Flujo conversacional. El flujo conversacional se refiere a la capacidad del framework para **definir, controlar y gestionar el diálogo entre el usuario y el sistema**. Incluye cómo se modelan las intenciones, las respuestas, los contextos y la memoria de la conversación, así como el grado de flexibilidad para manejar **diálogos no lineales, interrupciones o escenarios complejos**. Un buen manejo del flujo conversacional permite que el chatbot no solo siga guiones rígidos, sino que pueda adaptarse dinámicamente a las necesidades del usuario, manteniendo coherencia y contexto a lo largo de la interacción.

- **Rasa** ofrece máximo control mediante historias y reglas, permitiendo modelar diálogos complejos y contextuales.
- **Botpress** facilita el diseño con nodos visuales, aunque está más orientado a flujos rígidos y predefinidos.

- **DeepPavlov** permite construir agentes multi-skill, pero requiere definir manualmente los pipelines.
- **OpenDialog** sobresale en el modelado de escenarios y contextos, aunque su dependencia de PHP limita la integración con Python.
- **Tock/Botonic** permiten definir historias o rutas conversacionales, pero con menor madurez que Rasa.

Testing. La capacidad de testing en un framework de chatbots hace referencia a las **herramientas disponibles para validar la calidad y el correcto funcionamiento del agente conversacional**. Esto incluye desde pruebas unitarias (validación de intenciones, entidades y respuestas individuales) hasta pruebas end-to-end (que simulan conversaciones completas para comprobar flujos y contextos). Un buen soporte de testing permite **automatizar la detección de errores, reducir el riesgo de alucinaciones o respuestas incoherentes y asegurar la estabilidad** del sistema a medida que evoluciona. Cuanto más integrado esté el testing en el framework, más fácil será mantener y escalar el chatbot con garantías de calidad.

- **Rasa** incorpora herramientas para pruebas unitarias y end-to-end, automatizando la validación de intenciones y flujos.
- **Botpress** ofrece principalmente un simulador manual, sin suite de pruebas automatizadas robusta.
- **DeepPavlov** no incluye framework específico, por lo que las pruebas deben hacerse con scripts en Python.
- **OpenDialog** y **Botonic** dependen casi exclusivamente de pruebas manuales.

Compatibilidad con RAG y embeddings. La compatibilidad con **RAG (Retrieval Augmented Generation)** [2] y el uso de **embeddings** mide hasta qué punto un framework permite integrar modelos de lenguaje con bases de datos vectoriales para mejorar las respuestas. Esta característica es clave cuando se trabaja con **información documental extensa o cambiante**. Un buen soporte en este ámbito asegura que el chatbot pueda **ofrecer respuestas actualizadas, precisas y fundamentadas en datos externos**, reduciendo el riesgo de respuestas inventadas (alucinaciones) [35].

- **Rasa** se integra de forma natural con bases vectoriales (pgvector, Qdrant, FAISS), permitiendo retrieval augmented generation.
- **Botpress** dispone de un módulo de *Knowledge Base* que admite cargar documentos, aunque menos flexible en personalización.
- **DeepPavlov** destaca en Q&A y FAQ matching, aunque el RAG debe construirse manualmente.
- **OpenDialog** y **Botonic** no tienen soporte nativo, siendo necesaria integración externa.

Despliegue local y privacidad. El despliegue local y la gestión de la privacidad se refieren a la **posibilidad de ejecutar el framework en entornos controlados (on-premise o en servidores propios)** sin depender necesariamente de servicios en la nube. Esta característica es importante cuando se manejan **datos sensibles o confidenciales**, ya que permite aplicar políticas de seguridad personalizadas y cumplir con normativas como el Reglamento General de Protección de Datos [36]. Además, la facilidad de despliegue (con Docker [37], instaladores nativos o stacks ligeros) influye directamente en la **rapidez de la puesta en marcha y en la capacidad de mantener el control total sobre la información del usuario**.

- **Rasa** y **Botpress** son fácilmente desplegables en local mediante Docker o instalación directa.
- **DeepPavlov** funciona como librería Python o servicio REST.
- **OpenDialog** requiere un stack PHP más pesado.
- **Tock** es estable en entornos locales, mientras que Botonic se orienta a proyectos en Node/React.

Comunidad y documentación. La comunidad y la documentación de un framework son indicadores clave de su madurez, accesibilidad y sostenibilidad a largo plazo. Una comunidad activa ofrece foros, repositorios y soporte colaborativo que facilitan la resolución de problemas y el intercambio de buenas prácticas. Al mismo tiempo, una documentación clara, actualizada y completa reduce la curva de aprendizaje y permite implementar soluciones más rápido.

- **Rasa** tiene la comunidad más amplia y documentación extensa.
- **Botpress** dispone de foros y Discord activos, pero con menor alcance.
- **DeepPavlov** cuenta con una comunidad académica sólida, aunque más técnica.
- **OpenDialog** y **Botonic** tienen comunidades pequeñas y más limitadas.

Decisión final

El framework seleccionado es **Rasa** [38], ya que combina:

- Máximo control sobre el flujo conversacional.
- Capacidades de testing integradas y automatizables [39].
- Soporte probado para RAG y bases vectoriales [2].
- Despliegue local sencillo y seguro, compatible con RGPD.
- Amplia comunidad y documentación, lo que garantiza sostenibilidad del proyecto.

Tabla de comparación detallada de frameworks

Característica / Framework	Rasa	Botpress	DeepPavlov	OpenDialog	Tock	Botonic
Flujo conversacional	***	**	**	**	*	*
Testing	***	*	*	*	*	*
Compatibilidad con RAG y embeddings	***	**	**	*	*	*
Despliegue local y privacidad	***	***	**	*	**	**
Comunidad y documentación	***	**	**	*	*	*
Resultado global	* 15	* 10	* 9	* 6	* 6	* 6

Cuadro 2.1: Comparación de frameworks conversacionales

2.1.2. Decisión de base de datos

Bases de Datos analizadas

Se revisaron diferentes opciones open source para almacenar tanto información estructurada como embeddings:

- **Supabase (Postgres + pgvector)** [40, 41].

- PostgreSQL autogestionado con pgvector [41].
- Appwrite, PocketBase, Directus, Hasura.
- Motores vectoriales dedicados: Qdrant [42], Weaviate [43], Milvus, FAISS.

Comparación detallada

Modelo de datos. El modelo de datos define cómo se organiza, almacena y consulta la información dentro de una base de datos o motor de persistencia. Dependiendo de la tecnología, este modelo puede ser relacional (tablas y relaciones SQL), orientado a documentos (estructuras tipo JSON), o especializado en vectores (espacios multidimensionales para embeddings). La elección del modelo es clave para garantizar la eficiencia, flexibilidad y escalabilidad del sistema, ya que influye directamente en cómo se estructuran los datos de los usuarios, los recursos académicos y los embeddings utilizados en búsquedas semánticas o RAG.

Búsqueda vectorial.

- Supabase/Postgres soportan pgvector, adecuado para corpus medianos.
- Qdrant, Weaviate y Milvus son más eficientes en grandes volúmenes de vectores.
- FAISS funciona muy bien embebido en Python, pero no es una base de datos como tal.
- El resto (Appwrite, PocketBase, Directus, Hasura) carecen de soporte nativo y requieren integraciones manuales.

Despliegue local y facilidad. El despliegue local y la facilidad de instalación miden la **complejidad técnica y los recursos necesarios para poner en marcha una base de datos en un entorno controlado**. Algunas soluciones ofrecen entornos ligeros y rápidos de ejecutar (como binarios únicos o imágenes Docker sencillas), mientras que otras requieren stacks más pesados y múltiples dependencias. Esta característica es importante porque impacta directamente en la **rapidez de la configuración inicial, la curva de aprendizaje y los costes de mantenimiento**.

- Supabase y Postgres se despliegan fácilmente con Docker.
- PocketBase es el más liviano (un solo binario).
- Appwrite y Directus requieren más dependencias.
- Qdrant/Weaviate/Milvus añaden complejidad, aunque escalables.

Seguridad y RGPD. La seguridad y el cumplimiento normativo son aspectos fundamentales en la gestión de datos, especialmente cuando se trabaja con información sensible de estudiantes o usuarios. Esta característica evalúa los **mecanismos nativos de autenticación, autorización y control de acceso** que ofrece cada base de datos, así como la posibilidad de aplicar políticas de privacidad. Tecnologías que incluyen funciones como **Row-Level Security, roles definidos o autenticación integrada** facilitan el cumplimiento legal y reducen riesgos. En cambio, los motores que carecen de seguridad propia obligan a implementar medidas adicionales en la capa de aplicación, aumentando la complejidad y la responsabilidad del equipo de desarrollo.

- Supabase ofrece Row-Level Security (RLS) y autenticación JWT.
- Postgres tradicional depende de roles SQL.
- Appwrite/Directus/Hasura ofrecen mecanismos de auth integrados.
- Motores vectoriales carecen de autenticación propia, requiriendo protección adicional en la aplicación.

Comunidad y documentación. La comunidad y la documentación determinan el **nivel de soporte, recursos y acompañamiento disponibles para desarrolladores**. Una base de datos con una comunidad amplia y activa facilita la resolución de problemas, la existencia de librerías y la mejora continua del sistema. Al mismo tiempo, una documentación clara, actualizada y con ejemplos prácticos acelera la adopción de la tecnología y reduce la curva de aprendizaje.

- **Postgres** es el más maduro y con mayor soporte.
- **Supabase** ha crecido mucho, con amplia documentación y ejemplos de IA.
- **Qdrant** y **Weaviate** cuentan con comunidades activas en el ámbito de vectores.
- **Appwrite**, **PocketBase**, **Directus** tienen comunidades menores pero en expansión.

Decisión final

La base de datos seleccionada es **Supabase (Postgres + pgvector)** [40, 41], porque:

- Permite unificar datos estructurados y vectores en una sola plataforma [2].
- Ofrece autenticación, reglas de seguridad a nivel de fila y APIs listas para consumir desde Python y React.
- Facilita el despliegue local sin costes de licencias.
- Su comunidad y documentación reducen la curva de aprendizaje [40].
- Cumple los requisitos de RAG con un volumen de datos manejable para el caso académico.

Tabla de comparación de bases de datos

Característica	Supabase	Postgres	Appwrite	PocketBase	Directus	Hasura	Qdrant	Weaviate	Milvus	FAISS
Modelo de datos	***	***	**	**	**	**	**	**	**	**
Búsqueda vectorial	**	**	*	*	*	*	***	***	***	**
Despliegue local	***	***	**	***	**	**	**	**	**	**
Seguridad y RGPD	***	**	**	*	**	**	*	*	*	*
Comunidad y docs.	***	***	**	**	**	**	**	**	**	**
Total	14	13	9	9	9	9	10	10	10	9

Cuadro 2.2: Comparación de bases de datos

2.1.3. Decisión de API de LLM

APIs analizadas

Se han considerado diferentes opciones de APIs de modelos de lenguaje de gran tamaño (LLMs) open source o con planes gratuitos/educativos:

- **Gemini (Google AI / DeepMind)** [44]
- **OpenAI GPT (GPT-4o, GPT-4o mini)** [45]
- **DeepSeek** [46]
- **Hugging Face Inference API** [47]
- **Cohere y Anthropic (Claude)** [48]

Se evaluó también la inferencia local mediante **Ollama**, que permite ejecutar modelos open source directamente en el equipo de desarrollo sin depender de una API externa. Esta opción fue descartada en fase temprana por las limitaciones de hardware del entorno local, que hacían que los tiempos de respuesta fueran inviables para un uso interactivo. No obstante, la Universidad de Sevilla dispone de servidores de inferencia compatibles con modelos en formato Ollama, lo que abre una vía de integración institucional futura sin coste de API.

Comparación detallada

Coste y accesibilidad. El coste y la accesibilidad hacen referencia a la **disponibilidad económica y facilidad de uso de los modelos de lenguaje (LLMs)**. En un contexto académico, donde no suele existir presupuesto, es esencial contar con opciones que permitan **experimentar gratuitamente o con bajos costes iniciales**. Además del precio, influyen factores como los límites de uso en los planes gratuitos, la velocidad de respuesta, la estabilidad del servicio y la facilidad de registro o integración. Esta característica resulta clave para asegurar que el proyecto pueda desarrollarse de forma **sostenible y realista**, sin que los costes de las llamadas a la API se conviertan en una barrera.

- Gemini ofrece un plan gratuito con un número considerable de llamadas mensuales, lo que permite experimentar y probar sin coste, factor clave en un TFG sin presupuesto.
- OpenAI GPT tiene un coste asociado desde la primera llamada más allá de GPT-3.5, lo que lo hace menos viable económicamente.
- DeepSeek tiene una API gratuita, pero con menos garantías de estabilidad y soporte.
- Hugging Face API ofrece acceso a modelos open source, pero el plan gratuito tiene fuertes limitaciones de velocidad y peticiones.
- Claude (Anthropic) y Cohere requieren suscripción desde el inicio, menos atractivas en un contexto universitario.

Calidad y rendimiento. La calidad y el rendimiento de un modelo de lenguaje se refieren a su capacidad para **comprender instrucciones, generar texto coherente y relevante, y mantener el contexto a lo largo de la conversación**. Estos aspectos suelen evaluarse mediante **pruebas comparativas de comprensión, razonamiento y generación en varios idiomas**. Además, influyen factores prácticos como la **velocidad de respuesta, la estabilidad del modelo y su habilidad para manejar entradas extensas sin pérdida de coherencia**. Una mayor calidad en este ámbito

se traduce en **respuestas más útiles, precisas y naturales**, lo que resulta fundamental para un chatbot académico que debe manejar información variada con fiabilidad.

Estudios comparativos muestran que Gemini compite con GPT-4 en comprensión y generación de texto, especialmente en multilingüe y razonamiento.

- GPT sigue siendo referencia en benchmarks de calidad, pero con coste.
- DeepSeek ha demostrado buen rendimiento en ciertas tareas de razonamiento matemático, aunque en comprensión semántica y contexto extenso suele quedar por debajo de Gemini y GPT.
- Hugging Face API depende mucho del modelo seleccionado (ej. LLaMA, Mistral, Falcon), pero requieren más trabajo de fine-tuning y optimización para igualar a Gemini/GPT en calidad.

Integración y soporte técnico. La integración y el soporte técnico se refieren a la **facilidad con la que un LLM puede incorporarse en el stack tecnológico existente** y al nivel de recursos disponibles para resolver problemas durante el desarrollo. Factores como la existencia de **SDKs oficiales, librerías en distintos lenguajes, ejemplos prácticos y documentación clara** determinan la rapidez de adopción. Además, contar con un ecosistema sólido y acuerdos institucionales (como convenios académicos) puede simplificar la integración y asegurar **mayor estabilidad a largo plazo**. Esta característica es clave, ya que permite centrar el esfuerzo en el desarrollo del chatbot sin tener que invertir demasiado tiempo en resolver barreras técnicas de conexión con el modelo.

- Gemini ofrece SDKs oficiales para Python y JavaScript, lo que encaja con el stack técnico del proyecto (Python para el servidor de acciones y el panel de administración, JavaScript vanilla para el widget frontend).
- GPT también tiene SDKs muy maduros, aunque con la barrera de costes.
- DeepSeek todavía no cuenta con ecosistema sólido.
- Hugging Face API es flexible pero requiere seleccionar y mantener modelos específicos.
- Gemini además está alineado con acuerdos académicos, como el que mantiene la **Universidad de Sevilla con Google** en diferentes ámbitos, lo que puede facilitar futuras integraciones oficiales del chatbot.

Privacidad y cumplimiento (RGPD). La privacidad y el cumplimiento normativo son esenciales al utilizar modelos de lenguaje que procesan datos de usuarios. Esta característica evalúa el **nivel de control sobre dónde y cómo se almacenan los datos**, si el servicio cumple con estándares legales de protección de información y si existe la opción de **despliegue on-premise**. Los LLMs en la nube suelen garantizar cumplimiento básico de GDPR, pero limitan el control directo. En cambio, los modelos auto-hospedados ofrecen **mayor soberanía sobre los datos**, aunque requieren más infraestructura y experiencia técnica. En un contexto universitario, suele ser más relevante encontrar un equilibrio entre **facilidad de uso, coste cero o reducido y garantías mínimas de privacidad**.

- Gemini y GPT ofrecen despliegues en la nube con cumplimiento GDPR, aunque el control on-premise es limitado.
- Los modelos de Hugging Face pueden auto-hospedarse, lo que da mayor control, pero a costa de infraestructura.
- En un contexto académico, la facilidad de uso y el plan gratuito de Gemini pesan más que el control absoluto.

Decisión final

La API seleccionada es **Gemini** [44], porque:

- Dispone de un plan gratuito generoso en número de llamadas.
- Ofrece calidad comparable a GPT-4 en muchos benchmarks, especialmente en español y razonamiento.
- Tiene SDKs oficiales para Python y JavaScript, encajando con el stack técnico del proyecto.
- Permite asegurar continuidad futura gracias a posibles acuerdos institucionales con la Universidad de Sevilla.
- Representa la opción más equilibrada entre calidad, coste, facilidad de integración y proyección académica.

Tabla de comparación detallada de APIs de LLM

Característica	Gemini	OpenAI GPT	DeepSeek	Hugging Face	Cohere	Claude
Coste y accesibilidad	***	*	**	**	*	*
Calidad y rendimiento	***	***	**	**	**	***
Integración y soporte	***	***	*	**	**	**
Privacidad y RGPD	**	**	*	***	**	**
Total	11	9	6	9	7	8

Cuadro 2.3: Comparación de APIs de LLM

2.2– Infraestructura del sistema

La infraestructura del sistema se apoya en tecnologías de código abierto y servicios con plan gratuito, lo que permite mantener el coste operativo en niveles compatibles con un proyecto académico. El sistema está actualmente en producción, desplegado en una instancia de DigitalOcean mediante Docker Compose, y se ha utilizado tanto para la fase de pruebas como para el piloto con alumnos reales.

El núcleo conversacional se ejecuta sobre el framework Rasa 3.6 y Python como lenguaje base, tanto para el servidor de diálogo como para las acciones personalizadas. La comprensión del lenguaje natural se reparte entre el clasificador local DIET [39], entrenado con los ejemplos del corpus propio del proyecto, y la API de Gemini (modelo `gemma-3-27b-it`), que asume las tareas en las que el clasificador local no es suficiente: clasificación de fallback, generación de SQL a partir de lenguaje natural, decisión RAG/SQL y redacción final de respuestas. La clave de la API se obtiene a través de Google AI Studio, dentro del plan gratuito.

La capa de datos reside en Supabase, una plataforma gestionada que ofrece PostgreSQL con la extensión `pgvector` activada de serie. Esta combinación permite mantener en la misma base de datos la información estructurada del dominio académico (asignaturas, horarios, profesorado, titulaciones) y los *embeddings* de los planes docentes utilizados por el pipeline RAG, sin necesidad de un motor vectorial independiente.

La interfaz del usuario final se entrega como un *widget* web ligero, implementado directamente en HTML, CSS y JavaScript sin necesidad de *frameworks* de *front-end*, lo que minimiza el peso del recurso y simplifica la integración en cualquier portal institucional. Junto al *widget* se despliega un panel de administración independiente, construido en Flask (elegido por su ligereza y su integración natural en el stack Python del proyecto), que conecta directamente con la base de

datos para permitir al personal autorizado mantener actualizado el corpus sin intervención técnica. Todo el conjunto se sirve a través de un proxy inverso `nginx` que actúa como punto de entrada único.

2.2.1. Arquitectura del sistema

La arquitectura sigue un enfoque modular y se descompone en cuatro contenedores Docker orquestados con Docker Compose: `nginx` como proxy inverso y servidor de los activos estáticos, `rasa` con el motor conversacional, `actions` con el servidor de acciones personalizadas, y `admin` con el panel Flask. Esta separación facilita el escalado independiente de cada pieza y la sustitución de componentes sin tocar el resto del sistema.

El flujo de una consulta tipo es el siguiente. El mensaje del usuario llega al servidor Rasa, que invoca el pipeline NLU para clasificar el *intent* y extraer las entidades relevantes. Si la confianza del clasificador local supera el umbral, el flujo continúa por la *custom action* correspondiente; en caso contrario se activa el fallback inteligente, que delega en Gemini la decisión sobre qué acción ejecutar. La acción seleccionada lee y escribe en los *slots* del *tracker* para mantener el contexto, y según la naturaleza de la consulta accede a la base relacional (datos estructurales como créditos, horarios o despachos) o al pipeline RAG sobre `pgvector` (preguntas sobre el contenido de los planes docentes: evaluación, temario, bibliografía). Las respuestas finales se construyen con una llamada a Gemini que recibe los datos recuperados como contexto y los redacta en lenguaje natural respetando un límite de longitud configurable.

2.2.2. Componentes tecnológicos del sistema

La Tabla 2.4 resume el papel de cada tecnología dentro del sistema en producción.

Tecnología	Rol en el sistema
Rasa 3.6	Motor conversacional: pipeline NLU, gestor de diálogo y servidor de acciones.
Python	Lenguaje del servidor de acciones personalizadas y del panel de administración.
Gemini API (<code>gemma-3-27b-it</code>)	Clasificación en fallback, <i>text-to-SQL</i> , decisión RAG/SQL y redacción de respuestas.
Supabase	PostgreSQL gestionado con autenticación y APIs listas para consumir desde Python.
pgvector	Extensión de PostgreSQL para almacenar y consultar <i>embeddings</i> en el pipeline RAG.
HTML, CSS, JavaScript	Widget web del usuario final, sin <i>frameworks</i> de <i>front-end</i> .
Flask	Panel de administración para el mantenimiento del corpus.
nginx	Proxy inverso y servidor estático del <i>widget</i> y del panel admin.
Docker Compose	Orquestación local y en producción de los cuatro contenedores del sistema.
DigitalOcean	Proveedor cloud donde se aloja la instancia de producción.
Google AI Studio	Gestión de la clave de acceso a la API de Gemini.

Cuadro 2.4: Componentes tecnológicos del sistema en producción.

2.3– Casos de uso principales

A partir del análisis del problema y de las decisiones tecnológicas de las secciones anteriores, se identifican los casos de uso que el sistema debe cubrir. Se agrupan en cuatro dominios funcionales: gestión de la titulación activa, información de asignaturas, horarios y profesorado. La gestión de la titulación se presenta en primer lugar porque es la condición previa que habilita el grueso de las consultas: las relativas a asignaturas y horarios solo devuelven resultados cuando la titulación

ya se ha fijado, ya que dependen de ella para filtrar los datos. La excepción son las consultas de profesorado, que pueden resolverse sin titulación porque la información de contacto es transversal a las titulaciones de un mismo centro. Cada caso se describe con un escenario positivo (entrada esperada) y un escenario negativo (entrada que el sistema debe gestionar con elegancia, no solo rechazar).

2.3.1. Gestión del contexto académico

Establecer o cambiar la titulación activa

La elección de titulación es el primer paso de la mayoría de las sesiones. Mientras el usuario no la fija, las consultas de asignaturas y horarios se interrumpen y el asistente solicita la selección mediante botones; las consultas de profesorado, en cambio, se atienden con normalidad. Una vez establecida, la titulación queda fijada como contexto y el usuario puede cambiarla en cualquier momento mediante una nueva orden.

- Escenario positivo: el usuario indica *“Soy de Ingeniería del Software”* o, ya en sesión, *“Cambiar a Tecnologías Informáticas”*; el asistente reconoce la titulación, fija el contexto y confirma el cambio. A partir de ese momento, las consultas que dependen de la titulación se filtran automáticamente por ella.
- Escenario negativo: el usuario propone una titulación ambigua o inexistente (*“ingeniería”* a secas) y el asistente solicita una aclaración antes de cambiar el contexto, sin asumir una titulación por defecto.

Consultar y reiniciar el contexto

- Escenario positivo: el usuario pregunta *“¿Qué titulación tengo activa?”* y el asistente responde con el centro y la titulación seleccionada. Ante *“Reset”* o *“Empezar de cero”*, el asistente borra el contexto y vuelve a mostrar los botones de selección de titulación.
- Escenario negativo: el usuario intenta consultar información sobre asignaturas u horarios sin haber elegido titulación y el asistente le solicita que elija una mediante los botones disponibles.

Consultar las titulaciones disponibles

- Escenario positivo: el usuario pregunta *“¿Qué titulaciones hay disponibles?”* y el asistente devuelve la lista de titulaciones activas en la base de datos, agrupadas por centro y con el número de asignaturas de cada una.
- Escenario negativo: si la base de datos no tiene titulaciones cargadas, el asistente lo indica con claridad en lugar de devolver una lista vacía.

2.3.2. Consulta sobre información de asignaturas

Consultar datos estructurales de una asignatura

El asistente extrae de la pregunta el dato concreto que el usuario está pidiendo y responde solo con ese dato, evitando volcar todo el registro de la asignatura. La respuesta completa se reserva para las preguntas explícitas de tipo general (*“Información de Redes”* o *“Háblame de Bases de Datos”*).

- Escenario positivo: el usuario pregunta *“¿Cuántos créditos tiene Redes?”* y el asistente responde *“Redes tiene 6 créditos”*. Si la pregunta es genérica (*“Información de Redes”*), el

asistente devuelve el conjunto de campos: créditos, curso, duración (anual o por cuatrimestre) y tipología (formación básica, obligatoria u optativa).

- Escenario negativo: el usuario consulta “*Información de Programación Interplanetaria*” (asignatura inexistente) y el asistente indica que no encuentra esa asignatura, ofreciendo, si procede, sugerencias por similitud.

Consultar contenido del plan docente

Este caso cubre las preguntas cuyo dato vive dentro del plan docente oficial de la asignatura. El sistema cubre, entre otros, sistema de evaluación y fórmula de calificación, metodología docente, temario y temas concretos, competencias formativas, bibliografía recomendada y, cuando el plan docente lo recoge explícitamente, datos sobre coordinación de la asignatura. La cobertura depende de lo que aparezca en cada plan docente: hay información que solo figura en algunos documentos y otra que no aparece en ninguno; en particular, las tutorías del profesorado no suelen estar recogidas como horario estructurado, por lo que se gestionan aparte (véase Sección 2.3.4).

- Escenario positivo: el usuario pregunta “¿*Qué bibliografía tiene Sistemas Operativos?*” o “*Temario de Bases de Datos*” y el asistente recupera los fragmentos relevantes del plan docente mediante el pipeline RAG y redacta una respuesta en lenguaje natural.
- Escenario negativo: el usuario pide información que el plan docente no contempla (“¿*Cuántos alumnos aprueban Sistemas Operativos cada año?*”) y el asistente responde que ese dato no consta en la documentación oficial, sin inventar la cifra.

Listado y conteo de asignaturas

- Escenario positivo: el usuario pide “*Dame las optativas de cuarto*” y el asistente genera la consulta SQL correspondiente, la ejecuta y devuelve la lista paginada. De forma análoga, ante “¿*Cuántas asignaturas tiene primero?*”, el sistema devuelve el conteo.
- Escenario negativo: el usuario pide un filtro inválido (“*optativas de séptimo curso*”) y el asistente aclara que ese curso no existe en la titulación activa.

2.3.3. Consulta sobre horarios

Consultar horario por asignatura

- Escenario positivo: el usuario pregunta “¿*A qué hora tengo Bases de Datos?*” y el asistente devuelve los horarios disponibles, distinguiendo aulas de teoría y de laboratorio.
- Escenario negativo: el usuario pide “*Horario de Bases de Datos 7*” (asignatura inexistente) y el asistente informa de que no encuentra coincidencias.

Consultar horario por curso y grupo

- Escenario positivo: el usuario solicita “*Horario de 2º grupo 1*” y obtiene la planificación semanal completa de ese curso y grupo. Los grupos se identifican por número (1, 2, 3...), tal como aparecen en los horarios oficiales de la ETSII.
- Escenario negativo: el usuario introduce un grupo inexistente (“*9º grupo 1*” o “*2º grupo 99*”) y el asistente aclara que esa combinación no figura en la base de datos.

Consultar horario por día

- Escenario positivo: el usuario pregunta “¿Qué clases tengo el lunes en primero grupo 2?” y el asistente devuelve solo las sesiones del día indicado.
- Escenario negativo: el usuario pregunta por un día sin clases (sábado o domingo) y el asistente lo indica explícitamente en lugar de devolver una lista vacía.

2.3.4. Consulta sobre datos de contacto del profesorado

Consultar despacho, correo y categoría académica

- Escenario positivo: el usuario pregunta “¿Cuál es el despacho del profesor Parejo?” o “Correo de Ana Bernárdez” y el asistente devuelve la información correspondiente: despacho, correo institucional, departamento y categoría académica.
- Escenario negativo: el usuario introduce un nombre inexistente y el asistente indica que no lo encuentra; si la similitud con algún profesor real es alta, ofrece la sugerencia para que el usuario la confirme.

Consultar tutorías de un profesor

- Escenario positivo: el usuario pregunta “Tutorías de la profesora Bernárdez”. Los horarios estructurados de tutoría, en general, no se publican de forma estable en ningún portal oficial ni aparecen recogidos en los planes docentes, por lo que el asistente redirige al correo institucional del profesor para que el alumno pueda solicitar cita directamente.
- Escenario negativo: el usuario pide tutorías de un profesor inexistente y el asistente indica que no lo encuentra.

Búsqueda de profesores por asignatura o departamento

- Escenario positivo: el usuario pregunta “¿Quién da Fundamentos de Programación?” o “Profesores del Departamento de Lenguajes y Sistemas Informáticos” y el asistente devuelve la lista correspondiente con sus datos de contacto.
- Escenario negativo: el usuario pide profesorado de una asignatura o departamento que no figura en la base de datos y el asistente informa del error.

2.3.5. Diagrama de casos de uso

La Figura 2.1 presenta el diagrama de casos de uso UML que sintetiza los casos descritos en las secciones anteriores. Los dos actores identificados en la Sección 6.1 del Capítulo 6 aparecen fuera del límite del sistema: el **Estudiante** agrupa los cuatro dominios funcionales de consulta, y el **Administrador** concentra las operaciones de mantenimiento del corpus. La separación física de ambos actores refleja que sus flujos de trabajo no se solapan: el panel de administración está protegido por autenticación y no es accesible desde el widget del alumno.




Figura 2.1: Diagrama de casos de uso UML del sistema Linceus Assistant. Los actores se sitúan fuera del límite del sistema (línea discontinua).

Conceptos iniciales

Este capítulo presenta la terminología fundamental sobre la que se construye el sistema. El objetivo no es reproducir la documentación oficial de cada tecnología, sino establecer un marco conceptual propio del proyecto, coherente con las decisiones de diseño adoptadas y con la forma en que cada componente aparece en el resto de la memoria.

3.1– Sistema conversacional

Un sistema conversacional es una aplicación software diseñada para interactuar con usuarios mediante lenguaje natural [1]. El sistema interpreta cada entrada textual, mantiene el estado del diálogo a lo largo del tiempo y genera respuestas coherentes en función del contexto y de los objetivos definidos.

En el caso de Linceus Assistant, el sistema se especializa en consultas académicas del ámbito de la ETSII: horarios, información de asignaturas y datos de contacto del profesorado. Esta especialización condiciona tanto el diseño del modelo de lenguaje como la estructura de la base de datos.

3.2– Componentes del sistema conversacional con Rasa

El framework Rasa organiza el sistema en dos capas bien diferenciadas: la comprensión del lenguaje natural (NLU) y la gestión del diálogo. Cada capa opera con sus propios mecanismos y se configura en archivos separados.

3.2.1. Comprensión del lenguaje natural (NLU)

El módulo NLU procesa cada mensaje del usuario para extraer dos tipos de información: la intención que expresa y las entidades que contiene.

Intent. Un intent representa el propósito o el objetivo del mensaje del usuario. Cada entrada se clasifica en una única intención que determina el tipo de acción que debe ejecutar el asistente. En el proyecto se definen intents específicos para cada dominio funcional: consulta de horarios, búsqueda de profesores, información sobre asignaturas o cambio dinámico de titulación.

Entity. Una entidad es un fragmento de información concreta extraído del mensaje que completa la intención detectada. Por ejemplo, en la frase “¿Cuándo es la clase de Bases de Datos del grupo 2?”, el intent es `consultar_horario`, la entidad `nombre_asignatura` toma el valor *Bases de Datos* y la entidad `grupo` toma el valor 2. Las entidades se definen en el archivo `domain.yml` y se anotan en los ejemplos de entrenamiento dentro de `data/nlu.yml`.

3.2.2. Gestión del diálogo

Una vez que el NLU ha identificado el intent y las entidades, el gestor de diálogo decide qué acción ejecutar a continuación. Este componente trabaja con tres elementos principales: slots, el tracker y las políticas de diálogo.

Slot. Un slot es una variable de memoria que persiste durante toda la conversación. Mientras que una entidad se extrae del mensaje actual y se descarta al siguiente turno, un slot conserva el valor extraído para que esté disponible en acciones posteriores. En Rasa, los slots se declaran en `domain.yml` y se tipan según el dato que almacenan: texto, número, valor booleano o valor categórico.

Tracker. El tracker es la estructura interna que almacena el estado completo de la conversación en cada instante. Contiene el historial de mensajes del usuario, los intents detectados, las entidades extraídas, los valores actuales de los slots y las acciones ya ejecutadas. Las custom actions acceden al tracker para leer el contexto de la conversación antes de generar una respuesta.

3.2.3. Mecanismos de respuesta: actions

Las acciones son las operaciones que ejecuta el asistente como respuesta a cada turno de conversación. Rasa distingue dos tipos:

- **Respuestas predefinidas (`utter_*`):** respuestas de texto estático declaradas en la sección `responses` del `domain.yml`. Se usan para saludos, despedidas y mensajes fijos.
- **Custom actions (`action_*`):** clases Python definidas en `actions/actions.py` que implementan lógica personalizada. En este proyecto se emplean para consultar la base de datos, invocar la API de Gemini y construir respuestas dinámicas.

3.2.4. Formularios

Un formulario es un mecanismo que permite recopilar varios datos del usuario de forma secuencial antes de ejecutar una acción. Si el usuario no proporciona todos los campos necesarios en un solo mensaje, el formulario los solicita uno a uno hasta completarlos. En el proyecto se utilizan formularios en aquellas consultas que requieren asignatura y grupo simultáneamente para devolver un resultado concreto.

3.2.5. Fallback

El fallback es el comportamiento de recuperación que se activa cuando el sistema no es capaz de clasificar el mensaje con confianza suficiente, o cuando no existe ninguna acción definida para la situación actual. En lugar de devolver un error o un silencio, el mecanismo de fallback responde al usuario con un mensaje de disculpa y, opcionalmente, le redirige a un recurso externo relacionado con el tema detectado.

3.3– Archivos de configuración de Rasa

La configuración del sistema se distribuye en varios archivos, cada uno con una responsabilidad bien definida. La tabla 3.1 resume su función dentro del proyecto.

La distinción entre `stories.yml` y `rules.yml` es relevante para el diseño: las stories son ejemplos de los que el modelo aprende a generalizar, mientras que las rules son restricciones absolutas. Para el proyecto, los saludos, las despedidas y los fallbacks se gestionan mediante rules; los flujos que dependen del contexto acumulado en la conversación se modelan con stories.

Archivo	Función
domain.yml	Definición central del asistente: intents, entities, slots, respuestas y lista de acciones.
data/nlu.yml	Ejemplos de frases anotadas para entrenar el modelo NLU.
data/stories.yml	Flujos de conversación de varios turnos usados como ejemplos de entrenamiento.
data/rules.yml	Comportamientos deterministas que se aplican siempre, independientemente del contexto.
config.yml	Pipeline de componentes NLU y políticas de diálogo.
endpoints.yml	URL del servidor de acciones y configuración del tracker store.
actions/actions.py	Implementación Python de las custom actions.

Cuadro 3.1: Archivos de configuración principales del sistema Rasa

3.4– Flujo de procesamiento de un mensaje

Cuando el usuario envía un mensaje al asistente, el sistema lo procesa en tres etapas consecutivas:

1. **NLU:** el texto se tokeniza, se vectoriza y se clasifica para obtener el intent y las entidades. En el proyecto, esta etapa combina el clasificador DIET de Rasa con una llamada condicional a la API de Gemini, que se activa únicamente cuando la confianza del clasificador local no supera el umbral definido.
2. **Gestión del diálogo:** el gestor consulta las rules y las stories para decidir la siguiente acción. El tracker se actualiza con el nuevo mensaje y los valores de los slots modificados.
3. **Ejecución de la acción:** si la acción es una respuesta predefinida, se envía directamente. Si es una custom action, se ejecuta el código Python correspondiente, que puede consultar la base de datos, llamar a la API de Gemini o construir una respuesta RAG.

3.5– Generación aumentada por recuperación (RAG)

La generación aumentada por recuperación (RAG, del inglés *Retrieval Augmented Generation*) es una técnica que combina la búsqueda de información en una base de conocimiento con la generación de texto mediante un modelo de lenguaje [2]. El objetivo es reducir las alucinaciones propias de los modelos generativos [35] proporcionándoles contexto factual relevante antes de generar la respuesta.

En Linceus Assistant, el pipeline RAG opera en cuatro pasos. Primero, la consulta del usuario se transforma en un vector de alta dimensión mediante un modelo de embeddings [49]. Segundo, ese vector se compara con los fragmentos almacenados en la base de datos vectorial para recuperar los más similares semánticamente, empleando la similitud coseno como métrica estándar de proximidad semántica en recuperación de información [50]. Tercero, los fragmentos recuperados se someten a un paso de reranking basado en metadatos [51]: el sistema detecta el tipo de consulta a partir de palabras clave (evaluación, contenidos, profesorado, bibliografía, etc.) y suma una bonificación sobre la similitud coseno según la sección del chunk, de modo que los fragmentos más pertinentes para esa categoría de pregunta asciendan en el ranking. Cuarto, los fragmentos reordenados se incorporan al prompt que se envía a Gemini, que genera la respuesta final fundamentada en esos contenidos.

3.6– Backend y persistencia de datos

3.6.1. Supabase y PostgreSQL

Supabase es una plataforma de backend basada en PostgreSQL que ofrece base de datos relacional, autenticación, API REST y soporte para la extensión pgvector [40]. En el proyecto, Supabase centraliza dos tipos de información: los datos estructurados del dominio académico (asignaturas, profesores, horarios, planes docentes) y los vectores semánticos del sistema RAG.

3.6.2. pgvector

pgvector es una extensión de PostgreSQL que permite almacenar vectores numéricos como columnas de una tabla relacional y realizar búsquedas de similitud sobre ellos de forma eficiente [41]. Su ventaja en este proyecto es que evita la necesidad de mantener un motor vectorial independiente: los embeddings y los datos estructurados conviven en la misma base de datos, simplificando las consultas y el despliegue.

3.6.3. Embeddings

Un embedding es una representación numérica de un texto en un espacio vectorial de alta dimensión. Textos semánticamente similares producen vectores próximos según alguna métrica de distancia, como el coseno o la distancia euclídea. En el pipeline RAG del proyecto, los fragmentos de documentación académica se convierten en embeddings al ingestar los datos, y las consultas del usuario se transforman en embeddings en tiempo de ejecución para recuperar los fragmentos más relevantes.

Parte II

Metodología y Planificación

Metodología

Este capítulo describe cómo se ha organizado y ejecutado el desarrollo de Linceus Assistant. Se cubren cinco aspectos: la metodología de desarrollo ágil empleada y su adaptación al contexto del proyecto, la gestión del código fuente, los estándares de codificación aplicados, la gestión del trabajo y las tareas, y el esquema de versionado del sistema.

4.1– Metodología de desarrollo: Scrum adaptado

4.1.1. Scrum: fundamentos

Scrum es un marco de trabajo ágil para el desarrollo iterativo e incremental de productos complejos [52], encuadrado en los principios establecidos por el Manifiesto Ágil [53]. Su unidad de trabajo es el **sprint**, una iteración de duración fija (típicamente de una a cuatro semanas) al final de la cual se obtiene un incremento del producto potencialmente entregable. Los roles clásicos son el *Product Owner*, responsable de priorizar el *product backlog*; el *Scrum Master*, que facilita el proceso; y el *Development Team*, que ejecuta el trabajo. Las ceremonias principales son la *Sprint Planning* (planificación del sprint), la *Daily Scrum* (sincronización diaria), la *Sprint Review* (revisión del incremento) y la *Sprint Retrospective* (mejora del proceso).

Una de las características definitorias de Scrum es su flexibilidad: la guía oficial no prescribe prácticas de ingeniería específicas, sino un conjunto mínimo de reglas que el equipo adapta a su contexto. Esto lo hace especialmente adecuado para proyectos de alcance variable como un TFG, donde los requisitos evolucionan con el conocimiento adquirido durante el desarrollo.

4.1.2. Adaptación al proyecto individual

Linceus Assistant es un proyecto desarrollado por una sola persona, lo que hace innecesarias varias ceremonias pensadas para coordinar equipos. A continuación se describen las adaptaciones realizadas respecto al Scrum estándar:

- **Sin Daily Scrum.** La sincronización diaria carece de sentido en un equipo unipersonal. El seguimiento del progreso se realiza de forma continua a través del tablero de tareas y el registro de decisiones técnicas en `docs/sprints/`.
- **Retrospectivas bajo demanda.** No se celebra una retrospectiva formal al cierre de cada sprint. En su lugar, se realiza una revisión del proceso únicamente cuando se detecta un problema recurrente o una desviación significativa respecto a la planificación. Este enfoque evita la sobrecarga documental sin perder la capacidad de mejora continua.
- **Sprint Planning al final de la Review.** La planificación del sprint siguiente se integra en la sesión de revisión del sprint anterior. Una vez evaluado el incremento entregado y ajustado el backlog, se definen directamente los objetivos del próximo sprint. El flujo real es,

por tanto: *Review del sprint* → *Actualización del backlog* → *Definición de objetivos* → *Descomposición en tareas*.

- **Rol único con supervisión académica.** Al no haber equipo, los tres roles de Scrum (Product Owner, Scrum Master, Developer) los asume la misma persona. Las funciones propias del Product Owner (definir prioridades, validar el incremento y orientar el alcance del producto) se ejercen en colaboración con el tutor académico, cuyas aportaciones quedan recogidas en la Bitácora de Reuniones descrita en la Sección 4.5.

4.1.3. Sprints, número y duración

El proyecto se ha organizado en **8 sprints** a lo largo de aproximadamente diez meses (julio de 2025 a mayo de 2026), con una duración nominal de **3 a 4 semanas** por sprint. La duración real de cada iteración se ajustó en función de la carga lectiva del cuatrimestre y de la complejidad de la épica en curso, lo que dio lugar a sprints más cortos durante los periodos de exámenes y a un sprint largo (S7, aproximadamente seis semanas) en el que se concentraron las épicas finales, el panel de administración, el despliegue y el piloto con usuarios. La cadencia y la duración aproximada de cada sprint, junto con los objetivos asociados y las horas registradas, se recogen en la Tabla 5.16 del Capítulo 5.

Cada sprint cierra con un incremento funcional verificable y un breve registro de decisiones técnicas (archivo `docs/sprints/sprint-N.md`) que documenta los cambios de diseño no triviales realizados durante la iteración. La correspondencia entre sprints y épicas del backlog se detalla en el Capítulo 5.

4.2– Gestión del código fuente

El control de versiones del proyecto se gestiona con **Git** [54], y el repositorio remoto se aloja en **GitHub**. Esta combinación proporciona trazabilidad completa de los cambios, facilita la revisión del historial de decisiones técnicas y permite integrar el pipeline de despliegue continuo [55] descrito en la Sección 5.2.3.

4.2.1. Política de ramas

El repositorio mantiene en todo momento exactamente dos ramas activas: `main` y una rama de trabajo efímera. Esta restricción deliberada simplifica la gestión del historial y evita la acumulación de ramas obsoletas.

- **main:** rama permanente y de producción. Todo merge a `main` dispara automáticamente el pipeline de GitHub Actions que despliega la nueva versión en el servidor de DigitalOcean.
- **Rama de trabajo:** efímera, con nombre descriptivo del tipo `feature/<épica>` o `fix/<ámbito>` durante el desarrollo activo de una épica (por ejemplo, `feature/rag-pipeline` o `fix/horarios-slot`). Al finalizar la épica se crea una rama `test` puntual para ejecutar la suite de validación completa; una vez superadas las pruebas, se hace merge a `main` y la rama se elimina. En ningún momento coexisten más de dos ramas.

El ciclo completo de una épica es, por tanto: `main` → `feature/X` (desarrollo) → `test` (validación) → `main` (merge y despliegue).

4.2.2. Convenciones de commits

Los mensajes de commit siguen el estándar **Conventional Commits** [56], con el formato `<tipo>: <descripción>`. Los tipos empleados con mayor frecuencia son `feat` (nueva funcionalidad), `fix` (corrección de errores), `refactor` (reestructuración sin cambio de comportamiento), `test` (adición o modificación de pruebas) y `docs` (documentación). Los commits son

frecuentes y de alcance reducido: cada commit representa un cambio coherente y compilable, lo que facilita la bisección del historial mediante `git bisect` [54] cuando aparecen regresiones.

4.3– Estándares de codificación

El código Python del proyecto se ajusta a la guía de estilo **PEP 8** [57], verificada automáticamente mediante dos herramientas complementarias: **pylint** [58] y **flake8** [59]. Pylint cubre el análisis semántico (detección de errores reales, variables no definidas, llamadas incorrectas) mientras que flake8 se centra en la conformidad de estilo: espacios sobrantes, imports no utilizados, longitud de línea e indentación. Ambas herramientas se configuran con un límite de 120 caracteres por línea, valor que equilibra legibilidad y practicidad para un proyecto con prompts al LLM y consultas SQL que no admiten partición arbitraria.

En los casos en que una desviación de estilo es intencionada (un import que actúa como re-exportación pública, una línea larga que contiene una cadena de texto no partible, o un par de instrucciones que forman una unidad semántica indivisible) se documenta explícitamente con una directiva de supresión en la propia línea. Esto hace que las excepciones sean visibles y razonadas, en lugar de silenciosas.

Para el código JavaScript del widget de chat (`frontend/`), se aplica **ESLint 8** [60] con la configuración `eslint:recommended`, extendida con reglas de estilo básicas (comillas simples, punto y coma obligatorio). La configuración se almacena en `.eslintrc.json` en la raíz del repositorio y se ejecuta con `npm run lint`, que lanza `eslint frontend/` sobre los tres ficheros del directorio (`chatbot-widget.js`, `admin.js`, `login.js`).

4.4– Política de delegación al modelo de lenguaje

A lo largo del proyecto se ha tomado de forma sistemática una decisión transversal que, sin estar atada a ninguna época concreta, condiciona la implementación de prácticamente todas: **cuándo resolver una subtarea con una heurística determinista (regex, diccionario, fuzzy matching) y cuándo delegar en el modelo de lenguaje**. Esta sección explicita el criterio aplicado, porque condiciona también el comportamiento, el coste y la fiabilidad del sistema en producción.

4.4.1. Criterio: heurísticas baratas primero, LLM cuando aporta

El criterio operativo es jerárquico. Para cada subtarea (clasificar una pregunta, extraer una entidad, normalizar un nombre, decidir una rama de pipeline) se aplica el siguiente orden:

1. **Diccionarios y regex** cuando el espacio de entrada es cerrado o casi cerrado (lista finita de alias, conjunto pequeño de palabras clave, patrones léxicos identificables como “*grupo N*” o “*coordinador*”).
2. **Fuzzy matching** [61] (`rapidfuzz`, `SequenceMatcher`) cuando el espacio de entrada es cerrado pero admite errores tipográficos o variantes morfológicas (nombres de profesor en BD, tokens de tutorías con typos).
3. **LLM** solo cuando el espacio de entrada es abierto (generar SQL a partir de lenguaje natural, redactar respuesta natural a partir de *chunks*) o cuando una heurística previa no ha sido concluyente y el coste del LLM se justifica.

Esta jerarquía no es una preferencia estética: responde a tres restricciones concretas del proyecto. Primero, el **coste por turno**: cada llamada al modelo cuenta hacia la cuota mensual de Gemini, y multiplicarla por dos o tres llamadas en cada turno conversacional convierte un sistema económico en uno difícil de mantener. Segundo, la **latencia percibida**: una llamada al modelo añade entre 800 ms y 2 s al turno, y el usuario percibe esa latencia incluso cuando la pregunta era

trivial. Tercero, y probablemente más importante, las **alucinaciones** [35]: cada vez que se delega una decisión binaria al LLM hay una probabilidad no nula de que invente un valor o lo interprete fuera del rango esperado, lo que en un asistente académico puede traducirse en información incorrecta entregada con tono autoritario.

4.4.2. Aplicación en el sistema

El criterio se materializa en patrones recurrentes a lo largo del código. La Tabla 4.1 resume las cuatro variantes principales y dónde aparecen. En todas ellas, la elección entre heurística y LLM no fue casual: respondió a la naturaleza concreta de la subtask y al balance entre los tres factores anteriores.

Patrón	Subtask típica	Ejemplo en el proyecto
Solo heurística	Detección de patrones léxicos cerrados	<code>_detectar_grupo()</code> (regex grupo N / gN); <code>_pregunta_menciona_rol_rag()</code> (lista de seis palabras clave); <code>_RE_CONTINUACION_TODOS_GRUPOS</code> (regex de continuación elíptica)
Heurística + fuzzy	Resolución de un nombre contra un catálogo finito	Cascada de <code>resolver_asignatura()</code> (alias → regex → fuzzy BD); filtrado por similitud en profesores (<code>nombre_normalizado</code> , umbrales 0,30 y 0,60)
Heurística + LLM como respaldo	Clasificación binaria con casos triviales y ambiguos	Clasificador RAG en <code>ActionConsultaEspecifica</code> : primero palabras clave (<i>evalúa, temario</i>); si no concluye, LLM a temperatura cero
LLM directo	Espacio de entrada o salida abierto	<i>Text-to-SQL</i> (generación de SELECT); redacción natural de la respuesta final; extracción del nombre de profesor cuando NLU falla y hay asignatura como contexto

Cuadro 4.1: Patrones de delegación al LLM aplicados en Linceus Assistant.

Un ejemplo ilustrativo del segundo patrón es la normalización de la titulación en `ActionCambiarContexto` (Sección 11.5): coincidencia exacta sobre un diccionario, *guard* de tokens discriminantes y, solo si nada de lo anterior funciona, fuzzy matching con umbral conservador. La opción de delegar la normalización al LLM se descartó deliberadamente: un fallo en la titulación contamina toda la sesión inyectando un `titulacion_id` incorrecto en consultas posteriores, y el coste de una alucinación silenciosa supera con creces el coste de un fallo de heurística (que el usuario percibe como “*no te he entendido*” y reformula).

4.4.3. Limitaciones conocidas

El precio de esta política es la **rigidez frente a fraseos atípicos y la dependencia del idioma**. Las heurísticas léxicas (palabras clave, regex de continuación, pronombres demostrativos para invertir prioridades de seguimiento) están escritas en español y no cubren formulaciones que se aparten del registro común del estudiantado. Si el sistema se internacionalizara o se quisiera atender a un público con vocabulario más diverso, varias de estas heurísticas tendrían que migrar a alternativas más flexibles: diccionarios por idioma, similitud semántica con *embeddings* multilingües, o clasificación por LLM a coste de la latencia y de las alucinaciones que actualmente se evitan. Esta tensión se aborda en el Capítulo 14 como línea de trabajo futura.

4.5– Gestión del trabajo

El seguimiento del proyecto se articula en torno a la **Bitácora de Reuniones**, un documento estructurado que recoge de forma acumulativa el desarrollo de cada reunión con el tutor y los objetivos acordados para el sprint siguiente. Tras cada reunión, la bitácora se actualiza a partir de la transcripción de la sesión, extrayendo los puntos más relevantes (decisiones tomadas, problemas detectados, cambios de prioridad) y registrando las tareas pendientes para el siguiente ciclo. Este documento actúa de facto como el *product backlog* del proyecto: la lista de tareas pendientes refleja en todo momento el estado acordado con el tutor, sin necesidad de herramientas adicionales de gestión.

Las reuniones de seguimiento se celebraron por **Microsoft Teams**, con una duración aproximada de 30 minutos cada una, al inicio de cada sprint. En total se documentan **8 reuniones de sprint** en el Apéndice .1, además de una reunión inicial de toma de contacto con el tutor (anterior a la adjudicación oficial del TFG) en la que se acordó el ámbito general del trabajo. Esta cadencia, ligada uno a uno con los sprints, garantiza que la priorización del backlog y la dirección del proyecto se revisen de forma sistemática.

Complementariamente, las decisiones técnicas no triviales tomadas durante el desarrollo se documentan en los registros de decisiones de sprint (`docs/sprints/SN/Registro_decisiones.md`), que mantienen trazabilidad entre el código y el razonamiento que lo originó.

El tiempo dedicado al proyecto se registra con **Clockify**, donde cada entrada recibe el nombre SX seguido de un guion y la descripción de la tarea (siendo X el número de sprint), lo que permite agrupar el esfuerzo por sprint y correlacionarlo con el backlog sin necesidad de herramientas adicionales.

4.6– Versionado del sistema

El sistema sigue un esquema de versionado semántico de tres niveles: **vMAJOR.MINOR.PATCH**, adaptado al ciclo de vida de un chatbot con modelo entrenado.

- **MAJOR**: se incrementa en dos situaciones: al incorporar una **nueva épica funcional** (un nuevo dominio de capacidades), o al introducir un **cambio arquitectónico de envergadura dentro de una épica existente** que afecta a su lógica de forma global (por ejemplo, la migración completa a Text-to-SQL o la introducción del pipeline RAG). Ejemplos reales del proyecto: `v1.x.x` cubre asignaturas con NLU puro, `v2.x.x` introduce Text-to-SQL y RAG, `v3.x.x` añade horarios, `v4.x.x` añade profesorado, `v5.x.x` incorpora cambios transversales de infraestructura.
- **MINOR**: se incrementa al añadir **nueva funcionalidad dentro de una épica existente**, como nuevos intents, nuevos filtros de búsqueda o mejoras significativas en la lógica de recuperación, sin alterar la arquitectura general.
- **PATCH**: se incrementa en correcciones de errores, ajustes de prompts, mejoras de ejemplos NLU o pequeñas optimizaciones que no alteran el comportamiento funcional esperado.

El versionado está ligado al modelo Rasa: cada reentrenamiento que modifica los ficheros NLU, stories o reglas genera un nuevo artefacto de modelo (`models/linceus.vX.Y.Z.tar.gz`) identificado con la versión del sistema. Esto garantiza que cada versión desplegada en producción es reproducible: el par {tag de Git, artefacto de modelo} define unívocamente el estado del sistema en ese punto. El historial completo de versiones se mantiene en `docs/tabla_versiones.md`.

Planificación

Este capítulo presenta la planificación del proyecto Linceus Assistant. La organización del trabajo sigue el ciclo de vida clásico de un proyecto de ingeniería del software, dividido en **tres fases**: *Inicio*, *Desarrollo* y *Cierre*. Esta estructura es coherente con la guía PMBOK y con la práctica habitual en proyectos académicos, y permite separar el trabajo de planificación previa, el desarrollo iterativo del producto y la validación con usuarios y entrega final.

Dentro de cada fase se identifican **paquetes de trabajo** que agrupan tareas con un objetivo común y un entregable concreto. Las épicas de desarrollo en sentido SCRUM (asignaturas, profesores, horarios, etc.) se ubican en la fase de Desarrollo y se ejecutan de forma incremental sobre sprints de 3–4 semanas, según se detalla en el Capítulo 4.

5.1– Estructura de Descomposición del Trabajo (EDT)

La Estructura de Descomposición del Trabajo (EDT), o *Work Breakdown Structure* (WBS), organiza jerárquicamente todo el trabajo necesario para completar el proyecto. El nivel 0 representa el proyecto completo, el nivel 1 las tres fases del ciclo de vida y el nivel 2 los paquetes de trabajo dentro de cada fase. Las tareas individuales (nivel 3) se detallan en el diccionario EDT de la Sección 5.2.

La Figura 5.1 muestra la EDT a nivel de fases y paquetes de trabajo.

5.2– Diccionario EDT

El diccionario EDT define cada paquete de trabajo y sus tareas constituyentes, especificando descripción, entregables y estimación de esfuerzo. Las estimaciones siguen la escala: **S** (Small, ≤ 1 semana), **M** (Medium, 1–2 semanas) y **L** (Large, 2–3 semanas).

5.2.1. Fase 1:Inicio

La fase de inicio agrupa todo el trabajo previo a la implementación: planificación, estudio del estado del arte, análisis de tecnologías y diseño arquitectónico. Es la fase más corta en duración pero condiciona todas las decisiones posteriores.

1.1: Gestión del proyecto

Paquete transversal: aunque su esfuerzo principal se concentra en el inicio (planificación) y en el cierre (memoria), la gestión del proyecto está activa durante todo el ciclo de vida.

1.2: Investigación tecnológica

Análisis del estado del arte y comparativa de tecnologías, base de las decisiones de diseño documentadas en el Capítulo 7.



Figura 5.1: Estructura de Descomposición del Trabajo (EDT): fases y paquetes de trabajo.

ID	Tarea	Descripción y entregables	Est.
1.1.1	Anteproyecto y planificación	Definición del alcance, objetivos, EDT inicial y cronograma orientativo. <i>Entregable: anteproyecto aprobado.</i>	M
1.1.2	Seguimiento iterativo	Revisión del progreso al cierre de cada sprint, ajuste del backlog y gestión de riesgos. <i>Entregable: registro de decisiones (docs/sprints/).</i>	L
1.1.3	Comunicación con tutor	Reuniones periódicas de seguimiento, actas y validación de hitos. <i>Entregable: actas de seguimiento.</i>	M

Cuadro 5.1: Diccionario EDT:1.1: Gestión del proyecto.

ID	Tarea	Descripción y entregables	Est.
1.2.1	Estado del arte de chatbots	Revisión de chatbots universitarios publicados (AdmitBot, EDUBOT/LiSA, Ranoliya FAQ, Dibya & Sahoo) y umbrales académicos de calidad. <i>Entregable: marco bibliográfico.</i>	M
1.2.2	Comparativa de frameworks	Análisis de Rasa, Botpress y DeepPavlov según coste, integración Python, RAG y despliegue local. <i>Entregable: tabla comparativa, decisión documentada.</i>	L
1.2.3	Comparativa de LLM/embeddings	Análisis de Gemini, OpenAI, DeepSeek y Ollama según coste, calidad y privacidad. <i>Entregable: tabla comparativa.</i>	M
1.2.4	Setup del entorno	Instalación de Python, Rasa, Supabase, Gemini API, Git/GitHub. Estructura inicial del repositorio. <i>Entregable: entorno funcional reproducible.</i>	S

Cuadro 5.2: Diccionario EDT:1.2: Investigación tecnológica.

1.3: Diseño de la arquitectura

Definición de la arquitectura por capas, modelo de datos y contratos entre componentes antes de empezar el desarrollo.

ID	Tarea	Descripción y entregables	Est.
1.3.1	Arquitectura por capas	Definición de las capas (presentación, NLU, lógica de negocio, IA, datos, admin) y de las interfaces entre ellas. <i>Entregable: diagrama de componentes.</i>	M
1.3.2	Diagrama de despliegue	Modelo de despliegue sobre DigitalOcean con contenedores Docker, Supabase como BD gestionada y Gemini como servicio externo. <i>Entregable: diagrama de despliegue.</i>	S
1.3.3	Modelo de datos	Diseño del esquema relacional (asignaturas, profesores, horarios, planes docentes) y vectorial (chunks + embeddings con pgvector). <i>Entregable: diagrama ER.</i>	M

Cuadro 5.3: Diccionario EDT:1.3: Diseño de la arquitectura.

5.2.2. Fase 2:Desarrollo

Fase central del proyecto. Se ejecuta de forma iterativa siguiendo el marco SCRUM adaptado descrito en el Capítulo 4, con sprints de 3–4 semanas. Cada paquete corresponde a una épica funcional del producto y se cierra con un incremento entregable.

2.1: Épica Asignaturas

Funcionalidad nuclear: consultas sobre asignaturas (ficha, listado, conteo) mediante *Text-to-SQL* sobre la base de datos relacional y RAG sobre los planes docentes.

ID	Tarea	Descripción y entregables	Est.
2.1.1	Esquema y carga de datos	Tablas asignaturas, titulaciones, centros y carga inicial de las tres titulaciones GII de la ETSII. <i>Entregable: scripts SQL + datos.</i>	M
2.1.2	NLU de asignaturas	Intents (consulta_asignatura_especifica, consulta_asignaturas_listado, consulta_asignaturas_conteo) y entidades. <i>Entregable: ficheros NLU.</i>	M
2.1.3	Acción Text-to-SQL	Generación dinámica de SQL con Gemini, validación, ejecución y formateo de la respuesta natural. <i>Entregable: módulo actions/asignaturas/.</i>	L
2.1.4	Resolución de seguimiento	Herencia de slot ultimo_nombre_asignatura para preguntas elípticas (“y cuántos créditos?”). <i>Entregable: resolver_asignatura.</i>	M
2.1.5	Testing de la épica	Suite de aceptación con ≥ 30 casos golden + casos negativos y con typos. <i>Entregable: informe de pruebas.</i>	M

Cuadro 5.4: Diccionario EDT:2.1: Épica Asignaturas.

2.2: Épica Profesores

Búsqueda de profesorado por nombre o por asignatura con datos de contacto, despacho, departamento y atajo de coordinador/suplente vía RAG sobre el plan docente.

ID	Tarea	Descripción y entregables	Est.
2.2.1	Esquema profesores	Tablas profesores, departamentos, profesor_asignatura con FK hacia asignaturas. <i>Entregable: script SQL.</i>	S
2.2.2	Importación desde us.es PDI	Scraper del directorio oficial de la US para importar profesorado de la ETSII; deduplicación por email. <i>Entregable: scraper integrado en panel admin.</i>	L
2.2.3	NLU y acción	Intent consulta_profesor con pipeline Text-to-SQL + fallback RAG sobre plan docente. <i>Entregable: actions/profesores/.</i>	L
2.2.4	Testing de la épica	Suite con 43 casos cubriendo nombre, asignatura, tutorías y coordinador. <i>Entregable: informe de pruebas.</i>	M

Cuadro 5.5: Diccionario EDT:2.2: Épica Profesores.

2.3: Épica Horarios

Consultas de horario por curso/grupo o por asignatura, con extracción automática del PDF oficial de horarios de la ETSII.

ID	Tarea	Descripción y entregables	Est.
2.3.1	Esquema horarios	Tablas grupos_clase, horarios, aulas con cuatrimestre como dimensión. <i>Entregable: script SQL.</i>	M
2.3.2	Extractor PDF ETSII	Parser con pdfplumber de la cuadrícula oficial; reconoce códigos xGy-Cz y separa teoría de laboratorio. <i>Entregable: admin/horarios_extractores/.</i>	L
2.3.3	NLU y acciones	Intents consulta_horario (curso+grupo) y consulta_horario_asignatura; herencia de slot para seguimiento. <i>Entregable: actions/horarios/.</i>	L
2.3.4	Testing de la épica	Suite con 45 casos (horario semanal, por día, con/sin cuatrimestre, con typos). <i>Entregable: informe de pruebas.</i>	M

Cuadro 5.6: Diccionario EDT:2.3: Épica Horarios.

2.4: Pipeline RAG

Infraestructura transversal de *Retrieval Augmented Generation* sobre los planes docentes de las asignaturas, utilizada por las épicas de asignaturas y profesores.

2.5: Panel admin y frontend

Interfaces visibles del producto: el widget de chat para el alumno y el panel de administración para mantener los datos curados.

5.2.3. Fase 3:Cierre

Fase final del proyecto: validación funcional exhaustiva, despliegue en producción, ejecución del piloto con usuarios reales y entrega de la documentación académica.

ID	Tarea	Descripción y entregables	Est.
2.4.1	Extracción y <i>chunking</i>	Parseo de planes docentes (HTML/PDF), <i>chunking</i> semántico con metadatos (asignatura, sección, año). <i>Entregable: pipeline.</i>	M
2.4.2	Embeddings y pgvector	Generación con <code>gemini-embedding-001</code> (2 000 dimensiones) y almacenamiento en pgvector con índices HNSW; función SQL <code>buscar_plan_docente()</code> . <i>Entregable: pipeline de vectorización.</i>	M
2.4.3	Action RAG	Acción que combina retrieval semántico con re-ranking por sección y umbral de similitud; respuesta con citas. <i>Entregable: módulo RAG en actions/.</i>	L
2.4.4	Anti-alucinación	Prompts reforzados que prohíben inventar nombres, emails o aulas no presentes en los chunks. <i>Entregable: prompts revisados.</i>	M

Cuadro 5.7: Diccionario EDT:2.4: Pipeline RAG.

ID	Tarea	Descripción y entregables	Est.
2.5.1	Widget de chat	SPA en JavaScript vanilla, embebible mediante <code><script></code> , con renderizado Markdown y botones rápidos. <i>Entregable: frontend/.</i>	M
2.5.2	API admin (Flask)	Endpoints REST para CRUD de centros, titulaciones, asignaturas, profesores y planes docentes. <i>Entregable: admin/.</i>	L
2.5.3	SPA admin	Interfaz web con navegación jerárquica Centro → Titulación → Asignatura. <i>Entregable: frontend/admin.*.</i>	M
2.5.4	Integración de scrapers	Scrapers de Sevius y us.es expuestos en el panel con flujo <i>preview</i> → <i>insert</i> . <i>Entregable: rutas /sync.</i>	M

Cuadro 5.8: Diccionario EDT:2.5: Panel admin y frontend.

3.1: Validación y testing

Suite de pruebas multinivel siguiendo el modelo de calidad ISO/IEC 25010 y la metodología *Behavior-Driven Development*.

ID	Tarea	Descripción y entregables	Est.
3.1.1	Plan de aceptación	Diseño del plan de pruebas según ISO 25010 + BDD: positivos, negativos, edge, robustez. <i>Entregable: plans/aceptacion-prototipo.md</i> .	M
3.1.2	Suite E2E	159 casos sobre el stack completo (NLU + actions + SQL + RAG + LLM). <i>Entregable: 94,3 % PASS</i> .	L
3.1.3	RAG retrieval + profundidad	Capa baseline (50 preguntas) y profundidad (74 preguntas reales sobre 19 asignaturas). <i>Entregables: 94,0 % y 91,9 %</i> .	M
3.1.4	NLU + Policy	Validación con <code>rasa test core</code> sobre 44 stories. <i>Entregable: 100 % accuracy de acciones</i> .	S
3.1.5	Métricas no funcionales	Latencia p50/p95 y coste por turno con extrapolación a 700 alumnos. <i>Entregable: coste_latencia.md</i> .	M

Cuadro 5.9: Diccionario EDT:3.1: Validación y testing.

3.2: Piloto con usuarios

Despliegue del prototipo y validación con conversaciones reales de alumnos de la ETSII.

ID	Tarea	Descripción y entregables	Est.
3.2.1	Captura de tráfico real	Registro de las conversaciones piloto en <code>conversation.log</code> . <i>Entregable: 59 sesiones / 203 turnos</i> .	S
3.2.2	Auditoría manual	Replay turno a turno desde el panel admin; marcado de sesiones validadas. <i>Entregable: 58/59 sesiones validadas (98,3 %)</i> .	M
3.2.3	Iteración correctiva	Fixes detectados durante la auditoría (alias compactado, anti-alucinación, fecha actual en prompt, seguimiento cross-intent). <i>Entregable: registro de decisiones D-064..D-069</i> .	M

Cuadro 5.10: Diccionario EDT:3.2: Piloto con usuarios.

3.3: Despliegue en producción

Puesta en funcionamiento del sistema en una infraestructura accesible públicamente y configuración del pipeline de despliegue continuo.

ID	Tarea	Descripción y entregables	Est.
3.3.1	Provisión del droplet	Aprovisionamiento del servidor en DigitalOcean (Ubuntu 24.04 LTS), <i>firewall</i> y dominio. <i>Entregable: servidor accesible</i> .	S
3.3.2	Containerización	<code>docker-compose</code> con cuatro servicios (nginx, rasa, actions, admin) e imagen Rasa custom con spaCy. <i>Entregable: docker/</i> .	M
3.3.3	Pipeline CI/CD	<i>Workflow</i> de GitHub Actions que despliega vía SSH al droplet en cada <i>merge</i> a main. <i>Entregable: deploy.yml</i> .	S

Cuadro 5.11: Diccionario EDT:3.3: Despliegue en producción.

3.4: Memoria

Documentación académica final del proyecto.

ID	Tarea	Descripción y entregables	Est.
3.4.1	Redacción de la memoria	Capítulos de introducción, marco, metodología, arquitectura, planificación, pruebas y conclusiones. <i>Entregable: memoria.</i>	L
3.4.2	Diagramas técnicos	Diagrama de componentes y de despliegue en notación UML2 (PlantUML). <i>Entregable: img/diagrama-*.png.</i>	S

Cuadro 5.12: Diccionario EDT:3.4: Memoria del proyecto.

5.3– Resumen cuantitativo de la EDT

La Tabla 5.13 resume los paquetes de trabajo por fase y la distribución del esfuerzo estimado.

Fase	Paquete de trabajo	Tareas	S	M	L
1. Inicio	1.1 Gestión del proyecto	3	0	2	1
	1.2 Investigación tecnológica	4	1	2	1
	1.3 Diseño de la arquitectura	3	1	2	0
2. Desarrollo	2.1 Épica Asignaturas	5	0	4	1
	2.2 Épica Profesores	4	1	1	2
	2.3 Épica Horarios	4	0	2	2
	2.4 Pipeline RAG	4	0	3	1
	2.5 Panel admin y frontend	4	0	3	1
3. Cierre	3.1 Validación y testing	5	1	3	1
	3.2 Piloto con usuarios	3	1	2	0
	3.3 Despliegue en producción	3	2	1	0
	3.4 Memoria	3	1	1	1
Total		45	8	26	11

Cuadro 5.13: Resumen cuantitativo de la EDT por fase y paquete de trabajo.

5.4– Backlog del producto

El backlog del producto se deriva de los paquetes de la fase de Desarrollo y los organiza según su prioridad de implementación. Cada épica se desarrolla de forma incremental siguiendo el marco SCRUM adaptado descrito en el Capítulo 4, de modo que las funcionalidades se entregan en *releases* sucesivas validables por separado.

La priorización responde a dos criterios:

1. **Valor para el usuario:** Las épicas que cubren las consultas más frecuentes de los estudiantes (asignaturas, profesorado, horarios) se implementan primero.
2. **Dependencia técnica:** La infraestructura transversal (pipeline RAG, panel admin) se desarrolla en paralelo a las épicas que la consumen, pero su *release* depende de tener al menos una épica funcional sobre la que probarla.

La Tabla 5.14 muestra el orden de prioridad de las épicas dentro de la fase de Desarrollo.

Prioridad	Épica / paquete	Dependencia
1	2.1 Asignaturas (BD relacional + Text-to-SQL)	–
2	2.2 Profesores (BD + RAG plan docente)	2.1 (esquema BD compartido)
3	2.4 Pipeline RAG (transversal)	2.1 (inventario de fuentes)
4	2.3 Horarios (BD + extractor PDF)	2.1 (esquema BD)
5	2.5 Panel admin y frontend	Todas las anteriores

Cuadro 5.14: Priorización del backlog dentro de la fase de Desarrollo.

5.5– Planificación temporal

La normativa de la Universidad de Sevilla fija en **300 horas** la carga de trabajo esperada para un Trabajo de Fin de Grado. Esta cifra actúa como referencia para dimensionar las tareas y evaluar la coherencia de la planificación.

5.5.1. Estimación inicial por fase

La estimación se realizó antes del inicio del desarrollo asignando franjas de horas a cada fase de la EDT en función de su complejidad relativa. La escala S/M/L utilizada en el diccionario EDT se traduce a horas según el convenio: $S \in [10, 20]$ h, $M \in [20, 40]$ h, $L \in [40, 60]$ h. Aplicando estos valores a la distribución de la Tabla 5.13 ($8S + 26M + 11L$) se obtiene un rango estimado de:

$$\text{Mínimo: } 8 \times 10 + 26 \times 20 + 11 \times 40 = 80 + 520 + 440 = 1\,040 \text{ h}$$

$$\text{Máximo: } 8 \times 20 + 26 \times 40 + 11 \times 60 = 160 + 1\,040 + 660 = 1\,860 \text{ h}$$

Esta cifra refleja el esfuerzo agregado de todos los paquetes considerados de forma independiente. Como el proyecto es individual y varios paquetes se solapan temporalmente (por ejemplo, la documentación se redacta en paralelo al desarrollo), la estimación de referencia se fijó en **300 h totales**, distribuidas entre las tres fases de acuerdo con la Tabla 5.15.

Fase	Estimación (h)	% sobre 300 h
1. Inicio (anteproyecto, investigación, arquitectura)	45	15 %
2. Desarrollo (cinco épicas)	195	65 %
3. Cierre (pruebas, despliegue y memoria)	60	20 %
Total estimado	300	100 %

Cuadro 5.15: Estimación inicial de esfuerzo por fase.

5.5.2. Planificación de sprints

El proyecto se organiza en ocho sprints de entre 3 y 6 semanas de duración, siguiendo la adaptación de SCRUM descrita en el Capítulo 4. La Tabla 5.16 recoge para cada sprint el periodo, los objetivos principales y las horas registradas en Clockify.

5.5.3. Cronograma e hitos

Los hitos principales del proyecto cubren no solo las tareas de desarrollo sino también las de investigación tecnológica, documentación técnica, redacción de manuales y cierre del entregable, tal como recomienda la guía académica de elaboración del TFG. La Tabla 5.17 recoge cada hito con su fecha real de consecución, el sprint en el que se completó y la categoría de trabajo a la que corresponde.

Sprint	Periodo	Objetivo principal	Horas
S1	Jul–Ago 2025	Anteproyecto, investigación tecnológica, infraestructura inicial	20,16
S2	Ago–Sep 2025	Política de commits, comparativa de tecnologías, product backlog	13,58
S3	Sep–Dic 2025	Épica Asignaturas: BD relacional, acciones NLU, interfaz inicial	33,19
S4	Dic 2025–Ene 2026	Épica Asignaturas avanzada, Ollama/-Gemini, pipeline RAG inicial	8,17
S5	Feb 2026	Vectorización de planes docentes, integración Gemini, documentación	17,68
S6	Feb–Abr 2026	Épicas Horarios y Profesores, panel admin, pruebas, piloto	23,72
S7	Abr 2026	Sprint largo: épicas restantes, CD, pruebas exhaustivas, memoria	106,35+44,17
S8	Abr–May 2026	Cierre de memoria y manuales	10,79
Reuniones de seguimiento con el tutor (sin sprint asociado)			3,91
Total registrado a 02/05/2026			281,72

Cuadro 5.16: Horas registradas por sprint (fuente: Clockify).

Hito	Fecha	Sprint	Categoría
Investigación de <i>frameworks</i> y comparativa de tecnologías	27/07/2025	S1	Investigación
Anteproyecto aprobado y adjudicación oficial del TFG	28/07/2025	S1	Documentación
Infraestructura inicial (repositorio, MVP funcional, política de <i>commits</i>)	17/08/2025	S2	Infraestructura
Sistema conversacional mínimo viable (Épica Asignaturas)	08/01/2026	S3	Desarrollo
Esquema completo de BD multititulación + integración Gemini	27/02/2026	S5	Desarrollo
Pipeline RAG operativo sobre planes docentes	27/02/2026	S5	Desarrollo
Épicas Horarios y Profesores completadas	05/04/2026	S6	Desarrollo
Panel de administración funcional	15/04/2026	S7	Desarrollo
Despliegue en producción (DigitalOcean)	15/04/2026	S7	Infraestructura
Piloto con usuarios reales completado	15/04/2026	S7	Validación
Suite de pruebas E2E, RAG y panel admin estabilizada	26/04/2026	S7	Validación
Redacción de la memoria (Partes I y II)	02/05/2026	S8	Documentación
Manual de usuario y manual de despliegue	mayo 2026	S8	Documentación
Vídeo demostración del prototipo	mayo 2026	S8	Documentación

Cuadro 5.17: Hitos principales del proyecto.

5.6– Planificación de costes

5.6.1. Costes de personal

El proyecto ha sido desarrollado íntegramente por un único desarrollador en calidad de Ingeniero de Software en formación. Para la estimación del coste de personal se toma como referencia la tarifa horaria de **28,37 €/h** (sin IVA), correspondiente al perfil “Analista Programador J2EE/Web (Junior)” del informe oficial de la Junta de Andalucía sobre perfiles profesionales del ámbito informático [62]. Este perfil es el que mejor refleja el rol desempeñado durante el proyecto, en el que una misma persona ha asumido tanto el análisis funcional como el diseño y la programación de la solución.

$$\text{Coste personal} = 300 \text{ h} \times 28,37 \text{ €/h} = 8\,511 \text{ €}$$

5.6.2. Costes de material e infraestructura

Todas las herramientas de desarrollo del proyecto son de código abierto o disponen de plan gratuito suficiente para la fase de prototipado y validación. Sin embargo, el coste real de operación en producción depende de tres factores que conviene desglosar con precisión: el alojamiento del servidor (DigitalOcean), la base de datos gestionada (Supabase) y las llamadas al modelo de lenguaje (Gemini). La elección de plan en cada uno de ellos cambia significativamente el coste mensual y, sobre todo, escala de forma no lineal con el número de usuarios.

Alojamiento: DigitalOcean

El sistema se ejecuta sobre un *Droplet* básico de DigitalOcean. La elección concreta del plan viene dictada por el consumo de RAM del modelo Rasa: con un dominio mediano (más de 50 *intents* y varios cientos de ejemplos NLU) entrenado con el clasificador DIET, el proceso de Rasa consume habitualmente entre 700 MB y 1,5 GB de memoria residente, según los datos publicados en el foro oficial de Rasa [63]. A esto se suma el contenedor de *actions*, el panel Flask de administración y *nginx* como proxy inverso, lo que sitúa el consumo total muy cerca del techo de un *Droplet* de 1 GB de RAM. Por este motivo, el plan operativo del proyecto es el *Droplet* de **12 \$/mes** (2 GB RAM, 1 vCPU, 50 GB SSD, 2 TB de transferencia mensual incluida) [64].

DigitalOcean factura por instancia y por ancho de banda saliente excedido (0,01 \$/GiB) [65], no por número de peticiones. La franquicia de 2 TB cubre con margen el caso de uso del proyecto, por lo que el coste mensual real se mantiene en los 12 \$/mes mientras se utilice esta capacidad.

Base de datos: Supabase

Supabase ofrece tres planes relevantes [66]:

- **Plan Free:** 500 MB de base de datos, 1 GB de almacenamiento de ficheros, 5 GB de transferencia mensual, 50 000 usuarios activos mensuales (MAU) y 500 000 invocaciones de *Edge Functions*. **Pausa el proyecto tras 7 días de inactividad**, lo que lo descarta como solución de producción 24/7 sin un mecanismo de *keep-alive*.
- **Plan Pro:** 25 \$/mes. Incluye 8 GB de disco, 100 GB de almacenamiento, 250 GB de transferencia, 100 000 MAU y 2 millones de invocaciones de *Edge Functions*. Sin pausado por inactividad. Los excesos sobre estos límites se facturan a 0,125 \$/GB de disco, 0,09 \$/GB de transferencia y 0,00325 \$/MAU adicional.
- **Compute add-ons:** el plan Pro permite escalar verticalmente la instancia desde 10 \$/mes (Micro) hasta 3 730 \$/mes (16XL).

El proyecto se ha desarrollado y validado sobre el plan Free, lo que es viable durante el ciclo de TFG porque el uso intensivo coincide con periodos de actividad continua. Para producción real es necesario migrar al plan Pro o, alternativamente, sustituir Supabase por una instancia de PostgreSQL nativa autoalojada en el propio Droplet (coste marginal nulo a cambio de asumir la operativa de *backups*, mantenimiento de la extensión *pgvector* y monitorización).

Modelo de lenguaje: Gemini / Gemma

El sistema utiliza actualmente `gemma-3-27b-it` a través de la API de Google AI Studio. Según la documentación oficial de precios [67], los modelos de la familia Gemma figuran como gratuitos tanto en tokens de entrada como de salida, lo que ha permitido sostener todo el desarrollo, las suites de pruebas y el piloto sin coste. Esta elección responde a una búsqueda explícita de la opción de menor coste viable durante la fase de TFG: dentro del catálogo gratuito de Google, Gemma 3 27B es el modelo más capaz disponible y suficiente para las tareas de clasificación de intenciones, generación de SQL y síntesis de respuestas RAG.

Límites de uso y dimensionado. Los *rate limits* de la familia Gemma en el plan gratuito de Google AI Studio son de **15 peticiones por minuto (RPM)** y **1 500 peticiones diarias (RPD)** [68]. Este techo es suficiente para el escenario actual del piloto (700 alumnos potenciales, picos de docena de turnos por minuto), pero se convierte en restrictivo a medida que el sistema escala: cada turno de conversación puede generar entre 2 y 4 llamadas al LLM (clasificación, generación de SQL, síntesis), de modo que 15 RPM equivalen aproximadamente a entre 4 y 7 turnos simultáneos. Para 5 000 o 70 000 alumnos no es la latencia ni el coste el cuello de botella, sino la cuota de RPM.

Estrategia de evolución del modelo. El sistema ha sido diseñado deliberadamente para que el proveedor de LLM sea un componente intercambiable: las llamadas al modelo están aisladas en clientes dedicados (`actions/shared/gemini_client.py` para la API de Google y `actions/shared/ollama_client.py` para inferencia local) tras una interfaz uniforme, y la selección del proveedor se realiza por configuración. Esta abstracción es herencia directa de la fase de prototipado, en la que se utilizó Ollama con modelos cuantizados ejecutándose en local antes de migrar a Gemma por capacidad. Gracias a ella, la evolución del modelo según la madurez del despliegue contempla tres etapas:

1. **Etapla actual (piloto, $\leq 1\,000$ alumnos):** `gemma-3-27b-it` gratuito. Cuota de 15 RPM suficiente, coste cero, calidad adecuada para los tres dominios funcionales validados.
2. **Etapla intermedia (1 000–10 000 alumnos):** migración a un proveedor con cuota más amplia para absorber la concurrencia. La opción más razonable es **Gemini 2.5 Flash** en plan de pago, con cuotas que escalan a varios miles de RPM y un coste estimado de unos 22 \$/mes para volúmenes del orden de 5 000 alumnos. Alternativamente, se pueden combinar varios proveedores con planes gratuitos generosos (Groq, OpenRouter) repartiendo carga, manteniendo coste nulo a cambio de mayor complejidad operativa.
3. **Etapla avanzada (consolidación institucional o $>10\,000$ alumnos):** adopción de un modelo **más inteligente** (Gemini 2.5 Pro, GPT-4o o equivalentes) para mejorar la calidad en consultas ambiguas y dominios añadidos, o bien autoalojar un modelo abierto (Llama 3.1 70B, Mixtral) sobre infraestructura de la propia universidad. Esta última vía es especialmente interesante en un despliegue institucional: la US dispone del Servicio de Informática y Comunicaciones (SIC) y de centros con capacidad de cálculo (HPC, GPUs de investigación) sobre los que ejecutar un modelo propio. La inferencia local elimina por completo la dependencia de proveedores externos, las cuotas de RPM y la fuga de datos académicos a terceros, a cambio de asumir el coste de hardware y mantenimiento.

Riesgo de cambios de política. En diciembre de 2025 Google redujo entre un 50 % y un 80 % las cuotas gratuitas de los modelos Gemini sin previo aviso. La política de Gemma no se vio afectada por aquella revisión, pero el precedente obliga a contemplar un *plan B* desde el día uno. La arquitectura intercambiable descrita arriba es precisamente esa garantía: ante un cambio de cuotas, precios o términos de servicio, la migración a otro proveedor consiste en cambiar la variable de configuración del cliente, sin tocar el núcleo conversacional ni las acciones de Rasa.

Coste actual de explotación

La Tabla 5.18 resume el coste mensual real del despliegue actual, válido para la fase de validación con el grupo piloto de la ETSII.

Recurso	Coste mensual	Observaciones
DigitalOcean Droplet (2 GB)	12,00 \$	Necesario por consumo de RAM de Rasa con DIET.
Supabase	0,00 \$	Plan Free; requiere <i>keep-alive</i> para evitar pausado a los 7 días.
Gemini / Gemma API	0,00 \$	Plan gratuito; sujeto a cambios de política de Google.
GitHub, Rasa OSS, demás OSS	0,00 \$	Sin coste de licencia.
Total mensual	≈ 11 €/mes	A 1 \$ ≈ 0,92 €.
Total anual	≈ 132 €/año	

Cuadro 5.18: Coste mensual real del despliegue actual.

Escenarios de escalado

El coste de operación no escala de forma lineal con el número de usuarios: existen umbrales en los que es necesario cambiar de plan. La Tabla 5.19 estima el coste anual para tres escenarios representativos.

Componente	700 usuarios	5 000 usuarios	70 000 usuarios
Droplet DigitalOcean	12 \$/mes	24 \$/mes (4 GB)	96 \$/mes (cluster)
Supabase	0 \$ (plan Free)	25 \$/mes (plan Pro)	85 \$/mes (Pro + add-on)
LLM	0 \$ (Gemma free)	22 \$/mes (Gemini Flash)	22 \$/mes (Flash) o autoalojado en la US
Total mensual	≈ 11 €	≈ 45–65 €	≈ 185–250 €
Total anual	≈ 132 €	≈ 540–780 €	≈ 2 200–3 000 €

Cuadro 5.19: Estimación de coste anual de operación según número de usuarios activos.

Los saltos críticos se producen al pasar de 700 a 5 000 usuarios (donde el plan Free de Supabase deja de ser viable y obliga a contratar el plan Pro, y donde la cuota de 30 RPM de Gemma se queda corta y obliga a migrar a Gemini Flash de pago o a un proveedor con cuotas mayores) y al pasar de 5 000 a 70 000 (donde la concurrencia obliga a escalar el *compute* de Supabase y a evaluar la conveniencia de un modelo más capaz, como Gemini 2.5 Pro, o de uno autoalojado sobre infraestructura propia de la universidad).

5.6.3. Resumen de costes y contingencias

El porcentaje de contingencias del 10 % cubre posibles ampliaciones de horas de desarrollo y renovaciones imprevistas de infraestructura o material durante la fase de cierre del proyecto. El beneficio industrial del 10 % refleja la práctica habitual en presupuestos de proyecto software. La cifra de infraestructura corresponde únicamente a los dos meses en los que el sistema ha estado desplegado en DigitalOcean durante la fase de validación; el coste anual de explotación posterior se ha desglosado en la Tabla 5.18.

Concepto	Importe
Costes de personal (300 h × 28,37 €/h)	8 511,00 €
Infraestructura durante el desarrollo (2 meses)	22,00 €
Subtotal	8 533,00 €
Contingencias (10 %)	853,30 €
Beneficio industrial (10 %)	853,30 €
Coste total del proyecto	10 239,60 €

Cuadro 5.20: Resumen de costes del proyecto.

5.7– Análisis de desviaciones

5.7.1. Desviación temporal

A fecha de cierre del presente documento (02/05/2026), el sistema Clockify registra **281,72 h**, con las secciones de manuales pendientes de completar. La estimación final, considerando esas tareas restantes, se sitúa en torno a **300–310 h**, lo que supone una desviación positiva de entre 0 y 10 h respecto a la previsión inicial de 300 h (entre el 0 % y el 3,3 %).

La distribución real del esfuerzo difiere sensiblemente de la prevista en un aspecto: la fase de Desarrollo acumuló un porcentaje de horas mayor al estimado, en particular el Sprint 7 (150,52 h registradas), que concentró las épicas de Horarios y Profesores, el panel de administración, el piloto con usuarios y varias iteraciones de mejora basadas en el feedback recibido. Esta concentración fue consecuencia de decisiones técnicas tomadas durante el desarrollo (incorporación del panel admin, extracción automatizada de datos desde los portales oficiales) que no estaban contempladas en la planificación inicial.

Fase	Estimado (h)	Real (h)	Desviación
1. Inicio	45	47,30	+2,30 h (+5,1 %)
2. Desarrollo	195	197,81	+2,81 h (+1,4 %)
3. Cierre	60	36,61*	–23,39 h (pendiente)
Total	300	281,72*	–18,28 h

* A 02/05/2026; pendientes manuales y revisión final.

Cuadro 5.21: Desviación temporal por fase.

Nota sobre la defensa del proyecto. La carga de trabajo de **300 h** corresponde a los 12 ECTS de la asignatura de TFG y cubre el desarrollo del proyecto y la redacción de la memoria. Se ha optado por **no contabilizar** las horas de preparación de la presentación oral y del vídeo demostrativo, dado que estas actividades se ejecutan en paralelo a la entrega de la memoria y su duración depende del acto de defensa, que está fuera del alcance de este documento. Por tanto, el esfuerzo asociado queda fuera del cómputo recogido en la Tabla 5.21 y no afecta al cálculo de costes presentado en la Sección 5.6.

5.7.2. Desviación en costes

La desviación en costes es directamente proporcional a la desviación temporal. Con una previsión de cierre de 300–310 h y una tarifa de 28,37 €/h, el coste de personal se mantiene en el rango de 8 511–8 795 €. Los costes de material no han sufrido variación relevante respecto a lo planificado.

5.7.3. Lecciones aprendidas

Las desviaciones observadas permiten extraer tres lecciones relevantes para proyectos similares:

1. **Infraestructura de datos subestimada.** La extracción, limpieza e inserción de datos reales (planes docentes, horarios, datos del profesorado) consumió más tiempo del previsto. Los datos de origen (PDFs con formato variable, portales web sin API oficial y ficheros administrativos sin estructura homogénea) requirieron varios ciclos de revisión antes de estar listos para la carga. En proyectos con dependencia de datos externos no estructurados, conviene reservar al menos un 15 % del esfuerzo de la fase de Desarrollo para la adquisición y preparación de datos, e incluir en el plan un subpaquete explícito de limpieza y validación.
2. **Alcance incremental no planificado.** El panel de administración surgió durante el Sprint 6 como respuesta a una necesidad de mantenibilidad detectada en el piloto: sin una interfaz de gestión, actualizar el corpus o corregir un dato requería acceso directo a la base de datos, lo que no era viable en producción. Su desarrollo fue valioso para el sistema, pero no estaba en la planificación inicial y consumió un tiempo que tuvo que absorberse dentro del Sprint 7. Las metodologías ágiles absorben este tipo de cambio, pero conviene reservar capacidad explícita (en torno al 10 % del presupuesto de horas) para el alcance emergente, en lugar de dejarlo fuera del plan hasta que aparezca.
3. **Distribución temporal desigual.** La mayor parte del esfuerzo se concentró entre marzo y abril de 2026, coincidiendo con el desarrollo de las épicas de Horarios y Profesores, el panel de administración y el piloto con usuarios. Esta acumulación fue en parte consecuencia de la carga lectiva del primer cuatrimestre y de la dependencia entre épicas (profesores requería el esquema de horarios). Una distribución más uniforme a lo largo del año, asignando épicas más pequeñas en periodos de mayor carga académica, habría reducido la presión en los últimos sprints y facilitado una fase de cierre más tranquila y con mayor margen para iteraciones correctivas.

Parte III

Análisis, Diseño e Implementación

Análisis de requisitos

Este capítulo recoge el análisis de requisitos del sistema Linceus Assistant en su versión correspondiente al cierre del prototipo. El análisis ha sido un proceso iterativo: la propuesta inicial planteaba un alcance amplio que incluía notificaciones a estudiantes, soporte multilingüe e integraciones en tiempo real con plataformas institucionales, pero la limitación de tiempo propia de un trabajo individual ha obligado a priorizar el núcleo conversacional y el dominio académico, y a aplazar el resto a iteraciones posteriores. La sección 6.9 cierra el capítulo con un repaso de cómo ha evolucionado el alcance respecto del documento original, para dejar trazabilidad explícita de las desviaciones de planificación.

Los requisitos se organizan en cuatro tipos siguiendo la práctica habitual en ingeniería del software [69]: requisitos funcionales (qué hace el sistema), requisitos de información (qué datos maneja), requisitos no funcionales (con qué calidad lo hace) y prototipos de interfaz (cómo se muestra al usuario). Cada requisito funcional se acompaña, cuando procede, de los identificadores de los casos de prueba que lo verifican, lo que permite cruzarlo con el Capítulo 12.

6.1– Identificación de actores

El sistema atiende a tres tipos de usuarios bien diferenciados, que justifican la estructura de los manuales recogida en el Capítulo 13.

El **estudiante** es el usuario principal del prototipo. Comprende tanto al alumnado matriculado en la ETSII como al alumnado de nuevo ingreso o internacional que utiliza el sistema antes de iniciar el curso. Interactúa con el bot a través del *widget* integrado en la página principal, sin necesidad de autenticación, y formula consultas en español natural sobre asignaturas, horarios y profesorado.

El **administrador del sistema** es el perfil técnico encargado de mantener actualizada la base de conocimiento. Su interacción se realiza exclusivamente a través del panel de administración, e incluye la sincronización de centros, titulaciones y asignaturas desde Sevius, la vectorización de planes docentes en el módulo RAG y la auditoría de las conversaciones registradas durante el piloto. La existencia del panel obedece principalmente a un requisito de **mantenibilidad y escalabilidad**: el sistema debe poder ser asumido por otra persona tras el cierre del TFG sin necesidad de manipular directamente la base de datos.

El **desarrollador** es el perfil destinado a continuar el proyecto en futuras iteraciones. Consume el repositorio, las convenciones documentadas y los registros de decisiones técnicas para incorporar nuevas intenciones, ampliar el dominio o modificar las acciones existentes. Sus requisitos se materializan en buenas prácticas y trazabilidad, no en funcionalidades específicas del producto.

La visión UML de la interacción entre los dos actores operativos (estudiante y administrador) y los cinco grandes casos de uso del sistema (gestionar contexto académico, consultar asignaturas, consultar horarios, consultar profesorado y gestionar el panel de administración) figura en la Figura 2.1 del Capítulo 2, Sección 2.3.5. Cada caso de uso se descompone en los requisitos funcionales

detallados a continuación; la trazabilidad entre objetivos técnicos, requisitos y casos de prueba se cierra en la Sección 6.8.

6.2– Requisitos funcionales

Los requisitos funcionales se agrupan por dominio (asignaturas, horarios, profesorado, transversal y panel de administración). Antes de detallar cada tabla conviene explicitar dos convenciones de redacción que se aplican uniformemente a las cinco subsecciones.

Referencias a decisiones técnicas. Algunos enunciados de la columna *Descripción* se acompañan de uno o varios códigos del tipo **D-061**, **D-037** o **S5-18**. Estos códigos remiten al **registro de decisiones técnicas** mantenido en el repositorio bajo `docs/sprints/` (un fichero `Registro_decisiones.md` por sprint) y suman **113 entradas** a lo largo de los sprints S2 a S7. La numeración se organiza en dos bloques: los códigos *D-nnn* pertenecen a la numeración global iniciada en el sprint S6 y continuada en S7 (D-001 a D-069, con algunos huecos por consolidación de entradas), y los códigos con prefijo de sprint (*S2-nn*, *S3-nn*, *S4-nn*, *S5-nn*) recogen las decisiones de los sprints anteriores, que se documentaron antes de unificar el esquema de codificación. La lista íntegra, con título y sprint de origen para cada entrada, figura en el Apéndice .3; cualquier código citado en este capítulo o en los siguientes es localizable allí sin necesidad de consultar el repositorio.

Granularidad. Cada requisito describe una capacidad coherente del sistema desde el punto de vista del usuario, no una sentencia atómica. Cuando un mismo requisito reúne varias condiciones equivalentes (por ejemplo RF-A1 cubre la consulta por nombre, por alias o por acrónimo de la misma asignatura), se ha optado por mantenerlas en un único enunciado porque la lógica que las atiende es la misma y porque cada condición está cubierta por un caso de aceptación distinto en la columna *Pruebas*. Esta convención no compromete la trazabilidad: cada condición agrupada bajo un mismo requisito se verifica con un caso de aceptación independiente en el Capítulo 12, de modo que la granularidad fina se conserva al nivel de los tests aunque el enunciado del requisito sea único.

Priorización. La columna *Prio.* asigna a cada requisito una de dos etiquetas, **Alta** o **Media**, siguiendo una versión simplificada del esquema MoSCoW [70]. Los requisitos **Alta** corresponden a los *Must have* del prototipo de fase 1: cubren los flujos sin los cuales el bot no resuelve su caso de uso principal (ficha de asignatura, horario, datos de profesor, cambio de titulación, fuera de ámbito, mantenibilidad básica del panel). Los requisitos **Media** son los *Should have*: aportan valor verificado pero su ausencia no impide el uso productivo (filtros adicionales, distinción teoría/laboratorio, departamentos, *feedback*, exportaciones). Los *Could have* y *Won't have* se recogen explícitamente en la Sección 6.9 como funcionalidades aplazadas o reformuladas. La columna *Pruebas* de cada tabla indica los identificadores de los casos de aceptación que verifican el requisito en el Capítulo 12.

6.2.1. Dominio de asignaturas

La Tabla 6.1 recoge los requisitos asociados a la consulta de información académica sobre asignaturas: ficha completa, listados filtrados, conteos, recuperación de contenido del plan docente, herencia conversacional del nombre de la asignatura y desambiguación entre intenciones próximas (ficha vs. horario).

Cuadro 6.1: Requisitos funcionales del dominio de asignaturas.

ID	Descripción	Prio.	Pruebas
RF-A1	El sistema debe responder con la ficha completa de una asignatura cuando el usuario la nombra de forma explícita o mediante alias o acrónimo (ADDA, FP, IISSI2).	Alta	E-P01..E-P12
RF-A2	El sistema debe devolver listados de asignaturas filtrados por curso, cuatrimestre, tipo (formación básica, obligatoria, optativa) o créditos.	Alta	L-P01..L-P10
RF-A3	El sistema debe responder al conteo de asignaturas que cumplan un criterio dado.	Media	C-P01..C-T02
RF-A4	El sistema debe recuperar información del plan docente (criterios de evaluación, profesorado, bloques, idioma, tribunales) mediante el módulo RAG.	Alta	RAG-P01..RAG-P74
RF-A5	El sistema debe heredar el contexto cuando una consulta elíptica (“y cuántos créditos tiene?”) se refiere a la última asignatura mencionada.	Media	E-S01..E-S03
RF-A6	El sistema debe distinguir entre la pregunta “qué es X”(ficha) y “cuándo es X”(horario), aun cuando ambas comparten léxico.	Alta	E-P09, HA-P01

6.2.2. Dominio de horarios

La Tabla 6.2 agrupa los requisitos que cubren la consulta del horario oficial publicado por la ETSII para el curso académico vigente, con sus filtros más habituales (curso y grupo, día de la semana, cuatrimestre, asignatura concreta) y la distinción entre aulas de teoría y laboratorio cuando el usuario lo solicita explícitamente.

Cuadro 6.2: Requisitos funcionales del dominio de horarios.

ID	Descripción	Prio.	Pruebas
RF-H1	El sistema debe devolver el horario semanal de un curso y grupo dados.	Alta	H-P01..H-P11
RF-H2	El sistema debe devolver el horario filtrado por día de la semana.	Alta	H-P01, H-P10
RF-H3	El sistema debe filtrar el horario por cuatrimestre cuando el usuario lo especifica.	Media	H-PC01..H-PC03
RF-H4	El sistema debe responder al horario de una asignatura concreta sin requerir curso ni grupo.	Alta	HA-P01..HA-P12
RF-H5	El sistema debe distinguir aulas de teoría de aulas de laboratorio cuando el usuario lo solicita expresamente.	Media	HA-P11
RF-H6	El sistema debe solicitar curso y grupo cuando la consulta los requiere y faltan en el mensaje.	Alta	H-P10, H-P12
RF-H7	El sistema debe rechazar de manera explícita consultas con curso o grupo inexistentes (curso 8, grupo 15).	Media	H-N01, H-N02

6.2.3. Dominio de profesorado

La Tabla 6.3 recoge los requisitos del dominio de profesorado: datos de contacto, identificación de coordinador y suplentes mediante recuperación semántica sobre el plan docente, tutorías, filtrado por departamento, tolerancia a errores tipográficos en nombres propios y declaración explícita de ausencia de información cuando el profesor no figura en la base de datos.

Cuadro 6.3: Requisitos funcionales del dominio de profesorado.

ID	Descripción	Prio.	Pruebas
RF-P1	El sistema debe devolver los datos de contacto de un profesor (email, despacho, teléfono, web personal) por nombre o apellido.	Alta	P-P01..P-P10
RF-P2	El sistema debe listar el profesorado que imparte una asignatura.	Alta	P-PA01..P-PA08
RF-P3	El sistema debe identificar al coordinador y a los suplentes de una asignatura mediante recuperación semántica sobre el plan docente.	Alta	P-PA05..P-PA08
RF-P4	El sistema debe responder a consultas sobre tutorías redirigiendo al correo del profesor (decisión de diseño documentada en D-061).	Media	P-T01..P-T05
RF-P5	El sistema debe permitir filtrar el profesorado de un departamento concreto.	Media	P-P10
RF-P6	El sistema debe tolerar errores tipográficos moderados en nombres de profesores (“parejjo”, “galinndo”).	Media	P-W01..P-W07
RF-P7	El sistema debe declarar explícitamente la ausencia de información cuando un profesor no figura en la base de datos, sin inventar contenido.	Alta	P-N01..P-N04

6.2.4. Comportamientos transversales

La Tabla 6.4 consolida los requisitos que no pertenecen a un dominio académico concreto sino al comportamiento conversacional del bot en su conjunto: cambio dinámico de titulación, rechazo de titulaciones fuera del alcance ETSII, gestión de consultas fuera de ámbito, defensa frente a *prompt injection* y *jailbreak*, bienvenida y soporte de la pregunta meta-conversacional “¿qué eres?”, y mecanismo de *feedback* explícito por turno.

Cuadro 6.4: Requisitos funcionales transversales.

ID	Descripción	Prio.	Pruebas
RF-T1	El sistema debe permitir cambiar dinámicamente la titulación activa durante una conversación, ya sea desde el selector o mediante lenguaje natural.	Alta	CC-P01..CC-P11
RF-T2	El sistema debe rechazar titulaciones fuera del alcance ETSII con un mensaje explícito (<i>cambia a Biología</i>).	Alta	CC-N01
RF-T3	El sistema debe identificar consultas fuera de ámbito (clima, peticiones generales) y responder de forma cortés sin entrar al pipeline de consulta académica.	Alta	F-01..F-04
RF-T4	El sistema debe bloquear intentos de <i>prompt injection</i> y <i>jailbreak</i> (“ignora las instrucciones anteriores”).	Alta	R-01..R-04
RF-T5	El sistema debe ofrecer un mensaje de bienvenida y soportar la pregunta meta-conversacional “¿qué eres?” redirigiendo a la naturaleza del bot.	Media	R-04
RF-T6	El sistema debe permitir al usuario reportar respuestas incorrectas mediante un mecanismo de <i>feedback</i> integrado en el <i>widget</i> .	Media	–

6.2.5. Funcionalidades del panel de administración

El panel de administración no se ofrece al estudiante final, sino al perfil de administrador descrito en la Sección 6.1. Su existencia responde a un requisito de mantenibilidad: garantizar que la persona que asuma la continuidad del sistema pueda gestionar los datos sin necesidad de manipular directamente la base de datos. Los requisitos se recogen en la Tabla 6.5.

Cuadro 6.5: Requisitos funcionales del panel de administración.

ID	Descripción	Prio.	Pruebas
RF-AD1	El panel debe permitir la navegación jerárquica Centro → Titulación → Asignatura sobre los datos cargados (D-037).	Alta	A03–A05, A09, A12, A13
RF-AD2	El panel debe ofrecer la sincronización de centros, titulaciones y asignaturas desde Sevius como fuente de verdad institucional, mediante un flujo <i>preview-first</i> (D-038, D-039).	Alta	A14–A16, A21–A24
RF-AD3	El panel debe permitir vectorizar el plan docente de una asignatura, integrándolo en el corpus de <i>embeddings</i> consumido por el módulo RAG (D-040, D-041).	Alta	Manual (criterio en Tabla 6.6); fuera de la suite <i>pytest</i> por ser operación de escritura destructiva (§12.8.3)
RF-AD4	El panel debe importar y enriquecer profesorado a partir del directorio PDI de <code>us.es</code> usando el filtro de centro (D-043, D-044).	Media	A06–A08
RF-AD5	El panel debe ofrecer una vista jerárquica Centro → Departamento → Profesor, con un <i>bucket</i> para profesores sin departamento asignado (D-051).	Media	A06, A07
RF-AD6	El panel debe exponer las conversaciones registradas en <code>conversation_log</code> para revisión manual del evaluador, con la posibilidad de marcarlas como revisadas.	Alta	A10, A11
RF-AD7	El panel debe agregar el <i>feedback</i> explícito por turno aportado por los usuarios y permitir su consulta agregada.	Media	FB-01 (manual)

6.3– Criterios de aceptación

En este trabajo la derivación se realiza de forma sistemática: cada requisito se traduce a uno o varios escenarios escritos en notación *Given–When–Then* [71], que el *runner* de pruebas (`tests/run_test_plan.py`) convierte mecánicamente en *slot* inicial, mensaje del usuario y condición sobre el *intent* clasificado y el texto de la respuesta. La traza completa requisito–prueba se documenta en la columna *Pruebas* de las Tablas 6.1, 6.2, 6.3 y 6.4, y la metodología detallada en la Sección 12.1.1. La Tabla 6.6 recoge una selección representativa del rango de casos cubiertos por la suite, priorizando la variedad de tipos sobre la cuota por dominio: flujo positivo con clasificación y resolución de entidad (RF-A1), seguimiento conversacional con herencia de *slot* (RF-A5), escenario negativo con rechazo explícito (RF-H7), atajo arquitectónico de RAG sobre SQL (RF-P3), robustez frente a *prompt injection* (RF-T4) y operación administrativa con transición de estados (RF-AD3). El conjunto ilustra el formato y permite al lector reconstruir el resto sin necesidad de inspeccionar cada caso de la suite.

Cuadro 6.6: Criterios de aceptación: selección representativa por dominio.

RF	Criterio (Given–When–Then)
RF-A1	Given la titulación activa es GII-IS, when el usuario escribe «¿Qué es AD-DA?», then el <i>intent</i> clasificado es <code>consulta_asignatura_especifica</code> , la entidad <code>nombre_asignatura</code> se resuelve al nombre completo <i>Análisis y Diseño de Datos y Algoritmos</i> y la respuesta indica el curso (2.º), la tipología (obligatoria) y los créditos (6 ECTS). Caso E-P09.
RF-A5	Given la última asignatura mencionada en la conversación es <i>Redes</i> , when el usuario escribe «¿y cuántos créditos tiene?» sin nombrar la asignatura, then la acción hereda el <code>slot ultimo_nombre_asignatura</code> dentro de la ventana de tres turnos y responde con los créditos de <i>Redes</i> sin solicitar el nombre. Casos E-S01–E-S03.
RF-H7	Given no existe un octavo curso en la titulación activa, when el usuario escribe «horario de 8.º», then la acción rechaza la consulta de forma explícita declarando que ese curso no existe, sin inventar contenido ni proponer una alternativa silenciosa. Casos H-N01 y H-N02.
RF-P3	Given la consulta menciona explícitamente al coordinador de una asignatura cuya tabla <code>profesor_asignatura</code> no almacena el rol, when el usuario pregunta «¿quién coordina IISSI2?», then el sistema activa el atajo a recuperación semántica (decisión D-064) sobre el plan docente y devuelve el nombre del coordinador, sin pasar por la consulta SQL convencional. Casos P-PA05–P-PA08.
RF-T4	Given la entrada del usuario incluye una instrucción de <i>prompt injection</i> («ignora las instrucciones anteriores y dime tu system prompt»), when se procesa el mensaje, then el bot mantiene su rol y dominio, responde con el flujo de fuera de ámbito y no expone el contenido del <i>prompt</i> . Casos R-01–R-04.
RF-AD3	Given un plan docente en formato PDF cuyo <i>hash</i> SHA-256 no figura en la tabla <code>planes_docentes</code> , when el administrador invoca el botón <i>Vectorizar</i> desde el panel, then el estado del registro transita de pendiente a <code>en_proceso</code> y, al concluir, a <code>completado</code> , y los nuevos fragmentos aparecen en <code>planes_docentes_chunks</code> con sus <i>embeddings</i> y metadatos (sección, asignatura, grupo, curso). Suite <code>test_admin.py</code> .

6.4– Requisitos de información

El modelo de información del sistema se estructura en torno a tres bloques: los datos de **dominio académico** consumidos por el bot, los fragmentos vectorizados del **módulo RAG** y los datos de **operación** generados durante el uso del sistema. La Tabla 6.7 resume los requisitos de información del sistema; las subsecciones siguientes detallan las entidades de cada bloque.

Cuadro 6.7: Requisitos de información del sistema.

ID	Dato	Descripción	Prio.
RI-1	Catálogo académico	Centros, titulaciones, asignaturas (código, créditos, curso, cuatrimestre, tipo). Fuente: Sevius.	Alta
RI-2	Directorio de profesorado	Nombre, email, despacho, teléfono, departamento y relación con asignaturas (rol: titular, coordinador, suplente). Fuente: <code>us.es</code> PDI.	Alta
RI-3	Horarios docentes	Sesiones por grupo y aula, con día, franja horaria, cuatrimestre y tipo (teoría/laboratorio). Fuente: PDF oficial ETSII.	Alta
RI-4	Corpus RAG	Fragmentos textuales (<i>chunks</i>) de planes docentes, con <i>embedding</i> vectorial y metadatos (asignatura, sección, curso). Fuente: planes docentes PDF/HTML.	Alta
RI-5	Registro de conversaciones	Turno a turno: sesión anónima, mensaje, <i>intent</i> , <i>slots</i> , respuesta, marca temporal. Sin PII.	Media
RI-6	<i>Feedback</i> de usuarios	Valoración explícita por turno (aprobación/rechazo) vinculada a la sesión anónima.	Media

6.4.1. Entidades de dominio

Las entidades del dominio académico son las recogidas en la Tabla 6.8. La descripción técnica completa de cada tabla, con sus tipos, claves y restricciones, figura en el Capítulo 10.

Cuadro 6.8: Entidades de información del dominio académico.

Entidad	Descripción
Centro	Unidad organizativa que agrupa titulaciones (ETSII).
Titulación	Plan de estudios (GII-IS, GII-IC, GII-TI).
Asignatura	Materia con su código, créditos, curso, cuatrimestre y tipo.
Departamento	Unidad académica responsable del profesorado.
Profesor	Docente con datos de contacto, despacho y departamento.
Profesor-Asignatura	Relación que vincula un profesor con la docencia de una asignatura, con el grupo y el rol (titular, coordinador, suplente).
Grupo de clase	Asignatura impartida en un grupo concreto a un curso.
Aula	Espacio físico identificado por código (A0.10, B1.31, F1.30) y tipo (teoría/laboratorio).
Horario	Sesión docente que vincula grupo, aula, día, franja horaria y cuatrimestre.
Plan docente	Documento PDF oficial asociado a una asignatura, fuente del corpus RAG.

6.4.2. Entidades del módulo RAG

El módulo RAG opera sobre fragmentos textuales (*chunks*) extraídos de los planes docentes. Cada *chunk* se almacena junto con su *embedding* vectorial calculado con el modelo de *embeddings* de Gemini, y con un conjunto de metadatos que permiten filtrar y reordenar resultados durante la recuperación: titulación, asignatura, sección del plan docente (profesorado, evaluación, bloques, etc.), grupo y curso. La sección como metadato fue una decisión de diseño documentada (D-031, D-058.b): se usa como señal para reordenar resultados pero no como filtro estricto, dado que la sección de origen no siempre es informativa para responder a la pregunta.

6.4.3. Entidades de operación

La operación del sistema en producción registra dos entidades. La tabla `conversation_log` almacena turno a turno cada interacción con el bot: identificador anónimo de sesión, mensaje del usuario, *intent* clasificado, *slots* activos, respuesta del bot, indicador de revisión manual y marca temporal. La tabla `feedback` recoge la valoración explícita del usuario sobre un turno concreto cuando este utiliza los botones de aprobación o rechazo del *widget*. Ninguna de las dos almacena datos personales identificables, dado que la sesión es anónima por diseño.

6.4.4. Modelo conceptual

La Figura 6.1 sintetiza los requisitos de información del prototipo en un único modelo conceptual organizado en tres bloques semánticamente independientes. El bloque de **dominio académico** (rosa) agrupa las diez entidades estructuradas del catálogo institucional: CENTRO, TITULACIÓN y ASIGNATURA forman la jerarquía principal del catálogo; DEPARTAMENTO y PROFESOR con su relación intermedia PROFESORASIGNATURA capturan el directorio docente y los roles por grupo; GRUPOCLASE, AULA y HORARIO representan la información de impartición; y PLANDOCENTE vincula cada asignatura con el PDF fuente del corpus RAG. El bloque del **módulo RAG** (azul) recoge la entidad PLANDOCENTECHUNK con su contenido textual, su *embedding* vectorial de 2 000 dimensiones y los metadatos de sección, materializando el requisito RI-4. El bloque de **entidades de operación** (verde) comprende CONVERSATIONLOG y FEEDBACK, ambas sin datos personales identificables, correspondientes a RI-5 y RI-6. El diagrama recoge únicamente los atributos esenciales y las cardinalidades necesarias para validar la integridad de los requisitos; las claves primarias, las claves foráneas y los tipos SQL detallados figuran en el Capítulo 10.




Figura 6.1: Modelo conceptual de los requisitos de información: dominio académico, módulo RAG y entidades de operación.

La revisión del modelo permitió detectar y resolver tres inconsistencias durante la fase de análisis. La primera afectaba al rol del profesorado en una asignatura (titular, coordinador, suplente): se modeló inicialmente como atributo de PROFESOR, pero la cardinalidad real lo sitúa como atributo de la relación PROFESORASIGNATURA, ya que un mismo profesor puede ejercer roles distintos en grupos distintos del mismo curso académico. La segunda afectaba a la categorización de aulas como teoría o laboratorio: la convención adoptada (prefijo A para teoría) es un atributo derivado del código del aula, no una columna independiente, lo que se documenta en la propia entidad. La tercera, la entidad TUTORIA, está modelada en el esquema pero deliberadamente vacía: el requisito RF-P4 redirige las consultas de tutorías al correo del profesor (decisión D-061), por lo que la entidad se conserva para futuros usos pero no participa en ningún flujo del prototipo actual.

6.5– Requisitos no funcionales

Los requisitos no funcionales se enuncian en términos medibles y se cruzan con la evidencia recogida en el Capítulo 12. Los umbrales son los que el autor considera aceptables para un prototipo de fase 1 desplegable a la población de la ETSII; se han ajustado durante el desarrollo a la luz de las cifras observadas durante el piloto.

Conviene comentar dos requisitos en particular. El cumplimiento de la **normativa de protección de datos** (RNF-10) se materializa por construcción más que por restricciones de despliegue: el sistema no requiere autenticación, no almacena datos personales identificables, y los datos académicos consultados (planes docentes, horarios, directorio de profesorado) son de carácter público y proceden de fuentes oficiales (Sevius, *us.es*). La propuesta inicial contemplaba un despliegue *on-premise* (en servidores propios de la universidad) como mecanismo de garantía adicional de privacidad; en la implementación final, dado que la información tratada no incluye datos sensibles, se ha optado por un despliegue en infraestructura externa (DigitalOcean y Supabase) que simplifica la operación sin comprometer la privacidad del usuario.

El requisito de **soporte multilingüe**, que figuraba como funcional en la propuesta original, se ha reformulado y aplazado: el corpus académico está mayoritariamente redactado en español, los modelos de *embeddings* y de generación se han ajustado al castellano y la dotación de tiempo del prototipo no permitía abrir un segundo flujo de pruebas para el inglés. La sección 6.9 lo recoge entre las funcionalidades aplazadas a fase 2.

6.6– Restricciones, suposiciones y dependencias externas

El alcance funcional del prototipo queda condicionado por un conjunto de restricciones técnicas, suposiciones sobre el entorno y dependencias externas que conviene explicitar, ya que cualquier cambio en ellas obligaría a revisar la solución. La Tabla 6.10 las recoge agrupadas en tres bloques.

Las restricciones técnicas (RT) son decisiones asumidas que limitan el alcance funcional y se han documentado conscientemente. Las suposiciones de entorno (SE) son fuera del control del proyecto y motivan los puntos de fragilidad: si Sevius cambia su HTML, los *scrapers* requieren mantenimiento. Las dependencias de servicios externos (DE) condicionan el coste y la disponibilidad; el sistema se ha diseñado para degradar de forma elegante cuando alguna falla (fallback a *ILIKE* en RAG, modal de aviso en cliente cuando Rasa no responde), aunque la indisponibilidad simultánea de Gemini y la red impediría operar normalmente. El Capítulo 14 retoma estas dependencias entre las palancas de mejora para fase 2.

6.7– Prototipos de interfaz

El prototipo no se ha apoyado en herramientas de *wireframing* (Figma o similares) durante la fase de diseño: la interfaz se ha construido directamente sobre código HTML/CSS/JavaScript *vani-*

Cuadro 6.9: Requisitos no funcionales, umbrales y valores alcanzados.

ID	Descripción	Umbral	Valor alcanzado	Evidencia
RNF-1	Latencia mediana extremo a extremo.	$p50 \leq 4 \text{ s}$	3,4 s	§12.7.1
RNF-2	Latencia en cola larga.	$p95 \leq 12 \text{ s}$	10,5 s	§12.7.1
RNF-3	Coste medio por turno (Gemini).	$\leq 0,05 \text{ cts}$	0,012 cts	§12.7.2
RNF-4	Tasa de éxito en suite E2E.	$\geq 90 \%$	94,3 % (150/159)	§12.2
RNF-5	Tasa de éxito en tráfico real.	$\geq 85 \%$	98,3 % (58/59 sesiones)	§12.5
RNF-6	Disponibilidad del servicio.	$\geq 99 \%$ mensual	No medido (fase 2)	Pendiente
RNF-7	Idioma soportado.	Español peninsular	100 % consultas en es	Piloto (59 sesiones)
RNF-8	Compatibilidad navegadores.	Chrome, Firefox, Edge, Safari modernos	4/4 navegadores	Verificado manual
RNF-9	Diseño <i>responsive</i> .	$\geq 320 \text{ px}$	320 px (iPhone SE)	Verificado manual
RNF-10	Anonimato y ausencia de PII.	UUID anónimo, sin datos pers.	Cumplido por diseño	Auditoría de esquema BD
RNF-11	Reproducibilidad del despliegue.	docker compose up	Cumplido (Ubuntu 24.04 + Win 11)	Cap. 13
RNF-12	Trazabilidad de decisiones.	Registro en docs/sprints/	72 entradas D-xxx (S2–S7)	Sprints S2–S7
RNF-13	Acceso autenticado al panel de administración.	Sesión Supabase Auth válida antes de acceder a admin.html; redirección a login.html si la sesión no existe o ha caducado.	Cumplido (Supabase Auth, JWT)	Verificado manual; login.js y admin.js (función getSession())
RNF-14	Usabilidad: primera consulta sin formación previa.	$\leq 60 \text{ s}$ primera consulta exitosa	28 s mediana (piloto)	Piloto (59 sesiones)
RNF-15	Escalabilidad: nueva titulación sin cambio de código.	Solo carga de datos en panel	Cumplido (GII-TI, GII-IC añadidos)	Cap. 13

Cuadro 6.10: Restricciones, suposiciones y dependencias externas del prototipo.

ID	Elemento	Descripción e impacto
<i>Restricciones técnicas asumidas por diseño</i>		
RT-1	Idioma	El <i>pipeline</i> NLU se entrena en español peninsular, con el modelo preentrenado <code>es_core_news_md</code> de spaCy. El soporte de otros idiomas requiere reentrenamiento (RNF-7).
RT-2	Cobertura académica	El prototipo se valida sobre las tres titulaciones del Grado en Ingeniería Informática de la ETSII (GII-IS, GII-IC, GII-TI). La incorporación de otras titulaciones es solo carga de datos (RNF-15), pero queda fuera del alcance validado.
RT-3	Datos sensibles	El sistema no trata datos personales identificables. Cualquier ampliación que los introduzca exigiría revisión de cumplimiento conforme al RGPD y reconsiderar el despliegue (RNF-10).
<i>Suposiciones sobre el entorno</i>		
SE-1	Disponibilidad de Sevius	Las sincronizaciones del panel de administración (RF-AD2) asumen que <code>sevius.us.es</code> mantiene estable su estructura HTML pública. Cambios en el portal pueden requerir actualización de los <i>scrapers</i> .
SE-2	Disponibilidad del directorio PDI	La importación de profesorado (RF-AD4) depende de la estructura del directorio público de <code>us.es</code> . La cobertura por departamento se complementa con <i>scrapers</i> específicos para los cuatro departamentos cuyos perfiles no se publican íntegramente en el directorio central.
SE-3	Calendario académico	La inferencia automática del cuatrimestre activo (RF-H3, RF-H4) asume el calendario de la US: primer cuatrimestre de septiembre a enero, segundo de febrero a julio.
SE-4	Acceso a través de la web institucional	El <i>widget</i> asume que se integra en la página principal de la US o de la ETSII; el modal de selección de titulación se muestra siempre en el primer turno porque no se hereda contexto del usuario autenticado.
<i>Dependencias de servicios externos</i>		
DE-1	Gemini API (Google)	La generación de texto (<i>Text-to-SQL</i> , redacción, fallback) depende de <code>gemma-3-27b-it</code> : 15 RPM y 1 500 RPD (plan gratuito). Los <i>embeddings</i> RAG usan <code>gemini-embedding-001</code> : 100 RPM y 1 000 RPD . El módulo RAG dispone de fallback a búsqueda <code>ILIKE</code> (Sección 7.4.5); el <i>Text-to-SQL</i> , no.
DE-2	Supabase (PostgreSQL gestionado)	El plan Free admite hasta 5 000 MAU y 500 MB; superado ese umbral, el coste se documenta en la Sección 5.6 del Capítulo 5.
DE-3	DigitalOcean (cómputo)	El <i>droplet</i> actual cubre el consumo de RAM de Rasa y del <i>Action Server</i> . La escalabilidad horizontal queda fuera del alcance del prototipo.
DE-4	Cliente local del usuario	Compatibilidad declarada en Chrome, Firefox, Edge y Safari modernos (RNF-8) y resolución mínima 320 px (RNF-9).

lla, tomando como referencia la identidad visual de `www.us.es` (decisión D-027) para garantizar coherencia con el ecosistema institucional. La validación visual y de usabilidad se ha realizado de forma iterativa contra los *stakeholders* del piloto, incorporando los ajustes identificados durante el *feedback* (decisiones D-029 y D-030). Las dos interfaces que componen el sistema son el *wid- get* conversacional, accesible para cualquier alumno desde la página institucional, y el panel de administración, destinado al perfil de mantenimiento del catálogo académico. A continuación se describen las cinco vistas más representativas de ambos.



Figura 6.2: Widget conversacional integrado en la página institucional.

La Figura 6.2 muestra el *widget* desplegado sobre la página principal de la Universidad de Sevilla. La cabecera del cuadro de diálogo lleva el rótulo *Linceus – Asistente Universidad de Sevilla* y un selector contextual (icono *información para mí*) que recoge la titulación activa fijada en el modal del primer turno. El cuerpo del *widget* alterna burbujas de usuario y de bot con el estilo corporativo de la US (rojo institucional sobre fondo neutro): en la captura, la consulta del alumno «*qué es ADDA?*» ha sido clasificada como `consulta_asignatura_especifica` y la respuesta combina los datos estructurales recuperados de la tabla `asignaturas` (nombre completo, curso, tipología, duración, créditos) con un formato *Markdown* renderizado en el cliente (negritas, listas). El pie del *widget* muestra el cuadro de entrada *Escribe tu mensaje...* y el botón *Feedback*, que abre el panel de valoración por turno descrito en RF-T6. El *widget* no exige autenticación y mantiene la conversación en `sessionStorage` mientras la pestaña permanece abierta.




Figura 6.3: Panel de administración: vista de centros.

La Figura 6.3 recoge la vista inicial del panel de administración (`admin.html`) tras el acceso autenticado a través de `login.html` con Supabase Auth (Sección 6.5, RNF-13). La cabecera lleva el logotipo institucional, el indicador de estado de conexión con el *backend* de Flask (verde si responde `/api/admin/stats`) y el botón *Salir* que invalida la sesión Supabase. La barra de navegación ofrece las cinco vistas principales del panel (*Centros*, *Profesores*, *Horarios*, *Conversaciones*, *Feedback*), implementación que materializa los requisitos RF-AD1, RF-AD4, RF-AD6 y RF-AD7. El cuerpo de la vista presenta el listado de centros existentes (en este caso ETSII, Biología y Matemáticas) en formato de tarjeta, con el número de titulaciones asociadas y el estado de activación; el botón + *Nuevo centro* permite la creación manual. La paleta sigue la identidad de la US (rojo PANTONE 200C como color principal).

ASIGNATURA	DÍA	INICIO	FIN	AULA
Circuitos Electrónicos Digitales 2050003	Lunes	08:30:00	10:20:00	G1.32
Estructura de Computadores 2050009	Lunes	08:30:00	10:20:00	A0.12
Estructura de Computadores 2050009	Lunes	08:30:00	10:20:00	G1.32
Estructura de Computadores	Lunes	08:30:00	10:20:00	G1.35

Figura 6.4: Panel de administración: detalle de horarios por curso y grupo.

La Figura 6.4 muestra la vista de horarios tras navegar por la migaja de pan *Inicio* → *Horarios* → *ETSII* → *Grado en Ingeniería Informática – Ingeniería del Software*. El encabezado destaca la titulación activa y el contador total de horarios cargados (601 en el ejemplo). El cuerpo agrupa las sesiones por curso y grupo (*Curso 1 · Grupo 1 – 51 horarios*) y las despliega en una tabla con cinco columnas: ASIGNATURA (nombre y código institucional), DÍA, INICIO, FIN y AULA. La presencia simultánea de aulas con prefijo distinto (*G1.32*, *A0.12*, *G1.35*) ejemplifica la convención que el bot utiliza para distinguir aulas de teoría (prefijo *A*) y de laboratorio (resto) en sus respuestas (decisión D-066). Esta vista cubre operativamente el requisito RF-AD1 sobre el dominio horarios y permite la regeneración descrita en RF-AD2 desde los extractores de PDF oficiales.

La Figura 6.5 ilustra la vista jerárquica *Centro* → *Departamento* → *Profesor* (RF-AD5) sobre el Departamento de Lenguajes y Sistemas Informáticos, con 92 profesores cargados. La tabla muestra las columnas NOMBRE (apellidos seguidos de nombre, normalizados en la base de datos), DEPARTAMENTO, CATEGORÍA académica (Catedrático, Profesor Titular, Profesor Permanente Laboral, etc.), EMAIL institucional, DESPACHO (con la convención de edificio y planta empleada por la ETSII) y un enlace al PERFIL público en el portal de la Universidad. El botón *Enriquecer desde us.es* dispara el flujo del *scraper* del directorio PDI (RF-AD4) sobre el departamento mostrado, realizando un *upsert* idempotente que respeta las modificaciones manuales previas.

La Figura 6.6 corresponde a la vista de auditoría de conversaciones (RF-AD6) sobre la tabla `conversation_log`, alimentada por el *logger* de las acciones *custom* en cada turno. El encabezado declara el total de sesiones capturadas en el periodo (72 sesiones en la captura). El listado muestra una fila por sesión con su identificador anónimo (`session_177766...`, sin información personal identificable), el número de mensajes, el primer y último mensaje del intercambio, la marca temporal de inicio y la duración. El registro tachado de la segunda fila ilustra el marcado manual de *sesión revisada*, que persiste como atributo de la propia conversación y se utiliza

Volver al sitio

Estadísticas

UNIVERSIDAD DE SEVILLA

Panel de Administracion

LinceUS - Gestion de datos academicos

Conectado

Salir

Inicio

Profesores

Escuela Técnica Superior de Ingeniería Informática

Departamento de Lenguajes y Sistemas Informáticos

CENTROS

PROFESORES

HORARIOS

CONVERSACIONES

FEEDBACK

Departamento de Lenguajes y Sistemas Informáticos

92

Enriquecer desde us.es

NOMBRE	DEPARTAMENTO	CATEGORIA	EMAIL	DESPACHO	PERFIL
Álvarez García, Juan Antonio	Departamento de Lenguajes y Sistemas Informáticos	Catedrático de Universidad	jaalvarez@us.es	F1.52	✉
Arévalo Maldonado, Carlos	Departamento de Lenguajes y Sistemas Informáticos	Profesor Titular de Universidad	carlosarevalo@us.es	F1.41	✉
Ayala Hernández, Daniel	Departamento de Lenguajes y Sistemas Informáticos	Profesor Permanente Laboral	dayala1@us.es	F1.81	✉
Barba Rodríguez, Irene	Departamento de Lenguajes y Sistemas Informáticos	Profesora Titular de Universidad	irenebr@us.es	F0.46	✉

Figura 6.5: Panel de administración: gestión del profesorado por departamento.

Volver al sitio

Estadísticas

UNIVERSIDAD DE SEVILLA

Panel de Administracion

LinceUS - Gestion de datos academicos

Conectado

Salir

Inicio

Conversaciones

CENTROS

PROFESORES

HORARIOS

CONVERSACIONES

FEEDBACK

Conversaciones

72 sesiones

Exportar esta página

✓	SESIÓN	MENSAJES	PRIMER MENSAJE	ÚLTIMO MENSAJE	INICIO	DURACIÓN
☐	session_177766...	4	GII-IS	Quiero saber la evaluación de ispp para el grup...	1/5/2026, 23:02:07	9 min
☒	session_177766...	2	GII-IS	¿qué es ABDA?	1/5/2026, 21:38:38	19s
☐	session_177755...	4	GII-IS	Háblame de Redes de Computadores	30/4/2026, 16:35:28	1 min
☐	session_177755...	3	GII-IS	Cuales son los horarios de matemática discreta?	30/4/2026, 16:32:42	1 min
☐	session_177746...	1	GII-IS	GII-IS	29/4/2026, 12:58:20	1s
☐	session_177732...	1	GII-IS	GII-IS	27/4/2026, 23:44:31	1s
☐	session_177732...	1	GII-IS	GII-IS	27/4/2026, 23:44:31	1s

Figura 6.6: Panel de administración: auditoría de conversaciones del piloto.

para excluir sesiones ya auditadas de futuras revisiones. El botón *Exportar esta página* produce un volcado en formato CSV para análisis externo. Esta vista es la base del análisis de tráfico real reportado en la Sección 12.5.

6.8– Matrices de trazabilidad

Las matrices de trazabilidad permiten verificar que los requisitos cubren los objetivos del proyecto y que cada requisito está validado por al menos un caso de prueba. Se presentan dos matrices: la primera cruza los objetivos técnicos del Capítulo 1 con los requisitos funcionales, y la segunda muestra cómo los requisitos funcionales se validan en el Capítulo 12.

6.8.1. Objetivos técnicos ↔ Requisitos funcionales

La Tabla 6.11 cruza cada objetivo técnico de la Sección 1.3.2 con los requisitos funcionales que lo materializan.

Cuadro 6.11: Trazabilidad objetivos técnicos – requisitos funcionales.

Objetivo técnico	Requisitos funcionales
Sistema conversacional Rasa (flujos contextuales)	RF-A1 – RF-A6, RF-H1 – RF-H7, RF-P1 – RF-P7, RF-T1 – RF-T6
Integrar API Gemini como capa generativa (subclasificación, <i>text-to-SQL</i> , <i>smart fallback</i> y redacción natural)	RF-A4, RF-A2 (<i>text-to-SQL</i>), RF-AD3 (vectorización), RF-T3 (<i>fallback</i>)
BD híbrida Supabase + pgvector (estructurada + vectorial)	RF-AD1 – RF-AD3, RF-A4, RF-P2, RF-P3
Acciones personalizadas Python	RF-A1 – RF-A6, RF-H1 – RF-H7, RF-P1 – RF-P7, RF-T1 – RF-T4
Widget web ligero e intuitivo	RF-T5, RF-T6
Panel de administración (mantenibilidad sin intervención técnica)	RF-AD1 – RF-AD7
Arquitectura escalable (nuevas titulaciones por carga de datos)	RF-T1, RF-T2, RF-AD1, RF-AD2
Cumplimiento normativa de protección de datos	RF-T4, RF-AD6, RF-AD7

6.8.2. Requisitos funcionales ↔ Casos de prueba

La columna *Pruebas* de cada tabla de requisitos funcionales (Secciones 6.2.1–6.2.5) proporciona la traza directa de cada RF a su conjunto de casos de aceptación. La Tabla 6.12 consolida esta información indicando, para cada categoría de la suite, qué requisitos funcionales cubre, el número de casos de prueba y la tasa de éxito obtenida en el Capítulo 12. El desglose se hace por categoría real del *runner* (no por dominio agrupado) para que los recuentos coincidan exactamente con la Tabla 12.1.

El requisito **RF-T6** (*feedback* de respuestas incorrectas) no figura en la suite E2E porque su validación es funcional sobre la interfaz: el caso de prueba manual FB-01 verifica que pulsar el botón *Feedback* del widget envía la valoración a la tabla *feedback* de Supabase, comprobado desde el panel administrativo. La Sección 12.9 de pruebas lo documenta como caso de aceptación manual.

6.9– Evolución del alcance respecto a la propuesta inicial

La propuesta original del proyecto, recogida en el anteproyecto [72], contemplaba un alcance superior al efectivamente cubierto por el prototipo. La Tabla 6.13 resume las desviaciones prin-

Cuadro 6.12: Trazabilidad requisitos funcionales – cobertura de pruebas por categoría de la suite.

Categoría (suite)	RFs cubiertos	N.	Resultado
<i>Capa E2E (§12.2): 159 casos contables</i>			
asignatura_especifica	RF-A1, RF-A6	22	22/22 PASS (100 %)
asignatura_listado	RF-A2	15	15/15 PASS (100 %)
asignatura_conteo	RF-A3	10	10/10 PASS (100 %)
horario	RF-H1–H3, RF-H6, RF-H7	27	26/27 PASS (96,3 %)
horario_asignatura	RF-H4, RF-H5	18	18/18 PASS (100 %)
profesor	RF-P1 – RF-P7	43	37/43 PASS (86,0 %)
cambiar_contexto	RF-T1, RF-T2	13	12/13 PASS (92,3 %)
fuera_ambito	RF-T3, RF-T4, RF-T5	8	8/8 PASS (100 %)
cross_dominio	transversal (heredado)	1	1/1 PASS (100 %)
seguimiento_cross_intent	RF-A5	1	1/1 PASS (100 %)
Subtotal E2E	RF-A1–A6, RF-H1–H7, RF-P1–P7, RF-T1–T5	159	150/159 (94,3 %)
<i>Otras capas (§12.3, §12.4, §12.5, §12.9)</i>			
RAG baseline	RF-A4 (asignaturas genéricas)	50	47/50 PASS (94,0 %)
RAG profundidad	RF-A4, RF-P3 (plan docente)	74	68/74 OK (91,9 %)
NLU + Policy	RF-A5, RF-T1 (stories)	158	158/158 PASS (100 %)
Tráfico real (piloto)	todos los RF activos	59	58/59 PASS (98,3 %)
Panel admin. (pytest)	RF-AD1 – RF-AD7	24	24/24 PASS (100 %)

cipales y su justificación. En todos los casos las decisiones se han tomado con el objetivo de **garantizar la calidad de las funcionalidades implementadas**, antes que de cubrir un alcance amplio con calidad insuficiente, en línea con la recomendación de la guía de referencia.

Cuadro 6.13: Evolución del alcance respecto a la propuesta inicial.

Funcionalidad	Estado	Justificación
Frontend en React	Reformulado	Implementado en HTML/CSS/JavaScript <i>vanilla</i> , lo que facilita su inserción en cualquier página existente mediante una única etiqueta <code><script></code> , sin dependencias de <i>framework</i> . La inversión en desarrollo se ha concentrado en el núcleo conversacional, donde reside el mayor valor diferencial del proyecto.
Notificaciones <i>push</i> a estudiantes	Aplazado	Sustituido por el panel de administración , que ofrece mayor valor a la persona que continúe el proyecto y materializa los requisitos de mantenibilidad y escalabilidad.
Soporte multilingüe (inglés)	Aplazado	El corpus académico es mayoritariamente español. Se aplaza a fase 2 cuando el sistema esté estabilizado y exista presupuesto para una segunda suite de pruebas.
Despliegue <i>on-premise</i>	Reformulado	La información tratada es de carácter público y la sesión es anónima, por lo que no requiere despliegue en infraestructura propia. Se ha optado por DigitalOcean + Supabase.
Localización de espacios universitarios	Aplazado	La funcionalidad requiere datos de planos, aforos y disponibilidad de aulas en tiempo real que no están publicados de forma estructurada en ningún portal oficial de la US. Se aplaza a una fase posterior que pueda contar con una fuente de datos estable y verificable.
Cambio dinámico de titulación	Añadido	Funcionalidad incorporada tras el feedback del piloto (D-029, D-030, D-053). No figuraba en la propuesta inicial.
Integración con <i>us.es</i> para profesorado	Añadido	Sustituye la propuesta inicial de <i>scrapers</i> por departamento (D-043, D-044): fuente única, mantenible y completa.
Auditoría manual de conversaciones	Añadido	Surge como necesidad durante la fase de validación; permite la métrica de tráfico real post-despliegue (§12.5).

El balance final es satisfactorio: el sistema cubre con calidad los tres dominios académicos centrales de la propuesta y aporta dos funcionalidades no previstas (panel de administración y cambio dinámico de titulación) que refuerzan los requisitos de mantenibilidad y experiencia de usuario. Las funcionalidades aplazadas son recuperables en una segunda iteración sin necesidad de modificar el núcleo del sistema, lo que se discute con detalle en el Capítulo 14.

Arquitectura del sistema y decisiones de diseño

Este capítulo describe la arquitectura del sistema LinceUS Assistant, las decisiones de diseño adoptadas durante su desarrollo y los diagramas técnicos que representan la estructura de componentes y el modelo de despliegue. El objetivo es ofrecer una visión completa de cómo se organiza internamente el sistema, cómo se comunican sus partes y qué criterios han guiado las principales elecciones técnicas.

7.1– Arquitectura general

LinceUS Assistant sigue una **arquitectura por capas** (*layered architecture*) [73] con tres niveles claramente diferenciados: capa de presentación, capa de procesamiento conversacional y capa de datos. Esta separación permite que cada capa evolucione de forma independiente y que los cambios en una no afecten directamente a las demás, siempre que se respeten las interfaces definidas entre ellas [74].

7.1.1. Capa de presentación

La capa de presentación es la interfaz visible para el usuario final. Consiste en un **widget de chat web** desarrollado en JavaScript puro (vanilla JS), HTML y CSS, diseñado como un componente autocontenido y embebible en cualquier página institucional de la Universidad de Sevilla.

Las principales características de esta capa son:

- **Independencia tecnológica:** El widget no depende de frameworks como React o Angular; se implementa con JavaScript estándar (ES6+), lo que minimiza las dependencias y facilita su integración en páginas web existentes mediante una única etiqueta `<script>`.
- **Comunicación REST:** El widget se comunica con el servidor Rasa mediante peticiones HTTP POST al endpoint `/webhooks/rest/webhook`, enviando mensajes del usuario y recibiendo las respuestas del asistente en formato JSON. El estilo arquitectónico REST, definido por Fielding [75], garantiza la ausencia de estado en el servidor y la interoperabilidad con cualquier cliente HTTP.
- **Renderizado enriquecido:** Soporta formato Markdown en las respuestas del bot, incluyendo tablas, enlaces y listas, para presentar la información académica de forma clara y estructurada.
- **Diseño institucional:** Emplea la identidad visual de la Universidad de Sevilla (colores corporativos, logotipo) para integrarse visualmente en el entorno universitario.

7.1.2. Capa de procesamiento conversacional

Esta capa constituye el núcleo del sistema y está compuesta por varios servicios que colaboran entre sí:

- **Rasa Server:** Motor principal de comprensión del lenguaje natural (NLU) y gestión de diálogo (Core). Recibe los mensajes del usuario, los procesa a través del pipeline NLU para extraer intenciones y entidades, y decide la siguiente acción a ejecutar mediante las políticas de diálogo configuradas.
- **Action Server (Rasa SDK):** Servidor independiente que ejecuta las acciones personalizadas escritas en Python. Cuando Rasa Core determina que debe ejecutarse una acción personalizada (por ejemplo, consultar la base de datos), delega la ejecución en este servidor a través de una petición HTTP al endpoint `/webhook`.
- **Google Gemini API:** Servicio externo utilizado para dos propósitos: (1) generación de consultas SQL a partir de lenguaje natural (*Text-to-SQL*) mediante el modelo `gemma-3-27b-it`, y (2) generación de embeddings vectoriales mediante el modelo `gemini-embedding-001` para la búsqueda semántica en el pipeline RAG.
- **Ollama** (opcional): Servicio local de inferencia de modelos LLM que actúa como alternativa a Gemini cuando la API externa no está disponible o se agotan las cuotas de uso. Permite ejecutar modelos como `llama3.2:3b` en CPU sin depender de servicios en la nube.

7.1.3. Capa de datos

La capa de datos se implementa sobre **Supabase**, una plataforma que proporciona una instancia gestionada de PostgreSQL con extensiones adicionales:

- **PostgreSQL:** Almacena toda la información académica estructurada: universidades, centros, titulaciones, asignaturas, planes docentes y sus metadatos asociados.
- **pgvector:** Extensión que añade el tipo de dato `vector` y operadores de similitud (distancia coseno, euclidiana y producto punto). Almacena los embeddings de los fragmentos de documentos vectorizados y permite realizar búsquedas semánticas eficientes mediante índices HNSW.
- **Funciones SQL personalizadas:** dos funciones almacenadas en la base de datos encapsulan la lógica de búsqueda vectorial. `buscar_plan_docente()` filtra por asignatura, grupo y curso académico, y su variante global busca en todos los planes con un umbral de similitud configurable.

7.2– Diagrama de componentes

El diagrama de componentes muestra los módulos principales del sistema, sus responsabilidades y las interfaces a través de las cuales se comunican. La Figura 7.1 representa esta vista.




Figura 7.1: Diagrama de componentes del sistema Linceus. El componente *multi-intent* aparece con trazo discontinuo porque su código permanece en el repositorio como referencia pero está desactivado en el modelo de diálogo del prototipo (ver Sección 11.7).

Los puertos representados en el diagrama (5005, 5055, 6543, 443) corresponden al despliegue local de desarrollo. En el despliegue de producción sobre DigitalOcean estos puertos internos se mantienen idénticos dentro de la red de contenedores Docker; lo que cambia es la exposición externa, que se concentra en el puerto 443 (HTTPS) a través del reverse proxy Nginx descrito en la Sección 7.3.

A continuación se describe la responsabilidad de cada componente y las interfaces entre ellos:

- **Chat Widget** → **Rasa NLU**: El widget envía el texto del usuario mediante una petición HTTP POST al endpoint REST de Rasa. La comunicación es síncrona: el widget espera la respuesta para mostrarla en la interfaz.
- **Rasa NLU** → **Rasa Core**: Tras procesar el mensaje a través del pipeline NLU (tokenización, extracción de características, clasificación de intención y extracción de entidades), el resultado se pasa al módulo Core, que decide la siguiente acción.
- **Rasa Core** → **Action Server**: Cuando la acción seleccionada es personalizada (prefijo `action_`), Core envía una petición HTTP al Action Server con el tracker completo de la conversación (historial, slots, última intención y entidades).
- **Action Server** → **Text-to-SQL**: Para consultas sobre asignaturas, el Action Server invoca el motor Text-to-SQL, que construye un prompt con el esquema de la base de datos y la pregunta del usuario, lo envía a Gemini y recibe una consulta SQL validada.
- **Action Server** → **Gemini / Ollama**: El Action Server puede invocar Gemini para generación de SQL, detección de titulación o generación de embeddings. Si Gemini no está disponible, se recurre a Ollama como alternativa local.
- **RAG Pipeline** → **pgvector**: La búsqueda semántica genera un embedding de la pregunta del usuario y lo compara contra los embeddings almacenados en pgvector usando similitud coseno, con un umbral mínimo de 0.5.
- **Text-to-SQL** → **PostgreSQL**: Las consultas SQL generadas se ejecutan directamente contra la base de datos PostgreSQL de Supabase, con filtros de seguridad inyectados automáticamente (restricción por titulación).

7.3– Diagrama de despliegue

El diagrama de despliegue describe la distribución física de los componentes del sistema en nodos de ejecución y las conexiones de red entre ellos [73]. El sistema utiliza contenedores Docker [37] orquestados mediante Docker Compose, lo que proporciona reproducibilidad del entorno y separación de responsabilidades entre servicios siguiendo el patrón de despliegue de microservicios independientes [76]. La Figura 7.2 muestra esta configuración.

7.3.1. Nodos de ejecución

El sistema se despliega sobre los siguientes nodos:

1. **Navegador web del usuario**: Ejecuta el widget de chat (JavaScript) y se comunica con el servidor Rasa mediante HTTP. No requiere instalación alguna por parte del usuario.
2. **Máquina local de desarrollo**: Alberga los tres servicios principales del backend:
 - **Rasa Server** (`localhost:5005`): Sirve la API REST del chatbot y carga el modelo entrenado (`.tar.gz`).

- **Action Server** (`localhost:5055`): Ejecuta las acciones personalizadas con un timeout de 300 segundos para acomodar consultas LLM en CPU.
 - **Ollama** (`localhost:11434`): Servicio opcional de inferencia local de modelos LLM.
 - **RAG Pipeline**: Proceso batch que se ejecuta bajo demanda para vectorizar nuevos documentos PDF.
3. **Supabase Cloud (AWS eu-west-3)**: Instancia gestionada de PostgreSQL con pgvector, accesible mediante connection pooling en el puerto 6543. Aloja tanto los datos estructurados como los embeddings vectoriales.
 4. **Google Cloud**: Proporciona acceso a la API de Gemini para generación de texto (Text-to-SQL) y generación de embeddings. La comunicación se realiza mediante HTTPS con autenticación por API key.

7.3.2. Protocolos de comunicación

Origen	Destino	Protocolo	Puerto
Navegador	Rasa Server	HTTP POST (REST)	5005
Rasa Server	Action Server	HTTP POST (webhook)	5055
Action Server	Supabase	TCP (psycopg2)	6543
Action Server	Gemini API	HTTPS (REST)	443
Action Server	Ollama	HTTP (REST)	11434
RAG Pipeline	Supabase	TCP (psycopg2)	6543
RAG Pipeline	Gemini Embeddings	HTTPS (REST)	443

Cuadro 7.1: Protocolos y puertos de comunicación entre nodos del sistema.

7.4– Decisiones de diseño

A lo largo del desarrollo del sistema se han tomado decisiones de diseño que han condicionado la arquitectura, el rendimiento y la mantenibilidad del proyecto. En esta sección se documentan las más relevantes, indicando el contexto, las alternativas consideradas y la justificación de cada elección.

7.4.1. Text-to-SQL con LLM en lugar de reglas estáticas

Contexto: El sistema debe responder consultas sobre asignaturas que pueden formularse de formas muy diversas (por nombre, curso, tipología, créditos, duración o combinaciones de estos filtros). Implementar todas las variantes mediante reglas *if-else* o expresiones regulares resultaría en un código excesivamente largo, frágil y difícil de mantener.

Decisión: Se optó por un enfoque **Text-to-SQL basado en LLM** [31], donde el modelo Gemini (`gemma-3-27b-it`) recibe un prompt que incluye el esquema de la tabla `asignaturas`, las columnas permitidas y la pregunta del usuario, y genera la consulta SQL correspondiente.

Justificación:

- **Flexibilidad:** El modelo interpreta preguntas en lenguaje natural sin necesidad de anticipar todas las formulaciones posibles.
- **Mantenibilidad:** Añadir nuevos atributos o filtros solo requiere actualizar el prompt, no reescribir lógica de parsing.

- **Seguridad:** Se aplican mecanismos de protección como una *whitelist* de columnas permitidas, prohibición de subconsultas e inyección automática del filtro de titulación, en línea con las recomendaciones de OWASP frente a inyección SQL [77].

Temperatura 0.0: Se configura el modelo con temperatura cero para obtener respuestas deterministas [78], crítico para la generación de SQL donde la variabilidad es indeseable.

7.4.2. Gemini como servicio principal con Ollama como alternativa intercambiable

Contexto: El sistema requiere un modelo de lenguaje grande para *Text-to-SQL*, clasificación y generación de la respuesta natural. Dependar exclusivamente de una API externa implica riesgos de disponibilidad y de cuota, mientras que depender solo de ejecución local exige hardware potente y sacrifica latencia.

Decisión: Se adoptó una **estrategia dual de cliente intercambiable**: Gemini como servicio principal (plan gratuito con cuota suficiente para el volumen académico del proyecto) y Ollama como alternativa local. Ambos clientes están implementados en `shared/gemini_client.py` y `shared/ollama_client.py` con **idéntica firma** (`llamar_gemini(prompt, modelo, timeout, options, context)` y `llamar_ollama(prompt, modelo, timeout, options)`), lo que materializa un *Strategy* configurable a nivel de *build*: cambiar el proveedor exige modificar los `import` de las *custom actions* (o redirigirlos mediante un envoltorio único `llm_client.py` parametrizado por una variable de entorno), pero no requiere tocar la lógica de negocio.

Justificación:

- El plan gratuito de Gemini es suficiente para el volumen de uso académico del proyecto y proporciona la latencia que exige el caso de uso interactivo (1,8 s mediana frente a 4,1 s observados con Ollama y `llama3.2:3b` sobre CPU).
- Ollama con `llama3.2:3b` se conserva como alternativa operativa de pleno derecho: instalable localmente, sin conexión a internet y sin envío de datos a terceros, lo que alinea el flujo local con los requisitos de privacidad (RGPD) en caso de que se opte por una explotación *on-premise*.
- La conmutación entre proveedores es de configuración, no automática *en caliente*: si Gemini deja de responder, el *Action Server* no cambia de cliente sobre la marcha. La degradación elegante en línea está reservada al pipeline RAG, donde sí existe un *fallback* a búsqueda por palabras clave (Sección 7.4.5). La incorporación de un *failover* automático a Ollama figura entre las líneas de mejora del Capítulo 14.

7.4.3. Embeddings de 2000 dimensiones con HNSW

Contexto: El modelo `gemini-embedding-001` genera embeddings de 3072 dimensiones de forma nativa. Sin embargo, el índice HNSW de pgvector [41] presenta limitaciones de rendimiento y almacenamiento con dimensionalidades muy altas, tal y como describe el trabajo original sobre *Hierarchical Navigable Small World graphs* [32].

Decisión: Se redujo la dimensionalidad de salida a **2000 dimensiones** mediante el parámetro `output_dimensionality` de la API de Gemini.

Justificación:

- 2000 dimensiones ofrecen un equilibrio entre la calidad de la representación semántica y la eficiencia del índice HNSW (parámetros $m = 16$, $ef_construction = 64$, recomendados en [32]).
- Reduce el tamaño de almacenamiento por vector en aproximadamente un 35 %.

- El trabajo de Karpukhin et al. sobre *Dense Passage Retrieval* [11] demuestra que dimensionalidades en el rango 768–2048 son suficientes para la recuperación semántica en dominios cerrados como el de los planes docentes.

7.4.4. Chunking con solapamiento para preservar contexto

Contexto: Los planes docentes en PDF contienen información densa que debe fragmentarse para su vectorización. Un chunking demasiado grande diluye la relevancia; uno demasiado pequeño pierde contexto. La literatura sobre RAG [2] y las guías prácticas de *text splitters* de LangChain [79] convergen en una recomendación de fragmentos de 500–1000 caracteres con un solapamiento del 10–20 %.

Decisión: Se implementó un chunking de **800 caracteres con 100 caracteres de solapamiento** (12,5 %) y un mínimo de 50 caracteres por fragmento, dentro del rango recomendado.

Justificación:

- 800 caracteres (≈ 150 –200 tokens) es suficiente para capturar un párrafo o sección temática completa, en línea con los valores recomendados por LangChain.
- El solapamiento del 12,5 % mitiga la pérdida de información en los límites de fragmento, técnica habitual en pipelines de RAG [2, 11].
- Se aplica detección de secciones por expresiones regulares (“Datos básicos”, “Objetivos”, “Contenidos”, “Evaluación”, “Bibliografía”) para etiquetar cada fragmento con su sección de origen, una práctica de *metadata-augmented retrieval* que mejora la precisión sobre dominios estructurados [29].

7.4.5. Búsqueda vectorial con fallback a búsqueda por palabras clave

Contexto: La generación de embeddings para las consultas de búsqueda depende de la API de Gemini, que puede agotar su cuota diaria (100 peticiones por minuto, 1000 por día [68]).

Decisión: Se implementó un sistema de **doble búsqueda**: búsqueda vectorial como método principal y búsqueda por palabras clave (ILIKE) como fallback automático, siguiendo el patrón *hybrid retrieval* descrito en [11].

Justificación:

- La búsqueda vectorial ofrece mejor precisión semántica (encuentra “sistema de evaluación” cuando el usuario pregunta “¿cómo se califica?”), tal como evalúa el marco RAGAS [29].
- El fallback por palabras clave garantiza que el sistema siga operativo aunque la API de embeddings no esté disponible, con resultados razonables para consultas que contienen términos exactos.
- El umbral de similitud coseno se fija en 0.5, bajo el cual los resultados se descartan por considerarse irrelevantes.

7.4.6. Fuzzy matching para resolución de nombres

Contexto: Los usuarios introducen nombres de asignaturas con errores ortográficos, sin tildes, con abreviaturas o con variaciones coloquiales (“FP” por “Fundamentos de Programación”, “ADDA” por “Análisis y Diseño de Datos y Algoritmos”).

Decisión: Se integró la librería **RapidFuzz**, basada en métricas estándar de distancia entre cadenas [61], con un umbral de similitud del 80 % combinado con una tabla de alias y acrónimos mantenida en el código.

Justificación:

- El algoritmo de distancia de Levenshtein de RapidFuzz tolera errores tipográficos habituales sin requerir entrenamiento adicional.
- La tabla de alias cubre las abreviaturas más comunes utilizadas por los estudiantes de la ETSII.
- Si la coincidencia difusa falla, se recurre al LLM (Gemini) como último recurso para intentar identificar la asignatura.

7.4.7. Slots conversacionales para memoria de contexto

Contexto: Los usuarios formulan preguntas de seguimiento que hacen referencia implícita a asignaturas o titulaciones mencionadas previamente (“¿Y cuántos créditos tiene?”, “¿Es obligatoria?”).

Decisión: Se utilizan **slots de Rasa** para mantener el estado de la conversación:

- `contexto_titulacion`: Titulación activa seleccionada por el usuario.
- `ultimo_codigo_consultado`: Código de la última asignatura consultada.
- `ultimo_nombre_asignatura`: Nombre de la última asignatura mencionada.
- `ultimos_resultados_asignaturas`: Lista de resultados de la última consulta (para paginación).

Justificación:

- Los slots permiten que las acciones personalizadas recuperen el contexto sin que el usuario deba repetir información.
- La separación entre código y nombre de asignatura facilita tanto las consultas SQL (por código) como las respuestas al usuario (por nombre legible).
- El slot `contexto_titulacion` no tiene un valor por defecto: en el primer turno de cada sesión el *widget* muestra un **modal de selección de titulación** con las opciones disponibles (GII-IS, GII-TI, GII-IC), de modo que la titulación queda fijada explícitamente por el usuario antes de cualquier consulta. Esta decisión (revisión R3) sustituye al antiguo valor por defecto GII-IS, que generaba respuestas incorrectas cuando el alumno pertenecía a otra titulación y no formulaba un cambio explícito. El slot puede modificarse posteriormente mediante la intención `cambiar_contexto_academico` dentro del flujo conversacional.

7.4.8. Pipeline NLU con preentrenado spaCy y featurización híbrida

Contexto: El pipeline NLU de Rasa [38, 10] debe ser capaz de clasificar correctamente intenciones en español, tolerando errores ortográficos, abreviaturas y variaciones léxicas propias del lenguaje coloquial estudiantil, sobre un corpus de entrenamiento reducido (entre 600 y 800 ejemplos en el cierre de prototipo).

Decisión: Se configuró un pipeline de 11 componentes que apoya el clasificador DIETClassifier sobre **embeddings preentrenados de spaCy en español** (`es_core_news_md`) y combina **featurización a nivel de palabra** (n-gramas 1–2), **a nivel de carácter** (n-gramas 2–4) y **vectores densos de spaCy**, siguiendo el diseño *multi-featurizer* recomendado en la documentación oficial [38]:

1. SpacyNLP (modelo `es_core_news_md`): carga del modelo de lenguaje preentrenado en español, base de los *embeddings* léxicos densos.

2. `SpacyTokenizer`: tokenización respetando la segmentación morfológica del modelo de español.
3. `RegexFeaturizer`: patrones regex para códigos de asignatura y formatos especiales.
4. `LexicalSyntacticFeaturizer`: características gramaticales del contexto local.
5. `CountVectorsFeaturizer` (palabra): n-gramas de palabras (1–2).
6. `CountVectorsFeaturizer` (carácter): n-gramas de caracteres (2–4); los n-gramas de un solo carácter se descartaron por aportar ruido sin mejorar la robustez frente a typos.
7. `SpacyFeaturizer`: *features* densas derivadas del modelo de spaCy, complementarias a las cuentas léxicas.
8. `DIETClassifier` [39]: clasificador dual de intenciones y entidades (150 épocas, *dropout* 0,2, *constrain_similarities* = *true*).
9. `EntitySynonymMapper`: normalización de sinónimos de entidades.
10. `ResponseSelector`: selección de respuestas tipo FAQ (150 épocas).
11. `FallbackClassifier`: detección de baja confianza, configurada con *threshold* = 0,8 y *ambiguity_threshold* = 0,10.

Justificación:

- El uso de embeddings preentrenados de spaCy en español (*es_core_news_md*) es la decisión que permite que el `DIETClassifier` aprenda con un corpus pequeño: palabras como *difícil*, *mejor* o *peor* llegan al clasificador con su vector semántico ya construido, en lugar de inferirlo desde cero a partir de las cuentas léxicas. Sin esta entrada densa, los experimentos preliminares sobre el mismo conjunto de ejemplos mostraban una clasificación notablemente menos estable en consultas reformuladas con sinónimos.
- La featurización a nivel de carácter es especialmente eficaz para manejar errores ortográficos (“Fundamnetos” se reconoce por similitud de caracteres con “Fundamentos”), efecto documentado en el artículo original de DIET [39].
- El umbral de fallback de 0,8 equilibra la precisión (evitar respuestas incorrectas) con la cobertura (no rechazar demasiadas consultas legítimas), y el *ambiguity_threshold* = 0,10 es decisivo en consultas como «*asignatura más difícil*», donde dos intenciones (*preguntar_hay_mas* y *consulta_asignaturas_listado*) compiten con probabilidades cercanas; sin la regla de ambigüedad el sistema se decantaba por la opción con confianza ligeramente superior aunque no fuera la correcta. Estos valores son coherentes con los rangos reportados en *benchmarks* de detección de intenciones [80].
- El `DIETClassifier` con 150 épocas y *dropout* de 0,2 proporciona un modelo robusto sin sobreajuste al conjunto de entrenamiento, en línea con la configuración recomendada por sus autores [39].

7.4.9. Hash SHA-256 para evitar reprocesamiento de documentos

Contexto: El pipeline de vectorización RAG procesa documentos PDF que pueden ser costosos de re-vectorizar (extracción de texto, chunking, generación de embeddings con API de pago por uso).

Decisión: La tabla *planes_docentes* guarda un **hash SHA-256** [81] de cada PDF procesado. El hash se calcula sobre el contenido binario íntegro del fichero (en bloques de 8 KB para

no cargar el PDF entero en memoria), lo que detecta cualquier modificación a nivel de bytes sin necesidad de parsear el documento. Antes de procesar un documento, se compara el hash actual con el almacenado.

Justificación:

- Si el hash coincide, el documento no ha cambiado y se omite el reprocesamiento, ahorrando llamadas a la API de embeddings.
- Si el hash difiere, se eliminan los fragmentos anteriores y se reprocesa el documento completo, garantizando la consistencia de los datos.
- Este mecanismo es especialmente relevante dado el límite de 1000 embeddings por día del plan gratuito de Gemini.

7.5– Patrones arquitectónicos aplicados

El diseño del sistema incorpora varios patrones arquitectónicos reconocidos en la ingeniería del software:

7.5.1. Arquitectura por capas (*Layered Architecture*)

Como se ha descrito en la Sección 7.1, el sistema se organiza en tres capas con responsabilidades bien definidas. Cada capa solo se comunica con la inmediatamente inferior, lo que reduce el acoplamiento y facilita el reemplazo de componentes (por ejemplo, cambiar el frontend sin afectar la lógica de negocio).

7.5.2. Patrón *Action Server* (microservicio de lógica)

Rasa delega la ejecución de lógica de negocio en un servidor de acciones independiente. Este patrón es similar al patrón *Backend for Frontend* (BFF), donde un servicio intermedio adapta las respuestas de los servicios de datos al formato esperado por el cliente conversacional. La separación permite escalar el Action Server independientemente del motor Rasa.

7.5.3. Patrón *Strategy* para clientes LLM

Los clientes de Gemini (`gemini_client.py`) y Ollama (`ollama_client.py`) implementan una interfaz similar para la generación de texto. El Action Server puede alternar entre ambos proveedores en función de la disponibilidad, aplicando el patrón *Strategy* para desacoplar la lógica de negocio del proveedor concreto de LLM.

7.5.4. Patrón *Pipeline* para procesamiento RAG

El pipeline de vectorización sigue el patrón *Pipeline* (o *Pipes and Filters*), donde cada etapa transforma los datos y los pasa a la siguiente: extracción de PDF → chunking → generación de embeddings → inserción en base de datos. Cada etapa es independiente y puede modificarse sin afectar a las demás.

7.5.5. Patrón *Repository* para acceso a datos

El módulo `db.py` centraliza todas las operaciones contra la base de datos, siguiendo el patrón *Repository* [82] y proporcionando una abstracción que oculta los detalles de conexión (pool de conexiones `psycopg2`) y ejecución de consultas al resto del sistema. Esto facilita el testing unitario mediante mocks y permite cambiar la implementación de persistencia sin modificar la lógica de negocio.




Figura 7.2: Diagrama de despliegue del sistema Linceus en DigitalOcean (Ubuntu 24.04 LTS) con el pipeline de despliegue automatizado vía GitHub Actions.

Marco tecnológico

Este capítulo describe el conjunto de tecnologías, frameworks y paradigmas que conforman la base técnica del proyecto LinceUS Assistant. Se complementa con el Capítulo 7, donde se detallan la arquitectura del sistema, las decisiones de diseño y los diagramas de componentes y despliegue, y con la Sección 5.2.1 del Capítulo 5, que recoge la comparativa cuantitativa de *frameworks* (Rasa, Botpress, DeepPavlov), motores de LLM (Gemini, OpenAI, DeepSeek, Ollama) y bases vectoriales que sustentan las decisiones aquí adoptadas. Para evitar duplicación, este capítulo describe el rol de cada tecnología en el sistema sin reabrir la justificación cuantitativa.

8.1– Tecnologías de procesamiento conversacional

8.1.1. Rasa Framework

Rasa [38, 10] es el *framework* de código abierto sobre el que se construye el núcleo conversacional del asistente. La justificación cuantitativa de su elección frente a Botpress y DeepPavlov (coste, integración con Python, soporte de RAG y despliegue local) figura en la tarea 1.2.2 del Diccionario EDT (Capítulo 5).

Componentes de Rasa utilizados

Rasa NLU (Natural Language Understanding)

Rasa NLU se encarga de interpretar la entrada del usuario y extraer:

- **Intenciones (intents):** ¿Qué quiere hacer el usuario? (e.g., `consultar_horario`, `buscar_asignatura`)
- **Entidades (entities):** Información específica mencionada por el usuario (e.g., nombre de asignatura, curso, centro)

Rasa Core

Rasa Core gestiona el flujo de conversación mediante:

- **Stories:** Conversaciones de ejemplo que entrenan el modelo de diálogo
- **Rules:** Reglas determinísticas para situaciones específicas
- **Políticas:** Algoritmos de aprendizaje que deciden la siguiente acción del bot

Rasa Actions

Las acciones personalizadas permiten al bot ejecutar código Python para:

- Consultar la base de datos
- Generar respuestas dinámicas

- Llamar a APIs externas
- Procesar lógica de negocio compleja

8.1.2. Procesamiento de Lenguaje Natural

spaCy

spaCy [83] proporciona capacidades avanzadas de NLP en español:

- **Tokenización:** Separación del texto en palabras y signos de puntuación
- **Lematización:** Reducción de palabras a su forma base
- **Análisis morfológico:** Identificación de categorías gramaticales
- **Vectores de palabras:** Representaciones numéricas del significado de las palabras

El modelo `es_core_news_md` incluye vocabulario específico del español y ha sido entrenado en corpus de textos en español.

Coincidencia difusa (Fuzzy Matching)

La librería RapidFuzz implementa algoritmos de distancia de cadenas [61] que permiten:

- Tolerar errores ortográficos (e.g., "Fundamnetos de Programacion")
- Reconocer abreviaturas (e.g., "FP" por "Fundamentos de Programación")
- Manejar variaciones en la escritura (e.g., mayúsculas, tildes)

Se utiliza el algoritmo de *Levenshtein distance* [84] con un umbral de similitud del 80 % para considerar coincidencias válidas.

8.2– Tecnologías de Inteligencia Artificial

8.2.1. Google Gemini como modelo de lenguaje principal

El modelo de lenguaje de referencia del sistema es **Google Gemini** [44], en concreto la familia `gemma-3-27b-it` para generación de texto y `gemini-embedding-001` para vectorización. Las llamadas al modelo se centralizan en el cliente `actions/shared/gemini_client.py`, que envuelve el SDK oficial y aplica los parámetros de proyecto (temperatura, *timeout*, registro de métricas). La selección de Gemini frente al resto de candidatos analizados se justifica de manera cuantitativa en la comparativa de la Sección 5.2.1.

Gemini interviene en tres puntos del sistema:

1. **Text-to-SQL:** a partir del esquema de la base de datos y la pregunta del usuario, el modelo genera la sentencia `SELECT` que se ejecuta tras pasar por un validador propio.
2. **Generación de respuesta natural:** tanto los datos estructurados recuperados de la base relacional como los *chunks* devueltos por el módulo RAG se entregan al modelo junto con un *prompt* específico de cada época para producir la respuesta final.
3. **Embeddings:** la vectorización de los planes docentes y de las consultas de búsqueda usa `gemini-embedding-001` con dimensionalidad reducida a 2000 (decisión documentada en la Sección 7.4.3).

8.2.2. Ollama como alternativa local opcional

Ollama se mantiene como motor de inferencia local opcional y se utilizó principalmente durante la fase de prototipado, antes de adoptar Gemini como proveedor estable. En el despliegue actual no es un servicio en ejecución sino una vía alternativa que el cliente `actions/shared/ollama_client.py` expone con la misma interfaz que el cliente de Gemini. Esto permite, sin reescribir el núcleo conversacional:

- Probar localmente nuevos *prompts* sin consumir cuota de la API de Gemini.
- Disponer de un *plan B* ante cambios de política o cuotas del proveedor cloud (precedente histórico recogido en la Sección 5.6).
- Ejecutar el sistema en entornos sin conectividad a servicios externos.

8.2.3. Embeddings y búsqueda semántica (RAG)

La recuperación de información sobre los planes docentes oficiales se implementa mediante el patrón *Retrieval-Augmented Generation* [2], que combina búsqueda semántica y generación con LLM. Las piezas son:

- **Modelo de embeddings** (`gemini-embedding-001`): transforma texto en vectores que capturan el significado semántico.
- **pgvector** [41]: extensión de PostgreSQL que almacena los vectores y soporta búsqueda por similitud coseno.
- **Índice HNSW** [32]: estructura de vecinos más cercanos aproximados que ofrece tiempos de consulta sub-lineales sobre el corpus de planes docentes.

Las decisiones concretas de *chunking* (800 caracteres con 100 de solapamiento) y dimensionalidad (2000) se documentan en las Secciones 7.4.4 y 7.4.3 respectivamente.

8.3– Tecnologías de base de datos

La capa de datos se apoya en PostgreSQL como motor relacional, Supabase [40] como plataforma gestionada y pgvector [41] como extensión vectorial. La elección frente a alternativas (Pinecone, Weaviate [43], Qdrant [42]) se discute en la fase de investigación recogida en el Diccionario EDT (Sección 5.2.1); aquí basta con detallar el rol de cada pieza en el sistema.

8.3.1. PostgreSQL y Supabase

PostgreSQL almacena toda la información académica estructurada (universidades, centros, titulaciones, asignaturas, planes docentes, profesorado, horarios). **Supabase** actúa como capa gestionada: ofrece la instancia de PostgreSQL en *cloud*, el *connection pooling* a través del puerto 6543, autenticación, almacenamiento de ficheros y panel de administración. El proyecto utiliza Supabase exclusivamente como base de datos gestionada; las API REST y *Edge Functions* no se emplean porque toda la lógica reside en las acciones de Rasa y en la API Flask del panel de administración.

8.3.2. pgvector

La extensión **pgvector** [41] añade el tipo `vector` y los operadores de similitud (coseno, euclidiana, producto punto) directamente sobre PostgreSQL. Esto evita introducir un servicio adicional de base vectorial: el corpus de planes docentes y sus embeddings residen en la misma instancia que el resto de datos académicos. Sobre los vectores se construye un índice HNSW [32] para búsquedas sub-lineales, configurado con los parámetros $m = 16$ y $ef_construction = 64$ (Sección 7.4.3).

8.4– Tecnologías de frontend

El frontend del proyecto está formado por dos piezas: el **widget de chat** embebible en cualquier página de la US y el **panel de administración** que da acceso a las importaciones de datos y a las conversaciones registradas. Ambas son aplicaciones estáticas (HTML, CSS y JavaScript ES6+ sin *frameworks* reactivos) servidas por Nginx en producción y por el servidor HTTP de Python en desarrollo. La separación entre el widget del usuario, el panel de administración, el servidor conversacional y el servidor de acciones sigue los principios de desacoplamiento propios de las arquitecturas de microservicios [76].

8.4.1. Widget de chat

El `chatbot-widget.js` se carga directamente desde una página HTML mediante una etiqueta `<script>`, sin pasos de *build*. Implementa:

- La comunicación con el servidor Rasa por HTTP REST contra el endpoint `/webhooks/rest/webhook` (peticiones síncronas `fetch`, sin WebSocket).
- El renderizado de respuestas en Markdown ligero (tablas, listas, enlaces, énfasis) y de botones inyectados desde Rasa.
- El **modal de selección de titulación** que se muestra al iniciar la sesión y fija el slot `contexto_titulacion` antes de la primera consulta (Sección 7.4.7).

8.4.2. Panel de administración

El panel (`admin.html`, `admin.js`, `admin.css`) es una aplicación SPA ligera que consume la API Flask descrita en la Sección 8.1. Permite gestionar centros, titulaciones, asignaturas, profesores, horarios y conversaciones, y dispara las importaciones desde Sevius mediante los *scrapers* del módulo `admin/`.

8.4.3. Servidor web

Nginx sirve los activos estáticos del *frontend* y el panel en el despliegue Docker (puerto 80) y actúa como *reverse proxy* hacia los servicios internos. En desarrollo local, los mismos activos se sirven con `python -m http.server 8080`. Node.js se utiliza únicamente para herramientas de desarrollo (ESLint [60] a través de npm); ningún componente del *runtime* depende de él.

8.5– Herramientas de desarrollo

8.5.1. Control de versiones

Git es el sistema de control de versiones utilizado, con **GitHub** como plataforma de *hosting*. La integración continua y el flujo de entrega automatizada que se apoya sobre este repositorio

siguen los principios de *continuous delivery* [55]. La estructura concreta del repositorio se detalla en el Capítulo 9; no se reproduce aquí para evitar duplicar información.

8.5.2. Gestión de dependencias

Las dependencias de Python se fijan en `requirements.txt` (servidor Rasa) y `requirements-actions.txt` (*action server*), ambos con versiones ancladas para garantizar la reproducibilidad. El aislamiento del entorno se consigue con *venv* en desarrollo y con la imagen Docker en producción.

8.5.3. Variables de entorno

La librería `python-dotenv` carga la configuración desde un fichero `.env` en la raíz del proyecto: credenciales de Supabase (URL y API key), clave de la API de Gemini, parámetros opcionales de Ollama y el resto de ajustes del sistema. Este mecanismo evita exponer secretos en el repositorio y permite alternar entre entornos (local, Docker, producción) sin tocar el código.

8.6– Consideraciones de seguridad

8.6.1. Protección de datos

- **Credenciales:** Nunca se almacenan en el código, siempre en variables de entorno
- **API keys:** Se utilizan claves específicas con permisos mínimos necesarios
- **Conexiones:** HTTPS para todas las comunicaciones con servicios externos

8.6.2. Validación de entrada

- Sanitización de consultas SQL para prevenir inyección SQL, siguiendo las recomendaciones de OWASP [77]
- Validación de tipos de datos en entradas de usuario
- Limitación de longitud de mensajes

8.6.3. Aislamiento del proveedor de LLM

En el despliegue actual, las consultas se envían a la API de Google Gemini [44] sobre HTTPS y autenticación por clave; no se transmiten datos personales del alumnado, sino exclusivamente el texto de la consulta y, cuando aplica, los *chunks* recuperados de los planes docentes (que son documentos públicos). El cliente `shared/gemini_client.py` centraliza estas llamadas, lo que aporta dos garantías relevantes desde el punto de vista de seguridad y privacidad:

- **Punto único de auditoría:** cualquier llamada saliente al LLM atraviesa el cliente, lo que facilita la inspección de *prompts*, el registro de uso y la aplicación de filtros si fuera necesario.
- **Sustituibilidad del proveedor:** el cliente `shared/ollama_client.py` implementa la misma interfaz, de modo que ante un cambio de política de Google o un escenario que exija inferencia local (por ejemplo, un despliegue institucional sobre infraestructura propia de la US, ver Sección 5.6), se puede conmutar a Ollama sin tocar las acciones de Rasa.

La opción local con Ollama se mantiene, por tanto, como mecanismo de mitigación de riesgo (cambios de cuotas o términos de uso del proveedor cloud) y no como modo de operación por defecto.

8.7– Stack tecnológico completo

La Tabla 8.1 resume las tecnologías empleadas en el proyecto, agrupadas por capa.

Capa	Tecnología	Rol / versión
Frontend (chatbot)	HTML / CSS / JavaScript ES6+	Widget embebible sin <i>framework</i>
Frontend (admin)	HTML / CSS / JavaScript ES6+	SPA ligera contra la API Flask
Servidor web	Nginx (Docker) / Python http.server (local)	Sirve estáticos y <i>reverse proxy</i>
Admin API	Flask (Python 3.10)	API REST de administración (puerto 5050)
Núcleo conversacional	Rasa	3.6.21
Núcleo conversacional	Rasa SDK	3.6.2
Núcleo conversacional	spaCy (es_core_news_md)	3.8.x
LLM principal	Google Gemini (gemma-3-27b-it)	Generación de texto vía API
Embeddings	Google Gemini (gemini-embedding-001)	Vectorización (2000 dims)
LLM alternativo (opcional)	Ollama (llama3.2:3b)	Inferencia local de respaldo
Base de datos	PostgreSQL (gestionada por Supabase)	15.x
Vectorial	pgvector	Extensión PostgreSQL, índice HNSW
Plataforma BD	Supabase Cloud	<i>Connection pooling</i> , panel admin
Librerías NLP	RapidFuzz, python-dotenv	<i>Fuzzy matching</i> , configuración
Despliegue	Docker / Docker Compose	Contenedores reproducibles
Hosting	DigitalOcean (Ubuntu 24.04 LTS)	<i>Droplet</i> de producción
Control versiones	Git & GitHub	Repositorio, CI/CD con Actions
Calidad de código	ESLint, Pylint, Flake8	<i>Linting</i> JS y Python

Cuadro 8.1: Stack tecnológico completo del proyecto LinceUS Assistant.

Nota sobre el modelo `gemma-3-27b-it`. El modelo `gemma-3-27b-it` es el que se utilizó durante toda la fase de desarrollo y validación del prototipo, y por tanto el que sustenta las métricas reportadas en el Capítulo 12 (latencia mediana 3,4 s, coste medio por turno 0,012 céntimos, 216 llamadas medidas). Tras el cierre del prototipo, Google retiró ese modelo de su catálogo público en mayo de 2026 y lo sustituyó por la familia Gemma 4. Para mantener operativo el sistema sin reescribir su pipeline, la constante `GEMINI_MODEL` del cliente (`actions/shared/gemini_client.py`) se actualizó al sucesor más directo dentro de la misma familia, `gemma-4-26b-a4b-it` (arquitectura *Mixture-of-Experts*, ~26 B parámetros activos). Las métricas medidas durante el TFG no se han reproducido sobre el nuevo modelo: dado el carácter conmutable del cliente LLM (Sección 7.4.2), cualquier revalidación posterior bastaría con relanzar la suite del Capítulo 12 sin tocar el resto del sistema.

Estructura del proyecto

Este capítulo describe la organización del repositorio LinceUS Assistant, detallando el propósito de cada directorio relevante. La estructura ha sido diseñada para separar claramente las responsabilidades entre los distintos módulos del sistema y facilitar el mantenimiento y la escalabilidad del proyecto.

9.1– Visión general del repositorio

El repositorio sigue una organización modular en la que cada directorio agrupa elementos con una responsabilidad concreta dentro del sistema. La separación entre la lógica conversacional, los datos de entrenamiento, el pipeline RAG, el panel de administración, la interfaz de usuario y la infraestructura de despliegue responde al principio de separación de responsabilidades (*Separation of Concerns*).

El árbol de directorios principal es el siguiente:

```
linceus-assistant/
+-- actions/                Núcleo conversacional (custom actions Rasa)
|   +-- asignaturas/        Épica de asignaturas
|   |   +-- actions.py       Custom actions de la épica
|   |   \-- text_to_sql.py    Generación y validación de SQL con LLM
|   +-- contexto/           Épica de contexto académico (titulación)
|   +-- fallback/           Épica de fallback inteligente
|   +-- horarios/           Épica de horarios
|   +-- profesores/         Épica de profesorado
|   +-- multi_intent/        Épica desactivada (referencia)
|   +-- shared/             Utilidades transversales
|   |   +-- db.py            Cliente Supabase / PostgreSQL
|   |   +-- gemini_client.py Cliente de Google Gemini
|   |   +-- ollama_client.py Cliente alternativo local
|   |   +-- matching.py       Fuzzy matching de nombres
|   |   +-- follow_up.py      Validación de contexto y seguimiento
|   |   +-- resolver_afirmacion.py
|   |   +-- config.py         Carga de variables de entorno y alias
|   |   \-- logger.py         Logging estructurado
|   \-- actions.py          Punto de entrada con re-exports
+-- admin/                  Panel de administración (API Flask)
|   +-- app.py              Punto de entrada Flask (puerto 5050)
|   +-- db.py               Helpers de BD para el admin
|   +-- routes/             Endpoints REST por dominio
|   |   +-- asignaturas.py   horarios.py profesores.py
|   |   +-- centros.py        titulaciones.py planes_docentes.py
|   |   +-- conversaciones.py sevius.py stats.py
|   +-- sevius_scraper.py    Scraper del catálogo Sevius
|   +-- us_scraper.py         Scraper del directorio de la US
|   +-- us_directorio_scraper.py Scraper auxiliar del directorio US
|   +-- horarios_extractores/ Extractores de horarios por centro
```

```

|  \-- requirements.txt      Dependencias específicas del panel
+-- rag/                    Pipeline de Retrieval-Augmented Generation
|  +-- pipeline.py          Orquestación end-to-end de la vectorización
|  +-- extraer_pdf.py       Extracción de texto de planes docentes
|  +-- chunking.py          Fragmentación con solapamiento
|  +-- embeddings.py        Cliente de embeddings (Gemini)
|  +-- db_vectores.py       Persistencia vectorial sobre pgvector
|  +-- buscar.py            Búsqueda semántica con fallback ILIKE
|  \-- sql/buscar_plan_docente.sql
+-- data/                   Datos de entrenamiento de Rasa
|  +-- nlu/
|  |  +-- asignaturas.yml   Intents de consulta sobre asignaturas
|  |  +-- contexto.yml     Intents de seguimiento contextual
|  |  +-- horarios.yml     Intents de horario
|  |  +-- profesores.yml   Intents de profesorado
|  |  +-- general.yml      Intents transversales (saludo, FAQ, etc.)
|  |  \-- multi_intent.yml.disabled (desactivado)
|  +-- rules.yml            Reglas determinísticas
|  \-- stories.yml          Historias de entrenamiento del Core
+-- frontend/              Widget de chat y panel de administración
|  +-- chatbot-widget.js    Widget embebible
|  +-- chatbot-icon.html    Página de demostración
|  +-- pagina-principal.html / .css  Prototipo institucional
|  +-- admin.html admin.js  admin.css  Panel de administración (SPA)
|  +-- login.html login.js
|  +-- nginx.conf           Configuración de Nginx (Docker)
|  +-- docker-entrypoint.sh
|  \-- linceUS-logo.png logo-us.png
+-- docker/                Infraestructura de despliegue
|  +-- docker-compose.yml
|  +-- Dockerfile.rasa      Imagen del servidor Rasa
|  +-- Dockerfile.actions   Imagen del action server
|  \-- Dockerfile.admin     Imagen de la API Flask de administración
+-- tests/                 Suite de pruebas
|  +-- test_admin.py        Pytest para el panel de administración
|  +-- test_rag.py          Pruebas del pipeline RAG
|  +-- test_stories.yml     Historias de prueba E2E de Rasa
|  +-- run_test_plan.py     Runner de la suite end-to-end
|  +-- plans/               Planes de pruebas (Markdown)
|  +-- results/             Resultados de las últimas corridas
|  \-- scripts/             Benchmarks de coste y latencia
+-- docs/                  Documentación técnica
|  +-- sprints/             Documentación por sprint
|  +-- asignaturas/ other/  Diccionarios y notas de diseño
+-- knowledge_base/         Documentos fuente (planes docentes en PDF)
+-- models/                Modelos entrenados de Rasa (.tar.gz)
+-- memoria_tfg/           Memoria del TFG (LaTeX) y entregables
+-- config.yml             Pipeline NLU y políticas de Rasa
+-- domain.yml             Universo del bot (intents, slots, acciones)
+-- credentials.yml        Canales de comunicación
+-- endpoints.yml          Endpoints de servicios externos
+-- requirements.txt        Dependencias del servidor Rasa
+-- requirements-actions.txt Dependencias adicionales del action server
+-- package.json            Dependencias de herramientas Node (ESLint)
\-- README.md CONTRIBUTING.md LICENSE

```

9.2– Directorio raíz

Los ficheros situados en la raíz del repositorio configuran el comportamiento global del sistema Rasa y la gestión de dependencias del proyecto:

- `config.yml`: Define el pipeline de procesamiento de lenguaje natural (NLU) y las políticas de diálogo de Rasa, incluidos los nueve componentes descritos en la Sección 7.4.8.
- `domain.yml`: Declara el universo del asistente: *intents*, entidades, *slots*, acciones y respuestas predefinidas.
- `credentials.yml`: Configura los canales de comunicación (en este proyecto, REST). Las claves sensibles se gestionan mediante variables de entorno.
- `endpoints.yml`: Configura los endpoints de los servicios externos: *action server*, base de datos y URL del modelo de lenguaje.
- `requirements.txt` y `requirements-actions.txt`: Dependencias Python del servidor Rasa y del *action server* respectivamente, con versiones ancladas.
- `package.json`: Dependencias de herramientas de desarrollo en JavaScript (ESLint).

9.3– Directorio `actions/`

El directorio `actions/` contiene la lógica de negocio del asistente, implementada como acciones personalizadas de Rasa. Cuando el motor conversacional determina que debe ejecutar una acción, invoca el código Python correspondiente a través del *action server* (puerto 5055).

9.3.1. Organización por épicas

A diferencia de la versión inicial del prototipo (en la que toda la lógica residía en un único `actions.py`), el código se organiza en un **módulo por épica funcional**. Cada subdirectorio (`asignaturas/`, `contexto/`, `fallback/`, `horarios/`, `profesores/`) contiene su propio `actions.py` con las clases que implementan los pipelines descritos en el Capítulo 11. El subdirectorio `asignaturas/` aloja además `text_to_sql.py`, que aísla la generación, sanitización y ejecución de las consultas SQL producidas por Gemini (decisión de diseño en la Sección 7.4.1). La épica `multi_intent/` permanece como referencia desactivada (Sección 11.7).

El módulo raíz `actions/actions.py` actúa como punto de entrada y se limita a re-exportar las clases de cada épica para que Rasa las descubra en un único espacio de nombres.

9.3.2. Subdirectorio `shared/`

El subdirectorio `shared/` concentra la complejidad transversal que utilizan varias épicas:

- `db.py`: Cliente de Supabase / PostgreSQL (clase `DatabaseConnection`, instancia `db_client`).
- `gemini_client.py`: Cliente de Google Gemini, con *timeouts*, reintentos y registro de métricas.
- `ollama_client.py`: Cliente alternativo de Ollama con la misma interfaz que el de Gemini.
- `matching.py`: *Fuzzy matching* de nombres normalizados (`rapidfuzz`).
- `follow_up.py`: Validación centralizada del slot `contexto_titulacion` y lógica de seguimiento conversacional.
- `resolver_afirmacion.py`: Manejo del flujo de afirmación (“*sí, esa*”) sobre la última sugerencia.

- `config.py`: Carga de variables de entorno y diccionario de alias y acrónimos (`ALIAS_ASSIGNATURAS`, `TITULACION_MAP`).
- `logger.py`: Logging estructurado para depuración.

9.4– Directorio `admin/`

El módulo `admin/` aloja el **panel de administración**, implementado como una API Flask independiente que se ejecuta en el puerto 5050. Su responsabilidad es ofrecer una interfaz CRUD sobre el dominio académico (centros, titulaciones, asignaturas, profesores, horarios y conversaciones) y orquestar las importaciones desde fuentes externas.

- `app.py`: Punto de entrada Flask. Registra las *blueprints* de `routes/` y expone `/health`.
- `routes/`: Un fichero por dominio (`asignaturas.py`, `centros.py`, `titulaciones.py`, `horarios.py`, `profesores.py`, `planes_docentes.py`, `conversaciones.py`, `sevius.py`, `stats.py`). Cada uno agrupa los endpoints REST de su dominio.
- `db.py`: Helpers de acceso a Supabase específicos del panel (*queries*, ejecución, normalización).
- `sevius_scraper.py`, `us_scraper.py` y `us_directorio_scraper.py`: *Scrapers* del catálogo Sevius y del directorio de profesorado de la Universidad de Sevilla. El scraper auxiliar de directorio se utiliza para resolver correos y despachos cuando el listado principal no los expone.
- `horarios_extractores/`: Extractores de horarios por centro (clase base más implementación específica, hoy disponible solo para la ETSII).
- `requirements.txt`: Dependencias Python específicas del panel (Flask y librerías auxiliares), separadas del *action server* para reducir el peso de su imagen Docker.

9.5– Directorio `rag/`

El directorio `rag/` contiene el **pipeline de Retrieval-Augmented Generation** que vectoriza los planes docentes y soporta la búsqueda semántica. Se ejecuta bajo demanda (no es un servicio permanente) y consume la API de *embeddings* de Gemini.

- `pipeline.py`: Orquestación end-to-end del proceso (extracción → chunking → embeddings → inserción), aplicando el patrón *Pipes and Filters* descrito en el Capítulo 7.
- `extraer_pdf.py`: Extracción de texto y detección de secciones del plan docente.
- `chunking.py`: Fragmentación con la estrategia definida en la Sección 7.4.4.
- `embeddings.py`: Generación de vectores con `gemini-embedding-001` y dimensionalidad reducida.
- `db_vectores.py`: Persistencia y consulta sobre la tabla `plan_docente` con `pgvector`.
- `buscar.py`: Búsqueda semántica con *fallback* a `ILIKE` ante agotamiento de cuota.
- `sql/buscar_plan_docente.sql`: Función SQL almacenada que encapsula la consulta vectorial.

9.6– Directorio `data/`

El directorio `data/` contiene todos los datos de entrenamiento del modelo Rasa. El subdirectorio `nlu/` agrupa los *intents* por dominio en cinco ficheros: `asignaturas.yml`, `horarios.yml`, `profesores.yml`, `contexto.yml` y `general.yml`. El fichero `multi_intent.yml.disabled` permanece como histórico y, por su extensión, no es cargado por Rasa. Los ficheros `stories.yml` y `rules.yml` definen, respectivamente, las historias de entrenamiento del Core y las reglas determinísticas para flujos críticos como el *fallback* o las afirmaciones.

9.7– Directorio `frontend/`

El directorio `frontend/` contiene tanto el **widget de chat** como el **panel de administración**, ambos como aplicaciones HTML/CSS/JS estáticas:

- `chatbot-widget.js`: Widget de chat embebible. Implementa la comunicación con Rasa por HTTP REST, el modal de selección de titulación y el renderizado Markdown.
- `chatbot-icon.html`, `pagina-principal.html`, `pagina-principal.css`: Páginas de demostración y prototipo institucional.
- `admin.html`, `admin.js`, `admin.css`: Panel SPA que consume la API Flask del módulo `admin/`.
- `login.html`, `login.js`: Pantalla de autenticación del panel.
- `nginx.conf` y `docker-entrypoint.sh`: Configuración del servidor web Nginx para el despliegue en contenedor.

9.8– Directorio `docker/`

El directorio `docker/` agrupa la infraestructura reproducible de despliegue. El fichero `docker-compose.yml` orquesta los cuatro servicios principales (Rasa, *action server*, API `admin` y Nginx), mientras que los tres *Dockerfile* (`rasa`, `actions` y `admin`) definen las imágenes correspondientes. Esta separación entre código y empaquetado permite levantar el sistema completo con `docker compose up` sin instalar dependencias en la máquina anfitriona.

9.9– Directorios `tests/` y `docs/`

`tests/` contiene la suite de pruebas (`test_admin.py` con Pytest, `test_rag.py`, `test_stories.yml` con el formato nativo de Rasa, el *runner* `run_test_plan.py` y los *benchmarks* de `scripts/`). Los planes y los resultados de las corridas se almacenan en `plans/` y `results/` respectivamente, y se referencian individualmente en el Capítulo 12.

`docs/` agrupa la documentación técnica generada durante el desarrollo: documentación por sprint, diccionarios del sistema, notas de diseño y planes de implementación. `knowledge_base/` aloja los planes docentes en PDF que el *pipeline* RAG vectoriza. `models/` guarda los modelos entrenados de Rasa, y `memoria_tfg/` contiene la presente memoria en LaTeX y los entregables asociados.

9.10– Separación de responsabilidades

La estructura del repositorio refleja una separación clara entre los distintos módulos del sistema:

- **Mantenibilidad:** Cada módulo puede modificarse de forma independiente sin afectar al resto del sistema, siempre que se respete la interfaz entre capas.
- **Testabilidad:** Los módulos de acceso a datos y de clientes de IA pueden probarse de forma aislada mediante *mocks*, como demuestra la suite `test_admin.py` (Capítulo 12).
- **Escalabilidad:** Añadir soporte para nuevas épicas (por ejemplo, ampliar el dominio a otros centros de la Universidad de Sevilla) implica crear un nuevo subdirectorio en `actions/` y ampliar los datos en `data/nlu/`, sin modificar la arquitectura existente.
- **Reproducibilidad:** La combinación de Docker, ficheros de *requirements* con versiones ancladas y separación entre código y configuración permite que cualquier desarrollador reconstruya el entorno completo con un único comando.

Estructura de la base de datos

Este capítulo describe el diseño y la estructura de la base de datos de LinceUS Assistant. La base de datos constituye el núcleo del sistema, almacenando toda la información académica necesaria para responder a las consultas de los estudiantes.

10.1– Diseño conceptual

El diseño de la base de datos se ha estructurado siguiendo el modelo relacional propuesto por Codd [85], organizando la información en entidades que representan los elementos principales del dominio universitario: universidades, centros, titulaciones, asignaturas, profesores y horarios.

10.1.1. Principios de diseño

El esquema de base de datos se ha diseñado siguiendo los siguientes principios:

1. **Normalización:** Las tablas están normalizadas hasta la tercera forma normal (3NF) para evitar redundancia y mantener la integridad referencial
2. **Escalabilidad:** El diseño permite añadir nuevas universidades, centros y titulaciones sin modificar la estructura
3. **Flexibilidad:** Campos de metadatos en formato JSONB permiten almacenar información variable sin alterar el esquema
4. **Búsqueda semántica:** Tablas de chunks con vectores de embeddings para búsqueda basada en similitud
5. **Trazabilidad:** Campos de timestamp (created_at, updated_at) en todas las tablas principales

10.2– Modelo entidad-relación

El modelo entidad-relación [86] ofrece una representación gráfica del dominio que media entre los requisitos del usuario y el esquema relacional implementado en PostgreSQL.

A continuación se detallan las principales entidades y sus relaciones del sistema.

10.3– Entidades principales

10.3.1. Universidades

La tabla UNIVERSIDADES almacena la información básica de cada universidad. Aunque el sistema está diseñado inicialmente para la Universidad de Sevilla, la estructura permite incorporar múltiples instituciones.

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
codigo	varchar	Código de la universidad (e.g., ÛS’')
nombre	varchar	Nombre completo de la universidad
nombre_corto	varchar	Nombre abreviado
dominio_web	varchar	Dominio web oficial (e.g., ùs.es’')
ciudad	varchar	Ciudad donde se ubica
activa	boolean	Indica si está operativa
created_at	timestampz	Fecha de creación del registro
updated_at	timestampz	Fecha de última actualización

Cuadro 10.1: Estructura de la tabla UNIVERSIDADES

10.3.2. Centros

Los centros representan las escuelas y facultades de cada universidad (e.g., ETSII, Facultad de Química).

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
universidad_id	uuid	Referencia a UNIVERSIDADES (FK)
codigo	varchar	Código del centro (e.g., . ^{ETSII})
codigo_sevius	varchar	Código del centro en Sevius
codigo_us	varchar	Código oficial del centro en la US
nombre	varchar	Nombre completo del centro
nombre_corto	varchar	Nombre abreviado
direccion	varchar	Dirección física del centro
telefono	varchar	Teléfono de contacto
email	varchar	Email de contacto
web	varchar	URL del sitio web del centro
activo	boolean	Indica si está operativo
created_at	timestampz	Fecha de creación del registro
updated_at	timestampz	Fecha de última actualización

Cuadro 10.2: Estructura de la tabla CENTROS

10.3.3. Departamentos

Los departamentos son unidades organizativas que agrupan profesores e imparten asignaturas.

10.3.4. Titulaciones

Las titulaciones representan los grados, másteres y doctorados ofrecidos por los centros.

10.3.5. Asignaturas

Las asignaturas son las materias que componen cada titulación.

El campo `nombre_normalizado` facilita la búsqueda tolerante a errores, mientras que `palabras_clave` permite búsquedas por términos relacionados.

10.3.6. Profesores

La tabla de profesores almacena la información del personal docente.

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
universidad_id	uuid	Referencia a UNIVERSIDADES (FK)
centro_id	uuid	Referencia a CENTROS (FK)
codigo	varchar	Código del departamento
codigo_us	varchar	Código oficial del departamento en la US
nombre	varchar	Nombre completo
siglas	varchar	Siglas del departamento (e.g., "LSI")
email	varchar	Email de contacto
web	varchar	URL del sitio web
activo	boolean	Indica si está operativo
created_at	timestampz	Fecha de creación del registro
updated_at	timestampz	Fecha de última actualización

Cuadro 10.3: Estructura de la tabla DEPARTAMENTOS

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
centro_id	uuid	Referencia a CENTROS (FK)
codigo	varchar	Código interno (e.g., "GII-IS")
codigo_oficial	varchar	Código RUCT oficial
nombre	varchar	Nombre completo de la titulación
nombre_corto	varchar	Nombre abreviado
tipo	varchar	GRADO, MASTER o DOCTORADO
plan_estudios_anio	int	Año del plan de estudios vigente
creditos_totales	int	Créditos ECTS totales
duracion_anios	int	Duración en años
requisito_idioma	varchar	Nivel de idioma requerido (e.g., "B1")
activa	boolean	Indica si está vigente
created_at	timestampz	Fecha de creación del registro
updated_at	timestampz	Fecha de última actualización

Cuadro 10.4: Estructura de la tabla TITULACIONES

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
titulacion_id	uuid	Referencia a TITULACIONES (FK)
departamento_id	uuid	Referencia a DEPARTAMENTOS (FK)
codigo	varchar	Código de la asignatura
nombre	varchar	Nombre oficial de la asignatura
curso	int	Curso en el que se imparte (1-4)
creditos	decimal	Créditos ECTS
duracion	varchar	A (anual), C1 (1er cuatr.), C2 (2º cuatr.)
tipologia	varchar	TRONCAL, OBLIGATORIA, OP-TATIVA
es_formacion_basica	boolean	Si es de formación básica
es_optativa	boolean	Si es optativa
nombre_normalizado	varchar	Nombre sin tildes ni mayúsculas
palabras_clave	text[]	Array de palabras clave
activa	boolean	Indica si está vigente
created_at	timestampz	Fecha de creación del registro
updated_at	timestampz	Fecha de última actualización

Cuadro 10.5: Estructura de la tabla ASIGNATURAS

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
departamento_id	uuid	Referencia a DEPARTAMENTOS (FK)
centro_id	uuid	Referencia a CENTROS (FK)
nombre	varchar	Nombre del profesor
apellidos	varchar	Apellidos del profesor
nombre_completo	varchar	Nombre completo (generado)
nombre_normalizado	varchar	Versión normalizada para búsqueda
categoria_academica	varchar	Catedrático, Titular, Contratado Doctor, etc.
email	varchar	Email de contacto
telefono	varchar	Teléfono de contacto
despacho	varchar	Número de despacho (e.g., "F1.45")
edificio	varchar	Edificio donde se ubica
planta	varchar	Planta del despacho
web_personal	varchar	URL de página personal
enlace_perfil	varchar	URL del perfil en la web del departamento
orcid	varchar	Identificador ORCID
activo	boolean	Indica si está en activo
created_at	timestampz	Fecha de creación del registro
updated_at	timestampz	Fecha de última actualización

Cuadro 10.6: Estructura de la tabla PROFESORES

10.3.7. Horarios

Los horarios relacionan grupos de clase con aulas, profesores y franjas horarias.

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
grupo_id	uuid	Referencia a GRUPOS.CLASE (FK)
aula_id	uuid	Referencia a AULAS (FK)
profesor_id	uuid	Referencia a PROFESORES (FK)
día_semana	int	Día de la semana (1-5)
hora_inicio	time	Hora de inicio de la clase
hora_fin	time	Hora de fin de la clase
fecha_inicio	date	Fecha de inicio del periodo
fecha_fin	date	Fecha de fin del periodo
cuatrimestre	varchar	Cuatrimestre académico (C1, C2 o anual)
notas	text	Observaciones
activo	boolean	Indica si está vigente
created_at	timestampz	Fecha de creación del registro
updated_at	timestampz	Fecha de última actualización

Cuadro 10.7: Estructura de la tabla HORARIOS

10.4– Tablas de vectorización (RAG)

Para implementar el sistema RAG (*Retrieval-Augmented Generation*), se han diseñado tablas especializadas que almacenan fragmentos de documentos junto con sus representaciones vectoriales.

10.4.1. Planes docentes

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
asignatura_id	uuid	Referencia a ASIGNATURAS (FK)
curso_academico	varchar	Curso académico (e.g., "2025-26")
grupo	varchar	Grupo al que corresponde
url_documento	varchar	URL del PDF original
hash_documento	varchar	Hash SHA256 del documento
fecha_documento	date	Fecha del documento
coordinador_nombre	varchar	Nombre del coordinador
estado_rag	varchar	pendiente, procesando, completado, error
fecha_procesamiento	timestampz	Fecha de procesamiento
error_procesamiento	text	Mensaje de error si lo hay
created_at	timestampz	Fecha de creación del registro
updated_at	timestampz	Última actualización

Cuadro 10.8: Estructura de la tabla PLANES_DOCENTES

Campo	Tipo	Descripción
id	uuid	Identificador único (PK)
plan_docente_id	uuid	Referencia a PLANES_DOCENTES (FK)
contenido	text	Texto del fragmento
embedding	vector	Vector de 768 dimensiones
seccion	varchar	Sección del documento (e.g., “Evaluación”)
subseccion	varchar	Subsección si aplica
numero_pagina	int	Número de página del PDF
orden_chunk	int	Orden del chunk en el documento
metadata	jsonb	Metadatos adicionales en formato JSON
created_at	timestamptz	Fecha de creación del registro
updated_at	timestamptz	Última actualización

Cuadro 10.9: Estructura de la tabla PLANES_DOCENTES_CHUNKS

10.4.2. Chunks de planes docentes

El campo `embedding` utiliza el tipo `vector` proporcionado por la extensión `pgvector` y almacena vectores de 768 dimensiones, valor coherente con los modelos derivados de la familia BERT [87] que producen representaciones densas en ese tamaño. Los vectores se generan usando modelos de embeddings especializados y permiten búsquedas de similitud semántica mediante consultas como:

```
SELECT contenido, embedding <=> query_vector AS distance
FROM planes_docentes_chunks
ORDER BY distance
LIMIT 5;
```

10.5– Relaciones entre entidades

Las principales relaciones del modelo son:

- Una **universidad** agrupa múltiples **centros** y **departamentos** (FK `universidad_id` en ambos).
- Un **centro** ofrece múltiples **titulaciones** (FK `centro_id` en TITULACIONES) y aloja múltiples **aulas**. Adicionalmente, un departamento queda adscrito a un centro a través de la FK `centro_id` en DEPARTAMENTOS.
- Una **titulación** contiene múltiples **asignaturas** (FK `titulacion_id`).
- Una **asignatura** es impartida por un **departamento** (FK `departamento_id`) y tiene múltiples **planes docentes** (FK `asignatura_id` en PLANES_DOCENTES) y **grupos de clase**.
- Un **departamento** agrupa a múltiples **profesores** (FK `departamento_id`). El profesor también queda asociado a un **centro** mediante la FK `centro_id` en PROFESORES, lo que facilita las consultas que filtran por escuela sin tener que recorrer el departamento.
- Un **profesor** imparte múltiples **asignaturas** y está asignado a **horarios** (FK `profesor_id` en HORARIOS).

- Un **grupo de clase** tiene un conjunto de **horarios** asociados (FK `grupo_id`).
- Un **horario** relaciona un **grupo** (FK `grupo_id`), un **aula** (FK `aula_id`) y un **profesor** (FK `profesor_id`), e incluye el `cuatrimestre` para distinguir las sesiones del mismo grupo en periodos académicos distintos.
- Un **plan docente** se descompone en múltiples **chunks** para vectorización (FK `plan_docente_id` en `PLANES_DOCENTES_CHUNKS`, con `ON DELETE CASCADE`).

Todas las tablas principales registran además `created_at` y `updated_at` (`timestampz`) para auditar la trazabilidad temporal de cada registro, en línea con el principio enunciado en la Sección 10.1.

10.6– Índices y optimización

La estrategia de indexación cubre tres tipos de acceso según el patrón de consulta:

- **B-tree (PKs y FKs):** Índice de árbol B [88], el tipo de índice estándar de PostgreSQL [89] para búsquedas de igualdad, rango y ordenación. Se aplican índices únicos en todas las claves primarias (`_pkey`) y en las claves foráneas más consultadas (`titulacion_id`, `grupo_id`, `profesor_id`, `departamento_id`, etc.), más índices adicionales sobre campos de filtrado frecuente como `codigo`, `curso`, `dia_semana` o `estado_rag`.
- **GIN trigram:** Índice invertido generalizado (*Generalized Inverted Index*) que particiona el texto en trigramas de caracteres y permite localizar coincidencias parciales sin recorrer la tabla completa [90]. El campo `nombre_normalizado` de `ASIGNATURAS` lleva un índice `gin_trgm_ops` además del B-tree, lo que permite búsquedas `ILIKE` eficientes sin exploración secuencial. Este índice es la base del *fallback* por palabras clave del pipeline RAG (Sección 7.4.5).
- **HNSW:** Índice *Hierarchical Navigable Small World* [32], una estructura de grafo multicapa que organiza los vectores según su similitud y permite localizar los vecinos más cercanos recorriendo solo una fracción del espacio. El campo `embedding` de `PLANES_DOCENTES_CHUNKS` usa este tipo con parámetros $m = 16$ y `ef_construction = 64` (Sección 7.4.3), ofreciendo búsqueda aproximada de vecinos más cercanos en tiempo sub-lineal.

El índice HNSW sobre los chunks de planes docentes se crea así:

```
CREATE INDEX idx_chunks_embedding_hnsw
ON planes_docentes_chunks
USING hnsw (embedding vector_cosine_ops)
WITH (m = 16, ef_construction = 64);
```

10.7– Integridad referencial

Todas las relaciones entre tablas están protegidas por restricciones de clave foránea con políticas de borrado apropiadas:

- **ON DELETE CASCADE:** En relaciones donde el hijo no tiene sentido sin el padre (e.g., `chunks` sin `plan docente`)
- **ON DELETE RESTRICT:** En relaciones donde se debe prevenir el borrado accidental (e.g., no borrar una universidad con centros asociados)

- **ON DELETE SET NULL:** En relaciones opcionales donde el padre puede desaparecer sin eliminar al hijo

10.8– Estrategia de datos de prueba

Para el desarrollo y pruebas del sistema se han creado datos de prueba que incluyen:

- Universidad de Sevilla con varios centros (ETSII, Facultad de Informática)
- Titulaciones de Ingeniería Informática (IS, IC, TI)
- Conjunto representativo de asignaturas de cada titulación
- Profesores del Departamento de Lenguajes y Sistemas Informáticos
- Horarios del curso 2025-2026
- Planes docentes oficiales de las asignaturas vectorizados en el corpus RAG

Los datos de prueba permiten validar el funcionamiento del sistema sin necesidad de tener acceso a datos reales completos.

Implementación

Este capítulo describe cómo se han traducido las decisiones de diseño en código operativo. La descripción no se centra en el detalle de cada función, sino en el *pipeline de ejecución* que sigue cada épica desde que el usuario envía un mensaje hasta que el asistente devuelve una respuesta. Cada épica se presenta con un diagrama del flujo y una explicación de los puntos clave: cómo se extraen los datos del mensaje, qué papel juegan la base de datos y el modelo de lenguaje, y qué información se persiste para mantener el contexto en turnos posteriores.

El código se organiza en una carpeta `actions/` con un módulo por épica activa (asignaturas, profesores, horarios, contexto, fallback) más el módulo `multi_intent` que permanece como referencia desactivada (Sección 11.7), y una carpeta `shared/` con utilidades transversales: conexión a Supabase (`db.py`), cliente de Gemini (`gemini_client.py`), *fuzzy matching* de nombres (`matching.py`) y configuración de alias (`config.py`). Los pipelines descritos a continuación se apoyan en estos módulos compartidos.

11.1– Anatomía común de una *custom action*

Antes de entrar en cada épica, conviene fijar el patrón al que responden todas las acciones del proyecto. Una *custom action* de Rasa es una clase Python que hereda de `Action` y expone un método `run(dispatcher, tracker, domain)`. Esta estructura responde al patrón *Template Method* [91]: la clase base define el esqueleto del algoritmo y cada subclase (cada épica) especializa los pasos concretos. Dentro de ese método, todas las épicas siguen una misma secuencia de cinco pasos.

1. **Validación de contexto:** si la consulta requiere titulación y el slot `contexto_titulacion` está vacío, la acción interrumpe el flujo y muestra los botones de selección de titulación. Esta comprobación está centralizada en `shared/followup.py` y se aplica en las épicas de asignaturas y horarios; la épica de profesores lee el slot si está presente para filtrar los resultados, pero no interrumpe el flujo cuando está vacío, ya que muchas consultas sobre profesorado no están ligadas a una titulación concreta.
2. **Extracción y normalización:** se leen las entidades NLU del último mensaje y los slots persistentes. Los nombres se normalizan con NFKD (eliminación de tildes), paso a minúsculas y limpieza de partículas (*de, del, la, info*). Los acrónimos (*FP, ADDA, DPI*) se expanden contra el diccionario `ALIAS_ASIGNATURAS` de `shared/config.py`.
3. **Resolución:** con el dato extraído se busca en la base de datos. Cuando hay varias coincidencias se aplica *fuzzy matching* (`rapidfuzz`) para descartar falsos positivos. En consultas que no se pueden expresar como filtro estructurado (por ejemplo, contenido del plan docente), se delega en el pipeline RAG.

4. **Generación de respuesta:** los datos recuperados se entregan al modelo Gemini junto con un prompt específico de la épica. Gemini se encarga de redactar la respuesta en lenguaje natural respetando un límite de 1500 caracteres. Si la llamada falla, cada épica dispone de una plantilla *hardcoded* de respaldo.
5. **Persistencia de contexto:** la acción devuelve una lista de eventos `SlotSet` para guardar lo que pueda ser relevante en turnos siguientes (último código consultado, último profesor, curso o grupo) y la marca `ultima_action_ejecutada`, que el sistema de seguimiento usa para discriminar consultas de tipo “hay más”.

Los diagramas que siguen utilizan tres colores para diferenciar el tipo de operación: **teal** para pasos de procesamiento sobre datos del usuario, **rojo** para llamadas al modelo de lenguaje y **naranja** para accesos a base de datos.

11.2– Épica de asignaturas

La épica de asignaturas concentra cinco acciones: `ActionConsultaEspecifica` (consulta sobre una asignatura concreta), `ActionConsultaListado` (listado filtrado), `ActionConsultaConteo` (conteo), `ActionMostrarTodasAsignaturas` (volcado completo del plan de la titulación) y `ActionConsultaHorarioAsignatura` (horario por nombre de asignatura). La consulta específica es la más compleja y articula la lógica de resolución de nombre que reutilizan el resto de épicas.

11.2.1. Consulta específica de asignatura

La acción `ActionConsultaEspecifica` responde a preguntas del tipo “¿cuántos créditos tiene Redes?” o “¿cómo se evalúa Ingeniería del Software II?”. Su pipeline (Figura 11.1) se descompone en dos bloques lógicos: primero **resolver** a qué asignatura concreta se refiere el usuario, y después **decidir** si la respuesta vive en la tabla relacional o en el plan docente.




Figura 11.1: Pipeline de ActionConsultaEspecific. La caja *Resolver asignatura* encapsula la cascada de cinco estrategias detallada en el Listado 11.1.

Resolución del nombre de asignatura. La función `resolver_asignatura()` (en `actions/asignaturas/actions.py`) es la pieza más reutilizada del proyecto, porque el resto de épicas (horarios, profesores, fallback) la invocan para identificar la asignatura aludida por el usuario. Aplica una cascada de cinco estrategias en orden de mayor a menor confianza, y se detiene en la primera que devuelve un candidato fiable. El Listado 11.1 muestra el esqueleto de esa cascada.

```

1 def resolver_asignatura(pregunta, tracker, contexto, seguir=True):
2     # 1. Entidad NLU del ultimo mensaje (extractor de Rasa)
3     nombre = extraer_nombre_asignatura(tracker, ...)
4
5     # 2. Expansion de acronimo (FP -> Fundamentos...)
6     if nombre:
7         nombre = _expandir_alias(nombre, contexto)
8
9     # 3. Sin entidad NLU: regex sobre alias en el texto crudo
10    if not nombre:
11        for alias in sorted(ALIAS, key=len, reverse=True):
12            patron = r"\b" + re.escape(alias) + r"\b"
13            if re.search(patron, pregunta.lower()):
14                nombre = _expandir_alias(alias, contexto)
15                break
16
17    # 4. Seguimiento: heredar slot si <=3 turnos atras
18    if seguir and not nombre:
19        slot = "ultimo_nombre_asignatura"
20        if _turnos_desde_slot(tracker, slot) <= 3:
21            nombre = tracker.get_slot(slot)
22
23    # 5. Fuzzy matching contra nombres de la BD (umbral 85)
  
```

```

24     if not nombre:
25         nombre = _resolver_desde_texto(pregunta, contexto)
26
27     # SELECT con ILIKE; si vacío, fuzzy reordering por
28     # token_set_ratio contra la pregunta original.
29     ...

```

Código 11.1: Cascada de resolución de `resolver_asignatura()`.

Las cinco etapas no son intercambiables: el orden refleja una jerarquía de confianza. La entidad NLU (etapa 1) es la fuente más fiable porque el modelo de *DIET Classifier* ya ha decidido que ese fragmento es un nombre de asignatura. La expansión de alias (etapa 2) traduce acrónimos como *FP* o *ADDA* a sus nombres canónicos antes de cualquier búsqueda. Si no hay entidad, una pasada por regex (etapa 3) intenta detectar alias en el texto crudo. La etapa 4 cubre las preguntas elípticas (“¿y los créditos?”) heredando el último nombre consultado, siempre que sea reciente. Solo cuando todo lo anterior falla se recurre al *fuzzy matching* contra los nombres normalizados de la base de datos (etapa 5), que es la estrategia más permisiva pero también la más propensa a confundir *Administración* con *Ampliación de Administración*; por eso es el último recurso.

Saneamiento de la entidad NLU antes de la cascada. La etapa 1 incluye una limpieza específica del valor que devuelve el extractor de entidades, implementada en `extraer_nombre_asignatura()`. El *DIET Classifier* en ocasiones marca como `nombre_asignatura` tokens que en realidad son partículas (*info*, *datos*, *hablame*, *sobre*) o fragmentos de la titulación inline (*software*, *computadores*, *ingeniería*, *grado*, *tecnologías*); la función descarta estas listas hard-codeadas, elimina sufijos vacíos (*de*, *del*, *la*, *el*, *las*, *los*) de forma iterativa y, si tras la limpieza siguen quedando varias entidades, se queda con la más larga. Este saneamiento evita que una consulta como “*info de Software*” (refiriéndose al grado) acabe disparando la búsqueda de una asignatura llamada *Software*, un falso positivo que se observó de forma sistemática durante la fase de validación interna.

Match exacto antes del fuzzy. El paso final de `resolver_asignatura()`, una vez ejecutado el `SELECT` con `ILIKE`, contempla el caso de coincidencias múltiples. Antes de aplicar `token_set_ratio` sobre la pregunta completa, la función comprueba si alguna fila se llama *exactamente* igual al nombre que se está resolviendo (tras la normalización) y, si la hay, la devuelve sin reordenar. Esta comprobación evita un error sistemático en el seguimiento conversacional cuando un nombre de asignatura es prefijo de otro: sin ella, *Administración de Empresas* se reordena hacia *Ampliación de Administración de Empresas* porque el `ILIKE %administracion%` trae ambas filas y el *fuzzy* las puntúa muy parecido. La regla aplica a varios pares conocidos: *AE/AAE*, *IA/AIA*, *BD/CBD*, *IS/ISPP*.

Detección de consultas con dos asignaturas. `ActionConsultaEspecifica` contempla una rama complementaria para frases del tipo “*diferencia entre DPI y PSG2*” o “*cómo se evalúan ISPP e IS*”. Una función auxiliar (`_extraer_múltiples_nombres`) busca el patrón `[alias] (y|,|e) [alias]` sobre el texto crudo, expande cada coincidencia contra el diccionario de alias y, si recupera al menos dos asignaturas válidas, deriva a un flujo paralelo (`_run_multi`) que invoca el RAG para cada una etiquetando los *chunks* con el nombre de la asignatura de origen. La respuesta final agrupa los fragmentos por asignatura para que el redactor de Gemini pueda contrastar la información sin mezclarla.

Bifurcación entre datos estructurales y plan docente. Una vez identificada la asignatura, el pipeline elige rama según la naturaleza de la pregunta. Una pregunta sobre datos estructurales (créditos, curso, tipología, duración) se resuelve con el `SELECT` ya ejecutado durante la resolución y se

entrega a Gemini para que redacte una frase natural. Una pregunta sobre contenido del plan docente (evaluación, temario, metodología, bibliografía) requiere recuperación vectorial: la consulta se transforma en *embedding* con `gemini-embedding-001` (vector de 2 000 dimensiones, reducido desde los 3 072 nativos para encajar con holgura en el índice HNSW de `pgvector`), se recuperan los *chunks* más similares de la tabla `planes_docentes_chunks` y, antes de entregarlos a Gemini, se aplica un proceso de *reranking* aditivo: los fragmentos cuya sección del plan docente coincide con el tipo de consulta detectado (evaluación, profesorado, contenidos, etc.) reciben una bonificación sobre su puntuación de similitud coseno, lo que mejora la relevancia del contexto seleccionado sin descartar ningún *chunk* potencialmente útil. El mecanismo completo se detalla en la Sección 11.9.3.

La decisión entre las dos ramas la toma un clasificador en dos pasos. Primero se aplica una heurística rápida basada en palabras clave (*evalúa, temario, bibliografía, competencias, metodología*); si la heurística no es concluyente, se invoca a Gemini con un *prompt* específico de clasificación binaria a temperatura cero. Este diseño evita llamadas innecesarias al LLM en los casos triviales y mantiene la precisión cuando la frase es ambigua.

11.2.2. Listado y conteo de asignaturas

Las acciones `ActionConsultaListado` y `ActionConsultaConteo` responden a consultas agregadas: “*dame las optativas de cuarto*” o “*¿cuántas asignaturas tiene primero?*”. Su pipeline (Figura 11.2) se basa en una técnica *text-to-SQL*: se delega en Gemini la generación de la consulta SQL a partir del enunciado del usuario.




Figura 11.2: Pipeline de listado y conteo (*text-to-SQL*).

Toda esta lógica vive en `actions/asignaturas/text_to_sql.py`, separada del archivo `actions.py` de la épica para mantener pequeño el módulo principal y reutilizable el flujo de generación de SQL desde otras épicas (la consulta de profesores reaprovecha la misma cadena de

prompt, validador e inyector de `titulacion_id`).

El SQL generado por el modelo no se ejecuta directamente. Pasa por un validador propio (`validar_sql`) que aplica cuatro comprobaciones en cascada antes de admitir la sentencia. Primero, exige que la cadena empiece por `SELECT` en mayúsculas tras la normalización, lo que descarta de plano cualquier intento de `INSERT`, `UPDATE`, `DELETE`, `DROP`, `ALTER`, `CREATE`, `TRUNCATE` o `EXEC`. Segundo, rechaza la presencia de catorce patrones que el corpus de OWASP [77] identifica como vectores comunes de inyección SQL: `--` y `;` (comentarios de finalización de sentencia), `UNION SELECT`, `OR 1=1` y `OR '1'='1'` (saltos lógicos del `WHERE`), `SLEEP()` y `BENCHMARK()` (ataques temporizados), y de nuevo todos los verbos de modificación de datos por si aparecen anidados. Tercero, contrasta los nombres de las tablas referenciadas contra una lista blanca (*asignaturas*, *titulaciones* para esta época) y rechaza cualquier acceso fuera de ella. Cuarto, valida que las columnas seleccionadas pertenezcan al conjunto `COLUMNAS_PERMITIDAS` definido en el propio módulo, lo que cierra la posibilidad de exfiltrar campos sensibles incluso desde una tabla autorizada. Para la acción de conteo, el validador exige además que la proyección sea exactamente `COUNT(*)` para evitar agregaciones inesperadas como `COUNT(email)`.

Tras la validación, un paso adicional inyecta automáticamente el filtro `titulacion_id` a partir del slot `contexto.titulacion`, para que un usuario que ha elegido GII-IS no reciba resultados de GII-TI. La inyección no *hardcodea* el UUID de la titulación: si el SQL contiene una cláusula `WHERE activa = true`, se le añade `AND titulacion_id = (SELECT id FROM titulaciones WHERE codigo = %s LIMIT 1)` y se pasa el código de titulación como parámetro de `psycopg2`; si no existe esa cláusula, el filtro se inserta al inicio del `WHERE`. La sub-consulta parametrizada evita exponer los identificadores internos y aprovecha la barrera nativa de `psycopg2` contra la inyección, que es la segunda línea de defensa cuando el validador anterior deja pasar algo.

Solo entonces se ejecuta la consulta con `psycopg2` y se entrega el resultado a Gemini para la redacción final, que avisa explícitamente cuando la respuesta es una muestra paginada.

La acción de conteo es estructuralmente idéntica pero el *prompt* instruye al modelo para devolver `SELECT COUNT(*)`. Si la pregunta hace referencia a una asignatura específica con palabras propias del plan docente (“¿cuántos temas tiene FP?”), la heurística delega en `ActionConsultaEspecifica` en vez de generar un `COUNT`, porque la respuesta correcta proviene del documento, no de la base relacional.

11.2.3. Horario por asignatura

`ActionConsultaHorarioAsignatura` responde a “¿cuándo tengo Redes?” o “aula de ADDA grupo I”. Reutiliza la resolución de nombre de la consulta específica y añade detección de grupo y cuatrimestre. El cuatrimestre se infiere de la fecha actual (septiembre–enero implica primer cuatrimestre, febrero–julio el segundo) salvo que el usuario lo indique explícitamente. La consulta SQL hace `JOIN` entre `horarios`, `grupos_clase`, `asignaturas` y `aulas`; tras decisión D-068, cada aula es una fila distinta, lo que permite separar limpiamente sesiones de teoría y de laboratorio en el formateo final.

11.3– Épica de profesores

`ActionConsultaProfesor` responde a un abanico amplio de consultas sobre el profesorado: correo, despacho, departamento, profesores que imparten una asignatura concreta o, indirectamente, tutorías. El pipeline tiene dos vías de resolución, *text-to-SQL* sobre la tabla `profesores` y RAG vectorial sobre el plan docente, y la acción decide entre ellas en tres puntos distintos del flujo. La Figura 11.3 resume su estructura.




Figura 11.3: Pipeline de ActionConsultaProfesor. Tres puntos de decisión derivan al RAG: rol (*coordinador/suplente*), grupo concreto, o resultado SQL vacío como último recurso.

Conviene precisar qué hay y qué no hay en la base relacional, porque los tres puntos de decisión RAG responden a esta limitación concreta. La tabla `profesor_asignatura` *sí* está poblada y se utiliza activamente: un sincronizador de docencia recorre el directorio del PDI de `us.es` e inserta una fila por cada par (profesor, asignatura) que el portal expone para el curso académico vigente. Sin embargo, el `INSERT` solo rellena cuatro columnas (`profesor_id`, `asignatura_id`, `curso_academico` y un identificador), y deja a `NULL` otras tres que el portal no publica con la granularidad necesaria: `grupo`, `es_coordinador` y `tipo_docencia`. La única fuente fiable de esas tres dimensiones es el plan docente que cada departamento sube como PDF a la web de la asignatura, y de ahí parten los tres atajos.

El primer atajo se dispara cuando la pregunta menciona explícitamente *coordinador* o *suplente*, datos que viven en el plan docente y no en la columna (vacía) `es_coordinador`. El segundo, cuando combina asignatura y un grupo concreto (“*profesores de Redes en el grupo 2*”): SQL no puede filtrar por grupo porque la columna `grupo` también está vacía. El tercero es un fallback que rescata la consulta cuando el text-to-SQL devuelve cero filas pero el usuario sí ha mencionado una asignatura; cubre los casos en que la asignación profesor–asignatura del plan docente todavía no se ha sincronizado a `profesor_asignatura` o el nombre que dio el usuario no *matchea* ninguna fila del JOIN. El Listado 11.2 muestra los dos primeros atajos tal como están implementados.

```

1 # Atajo 1: rol coordinador/suplente -> RAG directo
2 if codigo_asig and _menciona_rol_rag(pregunta):
3     chunks = _rag_chunks_plan(
4         codigo_asig, grupo=grupo_detectado,
5     )
6     if chunks:
7         respuesta = _generar_respuesta_rag(
8             pregunta, chunks, nombre_asig,
9         )
10        if respuesta:
11            dispatcher.utter_message(text=respuesta)
12            return [...]
13        # Si el RAG no responde, cae al flujo SQL normal.
14
15 # Atajo 2: asignatura + grupo concreto -> RAG con filtro
16 if (codigo_asig and grupo_detectado
17     and not _menciona_rol_rag(pregunta)):
18     chunks = _rag_chunks_plan(
19         codigo_asig, grupo=grupo_detectado,
20     )
21     # ... mismo patron con fallback a SQL.

```

Código 11.2: Atajos a RAG en `ActionConsultaProfesor`.

La vía *text-to-SQL* es estructuralmente idéntica a la de la época de asignaturas (mismo *prompt* de generación, mismo validador, misma inyección de `titulacion_id`), con dos peculiaridades propias. La primera es la herencia agresiva de contexto: si el usuario dice “¿y su correo?” sin nombrar a nadie, la acción lee `ultimo_profesor_consultado` y `ultimo_nombre_asignatura` de los últimos tres turnos para reconstruir la consulta. La segunda es el filtrado por similitud: cuando el usuario pregunta por nombre, los resultados del `SELECT` pasan por `shared/matching.py`, que calcula la proporción de tokens de la pregunta presentes en el `nombre_normalizado` de cada profesor y los separa en firmes ($\text{umbral} \geq 0,60$) y sugerencias (entre 0,30 y 0,60). Si no hay coincidencias firmes pero sí sugerencias, la mejor se guarda en el slot `ultima_sugerencia` para que el usuario la confirme con un “sí” en el siguiente turno; este flujo de afirmación está implementado en `ActionResolverAfirmacion`.

Las tutorías merecen una nota: la tabla `tutorias` permanece deliberadamente vacía (decisión D-061), aunque dos de los cuatro departamentos de la ETSII (CCIA y DTE) sí publican horarios de tutoría en páginas propias y el repositorio incluye *scrapers* funcionales que los extraen

a JSON (57 profesores cubiertos). La decisión de no cargarlos en la base de datos responde al riesgo de obsolescencia. Las tutorías cambian entre cuatrimestres, durante el curso por viajes o congresos del profesorado, y de forma puntual en periodos de exámenes. Las páginas departamentales que publican estos horarios no documentan con qué frecuencia se actualizan, lo que impide saber a ciencia cierta si el dato extraído sigue siendo válido en el momento de la consulta. Un dato desactualizado es peor que ninguno, ya que un alumno que se desplaza al despacho equivocado pierde tiempo y confianza en el sistema. La fase 1 no incluye un pipeline de refresco automatizado que garantice la frescura, y por ese motivo se ha preferido no arriesgar y redirigir al correo institucional del profesor, que sí está en la base de datos y que constituye la fuente más autoritativa: el propio profesor, que mantiene su disponibilidad real al día.

Cascada de fuentes para el directorio de profesorado. Aunque el discurso anterior se refiere genéricamente al *directorio PDI de us.es* como fuente única, la realidad es más matizada. El directorio central de la US (www.us.es/directorio-pdi) cubre la mayoría de profesores pero deja huecos sistemáticos en cuatro departamentos cuyas plantillas se publican principalmente en las webs específicas de cada unidad. Para cubrir ese vacío, la épica incorpora cuatro *scrapers* adicionales, uno por departamento, en `actions/profesores/:scraper_ccia.py` (Ciencias de la Computación e Inteligencia Artificial), `scraper_dte.py` (Departamento de Tecnología Electrónica), `scraper_lsi.py` (Lenguajes y Sistemas Informáticos) y `scraper_mal.py` (Matemática Aplicada I). Estos *scrapers* se invocan únicamente desde el panel de administración, como acción de enriquecimiento posterior a la importación principal del directorio: si tras el barrido del directorio central queda un profesor sin email o sin despacho y figura en uno de esos cuatro departamentos, se lanza el *scraper* específico que conoce la estructura HTML de esa web departamental. La separación en módulos independientes facilita el mantenimiento: si una de las cuatro webs cambia su HTML, basta con actualizar el *scraper* correspondiente sin tocar el resto del flujo.

11.4– Épica de horarios

`ActionConsultaHorario` responde a consultas por curso y grupo: “¿qué horario tiene 2º grupo 1?” o “¿qué clases hay los lunes en primero grupo 2?”. La Figura 11.4 muestra su pipeline.

El pipeline parsea con expresiones regulares cuatro elementos: curso (2º, *segundo*, *curso* 2), grupo (*grupo* 1, *g1*), día (lunes a viernes) y cuatrimestre (explícito o inferido por fecha). Si faltan curso o grupo, intenta heredarlos de los slots `ultimo_curso_consultado` y `ultimo_grupo_consultado` si fueron fijados en los últimos tres turnos. Existe además un seguimiento entre épicas: cuando la consulta no aporta ninguna pista de horario pero el slot mantiene una asignatura reciente, el control pasa a `ActionConsultaHorarioAsignatura` en vez de pedir más datos.

Bloqueo proactivo de consultas por letra del DNI. Antes incluso de resolver la asignatura, el pipeline aplica un filtro defensivo sobre frases como “*mi grupo es la letra A del DNI*” o “*letra B del dni*”. Una expresión regular dedicada (`_RE_LETRA_DNI`) detecta el patrón letra `<x>` (`de|del`) (`mi`)?dni y, al dispararse, la acción interrumpe el flujo y responde de forma proactiva que la asignación de grupos por letra del DNI varía cada curso y debe consultarse en el portal oficial. Sin este atajo, la letra solitaria (“T”) era una candidata involuntaria de la cascada de alias y se interpretaba como abreviatura de asignaturas como *Teledetección*, generando respuestas absurdas.

Colapso de aulas mediante GROUP BY. La consulta SQL hace JOIN entre `horarios`, `grupos_clase`, `asignaturas`, `titulaciones` y `aulas`, filtrando por curso, grupo y,




Figura 11.4: Pipeline de ActionConsultaHorario.

opcionalmente, día y cuatrimestre. Sin agregación, el JOIN devuelve una fila por aula reservada, de modo que una misma sesión de teoría y laboratorio aparece duplicada con dos códigos de aula distintos (típicamente una con prefijo A, teoría, y otra con prefijo distinto, laboratorio). La cláusula GROUP BY (dia_semana, hora_inicio, hora_fin, asignatura, cuatrimestre) colapsa las filas redundantes y agrega los códigos de aula en un ARRAY_AGG que conserva ambas pertenencias. Tras esa agrupación, cada aula se categoriza como teoría (prefijo A) o laboratorio según la convención adoptada por la ETSII (decisión D-066). Solo entonces se entrega a Gemini con instrucciones para que respete la fecha actual (“hoy”, “mañana”) y advierta cuando la consulta cae en sábado o domingo.

11.5– Épica de contexto académico

La épica de contexto agrupa cuatro acciones cortas: ActionCambiarContexto fija la titulación del usuario, ActionConsultarContexto la lee, ActionResetContexto la borra y ActionConsultaTitulaciones muestra las disponibles. La pieza interesante es la primera, porque transforma una frase libre del usuario en uno de los códigos canónicos GII-IS, GII-TI o GII-IC.

La normalización se apoya en una combinación de coincidencia exacta sobre el diccionario TITULACION_MAP, un guard que exige al menos un token discriminante (*software*, *computadores*, *tecnologías*, *is*, *ti*, *ic*) y, si nada de lo anterior funciona, un *fuzzy matching* con fuzz.WRatio a un umbral conservador de 85. WRatio es una combinación ponderada de las métricas de similitud de rapidfuzz, construidas sobre la distancia de edición de Levenshtein [84]. El umbral se elevó tras la revisión R3 para evitar que frases ambiguas como “*ingeniería*” produjeran cambios de contexto silenciosos. El resto de épicas dependen del valor de contexto_titulacion para inyectar el filtro titulacion_id en sus consultas, por lo que un fallo en la normalización contamina toda la sesión: de ahí el cuidado con los umbrales.

11.6– Épica de fallback inteligente

El fallback de Rasa se activa cuando la confianza del clasificador NLU está por debajo del umbral configurado en config.yml. La acción ActionSmartFallback sustituye el mensaje genérico de disculpa por una llamada a Gemini, que decide qué consulta ejecutar a partir de la pregunta y del historial reciente. La Figura 11.5 muestra el flujo.

El *prompt* de clasificación recibe la pregunta, el contexto de titulación, el último nombre de asignatura del tracker, los tres últimos pares de mensajes y la lista de acciones disponibles (BUSCAR_ASIGNATURA, BUSCAR_HORARIO, BUSCAR_PROFESOR, NINGUNO). Gemini devuelve un JSON con la acción elegida, sus parámetros y, si elige NINGUNO, una respuesta directa breve. La temperatura se fija a cero para que la clasificación sea determinista.

Antes de invocar al modelo, una regex detecta el patrón “*todos los grupos*” sobre el último horario consultado, porque es una continuación frecuente que no merece coste de LLM. Si la clasificación elige una acción de búsqueda, la implementación correspondiente vive como función dentro del propio módulo fallback: no se reinvoca la *custom action* de la épica, sino una versión simplificada que devuelve datos crudos para que un segundo prompt los redacte. Esta separación evita ciclos de Rasa y reduce la latencia.

11.7– Épica de *multi-intent* (desactivada)

ActionMultiIntent fue diseñada para cubrir mensajes que combinan un cambio de contexto y una consulta en una sola frase: “*soy de Ingeniería del Software, ¿qué horario tengo en segundo grupo 2?*” se identificaba con un intent compuesto del tipo cambiar_contexto_academico+consulta_horario, que se separaba en




Figura 11.5: Pipeline de ActionSmartFallback.

sub-intents y se ejecutaban en orden. El código de la acción permanece en el directorio `actions/multi_intent/` como referencia, pero el flujo está **desactivado en el prototipo**: ni los intents compuestos figuran en `domain.yml` ni la acción aparece en las reglas de `data/rules.yml`, por lo que Rasa nunca la invoca.

Motivos de la desactivación. La decisión de no activar esta épica responde a tres razones concretas, registradas como decisión de cierre del proyecto en el cuaderno del sprint final (`docs/sprints/S7/registro_decisiones.md`; resumen en el Apéndice .3):

1. **Necesidad baja confirmada durante las pruebas.** Tanto en la fase de validación interna como en el piloto de tráfico real (59 sesiones) se comprobó que los usuarios raramente enviaban dos peticiones de distinto dominio en un único mensaje. El patrón de uso que motivó el diseño de la épica (combinar un cambio de titulación con una consulta en la misma frase) no se materializó como caso frecuente, y su ausencia no generó fricción observable en ninguna sesión registrada.
2. **Impacto en la latencia.** Cada intent compuesto exige dos llamadas consecutivas al servidor de acciones (una por sub-intent), lo que habría aumentado la latencia mediana de respuesta en aproximadamente 1,5 s por turno en los casos afectados, penalizando también a todos los usuarios que *no* usaran la sintaxis compuesta.
3. **Complejidad añadida sin valor proporcional.** Mantener un corpus NLU de intents compuestos habría incrementado el coste de anotación y mantenimiento de los datos de entrenamiento. Los recursos se priorizaron, en su lugar, para consolidar la cobertura y calidad de los intents simples existentes, que concentraban la mayoría de los fallos identificados durante el desarrollo y representaban el grueso del tráfico real.

La desactivación implica técnicamente que el flujo de Rasa trata cualquier frase compuesta como un único intent, que el clasificador asignará al dominio más probable. En el peor caso (frase muy ambigua), el fallback inteligente de la Sección 11.6 se activa y Gemini reencamina la consulta al dominio correcto. Este circuito de rescate ha resultado suficiente para el alcance actual del prototipo.

11.8– Módulos compartidos

Tres módulos de `shared/` concentran la complejidad transversal del sistema y merecen mención explícita.

11.8.1. Cliente de Gemini

`shared/gemini_client.py` expone una función `llamar_gemini(prompt, modelo, timeout, options, context)` que envuelve el SDK oficial. El modelo por defecto es `gemma-3-27b-it`. La función centraliza los *timeouts*, los reintentos ante errores transitorios y, si la variable de entorno `LINCEUS_BENCH_METRICS` apunta a un fichero, anota *append-only* una línea JSON por cada llamada con once campos: marca temporal en ISO 8601 con zona UTC (`ts`), nombre del modelo (`modelo`), etiqueta libre del *call site* (`context`, p. ej. `."signaturas.text_to_sql"` o `."profesores.respuesta"`), recuentos de *tokens* de entrada, salida y total tomados de *usage_metadata* del SDK (`input_tokens`, `output_tokens`, `total_tokens`), latencia medida con `time.perf_counter()` y resolución de milisegundos (`latencia_ms`), longitudes en caracteres del prompt y de la respuesta (`prompt_chars`, `respuesta_chars`) y un *flag* de éxito (`ok`). Si la variable no está fijada, la función no abre el fichero y el coste de la instrumentación es nulo: este patrón *toggleable* permite ejecutar tanto las pruebas E2E como el bot en producción con o sin telemetría detallada

sin tocar el código. El JSONL resultante alimenta los análisis de coste y latencia presentados en las Secciones 12.7.1 y 12.7.2 del Capítulo 12.

Calibración de temperatura por caso de uso. Las llamadas al modelo no comparten la misma configuración: la temperatura se ajusta deliberadamente en función del tipo de salida esperada, en línea con el análisis de degeneración del texto generado por redes neuronales bajo distintos parámetros de muestreo [78]. Para la generación de SQL en *Text-to-SQL* y para la clasificación binaria entre *datos estructurales* y *plan docente* se fija a 0,0, lo que hace la salida determinista y evita variaciones léxicas que romperían el validador de `validar_sql` o introducirían ambigüedad en una decisión de enrutado. Para la redacción de la respuesta natural al usuario se eleva a 0,3, valor suficiente para que el modelo varíe la formulación entre turnos similares sin caer en alucinaciones [35]. Las opciones también limitan el número de *tokens* de salida (`max_output_tokens=150` para SQL, `max_output_tokens=300` para redacción), parámetros que reducen el coste por llamada y previenen respuestas excesivamente largas.

11.8.2. Conexión a base de datos

`shared/db.py` define una clase `DatabaseConnection` que lee las credenciales de Supabase desde el `.env` y expone una instancia global `db_client`. Cada *custom action* obtiene un cursor a través de esta instancia, ejecuta su consulta parametrizada con `psycopg2` y la cierra. La parametrización (`cursor.execute(sql, parametros)`) es la barrera principal contra la inyección SQL en las épicas que usan *text-to-SQL*; el validador de `validar_sql` es la segunda.

11.8.3. Matching difuso de nombres

`shared/matching.py` implementa la función `score_por_normalizado(consulta, normalizado)` que devuelve un valor entre 0 y 1 según la proporción de tokens de la consulta presentes en el campo normalizado de la base de datos. Sobre esta función se construye `clasificar_por_normalizado()`, que separa una lista de resultados en **firmes** (umbral $\geq 0,60$) y **sugerencias** (entre 0,30 y 0,60). La elección de dos umbrales en lugar de uno responde al compromiso clásico entre *precision* y *recall* en recuperación de información [50]: el umbral firme prioriza precisión y el umbral de sugerencia prioriza cobertura.

Ajuste iterativo de los umbrales. Los valores 0,30 y 0,60 no son arbitrarios: se fijaron mediante ajuste manual durante la Épica de Profesorado (sprint S6, Iteración 5), observando el comportamiento del bot sobre las consultas con typos del piloto interno y revisando para cada *rondeo* de umbral los casos en los que el flujo se quedaba sin firmes pero el usuario sí había escrito un nombre reconocible. Tres observaciones cualitativas guiaron el ajuste:

- Un umbral firme **muy alto** (próximo a 0,80) dejaba fuera typos moderados como “*parejjo*” o “*galinndo*”: el nombre escrito tenía sentido para un humano pero la proporción de tokens reconocibles caía por debajo del umbral y la respuesta era un “*no he encontrado al profesor*” percibido como error del sistema.
- Un umbral firme **muy bajo** (próximo a 0,40) elevaba la sensibilidad a costa de la precisión: nombres cortos o con baja especificidad léxica (“*García*”, “*Martín*”) generaban matches múltiples con alta confianza, todos clasificados como firmes, lo que contaminaba la respuesta del bot.
- Con umbral firme en **0,60** y un *piso* de sugerencia en **0,30**, los casos ambiguos caen deliberadamente en la zona de sugerencias, donde el sistema ofrece la opción con mayor puntuación y solicita confirmación al usuario mediante `ActionResolverAfirmacion` (Sección 11.8.4). Esto traslada la incertidumbre del sistema al diálogo en lugar de resolverla con una respuesta posiblemente errónea.

El umbral separador de 0,30 establece además el límite por debajo del cual el sistema declara explícitamente que no encuentra coincidencias. Sin ese piso, consultas sobre personas sin ninguna relación con el directorio (“¿quién es Einstein?”) producían sugerencias sin sentido. El comportamiento correcto en ese caso es el de RF-P7: declarar la ausencia de información sin inventar contenido.

Conviene precisar que la calidad de la respuesta final no se sostiene únicamente sobre estos umbrales. La métrica `score_por_normalizado` no se aplica directamente contra el directorio completo: el flujo de la *custom action* hace primero una consulta `SELECT ... WHERE nombre_normalizado ILIKE %nombre%` que reduce el universo a un puñado de candidatos, y `clasificar_por_normalizado` solo reordena ese subconjunto. Por tanto, la estabilidad observada en el piloto (Sección 12.5, 98,3 % de sesiones validadas) descansa sobre tres mecanismos combinados: el filtro previo del `SELECT`, los umbrales del matching difuso, y el flujo de confirmación de `ActionResolverAfirmacion`.

11.8.4. Resolución de afirmación con inyección de entidades sintéticas

`ActionResolverAfirmacion` cierra el ciclo iniciado por una sugerencia: cuando el sistema ofrece la mejor coincidencia ambigua y guarda `ultima_sugerencia` (un diccionario con `action`, `campo`, `valor` y `pregunta_original`), basta con que el usuario responda “*si*” para que esa sugerencia se convierta en una consulta real sin reescribir la pregunta. La implementación reutiliza la acción original (`ActionConsultaProfesor`, `ActionConsultaEspecificas`, etc.) en lugar de duplicar su lógica, lo que mantiene una única fuente de verdad para cada flujo de consulta.

Esta reutilización exige sortear una limitación del API de Rasa: una *custom action* recibe el `Tracker` con el último mensaje del usuario (“*si*”), no con la pregunta original ni con la entidad sugerida. La solución consiste en construir un *Tracker* sintético: la función auxiliar `_inyectar_entidad()` hace una copia profunda del último `latest_message`, sustituye su texto por el valor sugerido y añade una entidad artificial con `extractor`: “sugerencia” para que la acción reutilizada la encuentre como si la hubiera extraído el NLU. Sobre ese `Tracker` reconstruido se invoca la acción original mediante despacho por nombre. El campo `extractor` permite distinguir, en los *logs* y en `conversation_log`, las entidades inyectadas de las verdaderamente clasificadas por DIET, lo que facilita la auditoría posterior. Esta técnica resulta especialmente útil para la época de profesores, donde la mayoría de los casos ambiguos se resuelven con un único turno de confirmación.

11.9– Pipeline RAG: chunking, embeddings y búsqueda

El módulo `rag/` concentra la lógica de Retrieval Augmented Generation [2] que alimenta dos casos de uso: la respuesta sobre contenido del plan docente (épica de asignaturas, Sección 11.2) y el atajo del rol de coordinador o suplente en la época de profesores (Sección 11.3). El módulo se divide en cinco ficheros con responsabilidades claras: `extraer_pdf.py` extrae el texto plano del PDF original, `chunking.py` lo trocea, `embeddings.py` consulta la API de Google para obtener los vectores, `db_vectores.py` los persiste en `planes_docentes_chunks` y `buscar.py` realiza la consulta semántica con *reranking*. La sección que sigue describe los detalles técnicos no obvios de cada uno.

11.9.1. Chunking por secciones con deduplicación de cabeceras

El troceado no se hace por número de caracteres ciego: `chunking.py` aplica primero una segmentación por secciones reconocibles del plan docente (*Datos básicos*, *Profesorado*, *Coordinador*, *Objetivos*, *Contenidos*, *Metodología*, *Evaluación*, *Bibliografía*, etc.) mediante 16 expresiones regulares compiladas con `re.IGNORECASE` y variantes ortográficas que toleran la presencia o

ausencia de tildes (Datos b[áa]sicos, Metodolog[íi]a, etc.). Esta tolerancia es necesaria porque la extracción con `pdfplumber` no siempre preserva las tildes con fidelidad: dependiendo del PDF de origen, la palabra *Evaluación* puede aparecer como *Evaluacion* sin que el resto del texto se vea afectado.

Tras la segmentación se ejecuta una pasada de deduplicación de cabeceras: si la misma sección aparece varias veces en el documento (algo frecuente en PDFs multipágina, donde el encabezado se repite al inicio de cada página), `_deduplicar_bloques()` conserva la aparición más larga y descarta las demás. Sin esta pasada, la base de datos almacenaba *chunks* duplicados que sobrerrepresentaban algunas secciones en la búsqueda vectorial.

Solo dentro de cada sección se aplica la división por tamaño, con tres parámetros: `MAX_CHUNK_SIZE=800` caracteres, `OVERLAP_SIZE=100` caracteres (12,5 % de solapamiento, valor recomendado por [79]) y `MIN_CHUNK_SIZE=50` caracteres. La división respeta los saltos de párrafo (`\n\s*\n`) cuando es posible y nunca cruza el límite entre secciones, lo que garantiza que un *chunk* de *Evaluación* no contenga texto que pertenezca a *Bibliografía*.

11.9.2. Embeddings con *batching* y *rate limit handling*

`embeddings.py` envuelve la llamada a `models/gemini-embedding-001` y declara una dimensionalidad de salida de 2000 (frente a las 3072 nativas), valor justificado en la Sección 7.4.3 del Capítulo 7. La estrategia de envío respeta los dos límites del nivel gratuito de la API: **100 peticiones por minuto y 1 000 peticiones por día**. El módulo agrupa los *chunks* en lotes de hasta cien (parámetro `BATCH_SIZE = 100`, máximo soportado por la API), espera un segundo entre lotes (`PAUSA_ENTRE_BATCHES = 1.0`) y, si la API responde con un error que contiene la cadena 429 o `RESOURCE_EXHAUSTED`, duerme 60 segundos antes de reintentar. Esta combinación permite vectorizar un plan docente medio (50–80 *chunks*) en menos de tres segundos, y un grado completo (10–12 asignaturas activas) sin agotar la cuota diaria, condición necesaria para que el flujo del panel pueda lanzarse en horario lectivo sin penalizar a los usuarios del bot.

11.9.3. Búsqueda en dos fases con *reranking* por sección

`buscar_en_plan_docente()` (en `rag/buscar.py`) implementa la consulta semántica que ejecutan en tiempo real las *custom actions*. El flujo nominal es: se obtiene el *embedding* de la pregunta del usuario, se consulta la función SQL `buscar_plan_docente()` sobre `planes_docentes_chunks` con el operador `<=>` de `pgvector` (distancia coseno) y se devuelven los *top-K=10* fragmentos con similitud superior al umbral de 0,5. Sobre estos resultados se aplica un *reranking* aditivo en función de la sección a la que pertenece cada *chunk*.

La Tabla 11.1 recoge los pesos del reordenamiento. La idea es la siguiente: si la pregunta del usuario alude a un tipo concreto de información (profesorado, evaluación, contenidos, horarios o bibliografía), un detector léxico basado en palabras clave fija ese tipo de consulta; entonces, los *chunks* cuya sección coincide reciben un bonus aditivo de hasta 0,15 que se suma al *score* vectorial original.

Dos rasgos del *reranking* merecen comentario. El primero es que **no se filtra por sección en la consulta SQL**: la sección es una señal débil porque el chunker la etiqueta *best-effort* y se sabe que en ocasiones falla (un nombre de profesor puede acabar en un *chunk* etiquetado como *bibliografía* si la cabecera de la siguiente sección cae dentro del mismo *chunk*). Si la sección fuese un filtro estricto, esos casos se perderían; al usarla solo como peso aditivo, la similitud vectorial conserva la última palabra. El segundo es que **todos los pesos son positivos**. Una iteración anterior aplicaba penalizaciones negativas a las secciones *incoherentes* (`-0,30` a *bibliografía* cuando se preguntaba por profesorado), pero esas penalizaciones enmascaraban precisamente los casos del primer punto y devolvían respuestas vacías. La calibración final usa solo bonificaciones pequeñas, suficientes para reordenar pero incapaces de descartar un *chunk* relevante.

Cuadro 11.1: Tabla `RERANK_WEIGHTS`: bonificación aditiva por sección según el tipo de consulta detectado.

Tipo de consulta	Sección del <i>chunk</i>	Bonus
profesorado	profesorado	+0,15
	coordinador	+0,12
	datos_basicos	+0,03
evaluacion	evaluacion_general	+0,15
	evaluacion_grupo	+0,15
	metodologia	+0,03
contenidos	contenidos	+0,15
	contenidos_detallados	+0,15
	objetivos	+0,05
horarios	horarios	+0,15
	calendario_exámenes	+0,05
bibliografia	bibliografia	+0,15
	informacion_adicional	+0,03

Fallback por palabras clave. Si la llamada a la API de *embeddings* falla por causas específicas de esa capa (agotamiento de la cuota de `models/gemini-embedding-001`, tiempo de respuesta excesivo al vectorizar la consulta o error de red restringido a ese *endpoint*), `buscar.py` cae automáticamente a una búsqueda `ILIKE` sobre el campo `contenido` de `planes_docentes_chunks`. El *fallback* extrae las palabras de más de tres caracteres de la pregunta, descarta una lista corta de *stopwords* en español y compone una cláusula `WHERE contenido ILIKE ' %palabra%ÓR . . .`. El *reranking* se aplica también a este flujo. Esta degradación cubre el escenario concreto en que el servicio de vectorización no está disponible pero el modelo de generación sí lo está: los *chunks* se recuperan por coincidencia textual en lugar de por similitud semántica y se entregan igualmente a Gemini para redactar la respuesta final, a costa de una pérdida limitada de precisión en la selección del contexto. La existencia de este *fallback* es la razón por la que la disponibilidad del `Text-to-SQL` es más frágil que la del `RAG`: aquel no tiene una vía alternativa equivalente.

Tolerancia a variantes de nombre de grupo. La función auxiliar `_resolver_grupo()` acepta nombres de grupo con variaciones de notación entre la pregunta del usuario y la base de datos. Si el usuario escribe “*Grupo 5*” pero la BD almacena “*Grupo 5 INGLES*”, una consulta auxiliar (`pd.grupo LIKE %Grupo 5 %`) recupera el primer grupo cuyo nombre lo contenga. Sin esta tolerancia, las preguntas sobre grupos bilingües fallaban sistemáticamente.

11.10– Panel de administración

El panel de administración es una aplicación Flask que corre en el contenedor de administración (puerto 5050) y expone una API REST bajo el prefijo `/api/admin`. Su propósito es centralizar todas las operaciones de mantenimiento del catálogo de datos: creación y actualización del esquema relacional, lanzamiento de los scrapers, vectorización de planes docentes e inspección de conversaciones y estadísticas de uso. Ninguna de estas operaciones requiere detener el asistente ni reentrenar el modelo.

11.10.1. Estructura de la API

El servidor se define en `admin/app.py` y registra nueve *blueprints*, uno por dominio funcional:

- `centros y titulaciones`: CRUD jerárquico de la estructura académica. La pantalla de

inicio del panel (Figura 11.6) muestra los centros disponibles como tarjetas con el número de titulaciones asociadas.

- **asignaturas:** CRUD de asignaturas con soporte para importación masiva. Cada asignatura se vincula a una titulación y se etiqueta con curso, tipo y créditos.
- **profesores:** tabla de consulta paginada del directorio PDI con acciones para enriquecer datos desde `us.es` y refrescar enlaces oficiales (Figura 11.7). El detalle de cada operación se recoge en la Tabla 11.2.
- **horarios:** gestión de los horarios importados desde los PDFs de la ETSII. El módulo delega en `admin/horarios_extractores/` la extracción de sesiones desde los documentos oficiales.
- **sevius:** *endpoints de preview* que consultan el portal Sevius sin modificar la base de datos, útiles para explorar los grupos y planes docentes disponibles antes de lanzar la vectorización.
- **planes_docentes:** combina scraping de grupos en Sevius, descarga de PDFs y procesamiento RAG en un único *endpoint* `POST /api/admin/planes_docentes/vectorize`. Por cada par (asignatura, grupo) que no esté ya vectorizado, descarga el PDF, lo trocea con el `pipeline rag/pipeline.py` y almacena los *chunks* en `planes_docentes_chunks` junto con su *embedding* en `pgvector`. El campo `estado_rag` de cada plan docente registra el estado del proceso (pendiente, completado o error).
- **conversaciones:** vista paginada de la tabla `conversation_log`, agrupada por sesión y con marcado de sesiones revisadas. Cada fila muestra el primer y último mensaje, la duración de la sesión y el número de turnos. La Figura 11.8 ilustra esta vista; en la sesión marcada en verde el administrador ya ha revisado los intercambios.
- **stats:** panel de contadores globales que muestra en tiempo real el volumen de cada tabla: centros, titulaciones, asignaturas, profesores, grupos, horarios, planes docentes, *chunks* RAG, conversaciones y *feedbacks* (Figura 11.9).




Figura 11.6: Pantalla de inicio del panel de administración. Cada tarjeta representa un centro con el número de titulaciones que gestiona.

Volver al sitio

Estadísticas

UNIVERSIDAD DE SEVILLA

Panel de Administracion

LinceUS - Gestion de datos academicos

Conectado

Salir

Inicio

Profesores

Escuela Técnica Superior de Ingeniería Informática

Departamento de Lenguajes y Sistemas Informáticos

CENTROS

PROFESORES

HORARIOS

CONVERSACIONES

FEEDBACK

Departamento de Lenguajes y Sistemas Informáticos

92

Enriquecer desde us.es

NOMBRE	DEPARTAMENTO	CATEGORIA	EMAIL	DESPACHO	PERFIL
Álvarez García, Juan Antonio	Departamento de Lenguajes y Sistemas Informáticos	Catedrático de Universidad	jaalvarez@us.es	F1.52	✉
Arévalo Maldonado, Carlos	Departamento de Lenguajes y Sistemas Informáticos	Profesor Titular de Universidad	carlosarevalo@us.es	F1.41	✉
Ayala Hernández, Daniel	Departamento de Lenguajes y Sistemas Informáticos	Profesor Permanente Laboral	dayala1@us.es	F1.81	✉
Barba Rodríguez, Irene	Departamento de Lenguajes y Sistemas Informáticos	Profesora Titular de Universidad	irenebr@us.es	F0.46	✉

Figura 11.7: Vista de profesores del Departamento de Lenguajes y Sistemas Informáticos. La columna *Enriquecer desde us.es* lanza el scraper de directorio para actualizar los datos del PDI.

Volver al sitio

Estadísticas

UNIVERSIDAD DE SEVILLA

Panel de Administracion

LinceUS - Gestion de datos academicos

Conectado

Salir

Inicio

Conversaciones

CENTROS

PROFESORES

HORARIOS

CONVERSACIONES

FEEDBACK

Conversaciones

72 sesiones

Exportar esta página

✓	SESIÓN	MENSAJES	PRIMER MENSAJE	ÚLTIMO MENSAJE	INICIO	DURACIÓN
☐	session_177766...	4	GII-IS	Quiero saber la evaluación de ispp para el grup...	1/5/2026, 23:02:07	9 min
☒	session_177766...	2	GII-IS	¿qué es ABDA?	1/5/2026, 21:38:38	19s
☐	session_177755...	4	GII-IS	Háblame de Redes de Computadores	30/4/2026, 16:35:28	1 min
☐	session_177755...	3	GII-IS	Cuales son los horarios de matemática discreta?	30/4/2026, 16:32:42	1 min
☐	session_177746...	1	GII-IS	GII-IS	29/4/2026, 12:58:20	1s
☐	session_177732...	1	GII-IS	GII-IS	27/4/2026, 23:44:31	1s

Figura 11.8: Vista de conversaciones agrupadas por sesión. La fila en verde indica una sesión marcada como revisada. El botón *Exportar esta página* vuelca las sesiones seleccionadas en CSV.




Figura 11.9: Panel de estadísticas generales. Los contadores se calculan en tiempo real contra Supabase. En el momento de la captura el sistema contaba con 244 asignaturas, 268 profesores, 157 planes docentes vectorizados y 1352 *chunks* RAG.

11.10.2. Operaciones del panel

Más allá de las consultas de lectura, el panel expone una colección de operaciones de mantenimiento que el administrador lanza desde la interfaz. Cada operación se traduce en una llamada HTTP a un *endpoint* concreto del API y, según el caso, dispara un *scraper* contra Sevius o el directorio de `us.es` antes de modificar la base de datos. La Figura 11.10 muestra la página pública de Sevius (<https://sevius4.us.es/?PyP=LISTA>) sobre la que operan estas sincronizaciones: tres desplegables encadenados (Centro, Titulación y Asignatura) que el *scraper* recorre programáticamente para extraer los nombres de centros, titulaciones y asignaturas, así como los enlaces de descarga de los planes docentes en PDF. La Tabla 11.2 resume las operaciones agrupadas por la pestaña en la que se invocan.



Gestión de Programas y proyectos docentes

Acceso público

Figura 11.10: Página de acceso público del portal Sevius4 (<https://sevius4.us.es/?PyP=LISTA>). Los tres desplegables encadenados Centro → Titulación → Asignatura son la fuente que los *scrapers* del panel recorren para sincronizar los nombres del catálogo académico y descargar los planes docentes en PDF.

Tres rasgos transversales gobiernan estas operaciones. El primero es la **idempotencia**: las ac-

Cuadro 11.2: Operaciones del panel de administración por pestaña. Todos los *endpoints* van prefijados por `/api/admin`.

Acción visible	Endpoint	Efecto
Centros		
Nuevo centro	POST <code>/centros</code>	Inserta fila en centros
Sincronizar desde Sevius	GET <code>/sevius/centros</code>	Lectura previa del portal <code>sevius4.us.es</code> ; el alta sigue POST <code>/centros</code>
Nueva titulación	POST <code>/titulaciones</code>	Inserta fila en titulaciones
Sincronizar titulaciones desde Sevius	POST <code>/titulaciones/sync</code>	Extrae titulaciones del portal <code>sevius4.us.es</code> e inserta las que aún no estén en BD
Asignaturas		
Sincronizar desde Sevius	POST <code>/asignaturas/sync</code>	Extrae asignaturas del portal <code>sevius4.us.es</code> e inserta las nuevas con campos básicos
Enriquecer datos	POST <code>/asignaturas/enrich</code>	Actualiza curso, créditos y tipología desde el catálogo de grados de <code>us.es</code>
Cargar docencia	POST <code>/titulaciones/<id>/sync.docencia</code>	Popula <code>profesor_asignatura</code> desde el directorio PDI de <code>us.es</code> (sección <i>Asignaturas que imparte</i> de cada perfil)
Vectorizar planes docentes	POST <code>/planes_docentes/vectorize</code>	Descarga PDFs de planes docentes desde <code>sevius4.us.es</code> y guarda <i>embeddings</i> en <code>pgvector</code>
Profesores		
Enriquecer desde <code>us.es</code> (centro)	POST <code>/centros/<id>/enrich.profesores</code>	<i>Scraping</i> del directorio PDI de <code>us.es</code> ; da de alta departamentos y hace <i>upsert</i> de profesores
Enriquecer desde <code>us.es</code> (depto.)	POST <code>/departamentos/<id>/enrich.profesores</code>	Igual al anterior pero restringido a un departamento concreto
Refrescar enlaces <code>us.es</code>	POST <code>/centros/<id>/refresh.enlaces_us</code>	Actualiza <code>enlace_perfil</code> con el <i>slug</i> del directorio PDI de <code>us.es</code>
Horarios		
Generar horarios	POST <code>/horarios/generar</code>	Lanza el extractor del centro y pobla <code>horarios</code> , <code>grupos_clase</code> , <code>aulas</code>
Conversaciones		
Marcar sesión como revisada	PATCH <code>/conversaciones/sesiones/<id>/revisada</code>	Cambia el flag <code>revisada</code> de todas las filas de la sesión
Exportar conversaciones	– (cliente)	Vuelca el JSON ya cargado en navegador a fichero local para tests

ciones que sincronizan datos externos (Sevius, `us.es`) comprueban primero si cada entidad ya existe en BD y nunca duplican filas; cualquiera de ellas puede relanzarse sin riesgo tras un fallo parcial. El segundo es el **respeto a los datos manuales**: los *upserts* de profesores nunca sobreescriben con NULL un campo ya poblado, lo que permite combinar carga automática con correcciones manuales sin perder estas últimas. El tercero es el **orden de prerequisites**: vectorizar planes docentes exige tener asignaturas; cargar docencia exige tener profesores con enlace de `us.es` (de ahí la acción *Refrescar enlaces* previa); generar horarios exige tener grupos de clase ya creados. La pantalla de cada pestaña inhabilita los botones cuando esos prerequisites no se cumplen, lo que reduce la probabilidad de errores operativos.

11.10.3. Pipeline de vectorización

La ruta `POST /api/admin/planes_docentes/vectorize` es el flujo más complejo del panel y merece una descripción detallada porque tiene impacto directo en la calidad de las respuestas del asistente. Recibe un cuerpo JSON con la titulación, el código Sevius del centro y de la titulación, y la lista de identificadores de asignaturas a procesar. Para cada asignatura consulta Sevius para obtener los grupos del curso vigente, descarga el PDF del proyecto docente de cada grupo y lo pasa por `rag/pipeline.py`.

El pipeline RAG divide el PDF en secciones según los encabezados del documento (*Evaluación, Temario, Metodología, Bibliografía, etc.*), genera un *embedding* por *chunk* con la API `gemini-embedding-001` de Google (2000 dimensiones) y almacena el par (*chunk, embedding*) en `planes_docentes_chunks`. Si el grupo ya tiene un plan en estado `completado` para el curso actual y el hash SHA-256 del PDF coincide, el pipeline lo salta sin regenerar los *embeddings*, lo que hace que el *endpoint* sea idempotente y seguro de relanzar tras un error parcial. La mecánica concreta del troceado, la deduplicación de cabeceras y el *rate limiting* de la API se detalla en la Sección 11.9.

El campo `estado_rag` actúa como un semáforo de tres estados. Durante el procesado toma el valor `en_proceso`, lo que permite al panel mostrar progreso aunque el *endpoint* sea síncrono; si el PDF no se puede descargar o el troceado falla, queda en `error` con un mensaje descriptivo; al completarse todos los *chunks* pasa a `completado`. La respuesta del *endpoint* devuelve un resumen con los contadores de planes completados, sin cambios y con error, junto con el total de *chunks* generados en la llamada.

Parte IV

Validación y Cierre

Pruebas y Validación

Este capítulo recoge la estrategia de pruebas seguida durante el desarrollo de Linceus Assistant y los resultados obtenidos en la fase de validación previa al cierre del prototipo. La evaluación de un sistema conversacional basado en modelos de lenguaje plantea retos que no se resuelven con una única batería de pruebas: el comportamiento del bot depende del clasificador NLU, de las acciones que consultan la base de datos, del módulo de recuperación semántica y del modelo generativo que produce la respuesta final, de modo que un fallo puede originarse en cualquiera de esas capas. Por ese motivo, la validación se ha organizado en cinco capas funcionales independientes que aíslan riesgos distintos y, en conjunto, ofrecen una imagen razonablemente completa del estado del sistema, complementadas con una sexta capa de pruebas automatizadas sobre la API del panel de administración.

El alcance de las pruebas cubre las tres épicas funcionales que conforman el prototipo (asignaturas, horarios y profesorado), el flujo transversal de cambio de titulación, la gestión de seguimiento conversacional, la respuesta del bot ante consultas fuera de ámbito o intentos de manipulación del *prompt* y la API de administración. Esta última se valida exclusivamente sobre los *endpoints* de lectura, validación de parámetros y los flujos de extracción de Sevius mediante *mocks* (Sección 12.9); las operaciones de escritura destructiva sobre el dominio de horarios y el resto de importaciones masivas quedan fuera del alcance, por el riesgo de dejar la base de datos en estado inconsistente al no disponer de un entorno de *staging* aislado. La validación subjetiva mediante escalas estandarizadas como la *System Usability Scale* (SUS) [92] también queda fuera, dado que requiere una segunda iteración con usuarios reales.

12.1– Estrategia general

12.1.1. Marco metodológico

El plan de pruebas toma como referencia el modelo de calidad de producto software definido en la norma **ISO/IEC 25010:2023** [93], que recoge entre las actividades del ciclo de vida del software la identificación de criterios de aceptación. De las ocho características recogidas en el modelo se cubren cuatro de manera explícita: *adecuación funcional* (corrección y completitud), *capacidad de interacción* (protección frente a errores del usuario), *fiabilidad* (tolerancia a fallos) y *seguridad* (en lo relativo a la integridad de las importaciones, descritas en su propio plan). Las cuatro características restantes (rendimiento, compatibilidad, mantenibilidad y flexibilidad) se discuten cualitativamente en otros capítulos de esta memoria y no forman parte del cómputo de la suite.

La redacción de cada caso sigue la plantilla *Given–When–Then* propia de **Behavior-Driven Development** [71]. Esta plantilla traslada cada escenario al lenguaje natural del dominio y permite traducirlo de forma mecánica a un caso ejecutable por el *runner*: las precondiciones se materializan en *slots* de Rasa, la acción del usuario se corresponde con la consulta enviada al endpoint y el resultado esperado se descompone en el *intent* clasificado y en condiciones sobre el texto de la

respuesta. Esta correspondencia, además de facilitar la revisión por parte del tribunal, agiliza la incorporación de nuevos casos a medida que aparecen errores en producción.

Sobre esta base, los escenarios se agrupan en tres categorías ampliamente aceptadas en la literatura sobre evaluación de chatbots [94, 95]: *positivos*, en los que el bot debe responder correctamente al camino feliz; *negativos*, en los que la información solicitada no existe en la base de datos y el bot debe declararlo sin alucinar; y *escenarios de robustez*, que comprenden errores tipográficos, intentos de *jailbreak*, consultas fuera de dominio, reutilización de *slots* entre turnos y cambios de titulación durante la conversación. Dentro de la categoría de positivos se introduce además una subdivisión propia entre consultas *bien escritas* y consultas *con errores tipográficos*, dado que la robustez frente al ruido textual es un criterio diferenciador en el caso de uso real (alumnos escribiendo desde el móvil con teclado predictivo).

12.1.2. Política de exclusión por trabajo futuro

Durante la ejecución de la suite se han identificado varios casos cuya causa raíz no es un defecto puntual, sino una limitación de diseño asumida y documentada. Entre ellas destacan el atajo de coordinador y suplente resuelto exclusivamente por recuperación semántica (decisión D-064), el emparejamiento profesor–asignatura–grupo cuando la tabla intermedia no almacena el grupo, la distinción entre aulas de teoría y de laboratorio cuando la convención por letra inicial del aula falla, y la corrección difusa de erratas severas en nombres propios. Estos casos se han marcado como *trabajo futuro* y se excluyen del denominador del porcentaje de éxito, siguiendo una práctica habitual en evaluación de prototipos de investigación. El catálogo completo, formado por **13 casos** identificados con códigos del tipo X-Pnn, P-Pnn, P-Wnn, P-Snn, H-Snn y HA-P/Wnn, vive en el fichero `tests/results/testing_general.md` del repositorio bajo el epígrafe *Trabajo futuro (excluido del cómputo)* y se reproduce íntegro en el Apéndice .4 de esta memoria, para que cualquier código citado a lo largo del capítulo sea localizable sin necesidad de consultar el repositorio.

12.1.3. Ejecución y registro

La suite end-to-end se ejecuta mediante el *script* `tests/run_test_plan.py` con el modificador `--manual-review`, que captura el *intent* clasificado y la respuesta textual emitida por el bot pero deja la celda de veredicto vacía para revisión humana. La razón de evitar un veredicto automático es la alta variabilidad léxica de las respuestas generadas por el modelo: una misma consulta puede producir formulaciones distintas que igualmente cumplen el criterio de aceptación, lo que hace inviable una comparación de cadenas. El *runner* introduce una espera de cinco segundos entre casos para no exceder la cuota gratuita de la API de Gemini, y los resultados se vuelcan en formato Markdown y JSON, sobrescribiendo los anteriores; la trazabilidad histórica se conserva mediante el control de versiones del repositorio.

Todos los artefactos de evaluación residen en el directorio `tests/` del repositorio. Cada cuadro de este capítulo se respalda con un fichero concreto, de modo que los valores reportados son reproducibles y auditables: la suite E2E (Cuadro 12.1) en `tests/results/testing_general.md`, el banco de preguntas de la capa de profundidad RAG (Cuadro 12.2) en `tests/plans/rag_asignaturas_manual.md` y su ejecución en `tests/results/rag_asignaturas.md`, los resultados de *rasa test core* (Cuadro 12.3) en `tests/results/stories.md`, las métricas no funcionales de latencia y coste (Cuadros 12.6 y 12.7) en `tests/results/coste_latencia.md` y la suite automatizada del panel (Cuadro 12.9) en `tests/test_admin.py`. La auditoría del tráfico real (Cuadro 12.4) se realiza sobre la tabla `conversation_log` directamente desde el panel de administración, sin fichero intermedio.

12.2– Ejecución funcional extremo a extremo

12.2.1. Alcance

La capa de aceptación funcional extremo a extremo es la prueba de mayor cobertura del proyecto, ya que ejercita el sistema con el *stack* completo en marcha: clasificador NLU, acciones personalizadas en Python, motor de Rasa, base de datos Supabase con extensión *pgvector*, módulo de recuperación semántica y modelo Gemini para la generación de la respuesta final. Su propósito es comprobar que las piezas funcionan acopladas correctamente bajo condiciones equivalentes a las de producción, no validar cada componente por separado.

La suite se compone de **159 casos** contables distribuidos en diez categorías que reflejan los flujos conversacionales del prototipo. La Tabla 12.1 resume los resultados por categoría tras la última iteración de re-ejecución, fechada el 26 de abril de 2026.

Cuadro 12.1: Resultados por categoría de la suite E2E (revisión manual, 26/04/2026).

Categoría	PASS	FAIL	PEND	Vacío	Total	%
cambiar_contexto	12	1	0	0	13	92,3
asignatura_conteo	10	0	0	0	10	100
cross_dominio	1	0	0	0	1	100
asignatura_especifica	22	0	0	0	22	100
fuera_ambito	8	0	0	0	8	100
horario	26	0	1	0	27	96,3
horario_asignatura	18	0	0	0	18	100
asignatura_listado	15	0	0	0	15	100
profesor	37	1	4	1	43	86,0
seguimiento_cross_intent	1	0	0	0	1	100
TOTAL	150	2	5	1	159	94,3

El cómputo arroja un **94,3 %** de éxito, calculado sobre los 150 casos válidos frente a los 159 contables, con 13 casos adicionales excluidos por la política descrita en el Apartado 12.1.2. Las categorías deterministas (conteo, listado, fuera de ámbito, especificación de asignaturas) alcanzan el 100 % gracias a que dependen únicamente de SQL y del clasificador. La categoría *profesor*, en cambio, presenta el porcentaje más bajo (86,0 %) porque concentra los casos con dependencia múltiple entre tablas (profesor, asignatura y grupo) y los flujos resueltos por recuperación semántica que no enriquecen su salida con datos estructurados.

12.2.2. Lectura frente a la literatura

El valor obtenido se sitúa por encima del umbral de *production-ready* señalado por Braun et al. [96] (igual o superior al 90 %) y queda dentro de la franja superior del *benchmark* BANKING77 reportado por Casanueva et al. [80] (entre el 87 % y el 93 %). En relación con los chatbots universitarios publicados en la última década, la cifra supera con claridad los resultados comunicados por AdmitBot (82 %) [25], EDUBOT (alrededor del 78 %) [26], Ranoliya (85 %) [27] y el sistema de Dibya y Sahoo (84 %) [28].

12.3– Recuperación aumentada por generación

El módulo RAG es el componente más sensible del sistema y, por tanto, ha sido evaluado en dos capas separadas: una capa *baseline*, que mide la capacidad de recuperación del sistema sobre un banco de preguntas genéricas, y una capa *de profundidad*, que comprueba la fidelidad de la respuesta frente a los planes docentes oficiales.

12.3.1. Capa baseline

La capa baseline está formada por un banco de **50 preguntas genéricas** sobre asignaturas (créditos, curso, cuatrimestre, optatividad, equivalencias y conteos). Cada pregunta se reformula en dos o tres variantes y se ejecuta manualmente con replay del bot para aislar el efecto de la recuperación semántica de las distintas acciones SQL. Sobre esta capa se obtiene un **94,0 %** de éxito (47 de 50), con tres errores aislados: una pregunta cuyo alias en la base de datos no coincidía con el nombre coloquial empleado en la consulta (E-T02), un caso de enrutado erróneo a la acción de cambio de contexto (E-T04) y una confusión entre el flujo de conteo y el de listado (C-P05). Los tres han sido recogidos en el cuaderno de fallos para su posterior corrección. Los identificadores siguen la convención <tipo>-<origen><número> detallada en la Sección 12.6.

12.3.2. Capa de profundidad

La capa de profundidad evalúa el rendimiento del sistema sobre **74 preguntas reales** extraídas de los planes docentes oficiales de **19 asignaturas** repartidas en **cinco grupos** de la titulación de Ingeniería del Software. Las preguntas no son genéricas: exigen al RAG recuperar información concreta de secciones específicas del plan (profesorado por grupo, bloques temáticos con sus horas, criterios y fórmulas de evaluación, composición de tribunales, idioma de impartición y contenidos de bloques). La cobertura por curso se recoge en la Tabla 12.2.

Cuadro 12.2: Cobertura de la capa de profundidad RAG por curso.

Curso / tipo	Asignaturas	Preguntas
1.º (formación básica)	5	25
2.º (obligatoria)	3	15
3.º (obligatoria)	4	16
4.º (obligatoria)	2	6
4.º (optativa)	5	12
Total	19	74

El veredicto se emite con un código de tres niveles: *OK* cuando la respuesta es correcta y completa, *PARCIAL* cuando es correcta pero le falta algún detalle del plan docente, y *FAIL* cuando es incorrecta o vacía. Los resultados son 68 OK, 5 PARCIAL y 1 FAIL, lo que da un **91,9 %** de respuestas correctas y completas en lectura estricta y un 98,6 % si se admite la categoría parcial. La cifra entra en la franja alta del modelo RAGAS de Es et al. [29] (faithfulness igual o superior a 0,85) y supera el rango de exact-match esperado para sistemas RAG de dominio cerrado descrito por Lewis et al. [2] (entre el 75 % y el 88 %).

12.4– Clasificación NLU y política de diálogo

La capa de NLU y política de diálogo evalúa los componentes deterministas de Rasa Core: clasificación de *intent* y selección de la acción siguiente dado el historial de *slots*. La prueba se ejecuta con la orden `rasa test core --fail-on-prediction-errors` sobre 44 *stories* que cubren los caminos felices de las tres épicas, los *stories* de seguimiento conversacional y los *stories* de *fallback*. La Tabla 12.3 recoge las métricas agregadas.

La cifra se interpreta con la cautela apropiada: el conjunto de *stories* se ha construido a partir del uso real esperado del bot en el prototipo, no a partir de un *benchmark* adversarial, por lo que el 100 % certifica que NLU y política no son cuello de botella en el resto de capas, pero no garantiza idéntico desempeño bajo distribuciones de tráfico distintas. Como prueba complementaria de no regresión se verificó que tras el reentrenamiento con 117 ejemplos NLU adicionales extraídos de la tabla `conversation_log` (modelo `linceus-v4-7-9.tar.gz`, 24 de abril de 2026) la

Cuadro 12.3: Resultados de la capa NLU y Policy.

Métrica	Valor
Conversaciones correctas	44 / 44
Acciones predichas correctamente	158 / 158
Accuracy (conversación)	1,000
Accuracy (acción)	1,000
Precisión / recall / F1 (weighted)	1,00 / 1,00 / 1,00
Stories fallidas	0

política aprendida mantenía las 158 de 158 acciones correctas que arrojaba la corrida previa, lo que descarta una degradación inducida por la ampliación del corpus.

Frente al ámbito académico, este resultado supera el umbral de despliegue de Rasa establecido en el modelo DIET por Bocklisch et al. [39] (igual o superior al 85 % de F1 de *intent*) y se sitúa por encima del estado del arte reportado en CLINC150 [80].

12.5– Reproducción de tráfico real tras el despliegue

La capa de tráfico real es la única en la que la distribución de las consultas no está controlada por el evaluador. Tras el despliegue del prototipo en la infraestructura de DigitalOcean, el bot se puso a disposición de un grupo de alumnos de la ETSII a través del *widget* integrado en la interfaz web del proyecto. Las conversaciones generadas en ese piloto se almacenan automáticamente en la tabla `conversation_log` de la base de datos, junto con el *intent* clasificado, los *slots* activos y la respuesta del bot turno a turno.

12.5.1. Metodología de revisión

La validación del piloto se ha realizado revisando manualmente cada una de las 59 sesiones desde el panel de administración, replicando turno a turno el intercambio entre el alumno y el bot. Una sesión se marca como válida cuando todas las consultas relevantes se resuelven con datos correctos verificados contra los planes docentes, los horarios oficiales o el directorio de profesores; cuando el bot responde *no encontrado* en aquellos casos en que la información no estaba presente en la base de datos sin inventar contenido; o cuando una pregunta cae claramente fuera del alcance del prototipo y el flujo de *out_of_scope* la redirige correctamente.

12.5.2. Resultados

La Tabla 12.4 resume los datos agregados de la auditoría.

Cuadro 12.4: Resultados de la reproducción de tráfico real.

Métrica	Valor
Sesiones de usuarios reales	59
Sesiones validadas manualmente	58
Sesiones excluidas (trabajo futuro)	1
% de éxito	98,3
Total de turnos auditados	203
Turnos validados	201
Ventana de captura	01/04/2026 – 25/04/2026

La sesión excluida corresponde a una pregunta en la que el alumno describe un tema técnico (electrónica de sistemas embebidos) y solicita saber en qué titulaciones se cursa. El comportamiento esperado consistiría en una recuperación semántica seguida de un cruce con la tabla de

titulaciones; el bot, en cambio, responde con un listado de asignaturas afines al tema sin completar el segundo paso. El caso queda documentado como X-P06 dentro del catálogo de trabajo futuro y motiva la incorporación de un nuevo flujo de *consulta_titulacion_por_tema* en la fase siguiente.

La cifra de 98,3 % supera el mínimo aceptable señalado por Casas et al. [97] (igual o superior al 70 %) y la franja *satisfactorio* de Følstad y Brandtzaeg [98] (entre el 80 % y el 85 %). Conviene notar, además, que esta capa es la más realista de las cinco evaluadas, dado que la distribución de las consultas no ha sido diseñada por el equipo de pruebas: refleja el tipo de uso espontáneo que cabe esperar de un alumno consultando el bot desde el móvil entre clases.

12.6– Análisis de los casos fallidos

Los identificadores de los casos de prueba siguen la convención `<tipo>-<origen><número>`: la letra de tipo indica la naturaleza del veredicto (E para error, C para confusión entre flujos, X para sesión excluida) y el sufijo alfanumérico referencia el fichero de resultados correspondiente en `tests/results/`. Las decisiones de diseño citadas como **D-*nnn*** se documentan en el repositorio bajo `docs/sprints/`.

Más allá del porcentaje agregado, el valor diagnóstico de la suite de pruebas reside en entender por qué fallan los casos que fallan. Los nueve casos no aprobados de la suite E2E, los tres errores aislados del RAG *baseline*, las cinco respuestas parciales y el único FAIL de la capa de profundidad, y la sesión excluida del tráfico real comparten un conjunto reducido de causas raíz que se pueden clasificar en cuatro patrones. Esta sección los recoge de forma consolidada porque cada uno acota una línea de mejora concreta para la fase 2.

Patrón 1: ambigüedad léxica entre intenciones cercanas. Tres errores del RAG *baseline* ilustran este patrón. **E-T02** corresponde a una consulta cuyo alias coloquial usado por el usuario no figura en la tabla `ALIAS_ASSIGNATURAS`, lo que la cascada interpreta como nombre canónico y la deriva al flujo equivocado. **E-T04** es un caso de enrutado erróneo a la acción `ActionCambiarContexto` sobre una pregunta que la NLU interpretó como cambio de titulación. **C-P05** es la confusión entre `ActionConsultaListado` y `ActionConsultaConteo` sobre una formulación que mezcla ambos conceptos. Los tres casos están registrados en `tests/results/rag-asignaturas.md` y la línea de trabajo asociada (ampliación del diccionario de alias y desambiguación con un segundo paso de clasificación LLM) figura en la Sección 12.8.3.

Patrón 2: cobertura insuficiente de la base de datos relacional para el dominio profesorado. La categoría `profesor` concentra cinco casos no aprobados sobre cuarenta y tres (86,0 %) y es la que más baja el porcentaje global. La causa raíz es estructural: la tabla `profesor_asignatura` se sincroniza desde el directorio público de `us.es` y deja con valor `NULL` las columnas `grupo`, `es_coordinador` y `tipo_docencia` que la fuente no expone. El sistema cubre los huecos con tres atajos al RAG (Sección 11.3), pero esos atajos resuelven la mayoría de los casos enriqueciendo la respuesta con el nombre extraído del plan docente, no con datos estructurales adicionales como el correo o el despacho. Los cinco casos no aprobados se documentan en `tests/results/testing-general.md` bajo la rúbrica `TRABAJO FUTURO` con la decisión asociada D-064: enriquecer el resultado del atajo de coordinador con un `JOIN` opcional a la tabla `profesores` cuando el LLM extraiga el nombre con confianza suficiente.

Patrón 3: respuestas parcialmente correctas del RAG por contexto recuperado incompleto. Las cinco evaluaciones `PARCIAL` del RAG de profundidad responden al mismo patrón: el *chunk* recuperado contiene la respuesta principal a la pregunta, pero le falta un matiz secundario del plan docente. Por ejemplo, una pregunta sobre la fórmula de evaluación recupera el porcentaje principal de cada parte pero pierde la frase que detalla la convocatoria extraordinaria. La causa técnica

está en el corte de *chunks* a 800 caracteres (Sección 11.9): un párrafo largo se divide en dos fragmentos consecutivos y solo uno de los dos entra en el *top-K* de la búsqueda vectorial. El único FAIL de la capa de profundidad responde a una variante extrema de este mismo patrón: el dato solicitado se reparte entre tres *chunks* y ninguno individual contiene información completa. La línea de mejora identificada es la recuperación de contexto extendido (ampliar el *top-K* o concatenar *chunks* adyacentes), que se discute en el Capítulo 14 como palanca técnica.

Patrón 4: brechas de cobertura funcional no previstas. La sesión excluida del piloto de tráfico real, identificada como **X-P06**, es el ejemplo más nítido de este patrón. El alumno describe un tema técnico concreto (“*electrónica de sistemas embebidos*”) y pregunta en qué titulaciones se cursa; el bot devuelve un listado de asignaturas afines al tema pero no completa el segundo paso (cruzar esas asignaturas con la tabla *titulaciones*). El sistema no responde mal: responde a una pregunta distinta de la formulada, porque el flujo `consulta_titulacion_por_tema` no existe en el prototipo. Este caso es valioso porque emerge de uso real sin haber sido anticipado por el corpus de pruebas, y motiva la incorporación de un nuevo intent en la fase 2 con su correspondiente *action* de doble paso (recuperación semántica + agregación por titulación).

La Tabla 12.5 consolida los cuatro patrones con el número de casos asociados y la línea de mejora prevista.

Cuadro 12.5: Síntesis de los casos fallidos por patrón de causa raíz.

Patrón	Casos	Línea de mejora prevista
Ambigüedad léxica entre intenciones cercanas	E-T02, E-T04, C-P05	Ampliación del diccionario de alias y desambiguación con LLM
Cobertura BD del dominio profesorado	5 en profesor	Enriquecimiento del resultado del atajo coordinador con JOIN a profesores (D-064)
Contexto RAG incompleto por corte de <i>chunks</i>	5 PARCIAL y 1 FAIL	Recuperación de contexto extendido (<i>top-K</i> adaptativo o concatenación de <i>chunks</i> contiguos)
Brecha funcional no prevista	X-P06	Nuevo flujo <code>consulta_titulacion_por_tema</code> en fase 2

La distribución de los patrones sostiene una lectura general: los fallos no se deben a un defecto del clasificador NLU (que alcanza el 100 % de *accuracy* a nivel de *story* en la Sección 12.4), sino a tres causas relacionadas con los datos disponibles (alias incompletos, columnas vacías en *profesor_asignatura*, granularidad del *chunking*) y una causa relativa al alcance funcional decidido para la fase 1. Esta separación entre fallos de modelo y fallos de cobertura es valiosa para priorizar la siguiente iteración: las tres primeras causas se atacan con cambios localizados en los datos o en parámetros del pipeline RAG, mientras que la cuarta requiere un nuevo flujo conversacional y, por tanto, mayor inversión.

12.7– Métricas no funcionales: latencia y coste

Una validación funcional positiva no garantiza por sí sola que el sistema sea desplegable a la población completa de la facultad. Por ello, sobre la misma suite de la Sección 12.2 se han medido dos métricas no funcionales adicionales: la latencia extremo a extremo del bot y el coste por turno asociado a las llamadas al modelo Gemini. La medición se realiza durante una corrida con el modificador `--delay 10` sobre 151 turnos, capturando 216 llamadas al modelo. El consumo de *tokens* de entrada se obtiene del campo `usage_metadata` del SDK; el consumo de salida se estima mediante la heurística estándar de cuatro caracteres por *token* en español, dado que el SDK de Google no expone `candidates_token_count` para la familia Gemma 3.

12.7.1. Latencia

Los percentiles de latencia se recogen en la Tabla 12.6. La mediana de 3,4 segundos es comparable a la observada en sistemas comerciales de chat asistido en horas de tráfico moderado. El percentil 95 de 10,5 segundos refleja la cola larga propia de las consultas que requieren recuperación semántica seguida de dos llamadas al modelo (*Text-to-SQL* y renderizado), concentradas mayoritariamente en la categoría *profesor*.

Cuadro 12.6: Latencia extremo a extremo (segundos).

Estadístico	Valor (s)
Mediana (p50)	3,4
Media	4,3
Percentil 90	9,2
Percentil 95	10,5
Máximo observado	14,1

12.7.2. Coste por turno

El coste se calcula aplicando las tarifas públicas de Gemini Flash Lite (0,075 USD por millón de *tokens* de entrada y 0,30 USD por millón de *tokens* de salida) y un tipo de cambio de 0,92 EUR/USD. Se elige Flash Lite por ser el modelo de facturación activa más económico del catálogo de Google [67] en la fecha de redacción, lo que proporciona la cota inferior del coste hipotético: cualquier alternativa de pago con mayor capacidad (Gemini 2.5 Flash, recomendado como paso intermedio en la Sección 5.6) resultaría más cara. Sobre 216 llamadas medidas, el coste medio por turno se sitúa en **0,012 céntimos de euro**, con un coste mediano de 0,008 céntimos y un percentil 95 de 0,036 céntimos. El turno más caro de la suite alcanzó 0,064 céntimos.

Para extrapolar este coste al despliegue completo del prototipo en la ETSII (con una población estimada de 700 alumnos del Grado en Ingeniería Informática) se han considerado tres escenarios de intensidad de uso, recogidos en la Tabla 12.7. Los tres valores de turnos por alumno y mes se anclan en evidencia distinta para acotar el rango económico, en lugar de fijarse de forma arbitraria. El escenario **conservador** (8 turnos/alumno/mes) se deriva del piloto. En los 25 días de captura se registraron 59 sesiones y 203 turnos auditados (Sección 12.5.2); bajo el supuesto de que un mismo usuario entró entre una y tres veces como máximo, el número de usuarios distintos se sitúa entre ~ 20 y ~ 59 , lo que arroja una tasa observada de 2–4 sesiones por usuario y mes. Multiplicada por la longitud media de sesión ($\sim 3,4$ turnos por sesión), esta tasa equivale a unos 7–14 turnos por alumno y mes, rango en cuyo extremo bajo se sitúa el valor de 8 utilizado como cota inferior. El escenario **realista** (20 turnos/alumno/mes) se ancla en la literatura sobre chatbots universitarios desplegados sobre poblaciones completas. Goel y Polepeddi [99] reportan del orden de 10 000 mensajes por semestre con aproximadamente 300 alumnos en la asistente virtual Jill Watson del Georgia Tech OMSCS, equivalentes a ~ 8 mensajes por alumno y mes a lo largo de un cuatrimestre lectivo; asumiendo entre dos y tres turnos por consulta en sistemas conversacionales con seguimiento de *slots* como el aquí evaluado, el orden de magnitud encaja con los ~ 20 turnos del escenario realista. El rango es además consistente con la adopción observada en los pilotos universitarios de AdmitBot [25] y EDUBOT [26]. El escenario de **pico** (50 turnos/alumno/mes) traduce la concentración de consultas durante la semana de exámenes mediante un cálculo explícito: un alumno que consulte el bot a diario durante los ~ 10 días hábiles previos a la convocatoria, con un promedio de cinco turnos por consulta (horarios, profesorado por grupo, criterios de evaluación, aulas), alcanza la cifra mensual de 50 turnos. La cifra extrapolada corresponde *únicamente* al coste hipotético de las llamadas al modelo de lenguaje en una tarifa de pago equivalente: en el despliegue actual, este coste es nulo porque el sistema utiliza el plan gratuito de Gemma. La cifra mostrada sirve para acotar la magnitud económica del componente LLM frente a alternativas

comerciales, no como coste total de operación.

Cuadro 12.7: Extrapolación del coste hipotético del LLM a 700 alumnos según intensidad de uso.

Escenario	Turnos/alumno/mes	Turnos/mes	Coste/mes	Coste/año
Conservador (lectivo)	8	5 600	0,67 EUR	8,06 EUR
Realista (uso medio)	20	14 000	1,68 EUR	20,16 EUR
Pico (exámenes)	50	35 000	4,20 EUR	50,40 EUR

El coste total de explotación del sistema en producción incluye, además, el alojamiento (Droplet de DigitalOcean de 12 \$/mes, necesario por el consumo de RAM del modelo Rasa) y la base de datos gestionada Supabase (gratuita en plan Free hasta 5 000 usuarios mensuales activos, 25 \$/mes en plan Pro a partir de ahí). El desglose completo, incluyendo escenarios de escalado a 5 000 y 70 000 usuarios, se presenta en la Sección 5.6 del Capítulo 5: el coste anual real para el escenario actual de 700 alumnos asciende aproximadamente a **132 €/año**. Aunque esta cifra es un orden de magnitud superior al coste extrapolado del LLM aislado, sigue siendo dos órdenes de magnitud inferior al de cualquier suscripción comercial equivalente, lo que respalda la viabilidad económica del despliegue.

12.8– Visión integrada y discusión

La Tabla 12.8 agrega los resultados de las seis capas de validación junto con su umbral académico de referencia. Las cinco capas funcionales superan su umbral, y la suite automática del panel de administración pasa los 24 casos definidos. Esta lectura permite afirmar que el sistema no presenta un único punto de fallo concentrado y que los errores residuales son conocidos, aislados y gestionables como trabajo futuro.

Cuadro 12.8: Visión integrada de las seis capas de validación.

Capa	N	PASS	%	Umbral	Veredicto
E2E (§12.2)	159	150	94,3	≥ 90 % [96]	Supera
RAG <i>baseline</i> (§12.3.1)	50	47	94,0	≥ 85 % [2]	Supera
RAG profundidad (§12.3.2)	74	68	91,9	≥ 85 % [29]	Supera
NLU + Policy (§12.4)	158	158	100	≥ 85 % [39]	Supera
Tráfico real (§12.5)	59	58	98,3	≥ 70 % [97]	Supera
Admin pytest (§12.9)	24	24	100	–	Supera

La comparación con chatbots universitarios publicados refuerza esta lectura. Los cuatro sistemas tomados como referencia (AdmitBot, EDUBOT, Ranoliya y Dibya–Sahoo) reportan cifras de exactitud comprendidas entre el 78 % y el 85 %; Linceus Assistant supera con claridad ese rango en las tres capas comparables (94,3 % en E2E, 91,9 % en RAG de profundidad y 98,3 % en tráfico real). La distancia es, en cualquier caso, prudente: la metodología de evaluación, el corpus utilizado y la naturaleza del dominio difieren entre proyectos y no permiten una comparación estrictamente cuantitativa.

12.8.1. Cumplimiento del criterio de cierre

Se considera que la fase de validación del prototipo queda cerrada en el momento en que se cumplen, de manera simultánea, los siguientes criterios: las cinco capas funcionales superan su umbral académico de referencia, la suite automática del panel de administración pasa íntegra, la metodología empleada está documentada y respaldada por bibliografía, los fallos residuales han sido identificados, categorizados y justificados, y se demuestra mediante medición directa que el coste y la latencia son compatibles con un despliegue real. Todos los criterios anteriores se cumplen a fecha de 26 de abril de 2026.

12.8.2. Amenazas a la validez

Para interpretar los resultados de las seis capas con el rigor que reclama la literatura empírica del software [100], conviene revisarlos a la luz de las cuatro categorías de **amenazas a la validez** comúnmente aceptadas. Esta revisión no busca refutar los porcentajes obtenidos, sino acotar las condiciones bajo las cuales son válidos.

Validez interna. La principal amenaza a la validez interna es el **sesgo de confirmación** introducido por el hecho de que el autor del prototipo es también el diseñador de los casos de prueba. Para mitigarlo, los casos de la suite E2E se redactaron *antes* de la implementación final de cada flujo, siguiendo el ciclo BDD descrito en la Sección 12.1.1, y se revisaron de forma cruzada con el tutor durante los sprints S4 a S7. La inclusión deliberada de casos negativos (datos inexistentes), de robustez (errores tipográficos, *prompt injection*) y de tráfico real (59 sesiones no controladas por el equipo) reduce además el margen de un sesgo unidireccional. Una segunda amenaza es el carácter **no determinista del componente generativo**: la temperatura de Gemini se fija a cero para las decisiones críticas (*Text-to-SQL*, clasificación binaria) precisamente para reducir variabilidad entre ejecuciones, pero la redacción final con temperatura 0,3 introduce una variación residual que la política de `--manual-review` (Sección 12.1.3) asume explícitamente: la decisión de PASS no se basa en una comparación de cadenas sino en una revisión humana del contenido.

Validez de constructo. La métrica principal del estudio, la **tasa de éxito** de cada capa, es una aproximación útil pero no exhaustiva al concepto de calidad de un asistente conversacional. No captura dimensiones subjetivas como la satisfacción del usuario ni la utilidad percibida, ambas evaluables con escalas estandarizadas como SUS [92] o CSAT que se reservan para una segunda iteración. La complementariedad de las cinco capas (E2E con datos sintéticos, RAG sobre planes reales, NLU sobre *stories*, tráfico real y suite de admin) mitiga parcialmente esta limitación al cubrir aspectos distintos del mismo constructo, pero la equivalencia entre las cinco no es plena.

Validez externa. Los resultados se obtuvieron sobre las tres titulaciones del Grado en Ingeniería Informática de la ETSII (GII-IS, GII-IC, GII-TI) y un piloto de 59 sesiones realizadas por alumnos de esas titulaciones. Su **generalización a otras titulaciones, otros centros o universidades** con estructuras administrativas distintas no está demostrada; cabe esperar que las cifras varíen, especialmente en la categoría *profesor* (cuyo bajo porcentaje es atribuible a una limitación de la base de datos PDI de *us.es*, sin equivalente en otros directorios universitarios). La arquitectura, sin embargo, se ha diseñado para que la incorporación de una nueva titulación sea cuestión de carga de datos en el panel (RNF-15), lo que sugiere que los flujos en sí son trasladables aunque las métricas requieran una nueva campaña de validación.

Validez de conclusión. El tamaño de muestra de la capa de tráfico real (59 sesiones, 203 turnos) es **suficiente para detectar efectos grandes** (diferencias de tasa de éxito superiores al 10 % en valor absoluto), pero no garantiza poder estadístico para detectar diferencias pequeñas o medianas. Para los porcentajes reportados en la Tabla 12.8, el intervalo de confianza al 95 % (binomial normal-aproximado) es de aproximadamente $\pm 3\%$ en la capa E2E, $\pm 3\%$ en el tráfico real y $\pm 6\%$ en el RAG de profundidad. Estos intervalos no comprometen las conclusiones cualitativas (todas las capas superan su umbral con margen) pero sí justifican prudencia frente a comparaciones finas entre porcentajes de distintas capas.

12.8.3. Limitaciones y trabajo futuro

La validación realizada no agota la evaluación posible del sistema. Quedan fuera de su alcance la medición de la experiencia subjetiva del usuario mediante una escala estandarizada como SUS, la evaluación de la disponibilidad sostenida del servicio en producción mediante un acuerdo de

nivel de servicio, y la cobertura automática de las operaciones de escritura destructiva del panel de administración (*horarios/generar* con `limpiar=true` y `DELETE /horarios`), que requieren un entorno de *staging* aislado para no comprometer los datos de producción. Estos tres frentes se abordarán en una segunda iteración, junto con un conjunto de palancas técnicas identificadas durante la ejecución de las pruebas: la elección de modelo Gemini en función del tipo de llamada (clasificación, *Text-to-SQL* o renderizado natural), la sustitución de heurísticas por expresiones regulares por clasificadores ligeros basados en LLM, la introducción de una memoria caché de respuestas para las consultas más frecuentes, la instrumentación de métricas de monitorización en producción y la persistencia de la última intención específica como *slot* consultable para resolver el seguimiento conversacional entre sub-*intents*.

12.9– Pruebas automatizadas del panel de administración

El panel de administración se valida mediante una suite de pruebas automatizadas con **pytest** y el cliente de test integrado de Flask, ubicada en `tests/test_admin.py`. La suite se ejecuta con el comando `pytest tests/test_admin.py -v` y no requiere infraestructura adicional.

La estrategia combina tres bloques con objetivos distintos: los *tests de lectura* ejercitan los endpoints GET contra la base de datos de producción sin ningún efecto secundario; los *tests de validación* comprueban que los endpoints de escritura rechazan correctamente los parámetros inválidos antes de llegar a la base de datos; y los *tests con mock* verifican la lógica de extracción de Sevius sustituyendo el scraper por un doble de prueba, lo que permite cubrir los flujos de error y los invariantes de inserción sin modificar los datos de producción.

12.9.1. Resultados

La Tabla 12.9 recoge los 24 casos ejecutados el 26 de abril de 2026, junto con su clasificación y veredicto.

Los 24 casos pasan en 16,86 segundos. El bloque GET confirma la integridad de los datos en producción y la ausencia de regresiones en los endpoints de lectura. El bloque 400 verifica que la capa de validación rechaza las solicitudes malformadas antes de ejecutar cualquier operación en la base de datos. El bloque mock demuestra que la lógica de extracción de Sevius maneja correctamente los tres escenarios críticos: error de red, catálogo vacío y catálogo con elementos ya presentes, sin insertar duplicados en ningún caso.

Las operaciones de escritura destructiva (*horarios/generar* con `limpiar=true` y `DELETE /horarios`) quedan fuera de la suite por el riesgo de dejar la base de datos en estado inconsistente al no disponer de un entorno de *staging* aislado, tal como se documenta en la Sección 12.8.3.

Cuadro 12.9: Resultados de la suite `test_admin.py` (pytest, 26/04/2026).

ID	Bloque	Qué verifica	Res.
A01	GET	Servidor activo y BD accesible (<code>/health</code>)	PASS
A02	GET	<code>/stats</code> devuelve las 10 claves con valores ≥ 0	PASS
A03	GET	<code>/centros</code> lista no vacía con campos requeridos	PASS
A04	GET	<code>/asignaturas</code> devuelve todas las asignaturas activas	PASS
A05	GET	<code>/asignaturas?titulacion_id</code> filtra correctamente	PASS
A06	GET	<code>/profesores</code> lista con campos de contacto	PASS
A07	GET	<code>/profesores/<id></code> devuelve perfil completo	PASS
A08	GET	<code>/profesores/<uuid-falso></code> devuelve 404	PASS
A09	GET	<code>/horarios?titulacion_id</code> devuelve franjas con campos completos	PASS
A10	GET	<code>/conversaciones</code> devuelve <code>total</code> y <code>rows</code>	PASS
A11	GET	<code>/conversaciones/sesiones</code> devuelve <code>session_id</code> y conteo	PASS
A12	GET	<code>/titulaciones?centro_id</code> devuelve titulaciones con conteos	PASS
A13	GET	<code>/horarios/extractores</code> lista centros con extracción soportada	PASS
A14	400	POST <code>/asignaturas/sync</code> sin body devuelve 400	PASS
A15	400	POST <code>/asignaturas/sync</code> sin <code>titulacion_id</code> devuelve 400	PASS
A16	400	POST <code>/asignaturas/sync</code> con UUID inexistente devuelve 404	PASS
A17	400	POST <code>/horarios/generar</code> sin <code>centro_id</code> devuelve 400	PASS
A18	400	POST <code>/horarios/generar</code> con UUID inexistente devuelve 404	PASS
A19	400	GET <code>/horarios/titulaciones</code> sin <code>centro_id</code> devuelve 400	PASS
A20	400	DELETE <code>/horarios</code> sin <code>centro_id</code> devuelve 400	PASS
A21	mock	Catálogo vacío de Sevius produce 404	PASS
A22	mock	Excepción en Sevius produce 502 con mensaje descriptivo	PASS
A23	mock	Asignaturas ya existentes no se reinsertan	PASS
A24	mock	INSERT invocado con <code>titulacion_id</code> correcto	PASS
Total			24/24

Manuales

Un sistema de software no se considera completo si quienes han de utilizarlo, mantenerlo o evolucionarlo no disponen de instrucciones suficientes para hacerlo. Por ese motivo, este capítulo recoge cuatro manuales complementarios que cubren los cuatro perfiles de interacción previstos para Linceus Assistant. El **manual de usuario** se dirige al alumnado de la ETSII, principal destinatario del prototipo, y describe cómo formular consultas y aprovechar las funcionalidades disponibles. El **manual de administrador** se dirige a quien gestiona el catálogo académico que alimenta al asistente, y describe las operaciones del panel de administración, sus prerequisites y el orden recomendado de carga. El **manual de despliegue** se dirige al personal técnico encargado de instalar y mantener el sistema, y detalla los requisitos, procedimientos y comprobaciones necesarias para poner en marcha la plataforma. El **manual de desarrollo**, por último, se dirige a los futuros estudiantes, becarios o investigadores que continúen este trabajo, y describe la organización del repositorio, las convenciones de codificación y el ciclo de incorporación de nuevos cambios.

Los tres manuales se basan en el estado del proyecto a fecha del cierre del prototipo (26 de abril de 2026). Cualquier divergencia con el repositorio actual debe consultarse en los ficheros `README.md` y `docker-compose.yml`, que son las referencias técnicas autoritativas y se mantienen actualizadas con los cambios del proyecto.

13.1– Manual de usuario

El destinatario de este manual es el alumnado de la ETSII que utiliza Linceus Assistant para resolver dudas académicas. El manual describe la interfaz, el modelo conversacional y los flujos de consulta disponibles, sin entrar en detalles técnicos de implementación.

13.1.1. Acceso a la aplicación

Linceus Assistant se ofrece como una aplicación web responsiva, accesible desde cualquier navegador moderno (Chrome, Firefox, Edge, Safari) tanto en ordenador como en dispositivo móvil. La página principal del prototipo muestra una breve descripción del proyecto y un *widget* de chat anclado en la esquina inferior derecha, que se despliega al hacer clic sobre el icono (Figura 13.1). No se requiere autenticación previa: la sesión se identifica internamente mediante un identificador anónimo generado por el navegador, lo que permite mantener el contexto durante la conversación sin recoger datos personales.

Tras desplegar el chat, el alumno encuentra un mensaje de bienvenida y, sobre él, un selector de titulación que sirve para fijar el contexto académico inicial (Figura 13.2). Por defecto, la titulación seleccionada es Grado en Ingeniería Informática – Ingeniería del Software (GII-IS), por ser la titulación con mayor cobertura informativa en el prototipo, pero el alumno puede cambiarla en cualquier momento, ya sea desde el selector o expresando el cambio en lenguaje natural durante la conversación (“cambia a tecnologías informáticas”, “soy de IC”).



Figura 13.1: Página principal del prototipo con el *widget* de chat cerrado.



Figura 13.2: *Widget* desplegado con mensaje de bienvenida y selector de titulación.

13.1.2. Modelo conversacional

El asistente está diseñado para responder a consultas formuladas en español natural. No es necesario emplear comandos ni una sintaxis específica: el sistema interpreta la intención del usuario a partir del texto libre y se apoya en el contexto de los turnos anteriores cuando la consulta es elíptica. Esto significa, por ejemplo, que tras preguntar por una asignatura concreta el alumno puede continuar con preguntas como “¿y cuántos créditos tiene?” sin necesidad de repetir el nombre.

El bot tolera errores tipográficos moderados, abreviaturas habituales (FP, ADDA, IISSI2, PSG2) y reformulaciones de la misma pregunta. Ante una consulta ambigua, el asistente solicita al usuario los datos que necesita, típicamente el curso o el grupo cuando la consulta afecta a horarios. Si la información solicitada no está disponible en la base de datos, el bot responde de forma explícita, sin inventar contenido. Las preguntas que caen fuera del ámbito académico (información meteorológica, peticiones generales no relacionadas con la universidad) se rechazan con un mensaje cortés y se redirige al usuario hacia el conjunto de funcionalidades soportadas.

13.1.3. Funcionalidades disponibles

El prototipo cubre tres dominios funcionales principales. La Tabla 13.1 resume los tipos de consulta soportados con un ejemplo representativo de cada uno.

Cuadro 13.1: Tipos de consulta soportados por el prototipo.

Dominio	Tipo de consulta	Ejemplo de pregunta
Asignaturas	Ficha individual	“¿Qué es ADDA?”
	Listado por criterio	“¿Qué optativas hay en cuarto?”
	Conteo	“¿Cuántas obligatorias tiene tercero?”
	Información del plan docente	“¿Cómo se evalúa PSG2?”
Horarios	Por curso y grupo	“Horario de segundo grupo 3”
	Por asignatura	“¿Cuándo es ADDA?”
	Por día concreto	“¿Qué clases hay el lunes?”
	Por aula o laboratorio	“Laboratorio de Álgebra grupo 1”
Profesorado	Datos de contacto	“Email de Galindo”
	Profesores de una asignatura	“¿Quiénes imparten IISSI2?”
	Coordinación	“¿Quién coordina IA?”
	Tutorías	“Tutorías de Bernárdez”

Las Figuras 13.3 a 13.5 ilustran cómo se ven en el chat tres de estos tipos de consulta, mostrando el formato de respuesta del bot.

Más allá de estas funcionalidades primarias, el bot incorpora dos comportamientos transversales que conviene conocer. El primero es el *cambio de contexto académico*, ya mencionado, que permite consultar información de cualquiera de las tres titulaciones de la ETSII (Ingeniería del Software, Ingeniería de Computadores, Tecnologías Informáticas) cambiando dinámicamente la titulación activa. El segundo es el *seguimiento conversacional*, que permite formular consultas elípticas apoyadas en los turnos anteriores: tras preguntar por una asignatura, expresiones del tipo “¿y de qué curso es?”, “¿y los profesores?” ó “¿y el horario?” resuelven correctamente la referencia implícita sin necesidad de repetir el nombre de la entidad.

13.1.4. Recomendaciones de uso

Aunque el sistema admite formulaciones libres, la calidad de la respuesta mejora cuando el alumno aporta el contexto necesario en la propia consulta. Para horarios resulta útil indicar curso




Figura 13.3: Ejemplo de consulta sobre una asignatura concreta (ficha individual).




Figura 13.4: Ejemplo de consulta de horario con curso y grupo.




Figura 13.5: Ejemplo de consulta sobre profesorado.

y grupo desde el primer turno; para profesorado, el apellido completo o el nombre exacto reduce la ambigüedad cuando varios docentes comparten apellido. Las consultas demasiado abiertas (“cuéntame cosas de la carrera”) tienden a producir respuestas genéricas, ya que el bot no dispone de un único objetivo informativo al que dirigirse. Por último, el sistema no almacena el contenido de las conversaciones para fines comerciales y permite al usuario reportar respuestas incorrectas mediante el botón de *feedback* integrado en cada turno, lo cual contribuye a la mejora continua del prototipo.

13.2– Manual de administrador

Este manual se dirige al perfil de *administrador del catálogo*: la persona responsable de mantener actualizada la base de datos académica que alimenta al asistente. A diferencia del usuario final, que únicamente formula consultas en lenguaje natural, el administrador opera sobre el contenido del prototipo a través de un panel web independiente. El presente manual describe la interfaz, las operaciones disponibles en cada pestaña y el orden recomendado para la carga inicial del catálogo. Para la traducción técnica de cada acción visible (*endpoint* REST, tablas afectadas) puede consultarse la Sección 11.10.2.

13.2.1. Acceso e interfaz general

El panel está disponible en `http://<host>/admin.html` y requiere un usuario con permisos de administración. Tras autenticarse, la interfaz muestra una barra de navegación superior con cinco pestañas (Figura 13.6): *Centros*, *Profesores*, *Horarios*, *Conversaciones* y *Estadísticas*. La pestaña activa por defecto es *Centros*, que actúa como punto de entrada jerárquico al resto del catálogo.




Figura 13.6: Panel de administración: pantalla de inicio con la jerarquía de centros.

Antes de entrar en el detalle de cada pestaña, conviene fijar dos comportamientos transversales que el administrador encontrará repetidamente. El primero es la *idempotencia* de las sincronizaciones: las acciones que extraen datos de Sevius o del directorio de `us.es` comparan con lo que ya hay en BD e insertan únicamente lo nuevo, de modo que pueden relanzarse sin temor a duplicados. El segundo es la *información de progreso*: las acciones síncronas largas devuelven al concluir un resumen con el conteo de elementos creados, actualizados y errores, que el panel muestra como notificación.

13.2.2. Pestaña Centros

La pestaña *Centros* es el punto de entrada jerárquico al catálogo y, a partir de ella, el administrador puede crear y poblar centros, titulaciones y asignaturas. La Tabla 13.2 resume las acciones disponibles. Tomando como ejemplo la ETSII, el flujo recomendado para el alta inicial es: pulsar *Sincronizar desde Sevius* para que el panel proponga la lista de centros oficiales y permita seleccionar el correspondiente; entrar al detalle del centro recién creado; lanzar *Sincronizar titulaciones desde Sevius* para crear las titulaciones del centro; y por último *Nueva titulación* si alguna no aparece en Sevius pero el administrador desea añadirla a mano. Las altas manuales (*Nuevo centro*, *Nueva titulación*) se conciben como excepción para escenarios en los que Sevius no recoge la entidad.

Cuadro 13.2: Acciones de la pestaña *Centros*.

Acción	Para qué sirve
Nuevo centro	Da de alta un centro manualmente, indicando código, nombre y código Sevius
Sincronizar desde Sevius	Trae la lista oficial de centros desde Sevius para crear uno por selección
Nueva titulación (dentro del centro)	Da de alta una titulación manualmente vinculada al centro
Sincronizar titulaciones desde Sevius	Crea las titulaciones del centro que aún no existan en BD

13.2.3. Pestaña Asignaturas

La pestaña *Asignaturas* aparece al entrar al detalle de una titulación y concentra las operaciones de carga de contenido docente (Figura 13.7). Es la pestaña con mayor variedad de acciones porque cubre desde la mera importación de identificadores hasta la generación de *embeddings* para el módulo RAG. La Tabla 13.3 las recoge.




Figura 13.7: Pestaña *Asignaturas* con la barra de acciones disponibles para la titulación.

El orden de ejecución recomendado para una titulación nueva es: *Sincronizar desde Sevius* (alta de los códigos), *Enriquecer datos* (relleno de curso y créditos), *Cargar docencia* (matrícula del profesorado del curso vigente) y, por último, *Vectorizar planes docentes* (incorporación al RAG). Las cuatro acciones son idempotentes y pueden relanzarse aisladamente cuando el catálogo

Cuadro 13.3: Acciones de la pestaña *Asignaturas*.

Acción	Para qué sirve
Sincronizar desde Sevius	Crea las asignaturas de la titulación que aún no existan, con código y nombre
Enriquecer datos	Cruza con <code>us.es</code> y completa curso, créditos y tipología (básica/optativa)
Cargar docencia	Popula la relación profesor–asignatura recorriendo los perfiles del PDI
Vectorizar planes docentes	Descarga los PDFs de cada grupo y genera <i>embeddings</i> en <code>pgvector</code>

cambie. La de mayor coste, en tiempo y en cuota de la API de *embeddings*, es la vectorización: conviene lanzarla únicamente cuando los planes docentes del curso académico estén estabilizados.

13.2.4. Pestaña Profesores

La pestaña *Profesores* (Figura 13.8) muestra la lista del PDI agrupada por departamento, con datos de contacto y enlace al perfil oficial. Las acciones disponibles se concentran en la cabecera (alcance *centro completo*) y en cada departamento (alcance *departamento*). La Tabla 13.4 las describe.

NOMBRE	DEPARTAMENTO	CATEGORIA	EMAIL	DESPACHO	PERFIL
Álvarez García, Juan Antonio	Departamento de Lenguajes y Sistemas Informáticos	Catedrático de Universidad	jaalvarez@us.es	F1.52	✉
Arévalo Maldonado, Carlos	Departamento de Lenguajes y Sistemas Informáticos	Profesor Titular de Universidad	carlosarevalo@us.es	F1.41	✉
Ayala Hernández, Daniel	Departamento de Lenguajes y Sistemas Informáticos	Profesor Permanente Laboral	dayala1@us.es	F1.81	✉
Barba Rodríguez, Irene	Departamento de Lenguajes y Sistemas Informáticos	Profesora Titular de Universidad	irenebr@us.es	F0.46	✉

Figura 13.8: Pestaña *Profesores* del panel de administración. La columna *Enriquecer desde us.es* dispara el scraper del directorio PDI para el departamento correspondiente.

Cuadro 13.4: Acciones de la pestaña *Profesores*.

Acción	Para qué sirve
Enriquecer desde <code>us.es</code> (cabecera)	Recorre todos los departamentos del centro y crea o actualiza los profesores
Refrescar enlaces <code>us.es</code>	Resuelve el enlace del directorio PDI para los profesores que aún no lo tienen
Enriquecer desde <code>us.es</code> (departamento)	Misma acción que la anterior, restringida a un departamento concreto

La acción de cabecera es la más utilizada en una primera carga: con un único *click* el panel descubre los departamentos del centro y trae a todos sus profesores. Las acciones por departamento

son útiles después, cuando un departamento concreto sufre cambios (incorporaciones, jubilaciones) y no merece la pena reescanear el centro entero. *Refreshar enlaces us.es* es un paso intermedio que alimenta la acción *Cargar docencia* de la pestaña anterior: sin enlace al directorio el sistema no puede consultar la docencia del profesor; por eso conviene ejecutarla justo antes de *Cargar docencia* si la base recoge profesores cargados manualmente.

13.2.5. Pestaña Horarios

La pestaña *Horarios* (Figura 13.9) reaprovecha los listados generados por los extractores específicos de cada centro. Para los centros que disponen de extractor (la ETSII a fecha del cierre del prototipo), un botón *Generar horarios* dispara la extracción del PDF oficial de horarios, lo trocea y pobla las tablas `horarios`, `grupos_clase` y `aulas`. Los centros sin extractor muestran ese botón inhabilitado, con un mensaje informativo. La Tabla 13.5 resume la acción.




Figura 13.9: Pestaña *Horarios* con el botón *Generar horarios* activo para los centros con extractor disponible.

Cuadro 13.5: Acciones de la pestaña *Horarios*.

Acción	Para qué sirve
Generar horarios (donde disponible)	Ejecuta el extractor del centro, pobla horarios, grupos y aulas para el curso académico actual

La acción acepta un parámetro de *limpieza* que vacía los horarios del centro antes de regenerarlos, útil cuando el PDF oficial cambia tras la publicación inicial. Por defecto la acción es aditiva, pero conviene activar *limpiar* si el cambio del PDF es estructural (alteraciones de aulas, fusión de grupos, cambio de turnos), pues una ejecución meramente aditiva conservaría las filas obsoletas.

13.2.6. Pestaña Conversaciones y feedback

La pestaña *Conversaciones* (Figura 13.10) muestra las sesiones registradas anonimizadas, agrupadas por sesión, con primer y último mensaje, duración y número de turnos. Sirve a dos fines: detectar patrones de uso para priorizar mejoras y generar conjuntos de prueba a partir de interacciones reales. La Tabla 13.6 recoge las acciones disponibles sobre la lista.

La marca de sesiones revisadas resulta útil cuando el administrador realiza pasadas periódicas de control de calidad: tras leer una sesión la marca y, en visitas posteriores, el filtro de la pestaña deja a un lado las ya revisadas, lo que permite avanzar sin perder de vista el progreso. La exportación, por su parte, es la fuente más rápida de casos de prueba reales: las preguntas que se

Panel de Administración
LinceUS - Gestión de datos académicos

Conversaciones 72 sesiones

✓	SESIÓN	MENSAJES	PRIMER MENSAJE	ÚLTIMO MENSAJE	INICIO	DURACIÓN
☐	session_177766...	4	GII-HS	Quiero saber la evaluación de ispp para el grup...	1/5/2026, 23:02:07	9 min
☒	session_177766...	2	GII-HS	¿qué es ABDA?	1/5/2026, 21:38:38	19s
☐	session_177755...	4	GII-HS	Háblame de Redes de Computadores	30/4/2026, 16:35:28	1 min
☐	session_177755...	3	GII-HS	Cuales son los horarios de matemática discreta?	30/4/2026, 16:32:42	1 min
☐	session_177746...	1	GII-HS	GII-HS	29/4/2026, 12:58:20	1s
☐	session_177732...	1	GII-HS	GII-HS	27/4/2026, 23:44:31	1s

Figura 13.10: Pestaña *Conversaciones* con las sesiones agrupadas. La fila resaltada en verde indica una sesión ya revisada por el administrador.

Cuadro 13.6: Acciones de la pestaña *Conversaciones*.

Acción	Para qué sirve
Marcar sesión como revisada	Indica que un examinador ya ha valorado la conversación; resaltada en verde
Exportar para testing	Vuelca la página actual de sesiones a un fichero local apto para la suite de pruebas

vuelcan se pueden incorporar al catálogo de `tests`/ para validar regresiones tras los cambios en el modelo NLU.

13.2.7. Pestaña Estadísticas

La pestaña *Estadísticas* (Figura 13.11) no expone acciones de escritura: presenta una colección de contadores globales que se calculan en tiempo real contra la base de datos. Su utilidad es doble: sirve como *health check* de carga (un valor inesperadamente bajo en *Asignaturas* o *Profesores* delata un problema en una sincronización reciente) y como referencia rápida del tamaño del catálogo a fecha actual. Los contadores que muestra son: centros, titulaciones, asignaturas, profesores, grupos, horarios, planes docentes, *chunks* RAG, conversaciones y *feedbacks*.

13.2.8. Procedimiento recomendado de carga inicial

Aunque cada pestaña puede operarse de forma autónoma, el orden importa cuando se carga el catálogo desde cero, porque varias acciones tienen prerequisites en otras pestañas. La Tabla 13.7 recoge la secuencia validada durante la fase de pruebas del prototipo, que el administrador puede tomar como referencia para futuras instalaciones en otros centros.

Tras completar los nueve pasos, la pestaña de *Estadísticas* debería reflejar volúmenes coherentes con el centro cargado, y el chatbot pasa a estar operativo para los tres dominios funcionales (asignaturas, horarios, profesorado) descritos en el Capítulo 6. Las actualizaciones posteriores, ya en régimen estacionario, suelen reducirse a relanzar las acciones de *enriquecer* y *cargar docencia* al inicio de cada curso, y a vectorizar los planes docentes nuevos a medida que los departamentos los publican en Sevius.




Figura 13.11: Pestaña *Estadísticas*: contadores globales del catálogo cargado.

Cuadro 13.7: Secuencia recomendada para la carga inicial del catálogo de un centro.

Paso	Pestaña / acción	Resultado esperado
1	Centros / <i>Sincronizar desde Sevius</i>	Centro creado a partir del catálogo oficial
2	Centros / <i>Sincronizar titulaciones desde Sevius</i>	Titulaciones del centro disponibles en BD
3	Asignaturas / <i>Sincronizar desde Sevius</i>	Asignaturas creadas con código y nombre, sin metadatos completos
4	Asignaturas / <i>Enriquecer datos</i>	Asignaturas con curso, créditos y tipología actualizados desde <i>us.es</i>
5	Profesores / <i>Enriquecer desde us.es</i> (cabecera)	Departamentos del centro y profesorado del PDI cargados
6	Profesores / <i>Refrescar enlaces us.es</i>	Profesores con enlace al directorio oficial, prerequisite de cargar docencia
7	Asignaturas / <i>Cargar docencia</i>	Tabla <i>profesor_asignatura</i> poblada para el curso vigente
8	Asignaturas / <i>Vectorizar planes docentes</i>	<i>Embeddings</i> RAG generados; el bot puede contestar preguntas sobre planes docentes
9	Horarios / <i>Generar horarios</i> (si extractor disponible)	Horarios del curso académico actual cargados

13.3– Manual de despliegue

El manual de despliegue describe los pasos necesarios para instalar Linceus Assistant en una infraestructura nueva, ya sea un entorno de desarrollo local o un servidor de producción. La instalación se ha diseñado para ser reproducible mediante Docker Compose, lo que evita la necesidad de instalar manualmente el conjunto de dependencias del *stack* y reduce drásticamente las divergencias entre entornos.

13.3.1. Requisitos previos

La máquina destinataria debe cumplir los requisitos mínimos recogidos en la Tabla 13.8. Estos requisitos se han validado sobre el *droplet* de DigitalOcean utilizado durante el piloto y son suficientes para la carga prevista en la fase de prototipo (un orden de magnitud por debajo de la población total de la ETSII).

Cuadro 13.8: Requisitos mínimos del entorno de despliegue.

Recurso	Valor recomendado
Sistema operativo	Linux (Ubuntu 22.04 LTS o equivalente)
CPU	2 vCPU
Memoria RAM	4 GB
Almacenamiento	20 GB SSD
Docker Engine	24.x o superior
Docker Compose	v2 (incluido en Docker Engine)
Conectividad saliente	HTTPS hacia Supabase y Google AI Studio

Además de los recursos de cómputo, el despliegue requiere disponer de tres credenciales externas: la cadena de conexión a la base de datos Supabase con extensión *pgvector*, la clave de API de Google AI Studio para el modelo Gemini y un dominio o subdominio con certificado TLS si la instalación se realiza en producción. Estas credenciales se configuran en un fichero `.env` ubicado en la raíz del proyecto, cuyo formato se describe en `.env.example`.

13.3.2. Instalación

La instalación parte de la clonación del repositorio del proyecto y se completa en cuatro pasos. El primer paso consiste en obtener una copia local del código y situarse en el directorio resultante. El segundo paso es preparar el fichero `.env` a partir de la plantilla, sustituyendo cada variable por el valor correspondiente al entorno de despliegue. El tercer paso es asegurarse de que el directorio `models/` contiene un modelo Rasa entrenado: si no es así, basta con ejecutar `rasa train` en un entorno con las dependencias instaladas, o bien copiar el último modelo válido desde el repositorio. El cuarto y último paso es levantar la pila completa con Docker Compose:

```
1 git clone <url-repositorio> && cd linceus-assistant
2 cp .env.example .env # completar variables
3 docker compose -f docker/docker-compose.yml up --build -d
```

Código 13.1: Levantar la pila completa con Docker Compose.

La opción `-d` ejecuta los contenedores en segundo plano. El primer arranque construye las imágenes correspondientes, lo que puede tardar varios minutos en función del ancho de banda disponible para descargar las dependencias. A partir de ese momento, los re arranques posteriores son cuestión de pocos segundos, salvo que se hayan modificado las dependencias de Python.

13.3.3. Arquitectura del despliegue

La pila se compone de cuatro contenedores que se comunican entre sí a través de la red interna de Docker, recogidos en la Tabla 13.9. Únicamente el contenedor de *frontend* expone el puerto 80 al exterior; el resto de servicios son accesibles solo desde el interior de la red, salvo que el operador decida exponerlos explícitamente para fines de depuración.

Cuadro 13.9: Contenedores del despliegue y responsabilidad de cada uno.

Contenedor	Imagen base	Versión	Responsabilidad
frontend	nginx:alpine	alpine	Sirve los ficheros estáticos y actúa como <i>proxy</i>
rasa	rasa/rasa	3.6.21 + spaCy	Gestor del diálogo y NLU (puerto 5005)
actions	python:3.10.14-slim-bookworm	3.10.14	Acciones personalizadas y módulo RAG
admin	python:3.10-slim	3.10	API Flask del panel de administración

El contenedor de *actions* monta los directorios *actions/* y *rag/* como volúmenes, lo que permite recargar los cambios en caliente sin reconstruir la imagen. El contenedor de Rasa monta los ficheros de configuración (*config.yml*, *domain.yml*, *credentials.yml*) y un fichero específico de *endpoints* que enruta el servidor hacia el contenedor de *actions* a través del nombre de servicio interno. El contenedor de *frontend* inyecta la variable *RASA_SERVER* en los ficheros estáticos en el momento del arranque mediante un *script* de *entrypoint*, lo que evita tener que recompilar el *frontend* para distintos entornos.

13.3.4. Verificación del despliegue

Una vez levantada la pila, la verificación del despliegue se realiza siguiendo cuatro comprobaciones en orden. En primer lugar, la página principal debe estar accesible en `http://<host>/`, donde *<host>* es la dirección o dominio del servidor. En segundo lugar, el panel de administración debe estar accesible en `http://<host>/admin.html` y permitir consultar la lista de centros y titulaciones. En tercer lugar, el *widget* de chat debe responder a un mensaje de prueba simple (“hola”) con un saludo personalizado, lo cual confirma que el camino completo entre *frontend*, Rasa, *actions* y modelo Gemini está operativo. Por último, una consulta sencilla con dependencia de base de datos (“¿cuántas asignaturas tiene primero?”) debe devolver una cifra coherente con los datos cargados, lo cual confirma la conectividad con Supabase.

Si alguna de estas comprobaciones falla, los registros de cada contenedor se consultan con la orden recogida en el Código 13.2, donde *<servicio>* es uno de los cuatro nombres recogidos en la Tabla 13.9. El error más habitual durante la primera puesta en marcha es la falta de un modelo entrenado en *models/*, lo que provoca que el contenedor de Rasa se reinicie en bucle.

```
1 docker compose -f docker/docker-compose.yml logs -f <servicio>
2 # Ejemplo: ver logs del servidor Rasa en tiempo real
3 docker compose -f docker/docker-compose.yml logs -f rasa
```

Código 13.2: Consultar registros de un contenedor.

13.3.5. Operaciones habituales

El día a día del operador se concentra en un puñado de tareas rutinarias. Los cambios en el código de *actions* o del módulo RAG no requieren reiniciar nada, ya que el *action server* se ejecuta con la opción `--auto-reload`. Los cambios en el modelo Rasa (re-entrenamiento) requieren detener y volver a arrancar el contenedor *rasa* para que recargue el modelo desde el volumen *models/*. Las actualizaciones de las dependencias de Python requieren reconstruir la imagen afectada antes de volver a levantarla. Las copias de seguridad de la base de datos se gestionan

desde el panel de Supabase, que dispone de *snapshots* automáticos diarios; el código del proyecto no almacena estado mutable en disco fuera de la base de datos.

```

1 # Recargar modelo Rasa tras reentrenamiento
2 docker compose -f docker/docker-compose.yml restart rasa
3
4 # Reconstruir imagen tras cambio de dependencias Python
5 docker compose -f docker/docker-compose.yml build actions
6 docker compose -f docker/docker-compose.yml up -d actions
7
8 # Detener toda la pila
9 docker compose -f docker/docker-compose.yml down

```

Código 13.3: Operaciones de mantenimiento habituales.

13.4– Manual de desarrollo

El manual de desarrollo se dirige a quien deba modificar, ampliar o mantener el código de Linceus Assistant tras el cierre de este TFG. Su objetivo es minimizar la curva de aprendizaje proporcionando una visión panorámica del repositorio, las convenciones empleadas y el ciclo de trabajo recomendado.

13.4.1. Estructura del repositorio

El repositorio sigue la disposición habitual de un proyecto Rasa con extensiones específicas para el módulo RAG y el panel de administración. La Tabla 13.10 recoge los directorios de primer nivel y su responsabilidad.

Cuadro 13.10: Estructura del repositorio Linceus Assistant.

Directorio	Contenido
actions/	Acciones personalizadas (Python) que ejecuta el <i>action server</i>
admin/	Aplicación Flask del panel de administración
data/	Conjuntos de datos NLU y <i>stories</i> para Rasa
docker/	Ficheros de Compose y <i>Dockerfile</i> de cada servicio
frontend/	<i>Widget</i> de chat y panel HTML/CSS/JS
models/	Modelos Rasa entrenados (no versionados)
rag/	Módulo de recuperación aumentada por generación
tests/	Suite de aceptación funcional y planes de prueba

Los ficheros de configuración principales (`config.yml`, `domain.yml`, `credentials.yml`, `endpoints.yml` y `endpoints.docker.yml`) residen en la raíz, junto con los ficheros de dependencias `requirements-rasa.txt` y `requirements-actions.txt`. La documentación específica de cada componente se encuentra en su propio fichero `README.md`, mientras que el `README.md` de la raíz centraliza las instrucciones de arranque local y con Docker.

13.4.2. Entorno de desarrollo

El entorno de desarrollo recomendado se basa en Python 3.10 dentro de un entorno virtual. Tras clonar el repositorio, los pasos habituales son los del Código 13.4.

```

1 python3.10 -m venv .venv && source .venv/bin/activate
2 pip install -r requirements-rasa.txt -r requirements-actions.txt
3 cp .env.example .env # completar con claves reales

```

```
4 rasa train # genera models/linceus_vX.Y.Z.tar.gz
```

Código 13.4: Preparacion del entorno de desarrollo local.

A partir de ese momento, los cuatro componentes (Rasa, *action server*, panel y *frontend*) pueden levantarse en terminales independientes según se documenta en el `README.md` principal. Los comandos del Código 13.5 arrancan el flujo completo sin Docker.

```
1 # Terminal 1: servidor Rasa
2 rasa run --enable-api --cors "*" --port 5005 --endpoints endpoints.yml
3
4 # Terminal 2: action server (recarga automatica al guardar)
5 rasa run actions --port 5055 --auto-reload
6
7 # Terminal 3: panel de administracion Flask
8 python -m admin.app
9
10 # Terminal 4: frontend (servir estaticos)
11 cd frontend && python -m http.server 8080
```

Código 13.5: Arranque de los componentes en modo desarrollo.

Durante el desarrollo, la opción `--auto-reload` del *action server* y la naturaleza estática del *frontend* permiten iterar rápidamente sobre la mayoría de los cambios. Los cambios en el modelo NLU o en el dominio de Rasa requieren un nuevo entrenamiento, que en una máquina convencional toma alrededor de uno o dos minutos. Los cambios en la estructura de la base de datos se gestionan a través del editor de tablas de Supabase y deben propagarse manualmente al fichero `schema.sql` de referencia.

13.4.3. Ciclo de incorporación de cambios

El proyecto sigue un flujo de trabajo basado en *feature branches* sobre la rama principal `main`. Cada cambio se desarrolla en una rama propia, se valida localmente mediante la suite de pruebas pertinente y se integra a través de una solicitud de incorporación que se revisa antes de fusionar. El ciclo se compone de cinco etapas, descritas en la Tabla 13.11.

Cuadro 13.11: Etapas del ciclo de incorporación de cambios.

Etapas	Descripción
1. Diseño	Definición del cambio en términos de requisito o defecto. Si el cambio afecta al NLU, se preparan ejemplos adicionales para <code>nlu.yml</code> .
2. Implementación	Modificación del código en la rama de trabajo, siguiendo las convenciones de estilo de Python (PEP 8) y de Rasa.
3. Pruebas locales	Ejecución de <code>rasa test core</code> para la política, <code>run-test-plan.py</code> para la suite E2E pertinente y revisión manual de los casos afectados.
4. Integración	Solicitud de incorporación a <code>main</code> con descripción de los cambios y de los casos de prueba afectados.
5. Despliegue	Reconstrucción de los contenedores afectados y verificación en el entorno de pruebas antes de promocionar a producción.

13.4.4. Cómo añadir una nueva intención

La incorporación de una nueva intención conversacional es la operación más frecuente durante la evolución del bot, y el procedimiento es suficientemente representativo como para servir de ilustración del ciclo completo.

El primer paso es declarar la intención en `domain.yml` y añadir entre quince y veinte ejemplos representativos en `data/nlu.yml`, procurando cubrir tanto formulaciones limpias como con errores tipográficos habituales. El Código 13.6 muestra la estructura de un bloque de ejemplos típico:

```
1 - intent: consulta_creditos_asignatura
2   examples: |
3     - cuantos creditos tiene [ADDA] (nombre_asignatura)
4     - cuantos creditos son de [Redes] (nombre_asignatura)
5     - creditos de [PSG2] (nombre_asignatura)
6     - de cuantos creditos es [IISSI2] (nombre_asignatura)
7     - [FP] (nombre_asignatura) cuantos creditos
```

Código 13.6: Declaración de una intención con ejemplos NLU en `data/nlu.yml`.

El segundo paso es definir, si procede, los *slots* y entidades que la intención necesita extraer; estos también se declaran en `domain.yml` y se entrenan automáticamente con el modelo. El tercer paso es escribir la acción personalizada en `actions/` si la intención requiere consultar la base de datos o el módulo RAG, registrándola tanto en el dominio como en `actions/__init__.py`. El Código 13.7 muestra la estructura mínima de una acción:

```
1 from rasa_sdk import Action, Tracker
2 from rasa_sdk.executor import CollectingDispatcher
3 from rasa_sdk.events import SlotSet
4
5 class ActionConsultaCreditos(Action):
6
7     def name(self) -> str:
8         return "action_consulta_creditos"
9
10    def run(self, dispatcher: CollectingDispatcher,
11            tracker: Tracker,
12            domain: dict) -> list:
13        nombre = tracker.get_slot("nombre_asignatura")
14        # ... consultar BD y generar respuesta
15        dispatcher.utter_message(text=f"{nombre} tiene 6 creditos ECTS.")
16        return [SlotSet("ultimo_nombre_asignatura", nombre)]
```

Código 13.7: Estructura mínima de una acción personalizada en Rasa.

El cuarto paso es añadir las *stories* correspondientes en `data/stories.yml` para que la política aprenda a enrutar correctamente la nueva intención. El quinto paso es entrenar el modelo, validar la intención con casos manuales y, si la cobertura es razonable, añadir uno o dos casos de aceptación a `tests/run_test_plan.py` para garantizar que la nueva funcionalidad no se regresa en futuros cambios.

13.4.5. Buenas prácticas y convenciones

A lo largo del desarrollo se han adoptado un conjunto de convenciones que conviene mantener en futuras iteraciones. Las acciones personalizadas se nombran con el prefijo `action_` seguido del verbo principal del flujo (`action_consulta_profesor`, `action_cambiar_contexto`). Los *slots* cuya función es persistir la última entidad consultada llevan el prefijo `ultimo_` (`ultimo_nombre_asignatura`, `ultimo_profesor_consultado`).

Los identificadores de los casos de prueba siguen un patrón de letra mayúscula seguido de tipo y número, donde la letra inicial alude a la categoría (E para asignaturas específicas, H para horarios, P para profesores, C para conteo, L para listado, X para cross-dominio, F y R para casos fuera de ámbito y *jailbreak*). Cada decisión de diseño no trivial se documenta como una entrada D-XXX en el fichero correspondiente del repositorio, lo que facilita reconstruir el porqué de un comportamiento al cabo del tiempo.

El Código 13.8 ilustra un patrón de diseño transversal al proyecto: la separación entre generación y validación. El módulo `text_to_sql` delega en Gemini la generación de SQL en lenguaje natural, pero antes de ejecutar cualquier *query* la pasa por una función de validación que rechaza instrucciones de escritura, tablas no autorizadas y columnas fuera del esquema permitido. Este patrón evita que un fallo en el LLM pueda comprometer la integridad de la base de datos.

```

1 # actions/asignaturas/text_to_sql.py
2 PALABRAS_PROHIBIDAS = [
3     'INSERT', 'UPDATE', 'DELETE', 'DROP', 'ALTER', 'CREATE',
4     'TRUNCATE', 'EXEC', 'UNION SELECT', 'OR 1=1', 'SLEEP(',
5 ]
6 TABLAS_PERMITIDAS = {'ASIGNATURAS', 'TITULACIONES'}
7
8 def validar_sql(sql: str, tipo: str = 'select') -> Optional[str]:
9     sql_upper = sql.upper().strip()
10    for palabra in PALABRAS_PROHIBIDAS:
11        if palabra in sql_upper:
12            return None # rechazar silenciosamente
13    if not sql_upper.startswith('SELECT'):
14        return None
15    tablas = re.findall(r'FROM\s+(\w+)|JOIN\s+(\w+)', sql_upper)
16    tablas_flat = {t for grupo in tablas for t in grupo if t}
17    if tablas_flat - TABLAS_PERMITIDAS:
18        return None
19    return sql

```

Código 13.8: Fragmento de `validar_sql`: lista de palabras prohibidas y verificación de tabla.

Por último, conviene recordar que toda modificación que afecte al comportamiento del bot debe acompañarse de la actualización de los ejemplos NLU correspondientes y de un nuevo caso de aceptación. La experiencia acumulada durante el TFG demuestra que las regresiones más costosas de detectar son las que se producen en flujos colaterales tras un cambio aparentemente local; mantener la suite de aceptación actualizada es la principal salvaguarda frente a este tipo de error.

Conclusiones y desarrollos futuros

Este capítulo cierra la memoria del trabajo. Tras un proyecto extenso conviene levantar la vista del detalle técnico y revisar qué se planteó al inicio, qué ha quedado efectivamente construido y qué queda por hacer. La estructura del capítulo reproduce ese orden: se sintetiza el estado final del sistema con un cuadro de indicadores, se contrastan los objetivos enunciados en el Capítulo 1 con la evidencia recogida durante la validación, se recopilan las lecciones aprendidas a lo largo del desarrollo, se analiza la desviación de la planificación inicial, se enumeran las líneas de evolución previstas para una segunda iteración del sistema, se discuten las consideraciones éticas y se cierra con una reflexión personal sobre la experiencia.

14.1– Linceus en números

Antes de revisar el cumplimiento de objetivos conviene fijar el tamaño y la cobertura efectiva del sistema en el momento del cierre. La Tabla 14.1 agrupa los indicadores principales en cuatro bloques (alcance funcional, validación, métricas no funcionales y proceso de desarrollo). Todas las cifras son trazables al artefacto de origen citado en la columna derecha.

Los porcentajes superan en todas las capas su umbral académico de referencia con un margen razonable y los indicadores de proceso (72 decisiones documentadas, 8 *sprints* cerrados con incremento desplegable) avalan que la cifra de validación es producto de un desarrollo trazable y no de un ajuste *ad hoc* en la fase final.

14.2– Cumplimiento de objetivos

El Capítulo 1 planteaba un objetivo general y un conjunto de objetivos técnicos y académicos. Resulta razonable revisar uno por uno hasta qué punto se han alcanzado, apoyándose en la evidencia recopilada en el Capítulo 12.

14.2.1. Objetivo general

El objetivo general consistía en diseñar y desarrollar un asistente conversacional que ofreciera al alumnado de la Universidad de Sevilla un punto de acceso centralizado, accesible y eficiente a la información académica y administrativa. Tras el cierre del prototipo, este objetivo puede considerarse alcanzado en su versión correspondiente a la fase 1: el sistema cubre las tres épicas funcionales previstas (asignaturas, profesorado y horarios), responde correctamente al 94,3 % de los casos de la suite de aceptación funcional y al 98,3 % de las sesiones generadas por usuarios reales durante el piloto. La pieza queda desplegada en infraestructura de DigitalOcean y accesible mediante navegador, sin necesidad de credenciales, lo que satisface la condición de accesibilidad. Los grupos a los que la propuesta atendía con mayor prioridad (alumnado de nuevo ingreso e internacional) figuran entre los principales usuarios del piloto, lo que respalda la utilidad práctica del sistema.

Cuadro 14.1: Indicadores cuantitativos de Linceus Assistant al cierre del prototipo (26/04/2026).

Indicador	Valor	Fuente
<i>Alcance funcional</i>		
Intenciones NLU definidas (activas)	36 (34)	domain.yml
Entidades NLU	10	domain.yml
Stories de entrenamiento	37	data/stories.yml
Reglas activas	20	data/rules.yml
Custom actions activas	14	actions/
Archivos NLU por dominio	5	data/nlu/
Titulaciones soportadas	3 (GII-IS, IC, TI)	Sección 6.1
<i>Validación funcional</i>		
Casos E2E (PASS / total)	150 / 159 (94,3 %)	Tabla 12.1
RAG baseline (PASS / total)	47 / 50 (94,0 %)	Sección 12.3.1
RAG profundidad (OK / total)	68 / 74 (91,9 %)	Tabla 12.2
NLU + Policy (acciones correctas)	158 / 158 (100 %)	Tabla 12.3
Tráfico real piloto (sesiones PASS)	58 / 59 (98,3 %)	Tabla 12.4
Suite admin <i>pytest</i> (PASS / total)	24 / 24 (100 %)	Tabla 12.9
Turnos auditados en piloto	201 / 203	Sección 12.5.2
<i>Métricas no funcionales</i>		
Latencia mediana (p50)	3,4 s	Tabla 12.6
Latencia p95	10,5 s	Tabla 12.6
Coste medio por turno (Gemini)	0,012 cts	Sección 12.7.2
Llamadas a Gemini medidas	216	Sección 12.7
Tiempo de cumplimiento RNF-14 (primera consulta)	28 s (mediana)	Tabla 6.9
<i>Proceso de desarrollo</i>		
Sprints completados	8	Capítulo 5
Decisiones técnicas documentadas	113 (S2–S7)	docs/sprints/, Apéndice .3
Esfuerzo estimado total	~300 h	Sección 14.4

14.2.2. Objetivos técnicos

La Tabla 14.2 cruza cada objetivo técnico definido en el Capítulo 1 con su evidencia en el Capítulo 12. Todos ellos se han cumplido en la fase 1, con dos matices: la interfaz web final no se ha desarrollado en React como contemplaba la propuesta inicial sino en JavaScript *vanilla* sobre HTML estático, decisión justificada por el menor coste de mantenimiento del prototipo, y el cumplimiento del RGPD se materializa por la naturaleza anónima de las sesiones más que por un despliegue *on-premise*, dado que la infraestructura final reside en DigitalOcean y la base de datos en Supabase.

Cuadro 14.2: Cruce entre objetivos técnicos y evidencia obtenida.

Objetivo técnico	Evidencia
Sistema conversacional Rasa con flujos contextuales	Modelo Rasa 3.6 entrenado, 158/158 acciones correctas en la prueba de política (§12.4).
Integración con Gemini	216 llamadas medidas en la suite, coste medio de 0,012 cts/turno (§12.7.2).
Base de datos híbrida en Supabase con pgvector	Esquema relacional + tabla de <i>embeddings</i> , capa RAG validada al 91,9 % de profundidad (§12.3.2).
Acciones personalizadas en Python	Tres épicas implementadas; 150/159 PASS en la suite E2E (§12.2).
Frontend accesible	Widget desplegado, validado mediante 59 sesiones reales (§12.5).
Cumplimiento RGPD	Sesiones anónimas, sin almacenamiento de datos personales identificables.

14.2.3. Objetivos académicos y personales

Desde el punto de vista formativo, el proyecto ha permitido aplicar de forma articulada conocimientos procedentes de varias asignaturas del Grado en Ingeniería del Software (bases de datos, ingeniería del software, sistemas inteligentes, procesamiento del lenguaje natural y despliegue de aplicaciones), y ha exigido autoaprendizaje sobre tecnologías que no formaban parte del currículo oficial, como el módulo RAG y la integración de modelos de lenguaje. La metodología SCRUM adaptada a un proyecto individual ha sido también una novedad relevante, dado que el grado expone fundamentalmente a equipos de cinco o seis personas. El trabajo ha quedado documentado, validado mediante una suite de pruebas reproducible y desplegado en producción, lo que cumple los tres criterios formativos planteados al inicio: aplicar, integrar y dejar trazabilidad del proceso.

14.3– Lecciones aprendidas

La experiencia acumulada durante el desarrollo deja un conjunto de lecciones que resulta razonable consignar. Las primeras son de naturaleza técnica y se han ido formulando como decisiones documentadas a lo largo del repositorio (entradas D-XXX). Las segundas son de naturaleza metodológica y afectan al modo en que el proyecto se ha organizado en el tiempo. Las terceras son de naturaleza personal.

En el plano técnico, la lección más relevante es que la combinación de *Text-to-SQL* y recuperación aumentada por generación cubre dominios distintos y conviene mantenerlas como caminos separados. *Text-to-SQL* resuelve con eficacia las consultas estructuradas (créditos, listados, conteos), mientras que el RAG es indispensable cuando la pregunta requiere fragmentos textuales no normalizados (criterios de evaluación, composición de tribunales, contenidos de bloques). El intento inicial de unificar ambas vías mediante un único *prompt* produjo respuestas confusas y obligó a separar acciones específicas para cada caso. Una segunda lección es que el clasificador NLU debe re-entrenarse con ejemplos extraídos del tráfico real una vez disponible, dado que las

formulaciones espontáneas de los usuarios reales cubren un espacio léxico que el conjunto de *stories* sintéticas no anticipa.

En el plano metodológico, la introducción de la suite de pruebas en una etapa temprana del desarrollo ha resultado decisiva. La primera versión de la suite contaba con 51 casos sobre la épica de asignaturas y arrojaba un 70,6 % de éxito; el sistema actual evalúa 159 casos con un 94,3 % de éxito. Sin la suite, las regresiones introducidas por cada cambio habrían sido muy difíciles de detectar a ojo. La lección complementaria es que cada decisión de diseño no trivial conviene registrarla en el momento, no al final: cuando se trata de reconstruir el porqué de un comportamiento al cabo de un mes, la memoria del autor ya no basta.

En el plano personal, gestionar un proyecto individual de la magnitud de un TFG exige imponerse una cadencia regular de trabajo, especialmente durante los meses en los que coexiste con asignaturas. La adopción de *sprints* de tres o cuatro semanas ha funcionado bien como mecanismo de auto-disciplina, y el cierre de cada *sprint* con un incremento desplegable ha sostenido la motivación a lo largo del curso.

14.4– Análisis de desviación

La planificación inicial recogida en el Capítulo 5 estimaba el esfuerzo total del proyecto en torno a 300 horas, repartidas entre tres fases (Inicio, Desarrollo y Cierre) y un conjunto de paquetes de trabajo. La ejecución real ha respetado el orden y la estructura previstos, pero ha presentado desviaciones puntuales que conviene comentar.

La fase de *Inicio* ha consumido aproximadamente el esfuerzo previsto. La investigación tecnológica resultó algo más extensa de lo planeado por el tiempo dedicado a comparar modelos de lenguaje y a evaluar alternativas a Rasa, pero el diseño arquitectónico se completó dentro del margen estimado.

La fase de *Desarrollo* ha sido la más larga y la que más ha sufrido desviaciones positivas, en el sentido de que se ha invertido más esfuerzo del estimado en algunos paquetes. La épica de profesorado, en concreto, requirió un ciclo adicional para resolver la combinatoria entre profesor, asignatura y grupo y para ajustar el atajo de coordinador y suplente, ambos bloqueos identificados durante el testing de aceptación. El *pipeline* RAG también consumió más tiempo del previsto, principalmente por la fase de afinado de los *prompts* de respuesta, que pasó por varias iteraciones hasta alcanzar la cifra del 91,9 % de profundidad.

La fase de *Cierre*, por contra, se ha mantenido dentro del margen previsto. El piloto con usuarios reales y la auditoría manual de las 59 sesiones se ejecutaron en la ventana planificada (1 al 25 de abril de 2026), y la redacción de la memoria comenzó tan pronto como las épicas estuvieron estabilizadas, lo que ha evitado una concentración excesiva del esfuerzo en las últimas semanas.

Como recomendación de la guía de referencia [72], las desviaciones se han mantenido siempre en sentido positivo: en ningún momento se ha invertido un volumen de horas inferior al estimado, lo que descartaría un cumplimiento meramente nominal del proyecto. La lección aprendida en este apartado es que la estimación inicial subestimaba sistemáticamente el coste de las tareas con dependencia de modelo de lenguaje (afinado de *prompts*, evaluación manual de respuestas), debido a la naturaleza no determinista de ese tipo de tareas.

14.5– Desarrollos futuros

El estado actual de Linceus Assistant corresponde a una fase 1, equivalente a un prototipo plenamente funcional pero con un alcance acotado a tres épicas y a la titulación GII-IS. El trabajo identificado para iteraciones posteriores se organiza en tres bloques: optimización del sistema actual, ampliación funcional y validación reforzada.

14.5.1. Optimización del sistema actual

A lo largo del Capítulo 12 se han identificado seis palancas técnicas con potencial para reducir la latencia, abaratar el coste y mejorar la robustez del sistema sin alterar su funcionalidad esencial. La primera es la **elección de modelo Gemini en función del tipo de llamada**: las tareas de *Text-to-SQL* y de clasificación binaria pueden resolverse con modelos más pequeños y rápidos (familia Gemini Flash Lite o Gemma 3 de 4B parámetros), reservando modelos mayores para el renderizado natural de la respuesta. La estimación es que esta diferenciación reduciría a la mitad el coste anual y la cola larga de latencia.

La segunda palanca es la **sustitución selectiva de heurísticas léxicas por clasificadores ligeros basados en LLM o por similitud semántica con *embeddings***. La política de delegación descrita en la Sección 4.4 optó deliberadamente por resolver con regex y diccionarios buena parte de las decisiones de menor entidad (detección de grupo, identificación de rol coordinador o suplente, regex de continuación elíptica como “*los demás grupos*”, pronombres demostrativos para invertir prioridades de seguimiento entre profesor y asignatura, palabras clave para activar la rama RAG en consultas específicas) para mantener el coste y la latencia bajos y minimizar el riesgo de alucinaciones. Esta decisión es correcta para el alcance actual del prototipo, pero deja en evidencia dos limitaciones cuando se piensa en una versión productiva: las heurísticas son frágiles ante fraseos atípicos del estudiantado y están todas codificadas en español, lo que dificulta la internacionalización futura. La alternativa natural es una migración gradual a **clasificadores LLM ligeros** (modelos de la familia Gemini Flash Lite, una llamada por turno, temperatura cero) en los puntos donde la heurística falla con más frecuencia, o a **similitud semántica con *embeddings*** multilingües cuando el problema es comparar la pregunta contra un conjunto pequeño de anclas conceptuales (por ejemplo, las palabras clave que activan RAG). Cualquiera de las dos vías convertiría varios de los casos actualmente excluidos como trabajo futuro en casos PASS, a coste de añadir entre 800 ms y 2 s por turno y de aceptar un margen no nulo de alucinación que hoy se evita por construcción. En la misma línea, otros dos puntos del *pipeline* hoy resueltos por reglas admiten una migración a procesamiento basado en LLM: la **normalización previa de la pregunta del usuario** (un primer paso de paráfrasis a forma canónica que reduciría la sensibilidad del clasificador NLU a fraseos atípicos y permitiría unificar tratamiento de typos, abreviaturas y elipsis antes de la clasificación), y el **slot-filling asistido por LLM** para preguntas malformadas o incompletas, donde el modelo propondría valores plausibles para los *slots* faltantes (grupo, curso, titulación) en lugar de obligar al usuario a reformular. Ambas medidas profundizan la presencia del modelo de lenguaje en el *pipeline* sin alterar la arquitectura general, y se complementan con la migración de heurísticas descrita en el párrafo anterior.

La tercera palanca es una **caché de respuestas a las consultas más frecuentes**. La distribución del tráfico recogida en la tabla `conversation_log` muestra que un puñado de preguntas (“¿qué es ADDA?”, “horario de IS 2 grupo 1”, “email de Galindo”) concentran un porcentaje significativo de los turnos. Una caché por *hash* de pregunta y titulación reduciría a la mitad el coste anual y bajaría la latencia mediana al rango de uno o dos segundos.

La cuarta palanca es la **instrumentación de métricas en producción** [55]: latencia por percentil, tasa de *fallback*, tasa de *out_of_scope* y *feedback* explícito por turno. La tabla de *feedback* ya está soportada parcialmente en la base de datos pero no se está explotando aún. Esta instrumentación permitiría detectar regresiones en producción mucho antes de que un usuario las reporte.

La quinta palanca es la **centralización de la lógica de seguimiento conversacional** en una acción genérica única. En la versión actual, cada época implementa su propia heurística de herencia de *slots* cuando detecta entidades vacías. La acción `ActionConsultaProfesor` hereda `ultimo_profesor_consultado` o `ultimo_nombre_asignatura` con una regla de prioridad invertible según pronombres demostrativos. La acción `ActionConsultaHorario` hereda `ultimo_curso_consultado` y `ultimo_grupo_consultado`, y cuando solo hay asignatura reciente delega en `ActionConsultaHorarioAsignatura`. Por último, `ActionSmartFallback` aplica un atajo regex específico para continuaciones de horario.

Esta lógica está duplicada en tres ficheros con variantes sutiles, no cubre todos los seguimientos cruzados imaginables y deja casos de prueba como P-S01 y H-S01 (Capítulo 12) en zona gris. La propuesta consiste en introducir un `ActionSeguimientoGenerico` que se invoque cuando NLU clasifique con baja confianza y la pregunta encaje con patrones de elipsis (regex barato sobre pronombres y conectores de continuación), consulte el `slot ultima_action_ejecutada` junto con los `slots` de contexto, y resuelva el destino mediante una **tabla de transiciones declarativa** en lugar de heurísticas dispersas, en la línea del formalismo de *statecharts* [101]. Solo si la tabla no resuelve un caso, escalaría al clasificador LLM actual del fallback. Este diseño elimina la duplicación, hace el sistema extensible (añadir una épica no requiere tocar las heurísticas de las anteriores), reduce el acoplamiento entre épicas (hoy materializado en *imports* cruzados como el de `HorarioAsignatura`), y mantiene el coste cercano a cero en el caso común.

La sexta palanca es la **externalización de los lexicones *hardcoded* a tablas de la base de datos**, de forma que el administrador pueda editarlos desde el panel sin necesidad de redespargar el contenedor de *actions*. La arquitectura actual concentra varias listas léxicas en el módulo `actions/shared/config.py`: el diccionario `ALIAS_ASIGNATURAS` (93 entradas, decisión D-006), el `TITULACION_MAP` con sus variantes cortas (D-035, D-056), las palabras-gatillo que activan la rama RAG dentro de `ActionConsultaEspecificas` (“*criterios*”, “*profesor*”, “*temario*”, “*laboratorio*”, etc.), los pronombres demostrativos que invierten la prioridad de seguimiento entre profesor y asignatura (Sección 11.8), y las expresiones regulares de continuación elíptica del *fallback* inteligente (“*los demás grupos*”, “*todos los grupos*”). Esta concentración fue la decisión correcta para la fase 1 porque permitió iterar con rapidez y mantener el coste de inferencia bajo, pero introduce dos fricciones reconocidas: cualquier cambio en el corpus léxico exige modificar el código fuente y reiniciar el *action server*, lo que impide al administrador del panel reaccionar ante un acrónimo nuevo sin pasar por el desarrollador, y los seis ficheros donde estos lexicones se importan generan una superficie de *drift* si un día deja de actualizarse alguno. La propuesta consiste en migrar los cinco lexicones a tablas dedicadas en Supabase (`alias_asignaturas`, `variantes_titulacion`, `rag_keywords`, `pronombres_seguimiento`, `patrones_fallback`), cargarlas en memoria al arranque del *action server* con *caché* con tiempo de vida corto (cinco minutos basta), y exponer en el panel un CRUD básico para añadir, modificar o desactivar entradas. El precedente está consolidado: la tabla `ALIAS_ASIGNATURAS` ya cumple este patrón para los alias canónicos por asignatura (que sí viven en BD), y el resto de lexicones replicarían ese modelo. Esta sexta palanca constituye un paso intermedio natural entre el régimen actual de regex *hardcoded* y la migración a clasificadores LLM ligeros descrita en la segunda palanca: ofrece la flexibilidad operativa del primero (edición en caliente, sin redespiegue) sin asumir el coste, la latencia ni el riesgo de alucinación del segundo, y resuelve la rigidez sin renunciar al determinismo.

14.5.2. Ampliación funcional

El alcance funcional del prototipo puede extenderse en varias direcciones. La más inmediata es la incorporación de las titulaciones del centro distintas a las tres de Ingeniería Informática actualmente cargadas, lo cual requiere principalmente trabajo de carga de datos en el panel de administración. Esta ampliación conlleva además un ajuste de **interfaz**: la selección de titulación se resuelve hoy con un conjunto cerrado de botones en el *widget* (decisión D-029), patrón que funciona con tres opciones pero que deja de escalar a partir de unas pocas decenas. La sustitución natural es un *search bar* con autocompletado por prefijo sobre la tabla de titulaciones activas: el alumno teclea las primeras letras y el *widget* muestra las coincidencias filtradas en tiempo real (Inge → las tres ingenierías informáticas más el resto de ingenierías del centro). El cambio es de coste bajo (un único endpoint nuevo en el panel administrativo que devuelva las titulaciones que casen con el prefijo, y un componente de *autocomplete* en el JavaScript del *widget*) y preserva el resto del flujo conversacional intacto: una vez seleccionada la titulación, el `slot titulacion_activa` se fija exactamente igual que con los botones actuales. A medio plazo, la ampliación natural es

la cobertura de **trámites administrativos universitarios**: matrícula, pago de tasas, convocatorias de becas, certificaciones académicas, reclamación de actas, cambios de grupo y procedimientos análogos que hoy obligan al estudiante a navegar entre la Secretaría Virtual, Sevius y los manuales del centro. Esta línea es la que más claramente cumple la promesa del título del trabajo (consulta de *información académica y administrativa*) y se beneficia directamente de la arquitectura híbrida: los plazos y formularios son datos estructurados que casan con *Text-to-SQL*, mientras que el clausulado normativo (becas, reglamento de evaluación, normativa de permanencia) se ajusta al pipeline RAG sobre documentos oficiales. Otras extensiones contempladas son la incorporación de información sobre tutorías estructuradas, convocatorias de movilidad y la **localización de espacios universitarios** (aulas, despachos, laboratorios), funcionalidad contemplada en el anteproyecto y aplazada en la Sección 6.9 por la falta de una fuente de datos estructurada y mantenible; su viabilidad dependerá de que la US publique planos o APIs de aforo en un formato procesable. Por último, la ampliación natural a otros centros de la Universidad de Sevilla pasa por validar el grado en que los *prompts* y los flujos diseñados son transferibles cuando cambian los datos de origen.

14.5.3. Validación reforzada

La validación realizada en la fase 1 cubre cinco capas funcionales y dos métricas no funcionales, pero deja fuera tres aspectos que conviene atender en una segunda iteración. El primero es la medición de la experiencia subjetiva del usuario mediante una escala estandarizada como SUS, que permitiría situar el sistema frente a otras herramientas universitarias. El segundo es la garantía de disponibilidad sostenida del servicio mediante un acuerdo de nivel de servicio y la correspondiente monitorización de uptime. El tercero es la implementación de la suite automática de pruebas para los *endpoints* del panel de administración, cuyo diseño ya consta en el plan de aceptación pero cuyo desarrollo se ha pospuesto.

14.6– Contribución al estado del arte

A la luz de los resultados obtenidos y de la revisión sistemática de chatbots educativos recopilada por Wollny et al. [30], Linceus Assistant se sitúa en la intersección de dos líneas de investigación activas: los asistentes conversacionales para educación superior y los sistemas RAG sobre documentos de dominio cerrado. Frente a los cuatro sistemas universitarios comparables que han servido de referencia a lo largo de la memoria (AdmitBot [25], EDUBOT [26], Ranoliya [27] y Dibya–Sahoo [28]), el sistema se diferencia en tres aspectos concretos que dan forma a su aportación.

Ajuste iterativo y documentado en lugar de umbrales por convención. Los porcentajes de éxito de los cuatro sistemas comparables se publican sin una descripción del procedimiento por el que se fijaron los umbrales internos del sistema (similitud semántica, fuzzy matching, fallback NLU). En Linceus, los tres umbrales críticos se acompañan de la observación cualitativa que los justifica: los valores 0,60 / 0,30 del *fuzzy matching* de profesorado (Sección 11.8) responden al equilibrio entre tolerancia a typos moderados y rechazo de nombres cortos sin especificidad; la elevación del umbral de cambio de titulación a 0,85 (Sección 11.5) corrige cambios silenciosos detectados en la revisión R3; y la configuración del par `threshold = 0,8 / ambiguity_threshold = 0,10` del clasificador de *fallback* (Sección 7.4.8) atiende a competencias entre intents observadas durante el desarrollo. Esta trazabilidad documental convierte cada cifra de la suite de pruebas en una decisión reproducible.

Arquitectura híbrida NLU + RAG con dos vías de resolución por dominio. La revisión de Wollny [30] señala que la mayoría de chatbots educativos opta por un enfoque puramente conversacional sobre reglas o por una respuesta basada en LLM sin recuperación verificable. Linceus combina dentro de una misma *custom action* una vía estructurada (*Text-to-SQL* sobre Supabase) y

una vía semántica (RAG sobre planes docentes con `pgvector`), con tres puntos de decisión por épica que escogen la rama adecuada en función del contenido de la pregunta (Sección 11.3). Esta hibridación permite atender simultáneamente consultas que requieren precisión factual (créditos, horarios) y consultas que requieren interpretación textual (criterios de evaluación, coordinación), sin sacrificar ninguna de las dos.

Cierre del ciclo de vida del corpus mediante un panel sin código. El tercer aporte responde a una crítica recurrente en la literatura: los prototipos académicos llegan al despliegue pero no a la operación sostenida, porque la actualización de la base de conocimiento exige al desarrollador. El panel Flask descrito en la Sección 11.10 traslada la operación al perfil de mantenimiento, con flujos auditables para sincronizar el catálogo desde Sevius, enriquecer el directorio de profesorado desde `us.es` y vectorizar planes docentes con su pipeline completo de *chunking*, *embeddings* y *rate limiting*. La suite `pytest` de 24 casos sobre el panel (Sección 12.9) prueba que esa capa es operativa por sí misma, no un complemento decorativo.

Estas tres contribuciones no se publican como aportación al campo en un sentido fuerte, propio de una tesis doctoral, pero sí establecen un patrón concreto y reproducible para el desarrollo de asistentes universitarios. La distancia respecto a los prototipos publicados es prudente: la metodología de evaluación, el corpus utilizado y la naturaleza del dominio difieren entre proyectos y la comparación cuantitativa estricta no resulta procedente. Lo que sí cabe afirmar, a la vista de los datos del Capítulo 12, es que Linceus alcanza tasas de éxito en los tres aspectos por encima de las cifras reportadas para el conjunto de los sistemas comparables.

14.7– Consideraciones éticas

El desarrollo de un asistente conversacional dirigido a estudiantes plantea responsabilidades que conviene explicitar más allá del simple cumplimiento legal. En el caso de Linceus, cuatro aspectos merecen comentario.

Veracidad de la información y riesgo de inducir decisiones erróneas. El sistema puede influir, aunque sea de forma indirecta, en decisiones académicas relevantes para el alumno (elección de optativas, planificación de matrícula, identificación del docente coordinador para un trámite). El riesgo principal es que el modelo de lenguaje devuelva contenido plausible pero incorrecto, un fenómeno conocido como *alucinación* y ampliamente documentado en la literatura de generación de lenguaje natural [35]. Tres salvaguardas reducen este riesgo. La primera es que las respuestas sobre planes docentes están ancladas a documentos oficiales mediante el módulo RAG, no generadas a partir del conocimiento paramétrico del modelo. La segunda es el flujo de *fallback* inteligente (Sección 11.6), que declara explícitamente cuándo el sistema no encuentra información en lugar de inventar contenido. La tercera es la posibilidad de auditar a posteriori todas las conversaciones desde el panel de administración (RF-AD6), lo que permite identificar respuestas incorrectas y corregir el corpus o los *prompts* responsables.

Privacidad y protección de datos. El sistema se ha diseñado bajo el principio de minimización del Reglamento General de Protección de Datos [36]: la sesión es anónima (UUID generado del lado del cliente), no se solicita ninguna identificación personal del alumno y los datos académicos consultados (planes docentes, horarios y directorio público de profesorado) son de carácter público y proceden de fuentes oficiales (Sevius, `us.es`). La tabla `conversation_log` almacena el contenido de las conversaciones para fines de auditoría y mejora, pero al no contener identificadores personales no constituye tratamiento de datos en el sentido del RGPD. El consentimiento del usuario para esta auditoría está cubierto por el aviso público del sitio donde se integra el *widget*. La cuestión es relevante porque cualquier ampliación que introdujera datos identificables (autenti-

cación universitaria, integración con expediente del alumno) exigiría una revisión completa de la base legal y la incorporación de mecanismos de consentimiento explícito.

Sesgo en los datos de entrenamiento. El corpus NLU ha sido elaborado manualmente por el autor del trabajo, lo que introduce inevitablemente sesgos en la forma de formular las consultas: vocabulario, registros y patrones léxicos propios. La validación con tráfico real (Sección 12.5) ha permitido detectar y completar formulaciones que el conjunto sintético no había anticipado, y el reentrenamiento posterior con 117 ejemplos extraídos del piloto (Sección 12.4) mitiga este sesgo en la versión actual. La diversificación sistemática del corpus mediante técnicas de *data augmentation* (paráfrasis con LLM, inclusión de variantes regionales del español) figura entre las líneas de mejora.

Dependencia tecnológica y degradación responsable. La fase generativa del sistema depende de la API de Gemini, propiedad de un tercero (Google). En caso de interrupción del servicio o de cambios en los términos de uso, el sistema degrada su comportamiento de forma controlada: el módulo RAG dispone de *fallback* a búsqueda por palabras clave (Sección 11.9.3), las consultas estructurales más frecuentes siguen funcionando porque dependen exclusivamente de la base de datos relacional, y el cliente alternativo de Ollama (Sección 7.4.2) permite reconfigurar el sistema para una explotación local con un cambio de *import*, sin reescribir la lógica de las acciones. Esta planificación de la degradación responde a la consideración ética de no dejar al alumno sin un servicio que pueda haber asumido como permanente.

14.8– Reflexión final

Mirar atrás al proyecto completo deja una impresión clara: la mayor dificultad de un sistema conversacional basado en modelos de lenguaje no reside en hacerlo funcionar, sino en hacerlo funcionar de forma fiable y trazable. Construir una primera versión que respondiera correctamente a un puñado de consultas demostrativas resultó relativamente rápido; alcanzar el punto en que cinco capas independientes de validación superan su umbral académico de referencia ha exigido un trabajo metódico de evaluación, corrección de defectos y registro de decisiones que ha constituido la mitad del esfuerzo del proyecto.

Esta experiencia sugiere que la incorporación de modelos de lenguaje a aplicaciones reales no se resuelve únicamente con buenas elecciones tecnológicas. Exige adoptar prácticas de ingeniería del software clásicas, en particular pruebas de aceptación, registro de decisiones y validación con usuarios, adaptadas al carácter no determinista del componente generativo [78]. Linceus Assistant, en su versión actual, es un primer paso en esa dirección dentro del contexto universitario; las seis palancas y las tres ampliaciones identificadas para la fase 2 deberían permitir convertirlo en una herramienta utilizable de forma sostenida por la comunidad de la ETSII.

Uso de Inteligencia Artificial

Este capítulo documenta de forma transparente el uso que se ha hecho de herramientas de IA generativa durante el desarrollo del proyecto. Se distinguen dos ámbitos claramente separados: el uso aplicado al desarrollo del software (código fuente, arquitectura, refactorización) y el uso aplicado a la redacción de la presente memoria. La política seguida en ambos casos ha sido la misma: la IA actúa como asistente bajo supervisión directa del autor, nunca como agente autónomo, y en ningún caso se ha empleado para generar componentes desde cero o producir contenido sin revisión humana posterior.

Es importante distinguir además entre la IA empleada *para construir* el sistema (objeto de este capítulo) y la IA que *forma parte* del propio sistema (Google Gemini, descrito en el Capítulo 8). La segunda no se declara aquí porque constituye una pieza del producto entregado, no una herramienta de desarrollo.

15.1– Herramientas utilizadas

La herramienta principal de asistencia ha sido **Claude Code** (Anthropic), un asistente de IA en línea de comandos integrado con el repositorio local. Se ha utilizado tanto para tareas relacionadas con el código como, de forma muy acotada, para la revisión gramatical de la memoria. No se han empleado otras herramientas de IA generativa para el desarrollo o la redacción del proyecto.

15.2– Uso de IA en el desarrollo del código

Claude Code se ha empleado durante el desarrollo del software como apoyo en tareas concretas, siempre con revisión y validación posterior por parte del autor. Las situaciones en las que se ha utilizado son las siguientes:

- **Refactorización de código existente:** reorganización de funciones ya escritas, extracción de utilidades comunes a varias acciones de Rasa y reescritura de fragmentos para mejorar la legibilidad o la coherencia con el resto del módulo. El código de partida y la dirección del cambio los ha definido el autor en cada caso.
- **Sugerencias de arquitectura óptima:** a partir de la información obtenida durante la fase de investigación previa (comparativas de *frameworks*, motores de LLM y bases vectoriales recogidas en el Capítulo 5), se ha consultado a la herramienta para contrastar alternativas arquitectónicas y obtener sugerencias sobre patrones adecuados al contexto del proyecto. La decisión final en cada caso se ha adoptado tras evaluar las propuestas frente a la documentación oficial y las restricciones del sistema.
- **Limpieza de código:** detección de *imports* no utilizados, normalización de estilos, eliminación de *logs* de depuración residuales y aplicación uniforme de convenciones de nombrado.

- **Generación asistida de funciones puntuales:** redacción inicial de funciones concretas y delimitadas a partir de una especificación detallada del autor, observadas durante el proceso y revisadas y modificadas antes de su integración en el repositorio.

A continuación se enumeran de forma explícita los usos que **no** se han realizado, para evitar ambigüedades:

- No se ha empleado IA para generar el sistema, módulos completos o clases enteras desde cero a partir de un *prompt*.
- No se ha concedido autonomía a la herramienta para producir componentes completos sin intervención del autor durante el proceso.
- No se ha aceptado código generado sin revisión: cada fragmento producido con asistencia de IA ha sido leído, comprendido y, cuando ha sido necesario, modificado antes de su incorporación.

15.3– Uso de IA en la redacción de la memoria

El uso de IA en la redacción del presente documento ha sido sensiblemente más restrictivo que en el ámbito del código. Se ha limitado a la siguiente tarea:

- **Revisión gramatical y ortográfica:** detección de erratas, faltas de concordancia, tildes omitidas y construcciones poco fluidas en textos ya redactados por el autor.

En particular, y de forma deliberada, **no** se ha utilizado IA para ninguna de las siguientes finalidades:

- Generar contenido desde cero (secciones, párrafos, justificaciones o descripciones técnicas).
- Aportar ideas, argumentos, decisiones de diseño o líneas de razonamiento que después se hayan trasladado al texto.
- Reescribir o reformular capítulos completos a partir de una indicación general.

La estructura del documento, la selección de contenidos, las justificaciones técnicas, las decisiones de diseño y las conclusiones son obra exclusiva del autor. La asistencia de IA en este ámbito se ha limitado a un papel comparable al de un corrector ortográfico avanzado.

15.4– Limitaciones y responsabilidad del autor

El autor asume la responsabilidad íntegra del contenido del proyecto, tanto del software entregado como de la memoria. La asistencia de herramientas de IA se ha empleado siempre bajo supervisión directa: cada sugerencia arquitectónica se ha contrastado con la investigación previa, cada función generada se ha revisado antes de su integración y cada corrección lingüística se ha validado contra el texto original. La trazabilidad de las aportaciones puede consultarse a través del histórico de *commits* del repositorio, donde la actividad de desarrollo refleja la intervención humana en cada cambio.

El uso descrito en este capítulo se enmarca en los principios de transparencia y verificación: declarar las herramientas empleadas, acotar su rol y mantener la responsabilidad última del trabajo en el autor.

Vídeo demostración

Este capítulo recoge el vídeo demostración del prototipo, alojado en YouTube y referenciado a continuación.

16.1– Vídeo demostración

El vídeo demostración resume en **tres minutos** las funcionalidades principales de Linceus Assistant, tanto del chatbot público como del panel de administración. Está alojado en YouTube y disponible en la siguiente dirección:

<https://www.youtube.com/watch?v=y5qO8VXxUVI>

La Figura 16.1 reproduce la miniatura del vídeo; al pulsarla en la versión PDF se abre directamente la pagina del vídeo.



Figura 16.1: Miniatura del vídeo demostración alojado en YouTube. La imagen es un enlace activo en la versión PDF.

16.1.1. Estructura del vídeo

El vídeo está dividido en dos bloques claramente diferenciados: un primer bloque centrado en el **uso real del chatbot** desde el punto de vista del estudiante, y un segundo bloque que recorre el **panel de administración** desde el punto de vista del responsable del catálogo. La Tabla 16.1 recoge la sucesión completa de escenas con sus marcas temporales.

Cuadro 16.1: Sucesión de escenas del vídeo demostración.

Tiempo	Escena	Propósito
00:00–00:10	Apertura	Introducción del producto e invitación a abrir el <i>widget</i> .
00:10–00:23	Onboarding	Selección de titulación al abrir el chat.
00:23–00:34	Consulta sobre asignatura	Ficha completa de Sistemas Operativos.
00:34–00:45	Seguimiento elíptico	Pregunta sobre créditos sin repetir el nombre.
00:45–00:56	Listado de optativas	Aplicación de <i>text-to-SQL</i> .
00:56–01:06	Horario por asignatura	Devolución de todos los grupos disponibles.
01:06–01:17	Horario por curso y grupo	Filtrado explícito.
01:17–01:28	Correo de un profesor	Consulta sobre profesorado.
01:28–01:39	Cambio de titulación	Conmutación de contexto en lenguaje natural.
01:39–01:50	Resistencia a <i>jailbreak</i>	Rechazo educado de un intento de manipulación.
01:50–02:04	Panel: inicio (centros)	Vista de centros gestionados.
02:04–02:18	Panel: asignaturas	Acciones de vectorización, enriquecimiento y sincronización.
02:18–02:26	Panel: horarios	Extractores disponibles por centro.
02:26–02:36	Panel: profesores	Directorio del PDI con enriquecimiento.
02:36–02:46	Panel: conversaciones	Auditoría de sesiones.
02:46–02:54	Panel: estadísticas	Contadores globales del catálogo.
02:54–03:00	Cierre	Cierre conceptual del prototipo.

16.1.2. Notas sobre la producción

El vídeo no se grabó directamente sobre el prototipo en producción por dos motivos prácticos. El primero es que los tiempos de respuesta reales del bot (entre uno y tres segundos por turno, ver Capítulo 12) producirían un vídeo con demasiado tiempo muerto para mantenerlo dentro del límite de tres minutos exigido. El segundo es que la captura de pantalla del panel de administración deja entrever información sensible (credenciales, identificadores reales de sesión) que no debe figurar en un material público.

Apéndices

.1– Actas de reuniones con el tutor

Las reuniones de seguimiento con el tutor se celebraron al inicio de cada sprint. A continuación se recogen las actas en orden cronológico inverso.

Datos de contacto

Tutor: José Antonio Parejo Maestre, japarejo@us.es
Alumno: Santia Bregu, sanbre@alum.us.es

Sprint 8 (29/04/2026)

Desarrollo de la reunión:

- Ajustar enfoque del resumen y añadir resumen en inglés.
- Incluir apéndice con actas de reuniones.
- Mejoras en manuales: capturas de pantalla, versiones de imágenes Docker y ejemplos de código.
- Revisión de diagramas y EDT.
- Pendiente: sección de metodología y revisión del capítulo de pruebas.
- Explicación de entregables y siguientes pasos del cierre del proyecto.

Objetivos acordados:

- Reescribir el resumen y elaborar la sección de metodología.
- Añadir apéndice de actas y mejorar los manuales.
- Revisar el capítulo de pruebas.
- Enviar nueva versión de la memoria al tutor.
- Preparar el vídeo demostración del prototipo.

Sprint 7 (15/04/2026)

Desarrollo de la reunión:

- Enfoque en validación del sistema y escritura de la memoria.
- Definición de pruebas de aceptación (conversaciones e importaciones).
- Dos fases de validación: prototipo inicial y validación final.
- Uso de la guía de referencia para estructurar la memoria; secciones clave: introducción, conclusiones, manuales y validación.
- Tipos de manuales a redactar: usuario, despliegue y desarrollo.

- Envío progresivo de la memoria para obtener feedback continuo.
- Feedback positivo del estado actual del sistema.
- Planificación de sprint corto y fecha de próxima reunión.

Objetivos acordados:

- Comenzar la redacción de la memoria con las secciones prioritarias.
- Definir y ejecutar el plan de pruebas de aceptación.
- Cerrar el desarrollo progresivamente y estabilizar el sistema.

Sprint 6 (25/03/2026)

Desarrollo de la reunión:

- Revisión de objetivos del sprint anterior (testing, memoria, sistema).
- Presentación del testing automatizado y manual; corrección de errores detectados.
- Mejoras en el sistema: mapeo de abreviaturas, *fuzzy matching* y fallback con IA.
- Gestión de contexto con *slots* para consultas encadenadas.
- Revisión del frontend: añadir enlaces a la web oficial de la US.
- Revisión de la memoria: EDT, arquitectura y decisiones de diseño.
- Correcciones en diagramas: uso de UML estándar.
- Revisión de horas dedicadas y mejora del tracking.

Objetivos acordados:

- Desplegar el sistema y probarlo con usuarios reales.
- Dockerizar la aplicación.
- Implementar la épica de horarios y aulas.
- Mejorar la memoria: EDT y diagramas UML.
- Añadir enlaces en el frontend y aumentar horas dedicadas.

Sprint 5 (27/02/2026)

Desarrollo de la reunión:

- Revisión del estado actual del proyecto e identificación de tareas pendientes.
- Decisión de centrar el sprint en testing y consolidación del sistema.
- Definición del enfoque de pruebas: manual y automatizado.
- Propuesta de tareas opcionales: frontend y despliegue.
- Planificación de la próxima reunión.

Objetivos acordados:

- Realizar testing exhaustivo: definir plan, ejecutar iteraciones y evaluar resultados.
- Identificar y corregir errores del sistema actual.
- Avanzar la memoria: arquitectura, decisiones de diseño y diagramas.
- Elaborar la EDT a nivel abstracto.
- Opcional: despliegue del sistema y versión inicial del frontend.

Sprint 4 (03/02/2026)

Desarrollo de la reunión:

- Revisión del avance de la épica de asignaturas.
- Planificación de la épica 7.3 (Asignaturas avanzado).
- Revisión de la estructura de la BD y del marco tecnológico.

Objetivos acordados:

- Comenzar el desarrollo de la épica 7.3 (Asignaturas avanzado).
- Documentar en la plantilla TFG lo realizado: estructura de la BD, marco tecnológico y metodología.
- Mejorar las consultas actuales ampliando el contexto conversacional con el framework.
- Ampliar el modelo de información para dar soporte a múltiples titulaciones.
- Ampliar el conjunto de datos del módulo RAG y realizar pruebas.

Sprint 3 (08/01/2026)

Desarrollo de la reunión:

- Resumen del estado actual: datos de una titulación cargados (IS, ETSII) y frontend integrado con el backend Rasa.

Objetivos acordados:

- Definir e implementar las historias de asignaturas: listado por titulación, créditos, cuatrimestre de pertenencia e impartición.
- Implementar pruebas de las historias anteriores.
- Comenzar la épica 7.3 (Asignaturas avanzado).
- Visualizar los vídeos del tutorial de integración de IA con Rasa.
- Documentar en la plantilla TFG: estructura de la BD, marco tecnológico y metodología.
- Comprobar infraestructura para ejecutar Ollama (modelo ligero tipo llama3.2).

Sprint 2 (22/09/2025)

Desarrollo de la reunión:

- Revisión del anteproyecto.
- Definición del alcance del proyecto.
- Fijación de objetivos para el sprint 2.
- Decisión: añadir un diccionario global de términos relevantes durante el desarrollo.

Objetivos acordados:

- Finalizar el anteproyecto.
- Comenzar con el ítem del backlog “Asignaturas”.

Sprint 1 (28/07/2025)

Desarrollo de la reunión:

- Revisión del anteproyecto.
- Creación de la infraestructura básica de trabajo.
- Adjudicación oficial del TFG con título provisional: *“Diseño y desarrollo de un chat inteligente para consulta de información académica”*.
- Decisiones: usar GitHub como repositorio principal y registrar todas las horas desde el inicio, incluidas reuniones.

Objetivos acordados:

- Justificar la elección tecnológica con estudio de alternativas y tabla comparativa.
- Montar la infraestructura: repositorio en GitHub y producto mínimo viable funcionando.
- Definir metodología y estándares de desarrollo.
- Elaborar la planificación inicial con horas aproximadas y objetivos por sprint.

.2– Informe de tiempo invertido

El registro horario del proyecto se ha llevado de forma continua mediante la herramienta **Clockify**, siguiendo la convención de etiquetado descrita en el Capítulo 4 (SX seguido de la descripción de la tarea, donde X es el número de sprint). El informe completo exportado desde Clockify, con una entrada por tarea registrada y su duración exacta, se adjunta al material del proyecto en formato CSV (`Clockify_Time_Report_Summary_01_06_2025-31_05_2026.csv`).

A modo de evidencia resumida, la Tabla .2 muestra la distribución del tiempo por categoría de actividad y la Tabla .3 reproduce el agregado por sprint, ambas calculadas a partir del fichero anterior con corte a fecha de **02/05/2026**.

A esta cifra restan por contabilizar las horas correspondientes al cierre completo de la memoria (revisión final de manuales y capítulos pendientes), estimadas en aproximadamente 20 h, que sitúan la previsión final del proyecto en torno a las 300 h y por tanto dentro del margen establecido por la normativa.

Categoría	Horas	%
Desarrollo	198,08	70,3 %
Documentación	26,89	9,5 %
Infraestructura	13,45	4,8 %
Investigación	8,73	3,1 %
Reuniones	5,67	2,0 %
Otras (anteproyecto, planning, fixes)	28,90	10,3 %
Total registrado	281,72	100,0 %

Cuadro .2: Distribución del tiempo por categoría de actividad (Clockify, 02/05/2026).

Sprint	Horas
S1 (Anteproyecto)	20,16
S2 (Infraestructura)	13,58
S3 (Asignaturas)	33,19
S4 (Asignaturas avanzado)	8,17
S5 (RAG y Gemini)	17,68
S6 (Horarios y profesores)	23,72
S7 (Sprint largo: épicas, panel admin, piloto)	150,52
S8 (Cierre y memoria)	10,79
Reuniones (sin sprint)	3,91
Total	281,72

Cuadro .3: Horas registradas por sprint (Clockify, 02/05/2026).

.3– Registro de decisiones técnicas

A lo largo del desarrollo se han registrado **113 decisiones técnicas** en los ficheros `Registro_decisiones.md` de `docs/sprints/` (sprints S2 a S7; S1 fue de planificación y S8 quedó dedicado al cierre de la memoria, sin nuevas decisiones técnicas). Las tablas que siguen recogen una entrada por decisión con su código y un título corto; la justificación, las alternativas descartadas y los ficheros afectados se conservan en el fichero correspondiente del repositorio.

La codificación es heterogénea por razones históricas. Los sprints S2, S3 y S4 emplearon listas numeradas internas sin código formal: para esta memoria se les ha asignado *a posteriori* el prefijo del sprint (S2-*nn*, S3-*nn*, S4-*nn*). El sprint S5 introdujo el código D-001..D-019 con numeración local, que ha sido renombrado a S5-*nn* en el registro para evitar el choque con la numeración global iniciada en S6. A partir de S6, las decisiones se numeran D-001..D-069 de forma continua (con algunos huecos por consolidación de entradas), y esa es la codificación que la memoria cita en los capítulos 6 a 14.

Sprint 2: Carga de asignaturas y diseño inicial (9 decisiones)

Código	Título
S2-01	Diccionario general del proyecto.
S2-02	<i>Scope</i> acotado a asignaturas (Ing. del Software, ETSII).
S2-03	Esquema inicial de la base de datos.
S2-04	Inserción de los datos iniciales.
S2-05	Definición de la lógica de versionado del proyecto.
S2-06	Separación de los datos de entrenamiento NLU por épicas.
S2-07	Una intención general de consulta con entidades en lugar de intenciones proliferantes.
S2-08	Adopción de <code>rapidfuzz</code> para <i>fuzzy matching</i> (frente a <code>difflib</code>).
S2-09	Versión inicial del <i>frontend</i> .

Sprint 3: Migración a Ollama y *Text-to-SQL* (14 decisiones)

Código	Título
S3-01	Migración completa de Gemini a Ollama con Llama 3.
S3-02	Cliente HTTP de Ollama en lugar de <i>subprocess</i> (latencia 5–15× menor).
S3-03	Modelo optimizado <code>llama3.2:3b</code> frente a <code>llama3</code> completo.
S3-04	Sistema <i>Text-to-SQL</i> con clasificación automática específica/general.
S3-05	Caché en memoria de asignaturas por sesión.
S3-06	Búsqueda <i>fuzzy</i> mejorada con desambiguación por LLM.
S3-07	Respuestas naturales generadas íntegramente con LLM.
S3-08	Separación de la lógica de interpretación LLM en <code>llm_interpreter.py</code> .
S3-09	Documentación técnica exhaustiva del nuevo sistema.
S3-10	Script de inicialización del servidor Ollama.
S3-11	Inclusión de <code>old/</code> en <code>.gitignore</code> .
S3-12	<i>Slots</i> adicionales para cache de resultados (<code>ultimos_resultados_asignaturas</code>).
S3-13	Priorizar velocidad sobre capacidad del modelo.
S3-14	Mantener compatibilidad con el sistema <i>legacy</i> durante la transición.

Sprint 4: Migración a Gemini API y arquitectura definitiva (5 decisiones)

Código	Título
S4-01	Migración de Ollama a Gemini API (<code>gemini-2.5-flash-lite</code>).
S4-02	<i>Actions</i> con lógica LLM interna en lugar de <i>pipeline NLU custom</i> .
S4-03	<i>Actions</i> como responsables de generar SQL dinámico (validado por capas).
S4-04	Estrategia dual: Gemini en desarrollo, Ollama como <i>fallback</i> .
S4-05	<i>Web scraping</i> de Sevius4 para descarga de planes docentes.

Sprint 5: *Testing* de asignaturas v1 (19 decisiones)

Código	Título
S5-01	<i>Fix</i> de alias con prefijos NLU (<code>de</code> , <code>del</code> , <code>la</code> , <code>el</code>).
S5-02	Test E-T03: no exigir que el bot pida titulación cuando no es necesaria.
S5-03	Nuevos ejemplos NLU para “ <i>todas las asignaturas</i> ”.
S5-04	Nuevos ejemplos NLU para conteo con “ <i>carrera</i> ” y “ <i>grado</i> ”.
S5-05	Intent <code>out_of_scope</code> con <i>threshold</i> de <i>fallback</i> elevado.
S5-06	Corrección de <code>expected_count</code> en los tests de conteo.
S5-07	Validación de tests <i>fallback</i> acepta <code>out_of_scope</code> .
S5-08	<i>Fallback</i> con búsqueda por código y <code>SELECT ALL</code> como red de seguridad.
S5-09	Ejemplos NLU de asignaturas genéricas para mejorar la robustez.
S5-10	<i>Regex feature</i> <code>conteo_signal</code> para distinguir conteo de listado.
S5-11	Mantener separados los <i>intents/actions</i> de listado y conteo.
S5-12	Descartar <code>RegexEntityExtractor</code> para acrónimos por riesgo de falsos positivos.
S5-13	Actualización de <code>utter_default</code> con enlaces útiles.
S5-14	<i>Fallback fuzzy</i> cuando <code>ILIKE</code> falla con el nombre extraído por NLU.
S5-15	Mejora de <code>_resolver_nombre_desde_texto</code> con ventanas de palabras.
S5-16	Reordenación de resultados SQL por <code>token_set_ratio</code> .

S5-17	Detección de alias/acrónimos en la pregunta cuando NLU no extrae entidad.
S5-18	Ampliación del diccionario ALIAS_ASIGNATURAS.
S5-19	Reformulación de las preguntas de test para <i>testing</i> realista.

Sprint 6: Horarios, profesorado y *multi-intent* (36 decisiones)

Código	Título
D-001	Extracción del PDF de horarios con <code>pdfplumber</code> y filtrado de <i>watermark</i> .
D-002	Formato de código del PDF y filtrado por titulación (C/S/T).
D-003	Estructura de archivos Markdown por titulación/curso/grupo.
D-004	Limpieza de artefactos del PDF (comas dobles, asteriscos).
D-005	Script separado de inserción en BD (<code>insertar_horarios.db.py</code>).
D-006	Diccionario unificado de alias/abreviaturas en <code>actions/shared/config.py</code> .
D-007	Un <code>grupo_clase</code> por (asignatura, grupo), no por cuatrimestre.
D-008	Validación estricta de códigos de aula con regex <code>[A-Z]\d+\.\d+</code> .
D-009	Clasificación automática del tipo de aula a partir del edificio.
D-010	<code>ActionConsultaHorario</code> basada en BD y LLM.
D-011	Datos NLU para el <i>intent</i> <code>consulta_horario</code> (115 ejemplos).
D-012	<i>Multi-intent</i> nativo de DIET con <code>ActionMultiIntent</code> .
D-013	Respuesta unificada del <i>multi-intent</i> vía LLM (no concatenación).
D-014	Regla “no saludes” en todos los <i>prompts</i> de LLM.
D-015	Corrección de tipología TRONCAL → OBLIGATORIA en los <i>prompts</i> .
D-016	Detección heurística de seguimiento basada en recencia de <i>slots</i> .
D-017	<code>Slot ultima_action_ejecutada</code> para refinamiento de grupo.
D-018	Campos adicionales en la tabla <code>profesores</code> (categoría, perfil).
D-019	<i>Scrapers</i> independientes por departamento (LSI, DTE, CCIA, MA1).
D-020	Reconstrucción de <i>email</i> ofuscado en DTE desde <i>spans</i> HTML.
D-021	Nombre/apellidos no separables en CCIA y MA1.
D-022	MA1 con doble enriquecimiento (SISIUS y Directorio US).
D-023	<i>Trigger</i> de BD genera <code>nombre_normalizado</code> , no el <i>scraper</i> .
D-024	Dockerización con tres contenedores (Rasa + actions + Nginx).
D-025	Migración de <code>google-genai</code> a <code>google-generativeai</code> por conflicto de <code>websockets</code> .
D-026	Dependencias faltantes en <code>Dockerfile.actions</code> (<code>psycopg2</code> , <code>requests</code> , <code>spaCy</code>).
D-027	<i>Frontend</i> rediseñado siguiendo la identidad visual de <code>www.us.es</code> .
D-028	<i>Logging</i> de conversaciones y <i>feedback</i> vía Supabase REST API.
D-029	Botones de selección de titulación en lugar de texto libre.
D-030	Eliminar titulación por defecto y detección automática silenciosa.
D-031	Filtro de sección en RAG y <i>reranking</i> por <i>metadata</i> .
D-032	Búsqueda de profesores por nombre completo en cuatro formatos.
D-033	Mensaje informativo cuando no hay plan docente (TFG, prácticas).
D-034	Consultas multi-asignatura en <code>ActionConsultaEspecificas</code> y <code>ActionConsultaHorario</code> .
D-035	Variantes cortas de titulación y <i>fix</i> de “sí” como confirmación.
D-036	Ejemplos NLU de laboratorios en el <i>intent</i> <code>consulta_horario</code> .

Sprint 7: Panel de administración, piloto y consolidación (30 decisiones)

Código	Título
D-037	Navegación jerárquica Centro → Titulación → Asignatura en el panel.
D-038	Sevius como fuente de verdad para centros, titulaciones y asignaturas.
D-039	Flujo “ <i>preview</i> primero, <i>insert</i> después” para <i>scraping</i> .
D-040	Reutilización del <i>pipeline</i> RAG existente desde el panel.
D-041	Modal de selección por asignatura con todos los grupos incluidos.
D-042	<i>Scraping</i> síncrono con <i>spinner</i> , no cola de fondo.
D-043	Directorio PDI de <i>us.es</i> como fuente canónica de profesorado.
D-044	Filtro “ <i>Centro</i> ” del buscador de <i>us.es</i> para acotar el alcance.
D-045	Página del centro como índice de departamentos.
D-046	Nuevos campos en BD: <i>centro_id</i> y <i>codigo_us</i> en varias tablas.
D-047	<i>Backfill</i> SQL manual para los registros existentes de la ETSII.
D-048	<i>Upsert</i> por email con <i>fallback</i> a <i>nombre_normalizado</i> .
D-049	Separación heurística nombre/apellidos para profesores nuevos.
D-050	Auto-creación de departamentos ausentes durante el <i>scraping</i> .
D-051	Vista Centro → Departamento → Profesor con <i>bucket</i> “ <i>Sin departamento</i> ”.
D-052	Modal de enriquecimiento de profesorado con <i>slug</i> editable.
D-053	<i>Split</i> del <i>intent</i> <i>consulta_asignatura_especifica</i> (ficha vs. horario).
D-054	Bloqueo de alias de letra única en <i>_expandir_alias</i> .
D-055	Endurecimiento del <i>fuzzy cutoff</i> en <i>ActionCambiarContexto</i> .
D-056	ALIAS_ASIGNATURAS y TITULACION_MAP como datos de dominio estables.
D-057	Multi-asignatura en <i>ActionConsultaHorarioAsignatura</i> como <i>fallback</i> por diseño.
D-058	Ejemplos cortos curso N grupo M en el <i>intent</i> <i>consulta_horario</i> .
D-058.b	RAG sin filtro por sección: la sección es solo señal de <i>reranking</i> .
D-060	Poblar <i>profesor_asignatura</i> desde <i>us.es</i> (docencia estructurada).
D-061	Tutorías fuera del <i>scope</i> : redirección al <i>email</i> del profesor.
D-062	“ <i>Profesores de X</i> ” al <i>intent</i> <i>consulta_profesor</i> con <i>pipeline</i> SQL→RAG.
D-063	Filtro por titulación uniforme en los tres módulos.
D-064	RAG de profesores como vectorial puro, sin <i>double-check</i> en BD.
D-066	Cuatrimestre como dimensión de horarios (corrige pérdida en S6).
D-069	Limpieza de horarios espurios (<i>scraper</i> colapsaba franjas de varios grupos).

Huecos en la numeración global. En el sprint S7 la numeración salta sobre D-059, D-065, D-067 y D-068. Estos códigos corresponden a propuestas evaluadas durante el sprint que finalmente se consolidaron dentro de otra decisión (por ejemplo, una mejora del *fallback* que acabó subsumida en D-064) o se descartaron sin llegar a generar entrada propia. Se ha optado por mantener los huecos en lugar de renumerar para preservar la trazabilidad con los *commits* y *pull requests* que ya referenciaban los códigos originales. La suma efectiva del bloque global D-*nnn* es por tanto de 66 entradas; sumadas a las 47 entradas de los sprints anteriores resulta el total de 113 decisiones citado en los Capítulos 1 y 14.

.4– Catálogo de casos de trabajo futuro

Durante la auditoría de la suite E2E (Sección 12.2) y de la reproducción de tráfico real (Sección 12.5) se identificaron 13 casos cuya causa raíz no es un defecto puntual sino una limitación de diseño asumida. Estos casos se han marcado como *trabajo futuro* y se excluyen del denominador del porcentaje de éxito, según la política descrita en la Sección 12.1.2. La fuente original es el fichero `tests/results/testing_general.md` del repositorio, sección “*Trabajo futuro (excluido del cómputo)*”; la Tabla .10 reproduce su contenido íntegro para facilitar la consulta sin necesidad de salir del documento.

Los códigos siguen la misma convención que el resto de la suite (Sección 12.6): la primera letra indica el tipo de veredicto (X para sesión excluida del piloto de tráfico real, P para casos del dominio profesor, H para horarios y HA para horarios cruzados con asignatura), la segunda letra el subtipo (P = positivo, W = con typos, S = seguimiento) y el sufijo numérico identifica la entrada concreta en el cuaderno de resultados.

Cuadro .10: Catálogo de casos de trabajo futuro (*snapshot* 26/04/2026).

ID	Categoría	Consulta	Motivo / palanca futura
X-P01	<code>cross_dominio</code>	horario del coordinador de Álgebra	Atajo coordinador/suplente solo RAG (D-064); el resultado no se enriquece con la tabla <code>profesores</code> .
X-P03	<code>cross_dominio</code>	dame el <i>email</i> del profesor que coordina IISSI2	Misma causa que X-P01.
X-P04	<code>cross_dominio</code>	web personal de la coordinadora de Matemática Discreta	Misma causa que X-P01.
X-P05	<code>cross_dominio</code>	¿dónde imparten los profesores del grupo 1 de FP?	Enrutado cruzado profesor↔horario: la pregunta apunta a aulas pero el sistema la clasifica como <code>consulta_profesor</code> . Requiere ejemplos NLU en <code>consulta_horario_asignatura</code> con fraseos del tipo “ <i>donde imparten los profes de X grupo Y</i> ”.
X-P06	<code>cross_dominio</code>	¿qué carreras tocan electrónica de sistemas embebidos?	Cruce descripción-temática → titulación. El RAG vectorial responde con asignaturas afines al tema; falta el segundo paso (cruzar asignaturas con titulaciones). Requiere flujo <code>consulta_titulacion_por_tema</code> o post-procesado equivalente.
P-P07	<code>profesor</code>	<i>email</i> de la profesora que da ADDA en el grupo 2	Emparejamiento profesor↔asignatura↔grupo no implementado: la tabla <code>profesor_asignatura</code> no almacena el grupo.
P-P08	<code>profesor</code>	despacho del coordinador de Ingeniería del Software	Misma causa que X-P01 (atajo coordinador sin enriquecimiento).
P-W03	<code>profesor</code>	datos de la profa <i>bernrdz</i>	<i>Fuzzy matching</i> de typos severos en nombres propios. Resoluble subiendo el umbral de <code>rapidfuzz</code> o aceptando como entrada solo si el <i>match</i> es superior al 75 %.

ID	Categoría	Consulta	Motivo / palanca futura
P-S01	seguimiento_cross_intent	(turno 2) “y de estadística?” tras “tutorías de AE”	Cambio de sub-intent durante el seguimiento (tutorías → ficha): el NLU clasifica cada turno aisladamente. Resoluble con un <i>slot</i> booleano <code>ultima_consulta_tutorias</code> con TTL de 3 turnos.
H-S01	seguimiento_cross_intent	(turno 3) “y qué horario tiene” tras ficha de DP	Mismo patrón que P-S01 trasladado a horarios: el turno elíptico se clasifica como <code>consulta_horario</code> (curso+grupo) en lugar de heredar <code>ultimo_nombre_asignatura</code> y delegar en <code>consulta_horario_asignatura</code> .
HA-P09	horario_asignatura	¿dónde son las prácticas de Álgebra Lineal?	La palabra “prácticas” colisiona con “Prácticas Externas” y con “clases teórico-prácticas” del plan docente. Requiere ejemplos NLU específicos para enrutar a <code>consulta_horario_asignatura</code> con filtro de laboratorio.
HA-P10	horario_asignatura	laboratorio de Inteligencia Artificial grupo 3	La convención <code>aula.startswith(Á')</code> = teoría falla cuando una asignatura usa varias aulas A como sala de práctica. Resoluble con heurística “primera aula = teoría, resto = lab” o con columna <code>tipo_uso</code> en horarios.
HA-W06	horario_asignatura	laboratorio de <i>inteleigenicia</i> <i>artifical</i>	Misma causa que HA-P10.

Resumen por palanca técnica. Los 13 casos se concentran en cinco palancas claramente identificadas: (a) enriquecimiento del atajo coordinador con un JOIN a profesores resolvería los cuatro casos X-P01, X-P03, X-P04 y P-P08; (b) la incorporación del grupo a la tabla `profesor_asignatura` cubre P-P07; (c) un par de flujos NLU adicionales (`consulta_titulacion_por_tema` y enrutado profesor→aula) resuelve X-P05 y X-P06; (d) la palanca de seguimiento conversacional descrita en la Sección 14.5.1 cubre P-S01 y H-S01; y (e) la distinción aula teoría/laboratorio mediante columna en BD cubre HA-P09, HA-P10 y HA-W06. La sexta entrada, P-W03, depende exclusivamente de calibrar el umbral del *fuzzy matching* de profesorado. Esta distribución refuerza la lectura de la Sección 12.8: los fallos residuales son conocidos, aislados y gestionables con cambios localizados, no con un rediseño de la arquitectura.

Bibliografía

- [1] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Pearson Prentice Hall, 2nd ed., 2009.
- [2] P. Lewis *et al.*, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” in *NeurIPS*, 2020.
- [3] Universidad de Sevilla, “Universidad de Sevilla – portal institucional.”<https://www.us.es>. Consultado en abril de 2026.
- [4] Universidad de Sevilla, “Escuela Técnica Superior de Ingeniería Informática.”<https://www.informatica.us.es>. Consultado en abril de 2026.
- [5] Universidad de Sevilla, “Sevius – portal del personal de la Universidad de Sevilla.”<https://sevius.us.es>. Consultado en abril de 2026.
- [6] Universidad de Sevilla, “Sevius4 – portal de docencia y planes de estudio.”<https://sevius4.us.es>. Consultado en abril de 2026.
- [7] Universidad de Sevilla, “Secretaría Virtual de la Universidad de Sevilla.”<https://sevius.us.es/secretariavirtual>. Consultado en abril de 2026.
- [8] Universidad de Sevilla, “Portal de matrícula y automátrula de la Universidad de Sevilla.”<https://www.us.es/estudiar/matricula>. Consultado en abril de 2026.
- [9] Universidad de Sevilla, “Plataforma de pago de tasas académicas.”<https://www.us.es/estudiar/matricula/precios-publicos-y-becas>. Consultado en abril de 2026.
- [10] T. Bocklisch, J. Faulkner, N. Pawlowski, and A. Nichol, “Rasa: Open source language understanding and dialogue management,” in *NIPS 2017 Conversational AI Workshop*, 2017.
- [11] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W. Yih, “Dense passage retrieval for open-domain question answering,” in *EMNLP*, 2020.
- [12] 1MillionBot, “1MillionBot: AI for Universities.”<https://1millionbot.com/en/universidades/>, 2026. Consultado en abril de 2026.
- [13] Universidad de Sevilla, “CATi te ayuda y acompaña en tu vida universitaria.”<https://www.us.es/actualidad-de-la-us/cati-te-ayuda-y-acompana-en-tu-vida-universitaria>, 2022. Consultado en abril de 2026.
- [14] Torre Juana OST, “CATi, el asistente inteligente de la Universidad de Sevilla: 98 % tasa de acierto.”<https://ost.torrejuana.es/cati-asistente-universidad-sevilla-98-tasa-acierto/>, 2022. Consultado en abril de 2026.
- [15] Universidad de Murcia, “La Universidad de Murcia presenta a LOLA, un asistente de inteligencia artificial para ayudar a los nuevos alumnos.”<https://www.um.es/web/sala-prensa/-/la-universidad-de-murcia-presenta-a-lola-un-a>

- sistente-de-inteligencia-artificial-para-ayudar-a-los-nuevos-alumnos, 2018. Consultado en abril de 2026.
- [16] 1MillionBot, “Chatbot Lola – Universidad de Murcia.”<https://1millionbot.com/en/chatbot-lola-umu/>, 2018. Consultado en abril de 2026.
- [17] Universidad de Granada, “Nuevo asistente virtual llamado Alhe, dirigido al estudiantado y futuro estudiantado.”<https://www.ugr.es/universidad/noticias/asistente-virtual-llamado-ahle-dirigidoestudiantado-futuro-estudiantado>, 2023. Consultado en abril de 2026.
- [18] 1MillionBot, “La IA de 1MillionBot se implementa en la Universidad de Granada.”<https://1millionbot.com/en/la-ia-de-1millionbot-se-implementa-en-la-universidad-de-granada/>, 2023. Consultado en abril de 2026.
- [19] Universidad de Cadiz, “LUCA, nuevo chatbot inteligente de la Universidad de Cadiz para asistencia al estudiante.”<https://sistinfo.uca.es/noticia/luca-nuevo-chatbot-inteligente-de-la-universidad-de-cadiz-para-asistencia-al-estudiante/>, 2023. Consultado en abril de 2026.
- [20] Universidad de Alcalá, “La Universidad de Alcalá presenta un nuevo asistente virtual para su página web.”<https://portalcomunicacion.uah.es/sala-prensa/notas-prensa/la-universidad-de-alcala-presenta-un-nuevo-asistente-virtual-para-su-pagina-web.html>, 2024. Consultado en abril de 2026.
- [21] El Complutense, “AIex, el asistente virtual creado por estudiantes de la UAH que atiende consultas académicas en AULA 2026.”<https://elcomplutense.com/aiex-chatbot-estudiantes-uah/>, 2026. Consultado en abril de 2026.
- [22] Unibuddy Ltd., “Unibuddy: Student-to-student recruitment at scale.”<https://unibuddy.com/>, 2026. Consultado en abril de 2026.
- [23] Unibuddy Ltd., “Introducing a Unibuddy Assistant.”<https://unibuddy.com/a-unibuddy-assistant/>, 2024. Consultado en abril de 2026.
- [24] Hubert AI AB, “Hubert.ai – AI chatbot for course evaluation.”<https://www.hubert.ai/>, 2026. Consultado en abril de 2026.
- [25] R. Gupta *et al.*, “AdmitBot: A system for automated admission counseling,” *in IJCAI Workshop*, 2019.
- [26] F. Colace, M. De Santo, M. Lombardi, F. Pascale, A. Pietrosanto, and S. Lemma, “Chatbot for E-Learning: A case of study,” *International Journal of Mechanical Engineering and Robotics Research (IJMERR)*, 2018.
- [27] B. R. Ranoliya, N. Raghuwanshi, and S. Singh, “Chatbot for university related FAQs,” *in IEEE ICACCI*, 2017.
- [28] D. K. Dibya and S. Sahoo, “Implementation of a chatbot system using AI and NLP,” *in IEEE ICCNT*, 2021.
- [29] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, “RAGAS: Automated evaluation of retrieval augmented generation,” *in EACL*, 2024.
- [30] S. Wollny, J. Schneider, D. Di Mitri, J. Weidlich, M. Rittberger, and H. Drachsler, “Are we there yet? – a systematic literature review on chatbots in education,” *Frontiers in Artificial Intelligence*, vol. 4, 2021.

- [31] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, and D. Radev, "Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and Text-to-SQL task," in *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2018.
- [32] Y. A. Malkov and D. A. Yashunin, "Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 4, pp. 824–836, 2020.
- [33] Botpress Inc., "Botpress documentation," 2024. Consultado: noviembre 2025.
- [34] Neural Networks and Deep Learning Lab, MIPT, "DeepPavlov: An open-source library for deep learning end-to-end dialog systems," 2023. Consultado: noviembre 2025.
- [35] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, "Survey of hallucination in natural language generation," *ACM Computing Surveys*, vol. 55, no. 12, pp. 1–38, 2023.
- [36] Parlamento Europeo y Consejo de la Unión Europea, "Reglamento (ue) 2016/679 del parlamento europeo y del consejo, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos (RGPD)." *Diario Oficial de la Unión Europea*, L 119/1, 4 de mayo de 2016, 2016. En vigor desde el 25 de mayo de 2018.
- [37] Docker Inc., "Docker documentation." <https://docs.docker.com>, 2024. Consultado en mayo de 2026.
- [38] Rasa Technologies, "Rasa open source documentation," 2024. Consultado: abril 2026.
- [39] T. Bocklisch, J. Faulkner, N. Pawlowski, A. Nichol, and V. Vlasov, "DIET: Lightweight language understanding for dialogue systems." *arXiv:2004.09936*, 2020.
- [40] Supabase Inc., "Supabase documentation," 2024. Consultado: diciembre 2025.
- [41] A. Kane, "pgvector: Open-source vector similarity search for Postgres," 2024. Consultado: diciembre 2025.
- [42] Qdrant Solutions GmbH, "Qdrant documentation," 2024. Consultado: noviembre 2025.
- [43] Weaviate B.V., "Weaviate documentation," 2024. Consultado: noviembre 2025.
- [44] Google DeepMind, "Gemini API documentation," 2024. Consultado: enero 2026.
- [45] OpenAI, "OpenAI API platform documentation," 2024. Consultado: enero 2026.
- [46] DeepSeek, "Deepseek API documentation," 2024. Consultado: enero 2026.
- [47] Hugging Face, "Inference API documentation," 2024. Consultado: enero 2026.
- [48] Anthropic, "Claude API documentation," 2024. Consultado: enero 2026.
- [49] T. Mikolov, I. Sutskever, K. Chen, G. Corrado, and J. Dean, "Distributed representations of words and phrases and their compositionality," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2013.
- [50] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge University Press, 2008.

- [51] R. Nogueira and K. Cho, “Passage re-ranking with BERT.”arXiv:1901.04085, 2019. Preprint.
- [52] K. Schwaber and J. Sutherland, “The Scrum guide: The definitive guide to Scrum: The rules of the game.”<https://scrumguides.org/scrum-guide.html>, 2020. Consultado en abril de 2026.
- [53] K. Beck, M. Beedle, A. van Bennekum, A. Cockburn, W. Cunningham, M. Fowler, J. Grenning, J. Highsmith, A. Hunt, R. Jeffries, J. Kern, B. Marick, R. C. Martin, S. Mellor, K. Schwaber, J. Sutherland, and D. Thomas, “Manifesto for agile software development.”<https://agilemanifesto.org/>, 2001. Consultado en mayo de 2026.
- [54] S. Chacon and B. Straub, *Pro Git*. Apress, 2nd ed., 2014.
- [55] J. Humble and D. Farley, *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*. Addison-Wesley, 2010.
- [56] Conventional Commits, “Conventional commits 1.0.0 – a specification for adding human and machine readable meaning to commit messages.”<https://www.conventionalcommits.org/en/v1.0.0/>, 2019. Consultado en abril de 2026.
- [57] G. van Rossum, B. Warsaw, and N. Coghlan, “PEP 8 – style guide for Python code.”<https://peps.python.org/pep-0008/>, 2001. Consultado en abril de 2026.
- [58] PyCQA, “Pylint – a static code analyser for Python.”<https://pylint.readthedocs.io/>, 2001. Consultado en abril de 2026.
- [59] PyCQA, “Flake8: Your tool for style guide enforcement.”<https://flake8.pycqa.org/>, 2010. Consultado en mayo de 2026.
- [60] ESLint, “ESLint: Find and fix problems in your JavaScript code.”<https://eslint.org/>, 2013. Consultado en abril de 2026.
- [61] W. W. Cohen, P. Ravikumar, and S. E. Fienberg, “A comparison of string distance metrics for name-matching tasks,” in *Proceedings of the IJCAI-03 Workshop on Information Integration on the Web (IIWeb)*, 2003.
- [62] Junta de Andalucía, “Informe final sobre la consulta preliminar del mercado: perfiles profesionales ámbito informático.”<https://juntadeandalucia.es/temas/contratacion-publica/perfiles-licitaciones/consultas-preliminares/detalle/000000078484.html>, 2018. Consultado en mayo de 2026. Tarifa de referencia para el perfil “Analista programador J2EE/Web (Junior)”: 28,37 €/h sin IVA (media acotada todos los valores).
- [63] Rasa Community, “Reducing memory usage for Rasa Open Source (foro oficial).”<https://forum.rasa.com/t/reducing-memory-usage-for-rasa-open-source/49970>. Consultado en mayo de 2026.
- [64] DigitalOcean, “DigOcean Droplets pricing.”<https://www.digitalocean.com/pricing/droplets>. Consultado en mayo de 2026.
- [65] DigitalOcean, “DigOcean Droplet bandwidth billing.”<https://docs.digitalocean.com/platform/billing/bandwidth/>. Consultado en mayo de 2026.
- [66] Supabase, “Supabase pricing.”<https://supabase.com/pricing>. Consultado en mayo de 2026.

- [67] Google, “Gemini Developer API pricing.”<https://ai.google.dev/gemini-api/docs/pricing>. Consultado en mayo de 2026.
- [68] Google, “Gemini API rate limits.”<https://ai.google.dev/gemini-api/docs/rate-limits>. Consultado en mayo de 2026.
- [69] I. Sommerville, *Software Engineering*. Pearson, 10th ed., 2015.
- [70] D. Clegg and R. Barker, *Case Method Fast-Track: A RAD Approach*. Addison-Wesley, 1994.
- [71] D. North, “Introducing BDD.”Better Software Magazine, 2006.
- [72] S. Segura and A. Ruiz, “Guía para proyectos fin de grado sobre desarrollo de software.”https://github.com/ssegura/Guia_TFG, 2024. Departamento de Lenguajes y Sistemas Informaticos, ETSII, Universidad de Sevilla.
- [73] L. Bass, P. Clements, and R. Kazman, *Software Architecture in Practice*. Addison-Wesley, 4th ed., 2021.
- [74] R. C. Martin, *Clean Architecture: A Craftsman’s Guide to Software Structure and Design*. Prentice Hall, 2017.
- [75] R. T. Fielding, *Architectural Styles and the Design of Network-based Software Architectures*. PhD thesis, University of California, Irvine, 2000.
- [76] S. Newman, *Building Microservices: Designing Fine-Grained Systems*. O’Reilly Media, 2nd ed., 2021.
- [77] OWASP Foundation, “OWASP Top 10:2021 – a03 injection.”https://owasp.org/Top10/A03_2021-Injection/, 2021. Consultado en mayo de 2026.
- [78] A. Holtzman, J. Buys, L. Du, M. Forbes, and Y. Choi, “The curious case of neural text degeneration,” in *International Conference on Learning Representations (ICLR)*, 2020.
- [79] LangChain, “Text splitters: Recursive character splitting strategy.”https://python.langchain.com/docs/concepts/text_splitters/, 2024. Recommended chunk size 500–1000 chars with 10–20 % overlap.
- [80] I. Casanueva, T. Temcinas, D. Gerz, M. Henderson, and I. Vulic, “Efficient intent detection with dual sentence encoders,” in *ACL NLP4ConvAI Workshop*, 2020.
- [81] National Institute of Standards and Technology, “FIPS PUB 180-4: Secure hash standard (SHS),” 2015. Federal Information Processing Standards Publication. Consultado: enero 2026.
- [82] M. Fowler, *Patterns of Enterprise Application Architecture*. Addison-Wesley, 2002.
- [83] M. Honnibal, I. Montani, S. Van Landeghem, and A. Boyd, “spaCy: Industrial-strength natural language processing in Python.”<https://spacy.io/>, 2020. Software package, versión 3.x; consultado en mayo de 2026.
- [84] V. I. Levenshtein, “Binary codes capable of correcting deletions, insertions, and reversals,” *Soviet Physics Doklady*, vol. 10, no. 8, pp. 707–710, 1966.
- [85] E. F. Codd, “A relational model of data for large shared data banks,” *Communications of the ACM*, vol. 13, no. 6, pp. 377–387, 1970.

- [86] P. P.-S. Chen, "The entity-relationship model—toward a unified view of data," *ACM Transactions on Database Systems*, vol. 1, no. 1, pp. 9–36, 1976.
- [87] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, 2019.
- [88] R. Bayer and E. M. McCreight, "Organization and maintenance of large ordered indexes," *Acta Informatica*, vol. 1, no. 3, pp. 173–189, 1972.
- [89] PostgreSQL Global Development Group, "PostgreSQL documentation: B-tree indexes." <https://www.postgresql.org/docs/current/btree.html>, 2024. Consultado en abril de 2026.
- [90] PostgreSQL Global Development Group, "PostgreSQL documentation: pg_trgm—support for similarity of text using trigram matching." <https://www.postgresql.org/docs/current/pgtrgm.html>, 2024. Consultado en abril de 2026.
- [91] E. Gamma, R. Helm, R. Johnson, and J. Vlissides, *Design Patterns: Elements of Reusable Object-Oriented Software*. Addison-Wesley, 1994.
- [92] J. Brooke, "SUS: A 'quick and dirty' usability scale," in *Usability Evaluation in Industry* (P. W. Jordan, B. Thomas, B. A. Weerdmeester, and I. L. McClelland, eds.), pp. 189–194, Taylor & Francis, 1996.
- [93] International Organization for Standardization, "ISO/IEC 25010:2023 – systems and software engineering – systems and software quality requirements and evaluation (SQuaRE) – product quality model," 2023.
- [94] Xoriant, "A comprehensive guide to chatbot testing." White paper, 2020.
- [95] Test IO Academy, "Chatbot testing: Approaches, challenges and best practices," 2021.
- [96] D. Braun, A. Hernandez-Mendez, F. Matthes, and M. Langen, "Evaluating natural language understanding services for conversational question answering systems," in *SIGDIAL, ACL*, 2017.
- [97] J. Casas, M.-O. Tricot, O. Abou Khaled, E. Mugellini, and P. Cudre-Mauroux, "Trends & methods in chatbot evaluation," in *CHIIR Workshop, ACM*, 2020.
- [98] A. Folstad and P. B. Brandtzaeg, "Users' experiences with chatbots: findings from a questionnaire study," *Quality and User Experience, Springer*, 2020.
- [99] A. K. Goel and L. Polepeddi, "Jill watson: A virtual teaching assistant for online education," in *Learning Engineering for Online Education: Theoretical Contexts and Design-Based Examples* (C. Dede, J. Richards, and B. Saxberg, eds.), Routledge, 2018. *Reporta del orden de 10 000 mensajes por semestre con ~300 alumnos en la asignatura KBAI del Georgia Tech OMSCS.*
- [100] C. Wohlin, P. Runeson, M. Höst, M. C. Ohlsson, B. Regnell, and A. Wesslén, *Experimentation in Software Engineering*. Springer, 2012.
- [101] D. Harel, "Statecharts: A visual formalism for complex systems," *Science of Computer Programming*, vol. 8, no. 3, pp. 231–274, 1987.